Hadoop 构建的银行海量数据存储系统研究

李德有， 赵立波， 解晨光
(哈尔滨金融学院 网络信息中心，黑龙江 哈尔滨 150030)

摘 要: 针对目前国内银行的 OLAP(Online Analytical Processing) 技术滞后于海量数据处理需求的情况，研究了海量数据存储、处理的关键技术，设计并实现了用 Hadoop 平台和关系型数据库架构的银行海量数据处理系统. 介绍了系统架构、文件存储层次设计、数据迁移方案、任务调度算法等关键技术的实现. 通过实验验证，系统能够实现数据的高可靠性与数据的高可用性目标，既能满足业务数据实时处理的需求，也能满足海量数据统计分析的需求.

关键词: 大数据; 数据迁移; 调度算法; 数据存储; 数据处理
DOI: 10.15938/j.jhust.2015.04.012
中图分类号: TP319 **文献标志码:** A **文章编号:** 1007-2683(2015)04-0060-06

The Research of a Big Data Storage System Constructed with Hadoop

LI De-you, *ZHAO Li-bo*, *XIE Chen-guang*
(Network Information Center, Haerbin Finance University, Harbin 150030, China)

Abstract: Nowadays, the OLAP(Online Analytical Processing) technology of civil banks is not developed properly according to the requirement of massive data processing. In view of this situation, a big data processing and store system base on Hadoop platform and relational database is proposed. The article introduced the implementation of core technologies, such as the structure of the system, the design of file store layers, methods of data transferring, algorithm of task scheduling etc. It is demonstrated by experiments that the system combines the merits of Hadoop with the advantages of relational database, such as extendibility, effectively, high fault tolerance, and good ability of transaction processing, Therefore, reliability and service ability of data have been enhanced, not only satisfies the real time business data processing, but also benefits data processing even the further requirements to data mining.

Keywords: big data; data migration; schedule algorithm; data processing; data storage

0 引 言

在线银行、移动银行、电子金融市场等业务已经推动银行进入大数据时代[1]，而现有的 OLAP(online analytical processing，联机分析处理) 技术滞后于数据增长速度和海量数据处理需求，不能满足国家级数据中心建设的技术和平台需要. 银行海量数据处理面临着的软、硬件成本、性能、可扩展性等方面的挑战. 数据中心从传统的数据库平台向云计算平

收稿日期: 2014-09-28
基金项目: 黑龙江省科技攻关项目(GC12A307).
作者简介: 李德有(1972—)，男，硕士，副教授，E-mail: xcgxxd@sina.com;
赵立波(1982—)，女，硕士，讲师;
解晨光(1965—)，男，硕士，教授.

中国知网 https://www.cnki.net

台转移已成为发展趋势,中国的银行数据分析应用处于从商业智能向大数据应用过渡期[2].

美国银行、花旗银行等跨国银行已经应用大数据处理技术实施了数据仓库和数据挖掘项目[3]. 相对于国外而言,中国银行业大数据应用处于起步尝试阶段. 从长期来看,国内银行目前着力进行投资建设的电话银行和网上银行、纷纷推出的综合业务系统或整合业务处理系统、以及注入巨资建设的银行内部网络、数据仓库等,都需要有效的 OLAP 完成数据的实际使用. 而国内银行的现行数据仓库大多数搭建在数据库上,而这种数据仓库在处理数据的性能上存在一定的局限性. 当数据量达到上限,基于数据库的数据处理系统就没有能力对数据进行处理,一些早年数据不得不离线保存,导致系统对数据处理能力有限,影响客户满意度. 因此,银行对海量数据的分析处理系统的需求十分强烈[3-6].

目前,有很多比较成熟的大数据平台系统. 其中,由 Apache 基金会所开发的分布式系统基础架构 Hadoop,由于只是使用多台廉价的 PC 机协同提供服务,经过精心设计,便能够达到稳定的性能和高速的处理能力,广受欢迎. 经过多年的发展,Hadoop 功能齐全,性能稳定,在大数据存储和处理方面应用广泛,如亚马逊、Facebook、Yahoo、阿里巴巴和淘宝等[7]. 本文提出一种基于 Hadoop 的多层银行海量数据处理系统,在文章中深入研究了海量数据处理系统的关键技术: 数据迁移方案、文件存储方案、任务调度算法等; 阐述了系统的架构设计,分析银行大数据特点,针对这些特点应用了在数据存储过程中的 MapReduce 调度的优化算法,提高系统的运行速度.

1　问题分析

整个系统分布如图 1 所示.

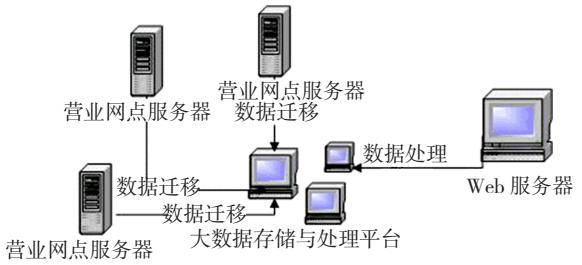

图 1　海量数据存储与处理平台结构

用 Hadoop 构建银行大数据存储与处理系统要考虑到以下特点:

1) 营业网点分散,数据需要整合存储;

2) 安全、完整地,即 "高可靠"存储原始数据,又要高效的进行数据处理,即 "高可用"性;

3) 要设计好数据处理的流程,才能高效的完成数据的存储与处理.

第 1 点中,数据要从各个营业点上传中心大数据处理平台,即: 数据迁移,数据迁移方案的设计主要应该考虑 3 方面: 第一,数据迁移后,系统的维护成本应该降低; 第二,数据迁移方案有良好的性能,迁移工作应该在有限时间内迅速完成; 第三,最重要的是保证迁移前后数据一致性[8].

在 Hadoop 框架的核心组件中,分布式文件系统 HDFS(Hadoop Distributed File System) ,为分布式计算存储提供了底层支持,以冗余备份的方式提供了文件的存储方案,能够满足文件存储的 "高可靠"性能[9-11].

HDFS 中存储的原始文件为非结构性数据,并不能满足 "高可用"性能,而作为 Hadoop 的三大核心组件之一的 HBase,是面向列存储的结构化数据的分布式存储系统,能够处理数据量很大的单张数据表,具有良好的扩展性和负载均衡的能力,能够很好的满足 "高可用"需求[12].

系统需要有数据解析、数据标准化、数据入库等功能,这些功能将由 Hadoop 的又一核心组件 MapReduce 完成. MapRedue 是一种处理任务的编程框架,MapReduce 任务将输入数据集划分为独立的块,并以完全并行的方式执行这行数据块,从而提高运算速度. 因此,MapRedue 提供了大规模廉价集群上的高可扩展性并行处理能力[13].

MapReduce 任务调度分配器负责 MapReduce 作业的分配,而调度策略直接影响系统的工作效率. Hadoop 自带 3 调度器: FIFO 调度器,Fair 调度器,Capacity 调度器. 这 3 调度器的缺点是假设集群是同构的[14-18],但在现实应用中,很难达到这样的标准,因此,针对银行数据的特点与系统的结构,我们对调度器的选择做了研究并在第 3 节中做了介绍.

2　统架构及文件层次设计

银行海量数据存储与处理系统由 Web 服务器、日志服务器、管理服务器(主、备) 、数据计算服务器组成,结构如图 2 所示.

中国知网　https://www.cnki.net

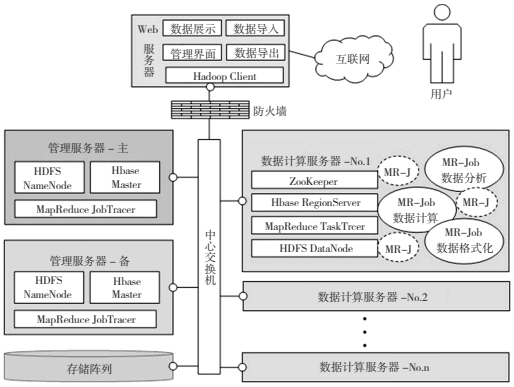

图 2 系统架构图

Web 服务器介于用户与数据中心处理系统之间,主要提供数据展示、管理界面等功能,同时,Web 服务器上安装了 Hadoop Client,能够实现与 Hadoop 集群之间数据的导入导出的功能. 管理服务器分为主、备两台,通过中心交换机与数据服务器集群连接,管理服务器负责管理 HDFS 文件系统的名称空间,同时也是 HBase 的主节点. Hadoop 集群中分布着 HDFS 文件存储系统、HBase 模块、MapReduce 模块,以及其他功能模块,是数据处理的中心集群.

为了满足银行大数据的存储与处理需要满足"高可靠性"与"高可用性"的性能需求,系统在 HDFS 中存储 2 份原始文件,将原始文件转换为结构化文件后,存储在 HBase 中,形成 2 + 1 存储结构.

文件系统设计如图 3 所示,整个文系统一共分为 3 层: 第 1 层文件系统用关系型数据库搭建,每张表容纳一天业务数据,位于各分行服务器中. 这层中存储的是针对商业银行的营业网点产生的即时数据,为实时数据处理系统提供数据; 第 2 层文件系统用 HDFS 搭建,位于商业银行总行的数据中心,主要用途在于备份银行海量业务数据,既可以为第 1 层和第 3 层文件系统提供备份,又可以在将来的业务扩展时提供数据基础; 第 3 层文件系统用 HBase 搭建,每张表以月为单位,即表中存储的是每个月的业务数据,这层同样位于商业银行总行的数据中心,存储的是第 2 层原始数据结构化后的数据,主要用途是为大数据分析、处理提供数据基础.

3 关键技术的实现

3.1 数据迁移方案

由上节介绍的文件存储方式可知,第 1 层中产生数据文件要备份在第 2 层的 HDFS 平台中,这涉及到每天将分散在各个营业点的业务数据的上传与汇总. 我们将"准确完整地将物理上存在的多点或单点数据转移集中至单一数据中心或单一存储系统的技术方案"称为数据迁移[8].

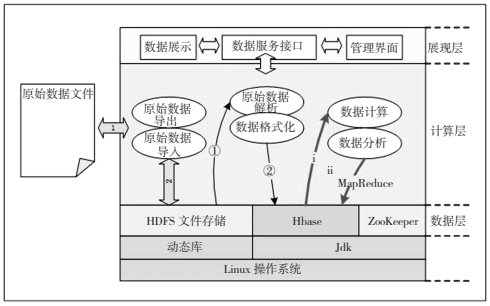

图 3 文件层次结构图

为了保证数据的一致性与完整性,采用数据摘要 MD5 算法[19],数据摘要 MD5 是一种比较成熟的保证数据完整性与一致性的算法,在此不再赘述.

迁移前,系统将前台业务数据每天形成一张表,营业结束后由程序将其格式转换为纯文本,存放在双方约定的目录下; 采用由服务器主动发起迁移的方式,依据文件中记录的第 1 层文件存储服务器的 IP 地址,依次执行以下迁移方案:

1) 在固定时间由目标机器发起数据迁移,通过 FTP 登录到存放源文件机器的目录中下载文件;

2) 下载文件后,通过 MD5 摘要算法检测数据一致性,如检测失败,转 3) ,否则转 4) ;

3) 通知源文件机器修复数据,等待修复成功的通知,接到通知后,转 1) ;

4) 删除源文件,迁移结束.

流程图如图 4 所示.

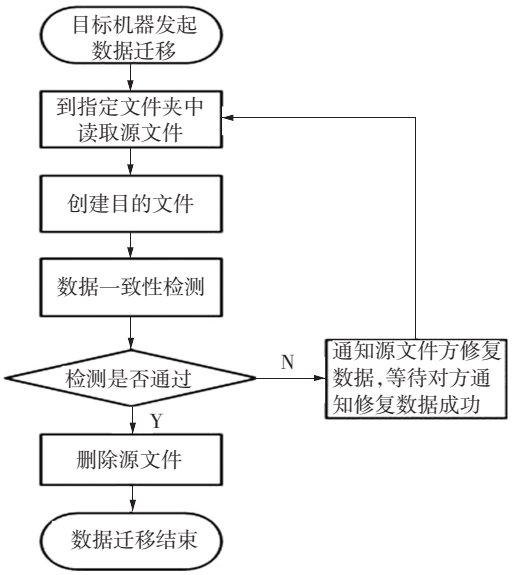

图 4 数据迁移流程

中国知网 https://www.cnki.net

3.2　任务调度算法选择与优化

Hadoop 自带调度算法的具有的一个优势在于对于错误的自动处理,即容错能力[18]. 如果一个节点出现宕机或者任务滞后 20% 的情况,系统会在其他的节点同时重新运行这些任务,当该任务在其中任一节点运行成功后,即将另外的节点任务结束. Google 的研究表明,当使用备份节点进行同时计算时,系统的整个响应时间加快达 44%[19]. 但是当集群异时,探测落后任务的算法只考虑到任务的执行进度,没有考虑到当前机器在集群中的排序,因而是不准确的. 为了弥补这个缺陷,Zaharia[20] 提出了 Longest Approximate Time to End(LATE) 算法.

LATE 算法指定了 3 个阈值:

1) SpeculativeCap: 系统中最大同时执行的备份任务数目;

2) SlowNodeThreshold: 判断节点处理任务快慢的阈值,备份任务放置在快节点中进行处理;

3) SlowTaskThreshold: 任务的进度速率与该参数进行比较,用于判断任务是否需要备份执行.

它的调度策略是: 当一个节点出现空闲资源且系统中总的备份任务数小于 SpeculativeCap 时,则执行以下步骤:

步骤 1: 如果该节点是快节点(节点得分高于 Slow-NodeThreshold) ,则忽略这个请求;

步骤 2: 对当前正在运行的任务(不包括已经在备份执行的任务) 按估算的剩余完成时间排序;

步骤 3: 选择剩余完成时间最大且进度低于 SlowTask-Threshold 的任务,为该任务启动备份任务.

LATE 算法也有自身的不足,在推测出落后任务后,它将此任务分配给任何一个请求任务的快节点,而评估节点是否是快节点的标准是依据之前的工作进度数据的总和,没有考虑每个节点的性能和负载的随时变化[21].

2013 年 5 月,胡丹[21] 提出了一种改进的 LATE 调度算法,算法中依据文 [21] 对 Hadoop 集群中的工作负荷类型分为 CPU-Bound 与 I/O-Bound 两种类型,同时将节点的负载情况由与结点的 CPU、内存、磁盘和网络资源使用率相关的公式得出,也划分出 CPU-Bound 与 I/O - Bound 两种类型的结点,再将不同类型的结点实时在链表中排序,在选择备份任务时,根据任务的类型在不同的链表中选择执行备份的快结点,提高了效率.

系统中的调度算法选择了文 [21] 中提到的改进的 LATE 算法,并根据 MapReduce 任务的特点,将算法进行一定的简化: 系统中所有的 MapReduce 任务算法复杂度不高,但读写频率较高,占用内存较多,因此,只需构建 I/O-Bound 列表.

算法描述如下:

当任务被判定为落后任务时,计算该结点的 workload,从 WorkloadForIOList 节点中找到第一个 workload 的值小于该节点的节点,继续执行此任务.

定义 1　设 WorkloadForIOList 为用于存储集群每个节点(TaskTracker) 的 I/O-bound 型负载的链表,该链表是按 Workload 的值升序排列的链表.

算法伪代码如下:

/* JobTracker 为落后任务分配节点执行其备份任务* /

for WorkloadForIOList WorkloadIO

if(WorkloadIO. hasSlot( ) && WorkloadIO. Workload < slowTaskTracker. worklaod) then

分配 slowTask 的备份执行任务到 worklaodIO. Task-Tracker 上执行

end for

workload 的计算方法如下:

$$\text{workdload} = w_{cpu} \times \mu_{cpu} + w_{mem} \times \mu_{mem} + w_{disk} + \mu_{disk} + w_{nw} \times \mu_{nw}$$

其中:

$$w_{cpu} + w_{mem} + w_{disk} + w_{nw} = 1, w_{cpu} + w_{mem} + w_{disk} + w_{nw} \in [0,1]$$

$w_{cpu}, w_{mem}, w_{disk}, w_{nw}$ 分别指节点工作时,衡量节点的 CPU、内存、磁盘和网络资源所占的权重. μ_{cpu}, μ_{mem}, μ_{disk}, μ_{nw} 分别指每个节点的 CPU 使用率、内存使用率、网络善、I/O 吞吐量,这些情况由心跳包发送给 JobTracker,JobTracker 用这些值计算 workload 的值,更新 WorkloadForIOList 列表.

3.3　数据处理步骤

数据迁移到系统后,要对数据进行一系列的处理,即:

1) 数据文件导入或导出

将本地磁盘存储的原始数据文件导入到 HDFS 中,存放到指定目录. 将 HDFS 中存储的原始业务数据导出到本地磁盘存储.

2) 数据解析

数据解析的目的是为了读取原始数据文件中存储的业务数据,并依据文件格式进行解析,将数据结构化. 采用 MapReduce 实现.

3) 数据标准化

数据标准化是对结构化之后的业务数据进行预处理,按照数据类型对各个数据项进行格式化,将数

中国知网　https://www.cnki.net

据转换为本系统标准格式,使其标准化,以提升数据存储密度,提高数据计算、分析的效率,降低时延. 将经过标准化处理之后的数据,以文件形式存储到 HDFS 中. 采用 MapReduce 实现.

4) 数据入库

在这一步中,系统将 HDFS 中经过标准化处理之后的数据文件导入到 HBase 数据表中,创建 HBase 数据表及列簇. 采用 MapReduce 实现.

4 结果测试及分析

实验环境,使用普通 9 台商业计算机搭建核心系统,每台内存 4G,硬盘 120G. 2 台主控服务器,6 台数据服务器,1 台数据库服务器. 操作系统安装了 RedHatLinux5. 0,JDK 版本为 1. 6. 0,使用的 Hadoop 版本为 1. 0. 3,HBase 版本为 0. 94,Tomcat 版本为 6. 0,Sqlserver2008,以太网带宽 100M. 依据银行原始数据格式,模拟生成了五年数据,形成了实验中所使用的数据,数据格式为纯文本文件,总数据量大小为 5GB.

1) 实验数据迁移: 迁移文件大小约为 1G.

2) 实验数据解析、数据标准化、数据入库过程两种调度算法对比

用 Hadoop 默认的 FIFO 调度器与本文中选用的调度算法对比,执行用 MapReduce 并行计算作业,将不同数量的原始数据存储在 HDFS 中,再导入到 HBase 数据库中,分别记录耗时. 在使用 LATE 算法时,实验中 3 个参数的选择是已经在文献 [21] 中论证的最佳参数值,分别是 SpeculationCap 为 20%、SlowTaskThreshold 为 25%、SlowNodeThreshold 为 25%.

3) 实验基于海量数据的统计

基于 HBase 中的海量业务数据,实现优化的 MapReduce 并行计算作业,完成海量业务数据的统计,统计内容为按月计算业务笔数,总交易额.

4) 实验结果分析

为了实验的准确可靠,我们将每个实验重复 5 遍,多次实验过程中,系统均安全可靠的完成了实验.

实验 1: 5 次实验结果记录如图 5 所示,数据传输单次平均时间为 160. 6 s,在时间上可以满足传输速度需求,传输结果没有发生数据检测不一致的情况.

实验 2: 输入的数据量分别为 1G,3G,5G,两种调度算法耗时比较如图 6 所示.

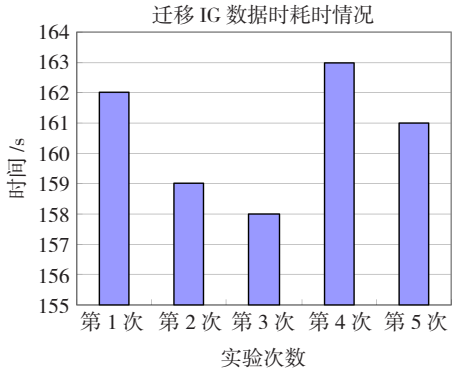

图 5 数据迁移实验结果记录图

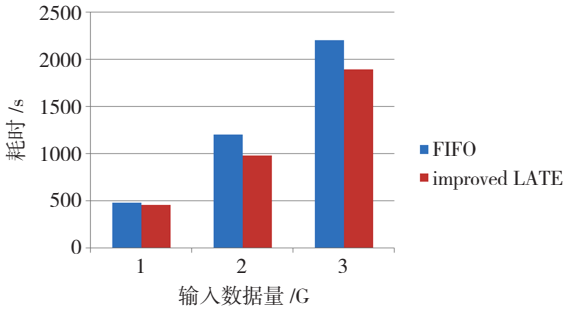

图 6 两种算法完成时间对比图

从图 6 中可以看出,使用改进后的 LATE 调度算法的系统运行速度提升 12% 左右. 当数据小于 3G 时,改进后的系统没有太大优势. 原因是数据量小时,系统负载小,没有落后节点,当数据量增加,系统负载加大,算法优势得以体现,运行速度得到提升.

实验 3: 输入数据为 5G,实验记录结果如图 7 所示.

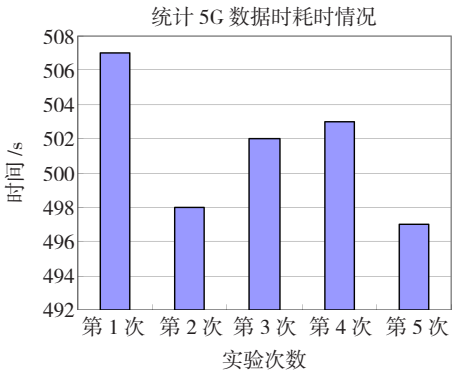

图 7 统计按月计算业务笔数与总交易额耗时实验记录图

统计时间 5 次实验的平均耗时为 501. 4 s,由于统计大数据不是实时操作,因此从时间上来看,结果符合银行业务需求.

中国知网 https://www.cnki.net

6 结　语

本文针对国内银行大数据处理系统应用方面的现状,提出了一个用 Hadoop 构建的银行大数据处理系统. 文章从文件存储、数据迁移、数据处理、任务调度算法等方面,介绍了对于银行大数据处理系统关键技术解决方案的探索,为金融数据挖掘以及更多的应用需求提供扎实的基础. 实验结果表明,本文提出的银行大数据处理系统具有处理银行大数据的能力,不仅能够满足大数据处理的功能需求,也有良好的处理效率.

参 考 文 献:

[1] 赵刚. 2013 – 2014 年中国银行大数应用年度研究报告 [R]. 北京赛智时代信息技术咨询有限公司,2013. 9

[2] 蔚赵春,凌鸿. 商业银行大数据应用的理论、实践与影响 [J]. 上海金融,2013(9):28 – 32,116.

[3] 王珊,王会举,覃雄派,等. 架构大数据: 挑战、现状与展望 [J]. 计算机学报,2011,34(10):1741 – 1751.

[4] 董新华,李瑞轩,周湾湾,等. Hadoop 系统性能优化与功能增强综述 [J]. 计算机研究与发展,2013(S2):1 – 15.

[5] 程学旗,靳小龙,王元卓,等. 大数据系统和分析技术综述 [J]. 软件学报,2014(9):1889 – 1908.

[6] 张引,陈敏,廖小飞. 大数据应用的现状与展望 [J]. 计算机研究与发展,2013,(S2):216 – 233.

[7] 王元卓,靳小龙,程学旗. 网络大数据: 现状与展望 [J]. 计算机学报,2013,(6):1125 – 1138.

[8] 吕明育. Hadoop 架构下数据挖掘与数据迁移系统的设计与实现 [D]. 上海: 上海交通大学,2012.

[9] 林闯,苏文博,孟坤,等. 云计算安全: 架构、机制与模型评价 [J]. 计算机学报,2013(9):1765 – 1784.

[10] CHEN C L. Philip,ZHANG Chun-Yang. Data-intensive Applications, Challenges, Techniques and Technologies: A survey on Big Data [J]. Information Sciences,2014,275(8):314 – 347.

[11] 董延华,李欣,董静薇,等. 用 VB 实现大数据块 CRC 校验码算法 [J]. 哈尔滨理工大学学报,2002(1):63 – 65.

[12] 申德荣,于戈,王习特,等. 支持大数据管理的 NoSQL 系统研究综述 [J]. 软件学报,2013(8):1786 – 1803.

[13] CHAO T,ZHOU H,HE Y,et al. A dynamic MapReduce Scheduler for HetErgeneous Workloads [C]//Proc of the 8th International Conference on Grid and Cooperative Computing,China,2009: 218 – 224.

[14] HAN Xixian, LI Jianzhong, WANG Jinbao,et al. TJJE: An Efficient Algorithm for Top-k Join on Massive Data [J]. Information Sciences,2013:222(10):362 – 383.

[15] MICHAEL Schermann,HOLMER Hemsen,CHRISTOPH Buchm?ller,et al, Big Data [J]. Wirtschaftsinformatik,2014,56(5): 281 – 287.

[16] SIMON Gog,MATTHIAS Petri. Optimized Succinct Data Structures for Massive Data [J]. Softw. Pract. Exper.,2014,44(11):1287 – 1314.

[17] HAN Xixian, LI Jianzhong, YANG Donghua. Supporting Early Pruning in Top-k Query Processing on Massive Data [J]. Information Processing Letters,2011,111(11):524 – 532.

[18] 陈全,邓倩妮. 异构环境下自适应的 Map-Reduce 调度 [J]. 计算机工程与科学,2009,31(A1):168 – 175.

[19] 张裔智. MD5 算法研究 [J]. 计算机科学. 2008,35(7):295 – 297.

[20] ZAHAFIA M,KONWINSKI A,JOSEPH A. Improving MapReduce Performance in Heterogeneous Environments [C]//Proc of the 8th Usenix Symp on Operating Systems Design and Implementation,2008:29 – 42.

[21] 胡丹,于炯,英昌甜,等. Hadoop 平台下改进的 LATE 调度算法 [J]. 计算机工程与应用,2014,50(4):86 – 89,131.

(编辑: 温泽宇)

中国知网 https://www.cnki.net