基于 Hadoop 的区域健康大数据平台研究与设计

单　珂　孔祥龙　张一鸣　张宏宽
（齐鲁工业大学（山东省科学院）　山东 济南 250353）
（山东省计算中心（国家超级计算济南中心）　山东 济南 250013）
（山东省人工智能研究院　山东 济南 250013）

摘　要　为了存储、共享、应用以及挖掘出对居民健康更有价值的信息，该文设计一种基于 Hadoop 的区域健康大数据平台，通过数据采集将各卫生机构、体检机构等健康数据存储到前置库，通过数据治理、数据交换将医疗数据存储到标准库中，最后以数据服务的方式将数据共享开放出去，对医疗机构、体检机构、健康管理公司等提供健康大数据支撑，促进医学健康产品的研发，更好地为居民提供医疗健康服务，最终实现全生命周期的健康数据管理。

关键词　医疗健康　大数据　数据交换　数据处理　数据采集

中图分类号　TP3　　**文献标志码**　A　　DOI：10.3969/j.issn.1000-386x.2025.04.002

RESEARCH AND DESIGN OF REGIONAL HEALTH BIG DATA PLATFORM BASED ON HADOOP

Shan Ke　Kong Xianglong　Zhang Yiming　Zhang Hongkuan
(*Qilu University of Technology*(*Shandong Academy of Sciences*), *Jinan 250353*, *Shandong*, *China*)
(*Shandong Computer Science Center*(*National Supercomputer Center in Jinan*), *Jinan 250013*, *Shandong*, *China*)
(*Shandong Artificial Intelligence Institute*, *Jinan 250013*, *Shandong*, *China*)

Abstract　In order to store, share, apply and mine more valuable information for residents' health, this paper designs a Hadoop-based regional health big data platform. The platform stored health data from various health institutions and physical examination institutions in the pre-database through data collection. The medical data was stored in the standard library through data governance and data exchange, and data was opened out in the form of data services to provide health big data support to medical institutions, physical examination institutions, health management companies, etc., which promoted the development of medical health products research and development, and better provided residents with medical and health services, and ultimately achieved full life cycle health data management.

Keywords　Medical health　Big data　Data exchange　Data processing　Data acquisition

0　引　言

我国健康大数据发展已经进入利好阶段[1]，国家作为政策引导方，已经出台了 50 余条相关“纲要”或者“意见”。2015 年国务院发布《促进大数据发展行动纲要》[2]，明确表示要发展医疗健康大数据服务，构建综合健康服务应用，而关键则是建立共享规范的健康大数据平台，促进数据交流互通。然而，国家卫计委提出的分级诊疗制度在推行过程中，仍然存在数据孤岛

收稿日期：2021－12－07。国家重点研发计划项目（2017YFE0132200）。**单珂**，助理研究员，主研领域：大数据技术应用。**孔祥龙**，助理研究员。**张一鸣**，研究实习员。**张宏宽**，研究实习员。

中国知网　https://www.cnki.net

问题,主要问题表现为:患者信息不流通、医院资源不流通、医院之间利益不互通[3-5]。

目前,大数据、人工智能、云计算等已经成为 IT 行业的主流技术,国内外都已经进入了大数据、人工智能、云计算等技术的研究热潮[6]。面对海量的医疗信息数据,如何充分使用这些数据,运用大数据、人工智能、云计算等技术,搭建合理先进的健康大数据平台,解决医疗数据信息不流通、资源不流通等问题,进而为广大患者、医务工作人员、医学科研人员提供服务,已经成为信息医学工作需要迫切解决的难题[7]。

1　健康大数据平台总体设计

1.1　平台设计原则

基于 Hadoop 的区域健康大数据管理平台(以下简称“平台”)是在大规模分布式集群环境下,基于云计算和大数据等相关技术为海量健康医疗数据提供大数据管理、大数据支撑和大数据存储等数据全生命周期管理功能,并基于此提供数据共享和数据开放服务,以数据为中心的设计理念体现了“平台 + 数据 + 服务”的思想[8]。平台遵循以下设计原则:

1) 自主可控:平台使用国际主流开放体系的技术路线,在源代码级别保证可控的基础上,平台具备可持续进行优化和完善的能力。

2) 技术先进:平台设计符合国内外大数据、云计算相关技术标准要求,采用国际上主流的技术架构体系,确保平台能够适应关键技术的长期发展需要。

3) 弹性扩展:平台能够随着用户和数据规模的增加,通过水平扩充计算设备和存储设备,实现资源的弹性扩容。

4) 安全可靠:平台采用自备份冗余的架构设计,保证服务提供的连续性,平台构建安全防护体系,提升整体系统安全性。

1.2　平台数据架构

平台对各类来源的数据进行数据采集,针对结构化数据、非结构化数据等采取不同的采集方式,采集的数据进入对应的原始库;原始库数据经过数据处理过程(清洗、脱敏等)形成标准库数据进入标准库;使用方从标准库获取数据服务。数据架构如图 1 所示。

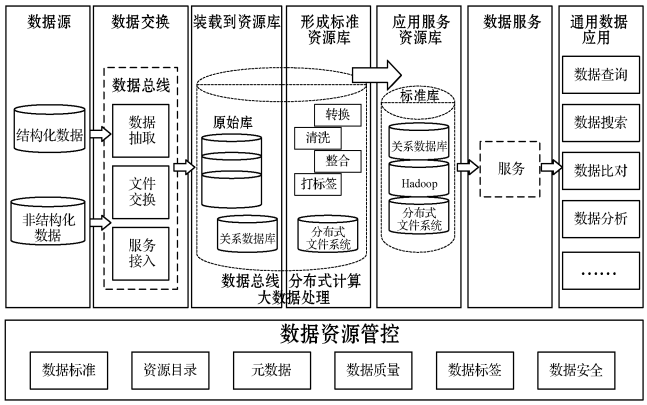

图 1　平台数据架构

1.3　平台业务架构

平台在数据共享交换过程中,通过互联网,统一的交换协议,将各业务单位的前置交换系统中的数据交换到平台的原始库中,按照国家卫计委各数据标准对原始数据进行处理,存储到标准库中,并统一对外提供开放的数据服务。平台的技术架构如图 2 所示。

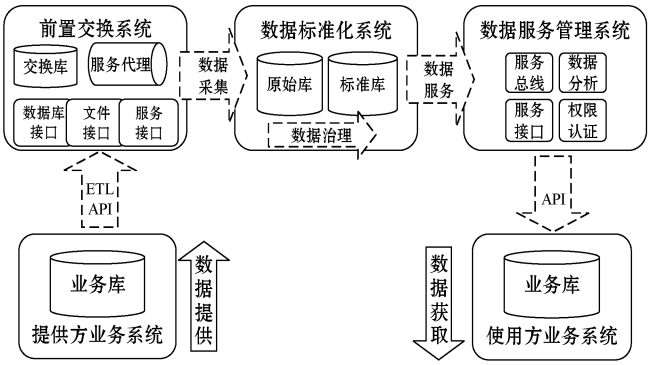

图 2　平台业务架构

1) 大数据平台提供交换数据的可靠传输服务、数据采集服务、数据处理服务、数据标准化服务,实现数据从提供方前置交换系统到平台原始库的数据交换功能,从原始库到标准库的数据标准化抽取功能,数据分析以及开放数据服务功能。

2) 前置交换系统设有数据库、文件以及服务接口,能够提供数据的临时存储、写入和读取等功能。

3) 数据提供方业务系统与前置交换系统之间通过交换桥接系统进行交换数据的提供和获取。

4) 数据使用方通过调用大数据平台统一的开放服务接口使用数据,每次接口调用均需要 token 认证。

1.4　平台应用架构

大数据平台作为智慧医养统筹建设的关键部分,承载着对医养海量数据的全生命周期管理功能,提供包括数据采集、数据管理、数据处理、数据支撑等相关大数据相关的技术组件、简单易用的平台部署监控和运维功能、不同数据应用的管理功能等,以数据为中心,实现对数据的统一管控,确保数据和内容是准确

中国知网　https://www.cnki.net

的、可用的和安全的,通过安全性和隐私控制,实现信息服务的可知、可用、可管、可控,使得这些数据资产能够在企业、医院和民众之间安全、自由地使用。平台应用架构图如图 3 所示。

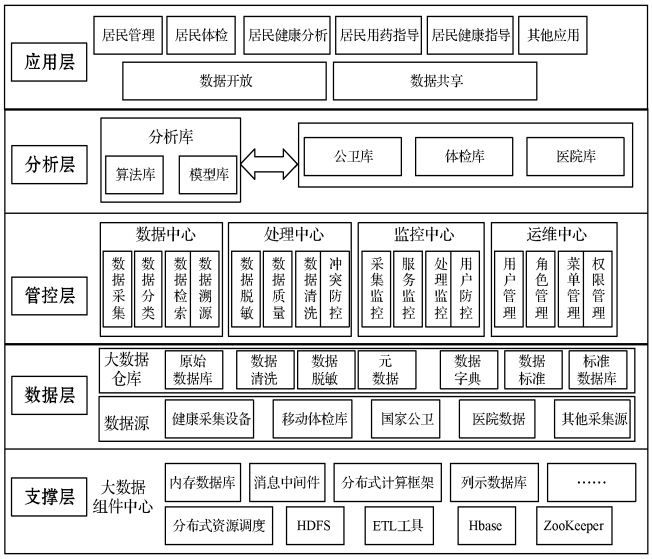

图 3 平台应用架构

1.5 平台稳定性设计

平台在数据共享交换过程中,通过互联网,统一的交换协议,将各业务单位的前置交换系统中的数据交换到平台的原始库中,按照国家卫计委各数据标准对原始数据进行处理,存储到标准库中,并统一对外提供开放的数据服务。

平台的稳定性将依靠 nginx 反向代理、前后端分离、MySQL 集群、HDFS 等先进技术的组合使用保障整个平台的稳定性。

1) Nginx 反向代理。平台建设本着高可用的设计原则,使用了 Nginx 反向代理,可配置多个访问节点,当其中一个节点挂掉以后,用户可以正常访问平台。

2) 前后端分离。平台建设采用前端展现与后端服务分离的设计方案,前后端使用高速服务(dubbo)通信,后端应用程序把服务发布到注册中心,前端请求直接去注册中心调用后端发布到注册中心的服务,相同的后端应用程序可以部署多个,都连接同一个注册中心,如果其中某一个应用程序挂掉,注册中心仍然有可用的服务存在,当修复好挂掉的程序以后,注册中心会通过心跳重新发布服务,保证了后端服务的高可用性。

3) MySQL 集群。平台建设使用 MySQL 集群作为关系型数据库,使用一主多从的模式,从库可做备份数据库,也可做读写分离,从而保证了数据的高可用性。

4) HDFS 分布式文件系统。平台建设将采用分布式文件系统,HDFS(分布式文件系统)在文件存储时,会将资源文件复制三份,存到不同的数据节点上,当其中某一个节点挂掉时,数据仍访问,节点恢复以后无需做任何操作,一切恢复如初。同时在实施过程中根据实际情况选择使用 HDFS HA,进一步提升了资源存储的稳定性。通过 HA 配置两个(主/备)namenode 热备,当主 namenode 出现问题时,集群会自动切换到备用的备 namenode,当主 namenode 修复完成后,再自行切换到主 namenode 上,有效地保证了系统稳定性。

1.6 平台高性能设计

1) 平台建设采用 Nginx。Nginx 可以缓存静态文件,比如 js、css、图片等。大幅提升页面渲染效率。在研发过程中,使用异步请求页面所需数据,有效地提升页面渲染速度,异步请求数据要比同步请求数据快很多。

2) 分布式缓存。redis 的使用,对于一些更新频率不高的数据,我们只有在第一次访问的时候从数据库中读取,然后将读取到的数据存放到 redis 中,这样在以后访问中,都是从内存中读取的,大幅提升了平台的数据获取速度。

3) 索引与读写分离。对那些更新频繁的数据,则直接从数据库中读取,索引是数据库优化比较常用的手段,我们会为业务表创建合适的索引。在研发过程中,我们严禁使用子查询,因为子查询无法使用索引,确保查询语句都可以用的索引。另外,基于 MySQL 集群我们还做了读写分离,有效地提升数据访问速率。

对于较大的文件,在读取时,会从多个数据节点上并行读取,有效提升文件读取速率。较小的文件存到 HBase 中,而不是所有的文件都存储到 HDFS 上,这样可以有效地降低集群的内存消耗。

2 健康大数据平台关键技术

Hadoop 作为一款软件框架模型,能够实现高效和可扩展地对大数据进行分布式处理,它具有容错能力强、跨平台、可靠性高等突出优势[9]。基于 Hadoop 框架搭建的平台,能够处理复杂的关系型数据库数据,能够支持跨计算机集群的分布式存储和计算。其中 HDFS、HBase 和 MapReduce 模型是 Hadoop 框架的三大关键技术[10]。

2.1 分布式文件存储系统

1) HDFS。HDFS 是一个具备高容错性、高吞吐量、高扩展性的分布式文件系统,利用 HDFS 系统具备的这些特性,能够显著提高整个系统的数据传输效

中国知网 https://www.cnki.net

率[11]。本平台采用主从架构的 HDFS 集群,由一个 NameNode 与若干个 DataNode 组成,其中 NameNode 是集群中的主节点,在 HDFS 集群中是唯一存在的,它负责管理 HDFS 的名称空间和数据块的映射信息,负责配置相关的副本信息并且处理来自客户端的请求;DataNode 负责存储实际数据并且将状态信息发送给 NameNode。HDFS 通过分块的方式,将海量健康数据分成数个固定大小的数据块存储在 DataNode 中。

HDFS 主要用来存储各类报告、心电图等文档及图片数据,这类数据可以直接采用 FTP 方式进行传输,最终存储在 HDFS 中。HDFS 在存储文件时,会将文件复制三份,存到不同的 DataNode 上,当其中某一个节点挂掉时,数据仍访问,节点恢复以后无需做任何操作,一切恢复如初,有效地保证了系统稳定性。HDFS 数据存储过程如图 4 所示。

图 4　HDFS 数据存储过程

2）HBase。HBase 是一个支持使用 MapReduce 来对其存储的数据进行快速操作的分布式存储系统[12],具有高可靠、高性能、面向列、可伸缩等特点,它也可以在廉价机器上搭建集群并且能够组织管理存储大规模的结构化数据。在读取大文件时,HBase 会从多个数据节点上并行读取,大幅提升文件读取速率。HBase 可以提供一个超大的内存 Hash 表,搜索引擎通过它来存储索引,方便查询操作,HBase 部署于 HDFS 之上,并且克服了 HDFS 在随机读写方面的缺点。

对于健康数据中血压、血氧、血常规、尿常规、BMI 等这种数据可以用 HBase 实现对数据的存储,它首先会使用到 Sqoop 工具对原始数据表内的数据进行采集,然后传输到 Hive 数据仓库内,经过数据清洗生成干净的数据表后,由于 Hive 不适合数据的实时查询,Hive 适用于清洗、处理和计算原始数据,所以最后要将 Hive 内的干净数据表同步至 HBase 中进行数据存储。HBase 数据存储过程如图 5 所示。

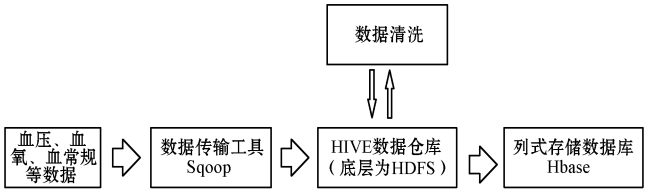

图 5　HBase 数据存储过程

2.2　MapReduce 并行计算

MapReduce 用于大规模数据集的并行计算。MapReduce 运行分为两个阶段,即“Map(映射)”阶段和“Reduce(化简)”阶段,Map 阶段主要分割处理,即把复杂的任务进行分解,将分解后的小任务进行处理;Reduce 阶段则是将 Map 阶段计算出的结果进行汇总操作。计算节点和存储节点在一起的配置可以高效地完成任务,充分利用集群的网络宽带。MapReduce 处理流程如图 6 所示。

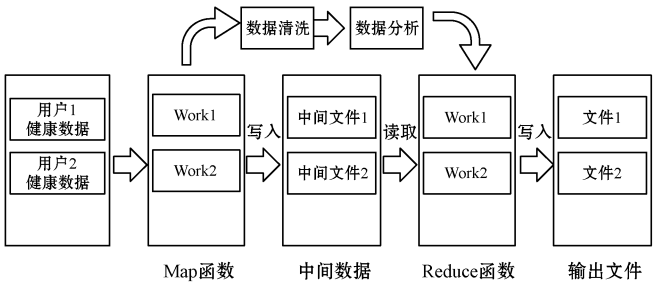

图 6　MapReduce 处理流程

为了提高平台对海量健康数据的处理效率,平台在传统数据处理逻辑的基础上,利用 Hadoop 的 MapReduce 计算框架,对健康大数据平台的健康数据分析模块进行改进。在健康数据分析模块引入 MapReduce 框架。以用户为单位,将健康数据按照检测项目如血压、血糖、心电等为一组放入一个 Map 作业中,Map 函数生成一个键值对放入内存中,并定期写入磁盘。Map 函数处理完成后将分析结果传递给 Reduce 函数,Reduce 函数对分析结果进行合并处理并输出到指定文件中。

2.3　数据服务

平台对医学大数据标准库中的数据以接口形式对外提供服务,以开放服务形式提供给医疗相关机构、公司,从而发挥数据的推动作用,便于各机构、公司挖掘数据的价值,为医生、居民等提供更精准的服务。

数据服务设计遵循 Web Service 或者 RESTful API 的接口规范,建立统一的服务中心,按照 SOA 的架构理念,对服务实现统一的管理和监控,采用开放的架构,提供高效稳定的一体化的服务管理平台。主要包括服务管理、服务设计、服务监控等功能。

平台主要设计实现基础服务类、数据服务类、元数据管理类、数据管理类四类服务,如表 1 所示。

表 1　平台服务分类

分类	服务分类	服务功能
基础服务类	权限认证	获取 token,刷新 token
数据服务类	元数据检索	查询元数据
	数据检索	查询数据
元数据管理类	元数据管理	增加、删除、修改等管理操作
数据管理类	数据管理	增加、删除、修改等管理操作

中国知网　https://www.cnki.net

3 系统实验及应用情况

3.1 健康数据处理实验

为了验证 Hadoop 集群在大数据处理方面的高性能,针对健康数据处理开展验证实验,通过处理健康数据,测试常规处理与基于 Hadoop 集群处理的时间消耗,通过时间消耗的长短来说明系统的性能。设置不同的文件数据,选取文件大小和文件类型不同的健康数据,设置不同的处理条数,分别统计两组的处理时间,测试结果如表 2 所示。(需要说明的是,每组测试结果均是 3 次测试的平均值)。

表 2 数据处理情况表

处理条数/万条	常规处理/s	Hadoop 集群/s
5	13.2	11.2
10	26.5	7.3
15	31	9.2
20	40.3	14.2
30	55.6	17.3
50	76.8	23.9
100	170.5	45.3

测试结果表明,Hadoop 集群的处理性能明显优于常规处理方式,特别是当处理条数不断增加时,当处理条数在 100 万条时,Hadoop 的处理时间明显少于常规处理时间,Hadoop 的集群处理优势体现得更加明显。因此,实验结果充分表明了基于 Hadoop 的大数据平台在处理健康数据更加具有优势。

3.2 应用情况

平台自设计研发完成并上线以来,已完成采集数据 188 万条,处理数据 98 万条,清洗掉脏数据 1 万条。表 3 为数据处理情况表。

表 3 数据处理情况表

序号	表名称	待处理	处理成功	无效数据	更新时间
1	体检车-B 超	124 115	61 516	0	2020 – 06 – 16
2	体检车-个人基本信息	113 996	132 555	1	2020 – 06 – 16
3	体检车-中医辨识	36 060	75 551	2 180	2020 – 06 – 16
4	体检车-健康体检	77 550	44 993	5 076	2020 – 06 – 16
5	体检车-尿检	190 016	216 857	0	2020 – 06 – 16

续表 3

序号	表名称	待处理	处理成功	无效数据	更新时间
6	体检车-心电	110 796	53 404	0	2020 – 06 – 16
7	体检车-生化	111 118	58 390	0	2020 – 06 – 16
8	体检车-自理能力	34 103	70 931	2 275	2020 – 06 – 16
9	体检车-血球	144 891	212 803	0	2020 – 06 – 16
10	体检车-问询	114 357	53 961	1	2020 – 06 – 16

4 结 语

本文设计了一种基于 Hadoop 的区域健康大数据平台,实现了医学健康数据从采集、处理、交换到开放服务、数据分析的全部流程;创建医学大数据库,为医疗机构、健康管理公司、居民用户等提供健康大数据支撑,促进医学健康产品的研发,切实保障居民健康。

参 考 文 献

[1] 陈敏,刘宁. 医疗健康大数据发展现状研究[J]. 中国医院管理,2017,37(2):46 – 48.

[2] 国务院关于印发促进大数据发展行动纲要的通知[J]. 中华人民共和国国务院公报,2015(26):26 – 35.

[3] 蒋骏,李志光,张雪静,等. “互联网 + 医疗”与分级诊疗制度建设探讨[J]. 医学与哲学,2021,42(19):70 – 73.

[4] 李文敏,李文志,曾祥英. 影响我国分级诊疗制度推进的关键问题研究[J]. 中国卫生政策研究,2018,11(10):12 – 19.

[5] 王鹏鹏,陶群山,王绍敏. 我国分级诊疗制度实施困境及对策建议[J]. 锦州医科大学学报(社会科学版),2021,19(5):40 – 44.

[6] 王笛,赵靖,金明超,等. 人工智能在医疗领域的应用与思考[J]. 中国医院管理,2021,41(6):71 – 74.

[7] 戴明锋,孟群. 医疗健康大数据挖掘和分析面临的机遇与挑战[J]. 中国卫生信息管理杂志,2017,14(2):126 – 130.

[8] 耿和清. 基于 Hadoop 架构的海洋牧场大数据平台设计研究[D]. 济南:齐鲁工业大学,2021.

[9] 黄华林,庞欣婷. 基于 Hadoop 的数据资源管理平台设计[J]. 计算机应用与软件,2018,35(7):329 – 333.

[10] 王永才. 基于 Hadoop 平台的用电行为数据特征挖掘方法[J]. 自动化与仪器仪表,2020(11):227 – 230.

[11] 刘军,冷芳玲,李世奇,等. 基于 HDFS 的分布式文件系统[J]. 东北大学学报(自然科学版),2019,40(6):795 – 800.

[12] 马翠云. 基于 HBase 的大规模数据存储解决方案的设计和实现[D]. 济南:山东大学,2015.

中国知网 https://www.cnki.net