基于Hadoop的大数据存储与检索性能优化

文/袁海平　四川巴蜀联胜科技有限公司

摘要：为实现大数据的安全存储和高效检索，本文提出基于Hadoop（分布式系统基础架构）的大数据存储与检索性能优化方法。以Hadoop架构为核心，构建分布式存储系统，利用Hadoop分布式集群优势，实现大数据的分块处理和存储，并引入分布式区域检索算法在各个区域中进行所需数据检索。测试结果显示：分布式存储能够更高效地完成大数据存储，各个类别数据的检索结果误差均低于2%。

关键词：Hadoop；大数据存储；检索性能优化

引言

计算机技术和网络通信技术的发展使数据规模激增，数据量大、异构性等对存储系统构成挑战，传统数据库难以满足需求[1]。同时，高效检索海量数据成为一大难题。此时，Hadoop（分布式系统基础架构）以其高可靠性、可扩展性和高处理效率逐渐进入大众视野，其能够有效处理大数据，支持并行处理，提升处理速度[2]。本文旨在利用Hadoop优化大数据存储与检索性能，解决分布式数据库的局限性，提高大数据管理的效率和支持能力。

1. 大数据存储与检索性能优化

1.1 基于Hadoop的大数据存储和检索方法整体架构

为保证大数据的存储和检索效果，本文提出基于Hadoop的大数据存储与检索性能优化方法，该方法以Hadoop为核心，构建分布式存储系统，并结合数据检索方法，实现大数据的统一管理[3]。基于Hadoop的大数据存储和检索方法整体架构如图1所示。

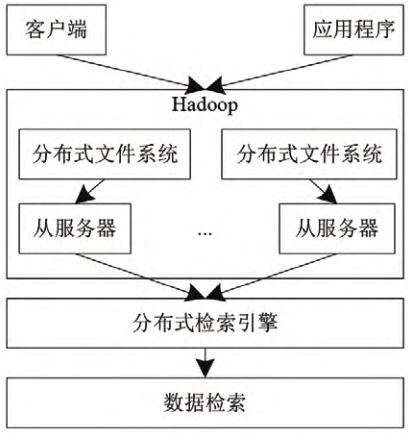

图1 基于Hadoop的大数据存储和检索方法整体架构

Hadoop分布式体系集成分布式文件系统（hadoop distributed file system，HDFS）、MapReduce框架以及HBase组件，构建一个针对大数据处理的完整架构。这一架构的核心在于实现大数据的高效存储、处理、分析及任务的并行化处理（Map阶段）与结果的综合整合（Reduce阶段）。在实际应用场景中，大数据技术展现了其无可比拟的可靠性，能有效应对众多企业面临的庞大数据量挑战[4]。其各个部分的详细功能如下所述。

（1）HDFS作为Hadoop的底层存储基石，为分布式计算环境提供强有力的文件系统支持。

（2）MapReduce负责在庞大的数据集上进行高效的分布式计算任务，可将大数据处理任务进行分割，使其形成数个小数据块，通过数个计算节点进行并行处理后，再将处理结果进行合并。

（3）HBase是一种适用于大数据应用的高性能数据库，其写操作包括暂存至HLog、按row key顺序写入MemStore内存，以及MemStore满时flush至HDFS。合理设置MemStore的flush阈值对提升大数据处理效率与稳定性至关重要。为加快数据访问，可构建多级缓存体系，减少磁盘I/O依赖，增强Hadoop生态系统的数据管理[5]。

1.2 数据存储

1.2.1 Hadoop分布式集群结构

在Hadoop分布式体系中，大数据

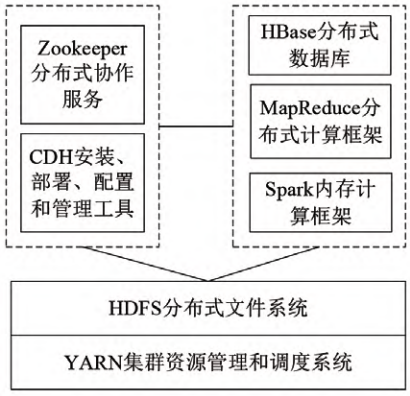

图2 Hadoop分布式集群结构

中国知网 https://www.cnki.net

以无索引堆结构存储在HDFS中，包含索引信息文件以提升检索能力。数据分块存储在从节点并冗余备份，确保安全可靠。关键索引文件存储在主节点内存中，主节点定期向备份节点传输索引备份，维护大数据完整性[6]。Hadoop分布式集群结构如图2所示。

1.2.2 基于HDFS的大数据存储优化

HDFS在进行大数据存储过程中，为保证数据存储效果，大数据分块处理后分布存储于从节点上，对各个数据块设定相应的存储副本率，以此为后续的大数据检索提供可靠依据[6]。基于HDFS的大数据存储优化流程如图3所示。

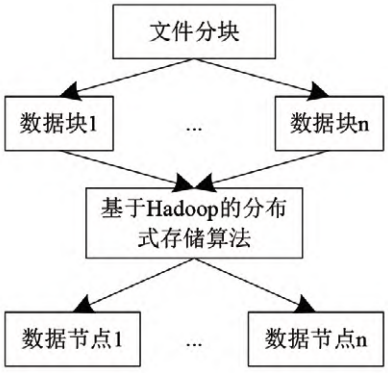

图3 基于HDFS的大数据存储优化流程

HDFS的主要目的是实现大文件或者大数据存储，其默认的数据块大小为64MB，在进行文件访问时，访问时间包括地址查询时间和数据传输时间，基于此可计算数据的传输效率ξ_c，其计算公式为

$$\xi_c=\frac{t_1}{t_1+t_2}=1-\frac{t_1}{\frac{S_c}{v}+t_2} \quad (1)$$

式中，t_1表示数据传输时间；t_2表示地址查询时间；s_c表示数据块大小；v表示数据传输速度。结合该公式，HDFS在进行数据存储时，须设定合理的s_c，以此保证数据传输效率和负载均衡性。

1.3 大数据检索方案

1.3.1 分布式区域检索方法

Hadoop的HDFS实现大数据分布式存储，配合分布式区域检索算法高效完成大规模数据的区域检索，通过多节点协同和索引机制实现快速数据检索[7]。基于分布式区域检索算法的大数据检索步骤如下所述。

步骤1：依据HDFS实现大数据分块存储后，对各个数据块进行信息命名。

步骤2：依据数据块所处的从节点和时序区间来划分存储区域，并为这些区域赋予相应的时间命名。同时，对每个时间范围内的数据，根据预设的数据块尺寸，为这些文件块中的数据构建一套时间索引架构[8]。

步骤3：为了计算各个区域从节点中需要的数据块数量，计算公式为

$$N=\frac{S_\Sigma(t+\chi)}{S_c} \quad (2)$$

式中，S_Σ表示大数据量；t代表数据传输的时间；x表示开销比，指的是除了实际数据以外，为了存储或传输数据而额外增加的开销。

步骤4：针对大数据的数据块数量分割结果，构建分区索引，即为每个分区生成一个独立的索引文件，文件详细记录该分区所涵盖的所有数据块。这个分区索引的主要作用是，当进行查询时，能够迅速定位到与查询区域存在交集的分区[9]。

步骤5：通过初始化与HDFS的连接，能够将所有局部的索引文件整合成一个统一的全局索引文件，以此构建全局索引系统。这个全局索引扮演至关重要的角色，能够在分布式环境中快速识别出哪些节点存储着满足查询条件的数据，从而精确地定位到数据分区所在的节点位置。

大数据检索通过分布式计算环境中

表1 数据服务器相关参数

IP名称	主机名称	作用	配置
10.103.2.2	数据备份-主机	NameNode：作为Hadoop集群的元数据节点，负责管理文件系统的命名空间和文件存储位置，并处理客户端的读写请求 ResourceManger：作为YARN集群的资源管理器，负责管理和调度集群中的计算资源，并将资源分配给应用程序 NodeManager：作为YARN集群的节点管理器，负责管理节点上的资源，并与ResourceManger通信，执行应用程序的任务 DataNode：作为Hadoop集群的数据节点，负责存储实际数据块，并处理客户端的读写请求	CPU：Intel Xeon E5504 2.00GHz 内存容量：36GB；硬盘容量：9.1TB
10.103.2.4	数据备份-主机1	SecondaryNameNode：作为NameNode的辅助节点，定期合并NameNode的编辑日志和镜像文件，以优化NameNode的性能	CPU：Intel Xeon E5504 2.00GHz 内存容量：36GB；硬盘容量：7.3TB
10.103.2.6	数据恢复-主机2	DataNode：作为Hadoop集群的数据节点，负责存储实际数据块，并处理客户端的读写请求	CPU：Intel Xeon X5650 2.67GHz 内存容量：36GB；硬盘容量：37GB

中国知网 https://www.cnki.net

的两级索引架构实现，全局索引文件存于主节点内存，局部索引文件存储在从节点，优化查询性能并减少Map任务数量。利用Hadoop容错能力，设计主从节点容错机制，包括主节点信息备份和从节点Block备份策略，确保数据完整性和可靠性[10]。

2. 结果分析

为检验方法有效性，选取四川巴蜀联胜科技有限公司对生产数据的处理为例。该企业原服务器难以应对大数据管理，查询效率低下。采用文中方法进行数据存储与检索，并分析其效果。在该企业原有的核心主机中部署Hadoop集群，设置静态内网IP，以此避免该服务器被外部网络入侵，并且修改计算机中的hosts文件，向该文件中添加所有服务器的IP和主机名称，以此保证大数据能够正确传输，同时保证worker节点和slave节点之间能够相互识别，保证节点之间能够完成远程连接，数据服务器相关参数如表1所示。

为验证文中方法对该企业大数据的存储效果，通过文中方法对该企业生产相关的大数据进行存储，获取在存储不同数据量时所需的存储时间，并将该存储结果与原始该企业的存储结果进行对比，测试结果如表2所示。

对表2测试结果进行分析后得出：文中方法在进行不同大小的数据存储时，能够在较短的时间内完成，数据量为100GB时，所需的存储时间为62.5秒；该企业原始的数据库在进行100GB数据存储时需要225.7秒。因此，文中采用的分布式存储能够更高效地完成大数据存储。

数据存储后则需满足数据的检索需求，为验证文中方法的数据检索效果，采用检索结果误差作为评价指标，测试该方法在进行不同类别数据检索时的效果，检索误差标准低于2%，测试结果如表3所示。

对表3测试结果进行分析后得出：随着数据块数量的逐渐增加，通过文中方法对设计数据、生产数据、检验数据进行检索后，各个类别数据的检索结果误差均低于2%。因此，文中方法能够满足该公司的大数据检索需求。

表2 大数据存储效果

数据量（GB）	原始检索时间（秒）	文中方法检索时间（秒）
10	157.3	32.1
20	161.4	37.1
30	172.8	41.9
40	184.3	44.2
50	191.2	48.8
60	201.2	50.5
70	207.4	53.4
80	214.6	56.1
90	219.8	59.7
100	225.7	62.5

结语

本文针对大数据的存储和检索展开相关研究，提出基于Hadoop的大数据存储与检索优化方法，该方法将Hadoop集成架构和分布式区域检索算法相结合，以此更好地满足大数据的存储需求和检索需求，为大数据的管理提供了可靠依据。

表3 不同类别的数据检索结果

数据块数量（块）	设计数据检索误差率（%）	生产数据检索误差率（%）	检验数据检索误差率（%）
10	1.55	0.70	0.56
20	1.20	1.28	0.80
30	1.36	1.40	1.60
40	1.17	1.65	1.77
50	0.90	1.09	0.94
60	1.40	1.38	1.85
70	1.33	1.50	1.52
80	1.66	1.25	1.44

参考文献：

[1]王亚伟.对大数据存储系统架构及数据安全放置机制的研究[J].信息记录材料,2024,25(4):171-173,176.

[2]李新平.大数据处理流程及存储与管理技术研究[J].电脑编程技巧与维护,2023(3):97-100,133.

[3]赵子晨,杨锋,郭玉辉,等.基于Hadoop技术的加速器大数据安全存储与高效分析系统设计[J].现代电子技术,2024,47(8):9-17.

[4]陈泽川,宁腾飞,李智,等.基于分布式微服务和Hadoop集群的系统研究[J].物联网技术,2023,13(1):107-108,111.

[5]王韶霞.基于云计算技术的电力数据检索及查询系统设计[J].太原学院学报(自然科学版),2023,41(1):74-79.

[6]王欣.基于云计算的大数据网络信息检索技术及扩展[J].电子技术与软件工程,2022(18):222-225.

[7]钟建坤,陈纪钦.云计算下的大数据网络信息检索技术分析[J].中国新通信,2023,25(8):29-31,34.

[8]刘静静.数据结构在大数据存储与检索中的性能优化研究[J].信息与电脑(理论版),2024,36(6):163-166.

[9]吴琼.基于大数据的网络数据安全存储检索系统的设计研究[J].中国新通信,2024,26(23):38-40.

[10]吴元杰.基于大数据的网络数据安全存储检索系统的设计[J].软件,2024,45(5):95-97.

作者简介：袁海平，本科，工程师，yhp@lzls.net，研究方向：大数据、人工智能。

中国知网 https://www.cnki.net