● 邓仲华，刘伟伟，陆颖隽（武汉大学 信息管理学院，湖北 武汉 430072）

基于云计算的大数据挖掘内涵及解决方案研究*

摘 要：文章基于传统数据挖掘与大数据挖掘对比的视角，对大数据挖掘的内涵进行了探讨，提出了云计算与挖掘服务融合的大数据挖掘体系架构，且以融合多功能的 Hadoop 大数据挖掘平台为例，剖析大数据挖掘内部工作流程并分析其优势及挑战，从而为用户对大数据挖掘的认知与应用需求提供参考。

关键词：大数据；大数据挖掘；云计算；体系架构

Abstract: Based on comparison of traditional data mining and big data mining, this paper discusses the connotation of big data mining and proposes a big data mining system architecture based on the fusion of cloud computing and mining service. Taking the multifunctional Hadoop big data mining platform as an example, the paper discusses the internal work flow of big data mining and analyzes its advantages and challenges as well, which provide reference for the users' cognition and application of big data mining.

Keywords: big data; big data mining; cloud computing; system architecture

继互联网、物联网、云计算的不断发展及智能终端的普及，海量复杂多样的数据呈现出爆炸式的增长，促使着大数据时代的到来。作为重要的生产因素，大数据已成为蕴含巨大潜在价值的战略资产，推动着产业升级和崛起，影响着科学思维与研究方法的变革。然而，大数据在依托其丰富的资源储备和借助强大的计算技术发挥优势的同时，也带来了挑战。海量、动态及不确定的数据使得传统数据处理系统面临着存储和计算瓶颈，同时，就如何从复杂的大数据中实时快速地挖掘出有价值的信息和知识，传统的数据挖掘技术自身受限的功能已无法满足用户的需求。因此，大数据环境下需要一种适用技术，即大数据挖掘，来应对当下存在的挑战。鉴于大数据环境下，参照传统数据挖掘的构建思想开发的挖掘系统无法提供令用户满意的服务，因此为满足建设与应用需求大数据挖掘的架构则必不可少。然而，目前可供借鉴的模型尚少，而且一些部门根据业务需求提出的大数据挖掘解决方案，由于系统不具可移植性且内部各组件融合较差致使其应用存在障碍。本文则通过对比传统数据挖掘来探讨大数据挖掘，且基于云计算提出大数据挖掘的体系结构以及构建具体的大数据挖掘系统，并以工作流程为主线客观地评价大数据挖掘的优势与不足，从而为推进其应用与发展提供参考方法。

1 大数据挖掘

大数据挖掘是从体量巨大、类型多样、动态快速流转及价值密度低的大数据中挖掘有巨大潜在价值的信息和知识，并以服务的形式提供给用户[1]。与传统数据挖掘相比，其同样是以挖掘有价值的信息和知识为目的。然而，就技术发展背景、所面临的数据环境及挖掘的广度深度而言，两者却存在差异。

1.1 发展背景

由于技术的进步、数据的大量产生以及对有价值数据的需求所驱使，两者都得以产生发展。但是，在技术的先进程度及数据的体量、多样复杂程度和处理分析能力方面，传统数据挖掘没有大数据时代所具备的充实环境技术条件，其在数据库、数据仓库及互联网发展等背景下，实现了从独立、横向到纵向数据挖掘的发展。而大数据挖掘则是在大数据背景下得益于云计算、物联网、移动智能终端等技术产生与发展。它是针对大数据的特征及现存挖掘系统面临的问题，借助先进技术加以系统地整合与改进。相比传统数据挖掘已相当成熟的应用、算法研究及系统工具开发，其技术的研究与应用还处于不断发展中，对于海量数据的挖掘主要是基于云计算进行相关技术的集成来实现。

1.2 处理对象

由于大数据挖掘与传统数据挖掘面临的数据环境不同，两者的处理对象则存在着特征差异。传统数据挖掘的数据来源主要是以某个特定范围的管理信息系统被动数据的产生为主，外加少数的 Web 信息系统中由用户产生的主动数据，数据类型以结构化数据为主，外加少量的半结构化或非结构化数据。而大数据挖掘的数据来源除了管理信息系统、Web 信息系统外，还包括感知信息系统等传感

* 本文为国家自然科学基金项目“大数据环境下面向科学研究第四范式的信息资源云研究”的成果，项目编号：71373191。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

设备自动产生的仿真数据[2]。相比于传统数据挖掘，大数据挖掘的数据来源更广、体量巨大、类型更加复杂；相应地，采集方式不再局限于被动，采集范围更为全面，吞吐量高，处理实时且快速，但由于对数据的精确度要求不高致使数据的冗余度和不确定性较高（如表1所示）。

表1　传统数据挖掘与大数据挖掘两者处理对象的特点对比

对比	传统数据挖掘	大数据挖掘
数据源	较少	众多、广泛
采集范围	局部采样	全局获取
采集方式	被动为主	主动和自动为主
数据类型	较为单一，以结构化数据为主	复杂多样，以半结构和非结构为主
数据冗余度	低	高
总数据体量	以TB计量	海量，以EB或ZB计量
处理单位	以MB为单位	以PB为单位
数据精确度	要求高	要求不高
处理效率	耗时较长	实时、快速

1.3　挖掘程度

大数据挖掘与传统数据挖掘处理分析数据的广度、深度也存在差异。在复杂类型、结构及模式的数据交错融合时，大数据挖掘能利用云平台集成多种计算模式与挖掘算法对庞杂的数据进行实时处理与多维分析，其处理数据的范围更广，挖掘分析更加全面深入。而传统数据挖掘主要是针对特定领域内维度较小的结构化数据采用相应的挖掘工具进行分析，其处理数据范围比较局限，分析数据类型较为单一。再加上，传统数据挖掘自身平台集成未成体系，且计算、挖掘算法的可扩展性不强，导致了其对多源异构数据获取、实时处理和挖掘分析功能受限[3]。

总体而言，大数据挖掘是在大数据环境下，以大数据为来源，依托云计算及大数据相关技术的支撑，利用挖掘工具发现潜在的有价值信息和知识，并将结果以云服务的方式提供给用户[4]。与传统数据挖掘相比，它是针对处理分析对象的变革，基于云平台对传统数据挖掘进一步扩展，与其他相关技术进一步融合，以实现大数据的实时、大规模、快速处理与交互分析。

2　基于云计算的大数据挖掘体系结构

传统数据挖掘系统一般运行在单机或客户/服务器上，体系结构通常为客户/服务器的二层结构或Web浏览器/服务器的3层结构。其系统结构大致分为数据源、数据存储、挖掘分析、前端展现4层，处理流程主要是采用数据移向计算的方式，将预处理的数据加载至数据仓库、数据集市存储，并迁移集中到服务器上分析挖掘，最终将结果以交互的方式展现给用户。然而，在处理海量分布、动态异构的大数据时，这种先存储后处理的集中批处理模式无疑增加了时间、空间复杂度和传输成本，此外也存在着如下问题：①传统挖掘系统扩展存在障碍。异构环境下其集群计算能力差且存储易受数据规模及类型的限制，但进行纵向扩展的成本巨大。②挖掘效果无法满足预期要求。传统分析工具和挖掘算法对多维、复杂的大数据不具可移植性和可伸缩性[5]，因分析不够深入导致低质量、低效率的挖掘结果。如传统聚类算法对于高维数据的处理都是以原始数据损失、低质量的聚类结果及高时间复杂度为代价[6]。③用户交互体验效果不佳。预处理阶段耗时且烦琐的手工整理以及对用户需求被动且非智能的认知过程等，与用户要求的简单、快捷、智能、实时等标准不符。

2.1　云计算

面对大数据时代传统数据挖掘存在的不足，云计算作为一种高扩展、高弹性、虚拟化的计算模式，则为大数据挖掘的存储能力及处理速度提供了动力支撑。云计算的核心技术包括分布式存储及分布式并行计算。其中，分布式存储主要为分布式文件存储和分布式数据库存储。以GFS为代表的分布式文件系统具有高扩展性、高容错能力和高吞吐率，大多数适用于大型、分布式、海量的数据并发访问，不适于存储大量小数据量的文件且存在单点故障问题等，但部分系统可存储海量小文件如Colossus、Haystack和TFS（Tao File System）。而分布式数据库包括事务性数据库和分析型数据库，见表2，部分结合了并行数据库的高性能和MapReduce的高扩展性，可存储结构化、半结构化及非结构化数据，以解决传统数据挖掘面临的存储问题。同时，以MapReduce为代表的分布式并行计算，具有简单易用性及良好的扩展性，适用于海量数据的批处理，能有效降低运算复杂度并提高计算效率[7]。目前，一些著名企业则针对自己的业务领域基于云计算推出相应的大数据挖掘解决方案，如Google构造的新一代搜索引擎平台可实现海量小文件存储以及大数据的实时交互分析；微软则将Windows Azure与Hadoop整合并与商务智能BI等应用软件集成，提供可兼容多平台且具有多功能、高性能的分析挖掘服务；IBM则基于Hadoop与流计算、智能分析等系统进行整合实现实时数据的管理及智能分析；其他公司则在开源Hadoop平台上进行功能的完善，如在Hadoop平台上雅虎开发了Pig，Facebook开发了Hive等[8]。虽然以上的大数据挖掘架构不尽相同，但是它们采用云平台与挖掘功能相融合的构建策略无明显差异。然而，在面对多领域间的数据共享和挖掘平台的适用性等问题时，各自的解决方案还需进行优势的相互借鉴和进一步融合。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

表 2　分布式数据库系统

类别	细分		代表系统
事务性数据库	NOSQL 系统	键值系统	Bigtable、Hbase、Dynamo、Cassandra 等
		文档存储系统	MongoDB、Couchbase 等
		图数据库	Neo4j、orientDB 等
	NEWSQL 系统	通用数据库	Spanner、NuoDB 等
		基于内存的数据库	SQLFire、VoltDB 等
分析型数据库	基于 MapReduce 的数据库		Hive、Pig
	基于 Hadoop 的数据库		HAWQ、Impala、Hadapt

2.2　大数据挖掘架构

基于以上的研究，笔者提出了大数据挖掘体系架构，其融合了多种计算、存储模式并具有强大的分析挖掘功能，整体上呈现出云计算/客户端的结构。该架构自内而外分为支撑平台层、功能层、服务层，见图 1。

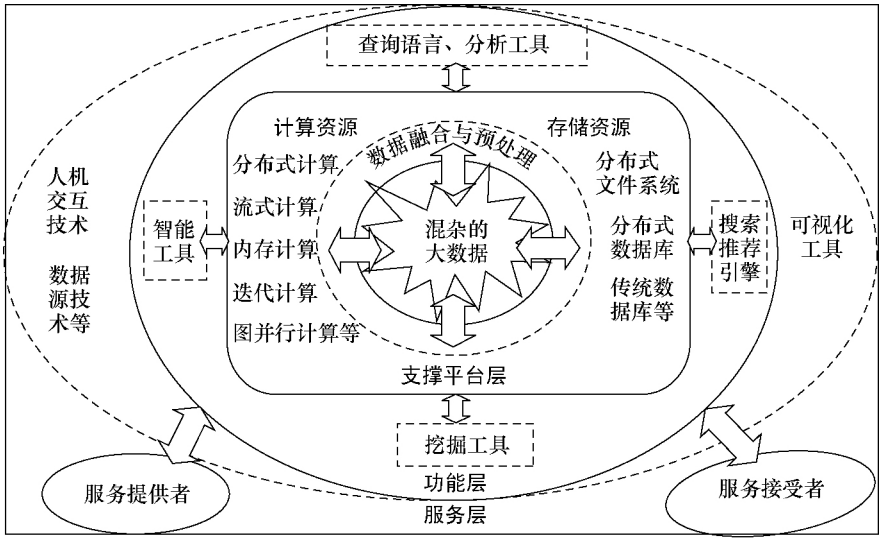

图 1　大数据挖掘体系架构

1）支撑平台层。作为大数据挖掘的资源和动力支撑，该平台通过将混杂的大数据与基于云计算的多种支撑处理技术相融合营造具有强大而丰富资源的云环境。这种云环境不仅可向外界提供数据、硬件、软件等资源，而且可以计算移向数据的方式为多源复杂数据的预处理、分析、挖掘等过程注入强大的动力。

2）功能层。该层依据用户需求与喜好可自动地进行智能化分析挖掘。其中，分析、挖掘等工具依托云平台高效的存储、计算能力具有较高的可伸缩性和可扩展性。

3）服务层。大数据挖掘通过客户端与服务提供者和使用者自动地进行交互认知。其挖掘结果则通过可视化、数据源等技术以服务的形式展示给用户。

整体看来，大数据挖掘呈现出云服务的模式，即功能层、服务层与平台层相互融合、相互依赖，三者形成了以强大计算和存储能力为核心的分析、挖掘及展示等多种功能相互融合的挖掘云，在云中可进行大数据的实时分析与挖掘，所得结果以基础设施即服务（IaaS）、平台即服务（PaaS）和软件即服务（SaaS）3 种形式提供给用户。

3　基于 Hadoop 的大数据挖掘平台

为便于对大数据挖掘进行具体的分析，本文通过构建融合多功能的 Hadoop 大数据挖掘平台来了解各个处理环节。基于 Hadoop 平台融合多功能的大数据挖掘，分为数据源、大数据挖掘平台、用户层 3 层。数据源是由结构、半结构、非结构数据所形成的复杂处理对象；大数据挖掘平台则是基于 Hadoop 融合多种计算模式和分析、挖掘等功能并结合实时数据的特征进行相应地处理；用户层则是以交互的方式进行系统认知与接受服务，见图 2。

大数据挖掘平台中，以 HDFS、HBase、MapReduce 为核心的 Hadoop 具有高可靠性、高扩展性、高容错性和高效性，计算模式以批处理和流处理为主，其中的 MapReduce 适合于体量巨大且更新率低的静态数据的批处理，Flume、Pig 等则对数据流的动态处理有一定的可伸缩性。然而，Hadoop 不适宜处理小量的低延迟数据和复杂关系的图数据，且难以支持内存计算[9-10]。对此，在构建此系统时，传统的数据库及处理工具、图并行计算 PowerGraph 及内存计算 Spark 等被融入 Hadoop 平台。如此，传统结构数据可借助分布式存储及计算技术提高查询处理的速率，半结构和非结构数据可借助内存计算和图计算等实现复杂数据快速实时地处理。

基于 Hadoop 平台的大数据挖掘依赖强大的支撑技术，相应的功能则丰富而多样。为具体了解其内部工作流程，笔者从数据预处理、数据存储、数据计算与分析、数据展示 4 方面结合传统数据挖掘来分析大数据挖掘各阶段的处理方法、特征及性能。

3.1　数据预处理

传统的数据挖掘先有模式后有数据，通过既定的模式，采用如 ETL、DBPut 等工具及查询、更新等驱动方法

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

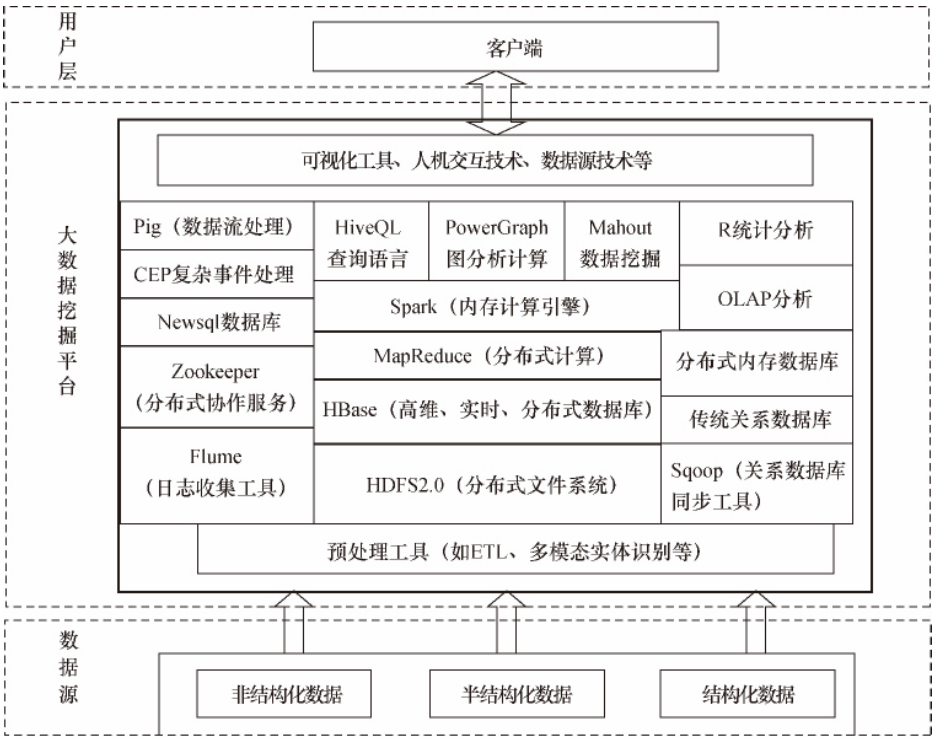

图 2　基于 Hadoop 平台融合多功能的大数据挖掘

进行静态数据的预处理[11]，其注重维护数据的完整性、准确性，处理的数据质量较高。而大数据挖掘先有数据后有模式，不是预先确定某种模式，而是随着数据的变化不确定性模型不断地变化[12]。大数据预处理主要是基于 MapReduce 融入传统预处理技术、数据流实时处理、多模态实体识别、Deep Web 集成及远程自动采集融合等技术，来提高预处理过程中并行计算、迭代计算、数据合并及共享等能力，如利用 Flume 或 Sqoop 等流式计算技术和嵌入式中间件多级数据处理技术进行数据的传输迁移，实现对历史数据及数据流同步处理，提高数据即时处理效率。但由于大数据的处理较关注数据间的关联关系而不注重因果联系，同时较关注数据处理的实时性而不注重完整性和精确性，重数据轻模型，导致处理后的大数据质量不佳[13]，挖掘结果的准确度及可信度不高，如 2013 年谷歌利用大数据进行流感的预测呈现的高出错率[14]。

3.2　数据存储

传统数据挖掘的存储管理以数据仓库、操作数据库系统和文件系统等关系数据库系统为主，主要采用行存储的方式将静态、确定的结构化数据以 E-R（实体和联系）或多维的数据模型存储，存储较为被动且存取方式随机，具体的模式一般由系统内部定义，灵活性和可扩展性较差，对事务 ACID（Atomicity、Consistency、Isolation、Durability）特性要求较高，容错能力不强。而大数据挖掘的存储除包括传统的数据存储外，还包括分布式存储，可存储结构、半结构及非结构数据，存储策略以列存储或行列混合存储为主，且模式一般由外部实现[15]，通常不支持 ACID 特性而支持 BASE（Basically Available、Soft State、Eventually Consistent）特性且相比关系数据库其支持的功能有限[16]。例如，Google 开发的 Bigtable 采用列存储的方式，并以新数据模型 Ordered Table 存储数据，模式灵活简单，具有很强的可扩展性，但数据一致性及兼容关系数据模型存在问题。对此，Spanner 系统则通过支持同步跨数据中心的复制和可视分片及提供 SQL 用户接口，有效实现了高可扩展性与 ACID 特性的融合。此外，对于不确定数据，大数据存储有相应的不确定数据库管理系统、不确定数据世系管理技术等[17]，数据以不确定关系模型存储，存储方式直接且严格先后次序，并且可基于内存而非磁盘构建概要数据结构，实现动态、不确定数据的直接存储处理。

3.3　数据计算与分析

相比于传统数据挖掘以数据移向计算的集中批处理模式，大数据挖掘则采用以计算移向数据多种计算模式相融合的方式对大数据进行分布并行处理。对于少量的维度较少的静态数据，传统数据挖掘由于反复多次、精确的查询方式以及 OLAP 较强的灵活性和较快的处理分析能力，其呈现出较高的查询分析性能[18]。但面对维属性繁多及数据立方体庞大的海量数据时，传统的 OLAP 却无法自动深入地分析[19]，而且以 SQL 为主的查询语言难以表达需构建的复杂分析模型，因此其查询分析的质量与效率会受到严重的影响。然而，大数据挖掘针对传统分析工具扩展性差和现有云平台分析功能薄弱的问题则进行系统功能的融合[20-21]，提高原有分析挖掘的分布式并行计算能力和支撑平台的分析能力。如图 2，将 R 分析软件和 Hadoop 深度集成，以及基于 Hadoop 对传统挖掘算法与现有算法进行整合改进。对于动态图数据，基于内存分布式的数据管理系统可支持低延迟地查询处理。对于数据流，其采用面

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

向滑动窗口模型的方法，通过概率维度索引进行单次近似连续地直接处理[22-23]。而基于 Hadoop 的 Apache Mahout 可将经典算法转化为 MapReduce 模式以提升算法吞吐量和性能，且支持半结构或非结构数据如音乐、视频等处理，并以自动交互的方式进行协同过滤及内容分析[24]。同时，除传统查询语言 SQL 外，大数据挖掘有相应的查询语言，如 HiveQL、Pig Latin 及其他专用 API，具有灵活的可扩展性，但查询性能较低，资源利用率不高。

3.4 数据展示

传统数据挖掘的展示适于数据量较小且关系较简单的数据结果集，主要以文本、报表及少数可视化图形（如 Gain Lift 图、ROC 图、饼状图、散点图等）的形式来反映模型效果、性能并呈现挖掘信息。然而，面对多维、海量、动态的数据，由于 I/O 限制、扩展性不强且交互方式被动难以反映结果之间的联系，其可视化效果不佳[25]。相比传统数据挖掘不具直观性且难以理解的展示，大数据挖掘的展示则是以人机交互的可视化方式将复杂的大数据以图像、动画的形式进行直观地解释，并辅助自动的可视化分析和挖掘，以帮助用户探索和理解数据。其中，代表性的可视化技术有反映复杂社交网络的宇宙星球图、标识对象知名度的标签云、显示集群成员分配的聚类分析可视化技术、反映事物历史变化的历史流图和空间信息流等，它们主要基于并行算法技术实现，涉及数据流线化、管道并行化、任务并行化和数据并行化。然而，为实现高效的可视化分析，基于内存的原位分析、众包与协同可视化、交互挖掘等技术还需深入研究以及可视化技术的时效、负载均衡及节点通信等问题仍需进一步解决[26]。

4 结束语

大数据的出现在带来丰富多样、具有潜在价值资源的同时，不论对传统数据管理方式还是对科学思维方式等都进行着变革。面对海量、复杂、不确定的动态数据，传统的数据处理方式无论是计算能力还是存储能力均面临着严峻的挑战，其扩展性、灵活性等都无法满足大数据实时处理要求。而云计算为大数据的处理提供了强大的计算和存储动力，同时大数据挖掘为大数据与云计算的深度融合提供了契机。

本文运用大数据挖掘与传统数据挖掘对比的方法，对大数据挖掘的内涵、体系结构和工作流程中的技术及方法进行了探讨，客观地分析了各自的优势与不足。总体而言，传统数据挖掘适于对静态、少量的结构化数据样本进行集中批处理，并具有较高的查询分析性能和挖掘效率，其计算模式及存储类型单一，较关注数据质量，对数据精确度要求较高。然而在面对大规模、快速流动的不确定数据时，传统数据挖掘较小的存储量、吞吐量及为提高计算效率采用的内部节约式策略则无法满足处理要求，同时系统自身的扩展性、灵活性不强且烦琐、复杂的挖掘算法不具可伸缩性也影响着其分析挖掘功能的发挥。而大数据挖掘则有效地弥补了传统数据挖掘存储及计算的不足，其基于云计算融合了多种计算、存储模式，适合于对多结构混杂的海量大数据进行实时快速地批处理或流处理，并具有较高的可扩展性、可伸缩性及容错能力。大数据挖掘较注重海量数据的处理速度，不太关注数据的精确度，其算法的复杂度较低，数据的质量欠佳，并且在处理小量数据时大数据挖掘不如传统数据挖掘灵活、高效。此外，大数据挖掘仍存在隐私安全、共享等问题，同时就实现智能分析挖掘、可视化与自动挖掘融合以及创建益于用户认知的人机交互界面等，大数据挖掘仍面临挑战。因此，针对以上问题后续的研究工作还需进一步推进与深入，以满足用户对大数据挖掘智能、可靠、高效、高质量等特性的需求。□

参考文献

[1] DENG Zhonghua，FAN Bing，LU Yingjun，et al. Discussion about big data mining based on hadoop [J]. Applied Mechanics and Materials，2013，380-384：2063-2066.

[2] 孟小峰，慈祥. 大数据管理：概念、技术与挑战 [J]. 计算机研究与发展，2013，50（1）：146-169.

[3] PHRIDVIRAJ M S B，GURURAO C V. Data mining—past，present and future—a typical survey on data streams [J]. Procedia Technology，2014（12）：255-263.

[4] 赵又霖，邓仲华，陆颖隽，等. 数据挖掘云服务分析研究 [J]. 情报理论与实践，2012，35（9）：33-36，44.

[5] HAN Rui，NIE Lei，GHANEM M M，GUO Yike. Elastic algorithms for guaranteeing quality monotonicity in big data mining [C] //Proceedings -2013 IEEE International Conference on Big Data. IEEE Computer Society，2013：45-50.

[6] JI Xiaokang，MA Xiuli，HUANG Ting，TANG Shiwei. Continuously extracting high-quality representative set from massive data streams [J]. Lecture Notes in Computer Science，2013，8346（1）：84-96.

[7] TODD D P，YUNG R C，YOSHIMURA A. Using performance measurements to improve MapReduce algorithms [J]. Procedia Computer Science，2012（9）：1920-1929.

[8] 刘鹏，吴兆峰，胡谷雨，等. 大数据——正在发生的深刻变革 [J]. 中兴通讯技术，2013，19（4）：1-7.

[9] CHEN Chun-Chieh，LEE Kuan-Wei，CHANG，Chih-Chieh，YANG De-Nian，CHEN Ming-Syan. Efficient large graph pattern mining for big data in the cloud [C] //Proceedings -2013 IEEE International Conference on Big Data. IEEE Com-

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

puter Society，2013：531-536.

[10] LEE D，JIN-SOO K，MAENG S. Large-scale incremental processing with MapReduce [J]. Future Generation Computer Systems，2014，36：66-79.

[11] HAN J W，MICHELINE K. 数据挖掘概念与技术 [M]. 范明，孟晓峰，译. 北京：机械工业出版社，2012.

[12] 王元卓，靳小龙，程学旗，等. 网络大数据：现状与展望 [J]. 计算机学报，2013，36（6）：1125-1138.

[13] 李建中，刘显敏. 大数据的一个重要方面：数据可用性 [J]. 计算机研究与发展，2013，50（6）：1147-1162.

[14] LAZER D，KENNDY R，KING G，VESPIGNANI A. The parable of google flu：traps in big data analysis [J]. Science，2014，343（6176）：1203-1205.

[15] ENRICO B，MARCO G，MAURO I. Performance evaluation of NoSQL big-data applications using multi- formalism models [J]. Future Generation Computer Systems，2014，37：345-353.

[16] 申德荣，于戈，王习特，等. 支持大数据管理的 NoSQL 系统研究综述 [J]. 软件学报，2013（8）：1786-1803.

[17] 高明，金澈清，王晓玲，等. 数据世系管理技术研究综述 [J]. 计算机学报，2010，33（3）：373-389.

[18] 赵博，叶晓俊. OLAP 性能测试方法研究与实现 [J]. 计算机研究与发展，2011，48（10）：1951-1959.

[19] PEI Jian. Some new progress in analyzing and mining uncertain and probabilistic data for big data analytics [J]. Lecture Notes in Computer Science，2013，8170：38-45.

[20] 丁岩，杨庆平，钱煜明，等. 基于云计算的数据挖掘平台架构及其关键技术研究 [J]. 中兴通讯技术，2013，19（1）：53-56，60.

[21] 李秋静，叶云. 电信大数据解决方案及实践 [J]. 中兴通讯技术，2013，19（4）：39-41，45.

[22] 白梅，信俊昌，东韩，等. 不确定数据流上的概率反轮廓查询处理 [J]. 计算机研究与发展，2011，48（10）：1842-1849.

[23] ARI I，OLMEZOGULLARI E，CELEBI，O FARUK. Data stream analytics and mining in the cloud [C] //CloudCom 2012-Proceedings：2012 4th IEEE International Conference on Cloud Computing Technology and Science. IEEE Computer Society，2012：857-862.

[24] LI K，GIBSON C，HO D，ZHOU Qi，KIM J，BROWN B O. Assessment of machine learning algorithms in cloud computing frameworks [C] //2013 IEEE Systems and Information Engineering Design Symposium. IEEE Computer Society，2013：98-103.

[25] CAMACHO J. Visualizing big data with compressed score plots：approach and research challenges [J]. Chemometrics and Intelligent Laboratory Systems，2014，135：110-125.

[26] PATTERSON R E，BLAHA L M，GRINSTEIN G G，et al. A human cognition framework for information visualization [J]. Computers & Graphics，2014，42：42-58.

作者简介： 邓仲华，男，1957 年生，教授，博士生导师。
刘伟伟，女，1990 年生，硕士生。
陆颖隽，男，1963 年生，副教授，硕士生导师。

收稿日期： 2014－12－08

（上接第 102 页）

[18] BLEI D M. Probabilistic topic models [J]. Communications of the ACM，2012，55（4）：77-84.

[19] ANDRIEU C，DE FREITAS N，DOUCET A，et al. An introduction to MCMC for machine learning [J]. Machine Learning，2003，50（1-2）：5-43.

[20] GRIFFITHS T L，STEYVERS M. Finding scientific topics [C] // Proceedings of the National Academy of Sciences of the United States of America，2004，101（Suppl 1）：5228-5235.

[21] HEINRICH G. Parameter estimation for text analysis [R]. Technical Report，2005.

[22] ZHANG H，QIU B，GILES C L，et al. An LDA-based community structure discovery approach for large-scale social networks [C]. Intelligence and Security Informatics，2007 IEEE. 2007：200-207.

[23] STEINBACH M，KARYPIS G，KUMAR V. A comparison of document clustering techniques [C]. KDD Workshop on Text Mining. 2000：525-526.

[24] DANON L，DIAZ-GUILERA A，DUCH J，et al. Comparing community structure identification [J]. Journal of Statistical Mechanics：Theory and Experiment，2005（9）：P09008.

[25] TANG L，LIU H. Community detection and mining in social media [J]. Synthesis Lectures on Data Mining and Knowledge Discovery，2010，2（1）：1-137.

作者简介： 吴小兰，女，1982 年生，博士生，讲师。
章成志，男，1977 年生，博士，教授，博士生导师。通讯作者。

收稿日期： 2014－12－08

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net