煤矿机电与信息化
doi:10.13301/j.cnki.ct.2023.01.047

煤矿设备状态大数据平台架构及关键技术研究*

曹现刚[1,2]，马晨飞[1,2]，王云飞[1,2]，段 雍[1,2]，霍小泉[3]
（1. 西安科技大学 机械工程学院，西安 710054；2. 陕西省矿山机电装备智能检测重点实验室，西安 710054；3. 陕西陕煤铜川矿业有限公司，陕西 铜川 727000）

摘 要：针对目前煤矿设备运行状态数据规模不断增大，结构化、非结构化数据并存，存储和查询效率低的现状，设计了一种基于 Hadoop 的煤矿设备运行状态大数据平台。采用 Hadoop 分布式文件系统（HDFS）实现设备文件数据的可靠存储，并采用 HBase 数据库实现结构化数据的持久存储，同时通过 MapReduce 对大量小文件处理过程中产生的资源消耗问题做了优化。实验表明，该平台实现了对煤矿设备状态大数据的高效存储与处理，为设备维护提供了很好的支持，并为智慧矿山的建设奠定数据基础。

关键词：煤矿设备；大数据；Hadoop；HBase；小文件处理
中图分类号：TD76 **文献标志码**：A **文章编号**：1008－8725(2023)01－222－03

Study on Big Data Platform Architecture of Coal Mine Equipment Status and Key Technologies

CAO Xiangang[1,2], MA Chenfei[1,2], WANG Yunfei[1,2], DUAN Yong[1,2], HUO Xiaoquan[3]
(1.College of Mechanical Engineering, Xi′an University of Science and Technology, Xi′an 710054,China; 2. Shaanxi Key Laboratory of Mine Electromechanical Equipment Intelligent Monitoring, Xi′an 710054, China; 3. Shaanxi Shanmei Tongchuan Mining Co., Ltd., Tongchuan 727000, China)

Abstract: Aiming at the current situation which the scale of coal mine equipment operating status data keep increasing, the structured and unstructured data coexisting,and the low efficiency of the storage and inquiry,a big data management platform based on mine equipment operation status is designed. Using Hadoop distributed file system (HDFS) to achieve reliable storage of equipment file data. And using HBase database to realize the persistent storage of the structured data.At the same time,optimized the resource consumption problems during the process of dealing with a large number of the small files through MapReduce.The experiments show that the platform has realized the efficient storage and handling of the big data which about the coal mine equipment status,providing good support for equipment maintenance and laying a data foundation for the construction of intelligent mine.

Key words: coal mineequipment; big data; Hadoop; HBase; small file handling

0 引言

随着工业大数据时代的到来，数据不断积累，海量数据涌现，同时煤矿设备日趋大型化、复杂化，造成了煤矿设备数据信息呈现爆炸式增长，比如煤矿机械设备运行状态数据、煤矿平台状态监测数据等，从 GB 级向 TB 级甚至 PB 级迅速扩展。同时设备状态数据来源多样，格式和标准不同，结构化、半结构化数据并存，使得传统的关系型数据库不再能够更好地存储和管理大规模的多源数据。早期的煤矿设备数据中心已经缺乏对海量异构数据进行高并发处理与维护的能力，更无法满足企业在自动化、智能化业务层面的应用需求。针对上述现状，本文提出一种基于 Hadoop 的煤矿设备数据平台架构对大数据进行有效存储与处理，并对小文件数据在处理性能上做了优化。

1 系统框架

煤矿设备大数据具有大容量、多源异构、快速性、价值性、真实性、可见性等特性，因此在数据存储和处理方面面临许多复杂的问题。Hadoop 分布式文件系统（HDFS）在大数据系统中扮演着重要的角色，它可以存储海量结构化、非结构化数据，相比于集中式存储机制，HDFS 是分布式的，由多个服务器组成，它具有高容错性、高扩展性、高可靠性、高吞吐率等特点，很适用于作为煤矿设备运行状态大数据的底层架构。HDFS 可以部署在大量廉价的 PC 上，并适合一次写入，多次读写的场景。

基于 Hadoop 的煤矿设备大数据平台系统架构由数据来源层、数据存储层、资源管理层、数据计算层、业务模型层 5 部分构成。系统框架如图 1 所示。

* 国家自然科学基金资助项目（51875451）

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

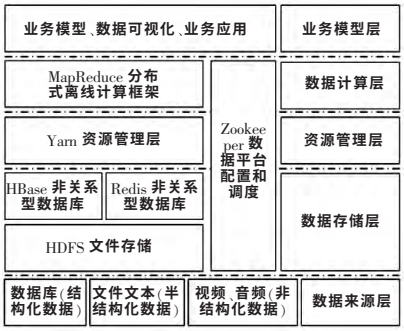

图1　系统总体架构

数据资源层是平台数据的主要来源，包括结构化、半结构化与非结构化数据，其中传感器节点是完成煤矿设备采集功能的节点，它们主要作用是对于设备运行状态参数进行有效采集，例如在采煤机摇臂上安装有温度、电流、红外传感器等，利用采集卡采集传感器中的数据，之后通过工业以太网将煤矿设备数据信息发送到主机服务器。

数据存储层是系统的数据容器，主要将采集到的海量数据进行分布式存储，底层采用 HDFS 存储架构，包括分布式内存数据库和分布式文件系统数据库。整体上采用主从多节点方式进行部署。对于结构化数据优先保存在关系型数据库中，随着数据量增大采用 Sqoop 工具将数据同步数据到 HBase 数据库中，实时数据则存储在内存数据库中方便查询。对于半结构化、非结构化数据，例如煤矿设备运行中产生的文本数据，图像、声音数据以及二次数据源(指存储在数据库中的历史数据，以及经过整理后产生的数据集)，则按照小文件模式存储在 HDFS 文件系统中。

资源管理层可对节点进行统一管理，实现节点间的动态上下线和软负载均衡，该层也实现了对煤矿设备状态数据的查询。数据计算层要求对煤矿设备数据做到稳定、低延迟的计算，它采用 MapReduce 作为数据处理框架，多个服务器整合成 1 个强大的计算集群，为整个平台提供了高效的并行计算能力，也为煤矿设备异常状态诊断提供了数据计算支持。

业务模型层可根据用户的需求通过接口 API 实现具体的业务操作，对于数据处理结果可通过可视化模型进行展示，采用 B/S 的架构设计，用户可通过客户端浏览器访问煤矿设备状态大数据平台。

2　关键技术

2.1　基于非关系型数据库的存储模型设计

随着工业化大数据量的快速增长，基于关系型数据库的存储模式已经很难满足大规模煤矿设备数据的存储需求。Hbase 是一种分布式、可扩展的NoSQL 数据库，目前在机电设备大数据的研究中越来越多的学者倾向于运用 HDFS，HBase 等相关技术解决大数据存储的问题。针对煤矿设备运行状态监测大数据，本文结合 HDFS 和 HBase 两者的优点，设计了一种复合式的存储方式来对海量数据进行有效存储，煤矿设备运行过程中所采集到的图片、噪声数据，以及处理后的衍生数据等众多半结构化，非结构化数据存储在 HDFS 中，表格数据和元数据信息存储在 HBase 中，从而实现煤矿设备运行状态大数据的高效存储与检索。以采煤机运行状态数据作为数据来源，存储模型如图 2 所示。

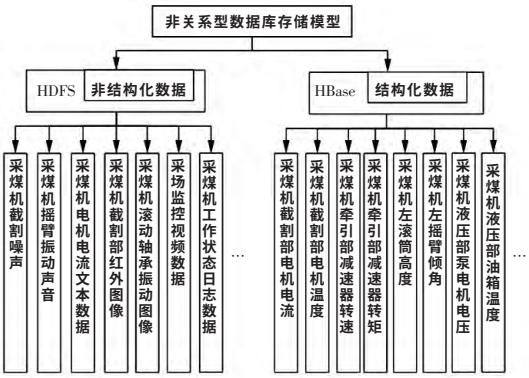

图 2　数据库存储模型(以采煤机为例)

对于煤矿设备中的半结构化、非结构化数据的存储主要通过文件 IO 流的读写操作来完成，读写数据流程如图 3 所示，从而实现数据的上传和下载。

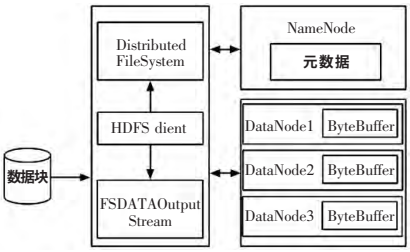

图 3　读写数据流程

通过传感器采集到的煤矿设备运行状态数据很多是以表格等形式存储，要对数据量庞大的结构化数据进行存储就需要借助非关系型数据库。针对采煤机截割部减速机在运行过程中所产生的大量状态监测数据，如电流、电压、转速、转矩等，这些数据作为元数据信息存储在 HBase 中。采煤机截割部减速机运行状态元数据的表结构如表 1 所示。

以采集到的元数据信息为例，Rowkey 是不同时间戳下的行键，作为唯一值存在；各个列族分别代表电流、电压、转速、转矩等数据，其中不同列表示了不同属性值。

2.2　设备小文件处理优化方法

表 1　截割部减速机运行状态元数据表结构

行键	时间戳	列族 CF_Cur			列族 CF_Vol			列族 CF_Sp			…
		输入电流 AID	采集值	平均值	输入电压 UID	采集值	平均值	转速 ID	采集值	平均值	
Rowkey	TimeStamp	InputAID	COV	AVE	InputUID	COV	AVE	SpID	COV	AVE	…

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

(1)煤矿设备大数据中的小文件问题

煤矿设备运行过程中采集到大规模图像、视频、声音、文本等文件数据，HDFS作为大规模数据集存储容器，需要对此类文件做存储和处理。HDFS中每个目录、文件和文件块在NameNode节点中都是有记录的，大量小文件会占用很多NameNode内存，从而影响HDFS横向扩展的能力，并且小文件存储过程中过长的寻址时间会降低数据访问的速度，同时在使用MapReduce处理小文件时，每个maptask只能处理1个HDFS块，大量小文件就需要多个maptask去处理，从而对集群资源产生消耗。

(2)解决方案

此前Hadoop自身提出建立har文件的解决方案，该方法能将小文件存入HDFS块，但是在读取har里面的小文件时需要通过二级索引进行查找，且不支持归档文件的压缩。SequenceFile是HDFS提供的一种二进制技术，通过键值对序列化后的小文件进行合并，支持数据块压缩，但该方法无法建立小文件到大文件的映射，数据读取效率较低。

综上，本文采用CombineFileInputFormat方法对大量小文件进行优化处理，MapReduce默认切片机制对任务按文件规划处理，每个任务都会单独形成切片交给单独的maptask处理。通过CombineFileInputFormat方法可以将多个小文件从逻辑上划归到1个切片中，多个小文件就可以交给1个maptask处理。该方法有虚拟存储和切片2个过程，优化处理流程如图4所示。

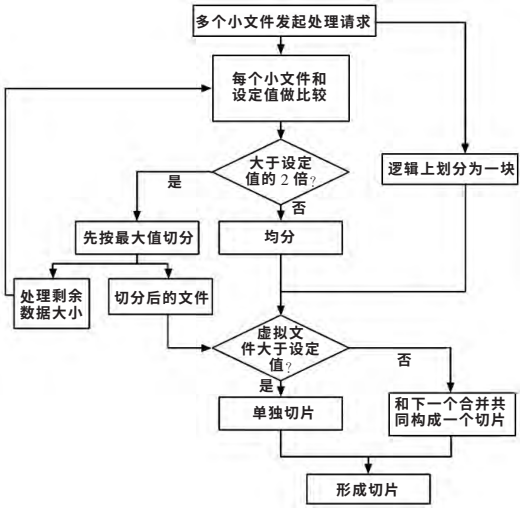

图4　小文件优化处理流程

针对存储在HDFS中的采煤机牵引部电机电流数据，它以文本文件格式存在，对其中的4个小文件进行分析，大小分别为2.7、5.3、3.1、7.8 MB，设置SetMaxInputSplitSize值为4 MB，则在虚拟存储之后会形成6个文件块，大小分别为2.7、2.65、2.65、3.1、3.9、3.9 MB，最终会形成3个切片，大小分别为(2.7+2.65)、(2.65+3.1)、(3.9+3.9) MB。

3　实验验证

本文在CentOS7上部署了Hadoop集群和Zookeeper集群，之后又安装部署了HBase和Redis集群，具体的配置如表2所示。

表2　集群各节点配置信息

节点名称	NameNode	DataNode1	DataNode2
主机名称	master	slave1	slave2
IP	192.168.18.132	192.168.18.133	192.168.18.134
Hadoop版本	Hadoop 2.7.2	Hadoop 2.7.2	Hadoop 2.7.2
Zookeeper版本	Zookeeper 3.4.10	Zookeeper 3.4.10	Zookeeper 3.4.10
Hbase版本	Hbase 1.3.1	Hbase 1.3.1	Hbase 1.3.1
Redis版本	Redis 6.0.8	Redis 6.0.8	Redis 6.0.8

本文对存储在HDFS中的采煤机牵引部电机电流的衍生数据做分析，选取50、100、500、1 000个大小为1~10 MB的文本格式的小文件作为研究对象，测试HDFS优化前后对小文件处理所需的时间，取5次结果的平均值，实验结果如图5所示。

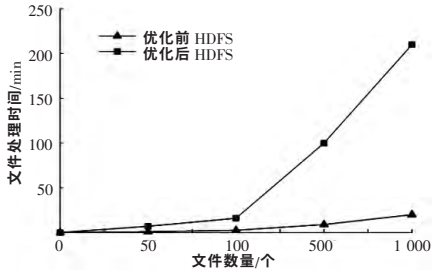

图5　小文件处理性能对比

上图表面，采用CombineFileInputFormat这种方式优化后的HDFS对小文件处理速度明显快于优化前的HDFS，随着小文件数量的增多，处理性能提升也愈发明显。

4　结语

本文提出了一种基于Hadoop的分布式存储系统来对煤矿设备运行状态中的海量数据进行有效存储，在针对煤矿设备数据中的小文件存储时，采用CombineFileInputFormat方法进行优化处理。实验表明，使用本文提出的小文件存储优化方法在处理文件效率上比优化前有明显提升，HDFS平台的搭建以及采用的关键技术在处理煤矿设备运行状态数据上具有很大优势，为设备故障诊断与状态监测提供了数据层面的支持。

参考文献：

[1]王元卓，靳小龙，程学旗. 网络大数据：现状与展望[J]. 计算机学报，2013，36(6)：1125-1138.
[2]王国法，王虹，任怀伟，等. 智慧煤矿2025情景目标和发展路径[J]. 煤炭学报，2018，43(2)：295-305.
[3]石照耀，侯晋珊. 大数据推动下的工业4.0[J]. 机器人产业，2016(3)：20-25.
[4]曹现刚，段欣宇，张梦园，等. 煤矿设备状态监测系统设计[J]. 工矿自动化，2021，47(5)：101-105.
[5]韩安. 基于Hadoop的煤矿数据中心架构设计[J]. 工矿自动化，2019，45(8)：60-64.
[6]张晓霞，李首滨，苏上海，等. 基于工业互联网体系架构的矿井大数据平台设计与实现[J]. 煤炭科学技术，2022，50(6)：277-285.
[7]张卫，丁金福，纪杨建，等. 工业大数据环境下的智能服务模块化设计[J]. 中国机械工程，2019，30(2)：167-173，182.
[8]张华伟，陈勇，李海斌，等. 基于HBase的工业大数据时序数据存储实现[J]. 电信科学，2017，33(S1)：21-27.
[9]田广兰. 大数据时代的数据主体权利及其未决问题：以欧盟《一般数据保护条例》为分析对象[J]. 中国人民大学学报，2020，34(6)：131-141.

作者简介：曹现刚(1970-)，山东莒南人，教授，博士研究生导师，博士，研究方向：现代设备维护理论与技术，电子信箱：172833610@qq.com；通信作者：马晨飞，电子信箱：358057377@qq.com.

责任编辑：李景奇　收稿日期：2021-12-26

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net