中文文本情感分析系统研究与实现

刘文华[1] 邓友[1] 任保金[2]

[1] (重庆对外经贸学院重庆超大城市数字化治理学院 重庆 401520)

[2] (北京华晟经世信息技术有限公司 北京 101100)

摘　要 为提升中文文本情感分析的准确性与计算效率，本文设计了一种多方法对比分析框架。基于 Kaggle 平台的 ChnSentiCorp 中文情感数据集，分别采用 TF-IDF 特征工程与 BERT 预训练模型实现文本向量化，并系统对比了 Scikit-learn、Spark MLlib 及 BERT 三类模型的性能。实验结果表明：BERT 模型的 F1 分数达 95%，但计算成本较高；Scikit-learn 中的 SVM 在传统方法中效率最佳；Spark MLlib 虽支持分布式训练，但单机模式下易受内存限制。实验结果验证了 Spark 分布式计算在大规模中文情感分析中的可行性。

关键词 机器学习；深度学习；情感分析；中文文本；并行计算

中图法分类号　P391.41　DOI:10.16707/j.cnki.fjpc.2025.09.006

Research and Implementation of a Chinese Text Sentiment Analysis System

LIU Wenhua[1], DENG You [1], REN Baojin[2]

[1](Chongqing School of Digital Governance for Mega Cities, Chongqing College of International Business and Economics, Chongqing, China, 401520)

[2] (Beijing Huasheng Jingshi Information Technology Co.,Ltd., Beijing, China, 101100)

Abstract To improve the accuracy and computational efficiency of sentiment analysis in Chinese texts, this study designed a multi method comparative analysis framework. The ChnSentiCorp Chinese sentiment dataset based on the Kaggle platform was used to vectorize text using TF-IDF feature engineering and BERT pre trained models, and the performance of Scikit learn, Spark MLlib, and BERT models was systematically compared. The experimental results show that the F1 score of the BERT model reaches 95%, but the computational cost is relatively high; SVM in Scikit learn has the best efficiency among traditional methods; Although Spark MLlib supports distributed training, it is susceptible to memory limitations in standalone mode. Verified the feasibility of Spark distributed computing in large-scale Chinese sentiment analysis.

Keywords Machine Learning; Deep Learning; Sentiment Analysis; Chinese Text; Parallel Computing

1 引言

随着互联网的普及和网络通信技术的进展，微博、手机新闻客户端、电子商务与电子政务等平台日益生成大量的文本数据。这些数据不仅反映了人们的日常交流与行为，还蕴含着丰富的情感信息。如何从海量的文本中提取有价值的情感数据，成为情感分析领域的重要研究课题。

目前，中文文本情感分析方法主要包括以下技术路线：基于情感词典计算情感得分，具有可解释性强、计算开销小的优点但存在词典更新滞后问题，并且无法处理隐含情感和讽刺表达；机器学习方法需要人工设计特征进行分类，依赖专家经大规模标注数据，传统机器学习方法训练速度快，但缺乏并行处理能力，基于 Spark 的分布式训练方法，受限于系统内存，可能导致系统出现瓶颈，进而影响模型的精度；深度学习方法能自动提取特征，学习上下文信息，但计算资源消耗大、可解释性差。

刘文华（**通信作者**），男，1972年生，主要研究领域为大数据、计算机视觉。E-mail: ok16998@163.com。邓友，男，1975年生，主要研究领域为数据管理，大数据应用、数字技术应用研究。任保金，男，1968年生，主要研究领域为嵌入式、大数据应用。

中国知网　https://www.cnki.net

本文针对上述问题，提出一种结合传统机器学习、Spark 分布式计算和深度学习的情感分析方案，以优化中文情感分析的准确性和计算效率。主要解决以下关键问题：探索适用于中文情感分析的最优算法，提升模型的分类效果；评估 Spark 在大规模情感分析中的可行性，并优化分布式计算策略，提高训练和推理效率；通过实验对比不同方法的性能，确定在不同应用场景下的最佳方案。

本文首先介绍中文文本情感分析用三类主流方法，随后设计并实现面向大规模文本数据的情感分析架构，并在 Kaggle 平台上进行实验验证。结果表明，BERT 在中文情感分析中表现最佳，同时 Spark 平台在大规模情感分析任务上具有良好的可行性。研究成果可为舆情监控、市场分析等应用提供技术支持，并推动情感分析技术的并行化发展。

2 相关技术

情感分析方法主要包括词典法、机器学习、Spark 机器学习（Spark Machine Learning Library，Spark MLlib）、深度学习如 长短时记忆网络（Long Short-Term Memory，LSTM）、双向编码器表示的 Transformer（Bidirectional Encoder Representations from Transformers，BERT）。

2.1 研究历史

早期情感分析依赖情感词典和人工规则。传统机器学习阶段从 2007 到 2016 年，2007 年推出的 Scikit-learn 提供了标准化机器学习接口，支持向量机（Support Vector Machine，SVM）、逻辑回归、随机森林等模型。深度学习阶段从 2018 至今。

开源 Python 机器学习库 Scikit-learn 于 2007 年发布。2011 年，Pedregosa 等人研究表明[1]，基于 Spark MLlib 的情感分析能提高大规模数据的处理效率。

2016 年，Balazs 等人使用 Spark MLlib 对亚马逊评论数据集 400 万条评论进行情感分析[2]。实验表明 Spark 能提升计算效率，其中 SVM 分类器的表现最佳，其准确率为 86%。

2018 年，Google 提出 BERT，实现了对文本深层语义的理解，使情感分析精度大幅提升。Devlin 等人介绍了 BERT 的预训练方法以及微调方法，显著提升了多种 NLP 任务的性能，标志着自然语言处理领域的重大突破[3]。

杨立月等于 2020 年研究了基于 Spark 平台的集成学习模型并行化算法[4]。该方法能够显著加快文本分类任务的处理速度。在实验中 F1-score 性能指标接近单机版本，并且具备良好的可扩展性，能够适应更大规模的文本情感分析需求。

Karthick 等在 2023 年的研究总结了词典、机器学习、深度学习和混合方法在情感分析中的场研究、政治分析、医疗健康等领域的应用[5]，并提供实验数据支持，提出应结合多模态数据进一步提升情感分析的准确性和可解释性，为未来研究提供了方向指导。

2.2 词典法

通过将分词后的文本词汇与情感词典词条进行比对，并结合统计频率来判断情感倾向。情感词典一般包含正向词语（如“出色”“快乐”“完美”）和负向词语（如“糟糕”“失败”“恼怒”）两类。通过统计分析这些词汇在文本中的出现频率和概率分布情况，可以判断文本中包含的情感倾向[6]。这种方法简单直观，在小规模数据集上能够较好地发挥作用，常用于初步分析文本的情感倾向，但它极度依赖人工构建和维护情感词典。在网络语言快速变化的背景下，新词不断涌现，使得人工难以及时跟进。此外，词典法对文本的上下文理解能力较弱、文本语境理解能力存在不足，特别是在中文处理中尤为突出。汉语表达往往依赖上下文且具有歧义性，例如“不错”一词，在某些情况下表示积极评价，而在其他语境下可能只是中性甚至略带否定意味。单纯依靠词库匹配和预设规则，很难精准判别情感倾向。随着数据规模持续增长，词典法的处理方式在大规模数据面前显得力不从心，在面对多样化表达、上下文依赖性强的语言如中文，其局限性暴露无遗，难以适应当前技术发展的需要。

2.3 机器学习法

逻辑回归（Logistic Regression）是一种有监督学习方法。其主要思想是对训练数据的特征向量进行模型训练后得到线性特征系数，预测时把新数据向量化后与线性特征系数进行组合，计算属于某个分类的概率。SVM 是一种适用于高维数据的分类算法，在高维数据分类中表现良好，特别适合处理复杂边界情况。在情感分析任务中，SVM 能够有效处理复杂的边界情况，并对小样本数据具有良好的适应性。

随机森林（Random Forest）是一种集成学习方法，由若干决策树构成，通过汇总各树的投票结果

中国知网 https://www.cnki.net

来确定最终分类。该算法凭借多树协作的特性，能够有效提升预测的稳定性，适合复杂分类任务。该方法对高维特征数据具有良好的鲁棒性，能有效降低噪声影响，并缓解过拟合问题。

2.4 基于 Spark 框架的方法

Spark 框架利用分布式计算优势、结合传统机器学习算法构建中文情感分析系统。Spark 以其分布式计算和内存计算能力著称，并且支持 Python、Java、Scala 等多种语言编程，特别适合处理大数据场景。Spark MLlib 采用基于弹性分布式数据集（Resilient Distributed Dataset，RDD）架构的并行计算方式，支持在大规模数据集上高效地训练机器学习模型。基于 Spark 的情感分析系统能够利用这些优势，实现高效、可扩展的系统完成数据处理、特征提取和模型训练与预测任务。

2.5 深度学习法

近些年，深度学习在情感分析领域展现出了突出成效，能够显著提高情感分类的精确性。卷积神经网络（Convolutional Neural Network，CNN）适用于提取文本的局部特性，而循环神经网络（Recurrent Neural Network，RNN）、LSTM 则擅长捕捉上下文的序列依赖关系。BERT 等预训练模型可以实现对文本包含的深层语义理解赖。深度学习方法往往需要高性能计算机、图形处理单元（Graphics Processing Unit，GPU）加速支持，训练耗时较长，模型的可解释性不足。此外在应对大规模文本数据时，其计算效率和扩展能力仍存在瓶颈。在分布式计算场景中，如何实现深度学习模型的高效并行训练，仍是一个亟需解决的技术难题。

随着中文文本数据的快速增长，如何有效提升中文文本情感分析的准确性和处理效率成为亟待解决的问题。传统机器学习方法在中文情感分析中的表现受限，难以充分利用中文词汇信息，而现有的分布式计算技术在大规模文本处理中的应用仍有待优化。此外，尽管 BERT 在中文文本分析任务中表现优异，但其在情感分析中的训练流程和泛化能力仍需改进。为此，本文结合中文词典、传统机器学习方法和分布式计算技术，探索优化 BERT 在中文情感分析中的应用，以提升大规模中文文本处理的效率和效果，从而为中文情感分析提供更优的理论与技术支持，为大规模中文文本处理提供理论与技术支持。

综上，现有方法在词典更新、泛化能力和计算效率上存在瓶颈，本文旨在结合 BERT 和 Spark 解决这些问题。

3 系统设计与实现

基于现有方法及其局限性的分析，设计了一种分层架构（如图 1 所示），以便高效处理大规模文本数据并提升情感分类的准确性。

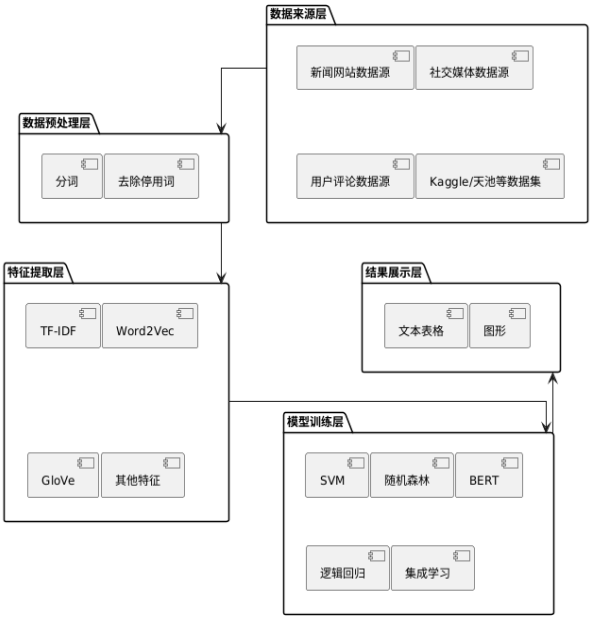

图 1 系统架构图

3.1 系统架构

系统采用分层结构，分为数据来源层、数据预处理层、特征提取层、模型训练层和结果展示层[7]。这种模块化方式便于维护系统，为未来功能扩展提供了便利，使整体设计更加实用灵活。数据预处理层主要负责对原始文本数据进行清洗和标准化[8]。特征提取层将处理好的文本转化为数值向量形式。模型训练层训练特征向量得到分类模型。而结果展示层则专注于将预测结果以可视化方式呈现，以简明的形式向用户传递分析结论。

3.2 数据预处理

数据预处理模块则负责对文本数据进行分词、停用词过滤、规范化等处理，为后续的分析奠定基础。原始文本数据通常包含标点符号、停用词、拼写错误等噪声，经过预处理步骤，可以有效降低噪音，提高文本的结构化层次。机器学习算法采用 Jieba 分词工具（https://github.com/fxsjy/jieba）进行文本预处理。Jieba 分词支持多种模式、内置词典并支持自定义词库，适用于搜索引擎、文本分析、情

中国知网 https://www.cnki.net

感分析等多个 NLP 任务、兼顾速度和效果并且免费，因此选择它作为分词主要工具。停用词是指文本分析中常见但对语义贡献较小的词汇，如“的”、“了”、“也”等，以及标点符号和特殊字符（如@、#、$）。它们都不携带重要的情感信息，因此需要将其去除。文本规范化操作包括大小写统一、拼写错误纠正、全角半角转换以及同义词替换。此步骤有助于减少文本的冗余信息，提高模型对相同含义但不同写法单词的识别能力。

3.3 特征提取

特征提取是文本情感分析的核心步骤，目的是将原始文本数据转换为机器学习模型可以处理的数值向量形式，以便后续模型训练与分类。在本文中，Scikit-learn 与 Spark 系统特征提取采用词频-逆文档频率（Term Frequency-Inverse Document Frequency，TF-IDF）方法，以充分利用统计特征和语义特征，提高情感分析的精度和鲁棒性。TF-IDF 综合了 TF 和 IDF，用于评估词在文档中的重要性，同时参考其在语料库中出现的普遍性，方法简单高效，特别适合捕捉关键词的重要性[8]。

BERT-Base-Chinese 是一个预训练的 BERT 模型的标识符。BERT 通过 WordPiece 分词将中文文本拆分为子词或字符级 token，并在序列首尾添加特殊标记“[CLS]，[SEP]”。随后 BERT 通过嵌入层将 token 转换为数值向量，并输入到 Transformer 网络进行处理。最终模型输出 token 级向量（用于每个 token 的上下文表示）和句子级向量（通常使用“[CLS]”位置的向量来表示整个句子的语义）。BERT 将中文文本转化为向量后用于各种 NLP 任务。

3.4 模型训练

模型训练是在谷歌 Kaggle 平台使用 Juper Lab notebook 编写 Python 代码实现的。

Kaggle 是一个流行的数据科学竞赛平台，拥有庞大的公共数据集库（https://www.kaggle.com）。这些数据集可用于学习、研究和实验。本文实验使用 Kaggle 平台已有的 ChnSentiCorp 数据集（https://www.kaggle.com/datasets/yizhongchao/chnsenticorp-alllabeled）训练模型。ChnSentiCorp 数据集已经预先划分好了训练集、验证集和测试集，训练集用于模型学习，验证集用于参数校验。

在 Kaggle 中创建四个新的 Notebook 后，首先在每个 notebook 加入数据预处理代码，如数据加载、清洗和分词。然后分别使用 Scikit-learn、Spark MLlib 和 BERT 等算法框架在 Notebook 中训练不同模型（spark 上随机森林模型单独训练）。在模型训练过程中包括过导入相应的库，模型初始化、模型训练与评估。

此外，通过优化超参数（如正则化强度、核函数类型及树的数量），系统提升了模型的性能，确保其在多种应用场景下具备较强的适应能力。

在参数优化环节，针对不同算法采用了差异化的调优策略。对于逻辑回归模型，选择了 L2 正则化方式，通过网格搜索方法对正则化系数 C（取值 0.1、1、10）和优化算法 lbfgs（Limited-memory Broyden-Fletcher-Goldfarb-Shanno）与坐标下降法（Library for Large Linear Classification， liblinear）进行组合调优，最终确定 C=10 配合 lbfgs 算法为最优参数组合。在支持向量机模型中，同样采用网格搜索方法，对正则化系数 C（取值 0.1、1、10）和核函数类型线性求解器 liblinear 与为 rbf（Radial Basis Function，径向基函数）进行组合优化，最终选择 C=10 配合 RBF 核函数的效果最佳。

实验随机森林模参数超参数网格包含决策树数量（4 种：50，100，200，300）、最大树深（3 种：10，20，30）、节点最小样本分裂数（3 种：2，5，10）、叶子节点最小样本数（3 种：1，2，5）以及是否自助采样，共 216 种组合。每个组合通过 3 折交叉验证，随机森林模型可能包含多达 300 棵决策树。设置迭代次数 n_iter=100，随机抽取 100 种组合，在保证搜索效率的同时获得较好的参数组合。

BERT 算法中设置学习率为 2×10^{-5}的，使用交叉熵作为分类损失函数，训练 10 轮。

Kaggle 平台还提供 GPU 支持，使得深度学习模型（如 BERT）的训练更加高效。通过在 Jupyter Notebook 可以方便地完成中文情感分析任务的模型训练和测试。

3.5 结果输出

在模型训练完成后，对测试数据进行情感预测，通过文本列表和图表的形式展示结果。文本列表方便查阅具体内容；而图表则直观地呈现情感分类的分布比例，可以快速了解整体趋势。准确率、精确率、召回率和 F1-score 数指标以数值表格、条形图、热力图形式呈现。系统通过混淆矩阵展示真实情感标签与预测标签之间的关系，分析不同类别上的分类效果[9]。在结果输出层，用户能够迅速获

中国知网 https://www.cnki.net

取预测结果，并通过可视化手段分析模型在实际应用中的表现，从而为调整参数提供依据，提升情感分析的准确性和适用性。

4 实验与分析

模型主要评估指标包括准确率、精确率、召回率和 F1 分数，还有模型训练时间，以探讨其在实际应用中的可行性[10]。

准确率，反映预测正确的样本数量占整个测试集的比例；精确率，用于衡量模型预测属于某一类别的样本与实际属于该类别的样本的比例；召回率，表示实际属于某类的样本被正确识别的比例；F1 分数，作为精确率与召回率的调和平均值，用以综合评估模型表现。

4.1 实验设置

4.1.1 运行环境

Kaggle 平台软硬件环境：Scikit-learn 与 Spark MLlib 训练环境为单台云服务器 CPU；BERT 训练环境为单台云服务器+两块 NVIDIA Tesla T4 GPU；软件环境包括 python3.10、pyspark-3.5.5、scikit-learn-1.2.2、transformers-4.36.0 等模块。

4.1.2 数据集介绍

实验采用 ChnSentiCorp 数据集。该数据集包含来自酒店、笔记本电脑和书籍的中文网购评论，共 12000 条数据，划分如下拥有 9600 条训练数据，1200 条验证数据 1200 条测试数据。

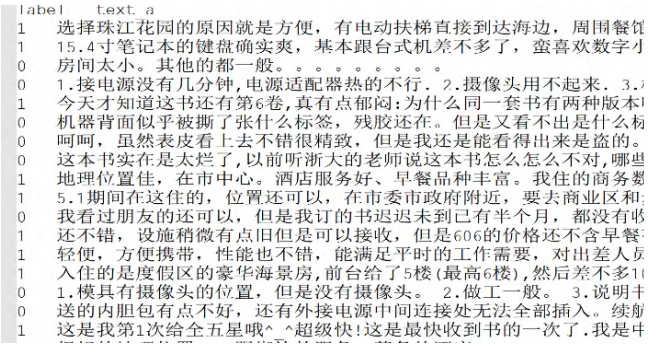

label	text_a
1	选择珠江花园的原因就是方便，有电动扶梯直接到达海边，周围餐饮
1	15.4寸笔记本的键盘确实爽，基本跟台式机差不多了，蛮喜欢数字小
0	房间太小。其他的都一般。。。。。。。。。
0	1.接电源没有几分钟,电源适配器热的不行. 2.摄像头用不起来. 3.
1	今天才知道这书还有第6卷,真有点郁闷:为什么同一套书有两种版本
0	机器背面似乎被撕了张什么标签，残胶还在。但是又看不出是什么标
0	呵呵，虽然表皮看上去不错很精致，但是我还是能看得出来是盗的。
0	这本书实在是太烂了,以前听浙大的老师说这本书怎么怎么不对,哪些
1	地理位置佳，在市中心。酒店服务好、早餐品种丰富。我住的商务数
1	5.1期间在这住的，位置还可以，在市委市政府附近，要去商业区和
0	我看过朋友的还可以，但是我订的书迟迟未到已有半个月，都没有收
1	还不错，设施稍微有点旧但是可以接收，但是606的价格还不含早餐
1	轻便，方便携带，性能也不错，能满足平时的工作需要，对出差人员
1	入住的是度假区的豪华海景房,前台给了5楼(最高6楼),然后差不多1
0	1.模具有摄像头的位置，但是没有摄像头。 2.做工一般。 3.说明书
0	送的内胆包有点不好，还有外接电源中间连接处无法全部插入。续航
1	这是我第1次给全五星哦^_^超级快!这是最快收到书的一次了.我是中

图 2 ChnSentiCorp 训练数据示例图

图 2 展示了训练集数据格式，表头 label 代表标签，text_a 代表评论文本。每条记录单独成一行，其中数据标签用 0 代表正向、用 1 代表负向。所有评论均标注为正面或负面情感。

4.2 实验结果

4.2.1 Scikit-learn 与 BERT 模型对比

表 1 结果表明，用 Scikit-learn 训练的 SVM 模型在实验中表现最佳，准确率达到 91.8%；BERT 在多个指标上表现最佳，准确率 95.00%，优于 Scikit-learn 的 SVM（91.8%）和逻辑回归（89.6%）。模型的准确率、精确率、召回率和 F1 分数均较高，说明模型在区分正例和反例方面表现良好，误判率较低。

表 1 Scikit-learn 与 BERT 算法比较表

算法	准确率	精确率	召回率	F1 分数
逻辑回归	89.6%	88.9%	88.9%	88.9%
SVM	91.8%	91.9%	91.8%	91.8%
随机森林	90.5%	90.7%	90.6%	90.6%
BERT	95.00%	94.25%	93.75%	95.00%

4.2.2 Spark MLlib 与 BERT 模型对比

表 2 总结了 Spark MLlib 三种机器学习算法的训练和预测结果在精度评估方面，BERT 表现最佳，在 Spark 环境中逻辑回归准确率 89.6%优于 SVM。Spark MLlib 提供的算法训练模型，逻辑回归的准确率最高，其次是 SVM。

表 2 Spark MLlib 与 BERT 算法比较表

算法	准确率	精确率	召回率	F1 分数
逻辑回归	89.6%	89.6%	89.6%	89.6%
SVM	89.3%	89.3%	89.3%	89.3%
随机森林	79.1%	79.1%	79.1%	79.1%
BERT	95.00%	94.25%	93.75%	95.00%

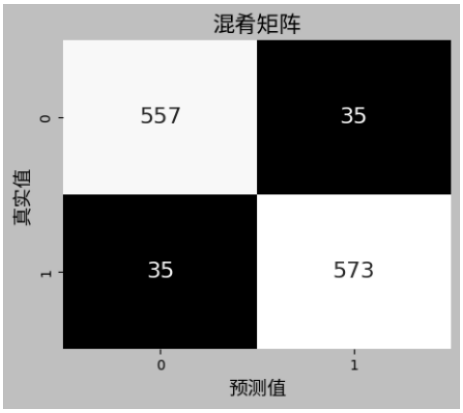

图 3 BERT 混淆矩阵图

从表 2 与图 3 可以看出，BERT 型在整体上做出了正确的预测。在所有被预测为正例的样本中，有 95%是真正的正例，误报较少；在所有实际为正例的样本中，有 93.75%被成功识别出来，漏报较少；

中国知网 https://www.cnki.net

F1 分数为 95%。

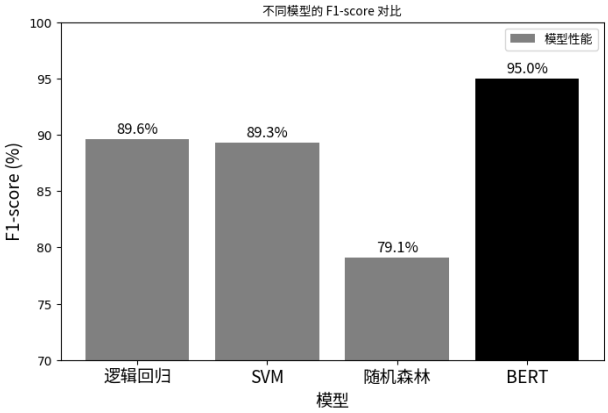

图 4　Spark MLlib 算法与 BERT F1-score 比较图

从图 4 可以看出，Spark MLlb 算法与 BERT 相比，BERT 模型最优，逻辑回归模型次之。

4.2.3 BERT 训练过程分析

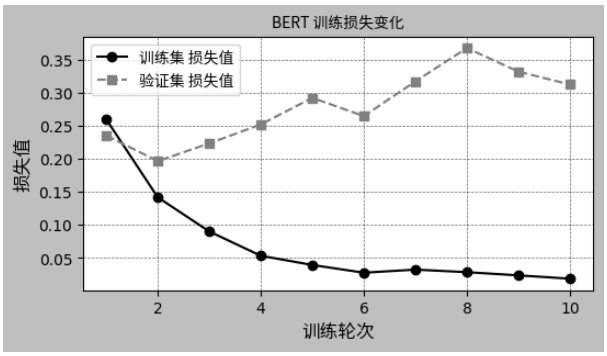

图 5　BERT 训练集训练与验证集损值失变化图

从图 5 可以看出，BERT 模型在训练过程中表现出一定程度的过拟合，训练损失 0.2596 降到 0.0189 持续下降，而验证损失值在第 2 轮降至最低 0.1965，随后逐步上升到 0.3673，表明模型在训练集上拟合较好，在验证集上表现有所下降。

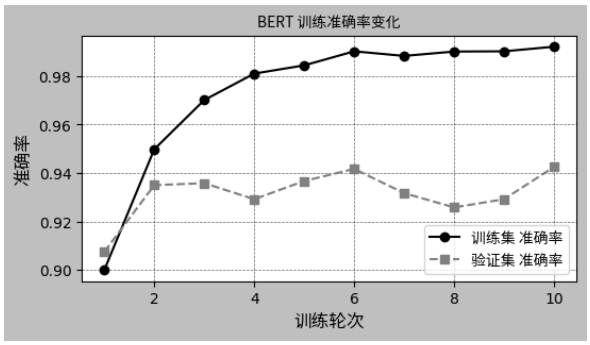

图 6　BERT 训练集与验证集准确率变化图

从图 6 可以看出，训练在第 6 轮精确率高达 99.21%，接近 100%，而验证精确率达到最高 94.25%，随后略有波动。

为了防止过拟合，采用逐步降低学习率的方法；同时验证损失值连续 3 轮不下降，进一步降低学习率至最小值 10^{-5}，并增加训练轮数、Dropout 和 L2 正则化来抑制过拟合。Dropout 是一种正则化技术，用于防止神经网络过拟合。在每轮训练过程中，随机“关闭”20%的神经元，使模型更具鲁棒性并提高其泛化能力，保证模型精度的同时，提高对预测数据的适应性。

为验证 Bert 模型 Dropout 和 L2 正则化对模型精度的影响，设定种 Dropout 比率{0.1，0.3，0.5}、L2 参数{0.0，0.01，0.1}共九种组合，每个组合训练 3 轮 Bert 模型。结果显示：在 Dropout=0.1 时，L2 权重对准确率几乎没有影响；在 Dropout=0.5 时，适当增加 L2 权重（如从 0.0 提升到 0.01 或 0.1）可显著提升准确率。推荐使用 Dropout=0.1 搭配任意 L2（尤其是 0.01），获得稳定且最高的验证准确率。如果 Dropout 比例必须提高，应适当提升 L2 正则强度以弥补 Dropout 带来的信息丢失。

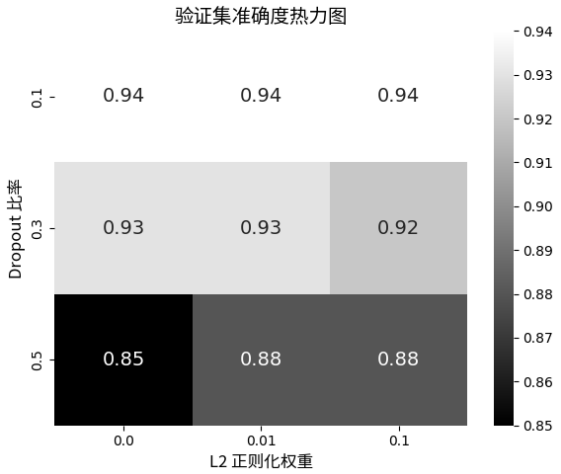

图 7　BERT 模型 Dropout 与 L2 参数影响图

4.3 计算效率分析

在实验中，记录了每个阶段的耗时，用来分析不同算法的运行效率。使用 Scikit-learn 的逻辑回归、SVM、随机森林 3 个算法训练模型效率最高。随机森林在 spark 单机系统效率最差。由于 Kaggle 平台限制运行内存，Spark MLlib 随机森林算法耗时最长。BERT 训练模型耗时较长，但预测环节，BERT 处理 1200 条评论需要 90 秒，用时很短，但这是在有 2 块 GPU 支持下，整体表现能

中国知网　https://www.cnki.net

满足实验需求，说明系统在中等规模数据集上时间效率还是比较理想的。如果数据量比较小，可以考虑直接使用 Scikit-learn SVM 算法训练模型，只有在数据规模超大时才使用分布式计算集群，以降低模型精度位代价换取效率的提升。

表 3 各算法训练时间表

方法	训练时间
Scikit-learn	5 分 40 秒
Spark SVM+逻辑回归	16 分 5 秒
Spark 随机森林	62 分 29 秒
BERT	45 分 29 秒

4.4 系统扩展性

由于本次实验的数据量较小，系统在 Kaggle 环境下运行稳定，且能在合理时间内完成模型训练与预测。未来研究中，引入真实的分布式计算集群并且借助 GPU 加速技术，或者使用云服务器集群以提升训练和预测的处理速度，从而增强系统的适应能力。

5 结语

本文分别采用 Scikit-learn、Spark MLlib 以及 BERT 设计与实现了中文文本情感分析系统。具体地，使用逻辑回归、SVM 和随机森林三种传统机器学习算法、引入基于深度学习的 BERT 模型训练和测试中文文本情感分析模型，实现了一个中文文本情感分析系统。结果显示，BERT 模型在测试集上的表现最为优异，取得了 94.25%的精确率、93.75%的召回率，以及 95%的 F1 分数，显著超越了其他三种传统方法。在传统机器学习方法中，使用 scikit-learn 工具包训练的 SVM 模型表现性能最佳，且训练时间最短。值得注意的是，即使是相同的算法，在 scikit-learn 和 Spark MLlib 中也会有性能差异。特别是训练较深的随机森林模型时，内存需求会显著增加，这与 Spark 的分布式计算开销及 Kaggle 平台的内存限制有关。为应对传统单机环境下的 BERT 模型训练时面临显著的计算和内存瓶颈，可采用基于 Spark 与 BERT 结合的分布式文本处理与模型训练架构，旨在提升数据预处理效率与训练可扩展性。在数据预处理阶段，采用 Spark 对原始文本数据进行分词、去除停用词及标签提取等操作。利用 Spark 分布式机制提升数据加载与清洗速度、减少了 I/O 等待时间。在模型训练阶段集成 Uber 开发的 Horovod 开源分布式训练框架。通过 Spark 任务调度机制，将训练任务分配至各个节点，同时同步各节点的梯度参数，保持模型训练一致性。在此基础上对每轮训练的样本数量学习率进行微调，确保模型在多节点条件下仍能稳定收敛。该优化方案可充分发挥 Spark 在数据处理方面的并行能力，并有效融合了 BERT 在深度语义理解方面的优势，具有良好的实用性与可扩展性。

本研究的主要贡献在于首次对 Spark MLlib、Scikit-learn 和 BERT 在中文文本情感分析任务中的计算效率和性能进行了综合对比分析，验证了在 Spark 平台进行中文文本情感分析是可行的，为未来在大规模数据环境下选择合适的情感分析方法、实现高效的实时情感分析任务提供了参考。

参 考 文 献

[1] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in python. Journal of Machine Learning Research, 2011, 12(1): 2825-2830

[2] Balazs M, Szabo Z. A large-scale sentiment data classification for online reviews under Apache Spark. Procedia Computer Science, 2016(80):71-79

[3] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, USA, 2019:4171-4186

[4] 杨立月,王移芝.Spark 在集成学习文本情感分析中的应用.计算机应用与软件,2020,37(06):130-134

[5] Gunasekaran K P. Exploring sentiment analysis techniques in natural language processing: A comprehensive review. arXiv, 2023. Available: https://arxiv.org/abs/2305.14842

[6] 王泽辰,王树鹏,孙立远,等.基于情感对象识别和情感规则的微博倾向性分析.北京航空航天大学学报,2022,48(02):301-310

[7] 禹宁,谷良,狄婷.基于深度学习的网络攻击检测模型.火力与指挥控制,2023,48(05):66-74

[8] 郭小磊,张吴波.基于短文本扩展和特征融合的市民热线文本分类.山西大同大学学报(自然科学版),2024,40(01):42-47

[9] 钱晨嗣,夏寒,夏天,等.基于机器学习的公共卫生数据可靠性评估系统的研究与设计.中国卫生资源,2023,26(03):244-248

[10] 梁礼明,董信,何安军,等.融合注意力线性特征多样化的DR分级模型.光电子·激光, 2024,35(06):612-622

中国知网 https://www.cnki.net