DOI：10.16661/j.cnki.1672-3791.2404-5042-7336

基于Python数据采集分析的实时监控系统的开发与应用

张竖群　朱志苹　韦金培
广东农工商职业技术学院　广东广州　510507

摘　要：主要围绕基于实时采集分析监控系统实现对B/S架构的管理系统进行分析与监控，以保障企事业单位管理系统的高可用性，并降低系统巡检监控所产生的人力成本。同时，在管理系统出现问题时，实时采集分析监控系统可以为技术人员提供数据追溯查询，以便于定位和解决问题，减少处理问题的时间，提高解决问题的效率。

关键词：数据采集分析　监控系统　数据可视化　监测预警

中图分类号：TP312.1;TP274.2　　**文献标识码：**A　　**文章编号：**1672-3791(2024)20-0075-03

Development and Application of Real-Time Monitoring System Based on Python Data Collection and Analysis

ZHANG Shuqun　ZHU Zhiping　WEI Jinpei
Guangdong AIB Polytechnic, Guangzhou, Guangdong Province, 510507 China

Abstract: This article mainly focuses on the implementation of real-time data collection, analysis, and monitoring of B/S architecture-based application management systems. The system aims to ensure high availability of the application management systems in enterprises and institutions, while can also reduce the labor costs associated with routine inspections and monitoring of application systems. Additionally, the real-time data collection, analysis, and monitoring system can provide technical personnel with data tracing and querying capabilities in the event of any issues with the application management system, enabling them to quickly locate and resolve problems, thereby reducing the time required to address issues and improving the efficiency of problem-solving.

Keywords: Data cololection and analysis; Monitoring system; Data visualization; Monitoring and early warning

近年来，我国境内被攻击的网站数量急剧上升，其中，中小型企业被攻击的比例更是呈现逐年增长的趋势，教育机构类的网站被攻击的概率也相应增加。分析统计显示，黑客攻击的主要方式为DdoS攻击，这就导致企业和教育机构类网站不胜负荷，以至于瘫痪而无法提供正常的网络服务。除了人为主动攻击、破坏之外，大部分系统运行过程中也无法避免出现资源超载、内存溢出和网络中断等问题。一旦出现应用无法访问的情况，如果没有安装应用监控软件，很难及时发现情况并予以解决，从而导致业务无法正常处理，影响企业单位的正常运转。根据这一现象，市面上相继出现了各种应用安全监控预警平台，但是，其性价比往往偏低，一个普通的安全产品要十几万，所以，大部分企业通常采取人工定时巡检。为了解决这个问题，本文主要阐述实时采集分析监控系统，以低成本、高效率的方式实现Web应用的实时监测，确保Web应用的稳定

作者简介：张竖群（1989—），男，本科，实验师，研究方向为软件工程。
朱志苹（1992—），女，本科，研究方向为计算机网络。
韦金培（1996—），男，本科，研究方向为软件工程。

中国知网 https://www.cnki.net

运行，为技术人员提供数据追溯查询，以便于定位和解决问题，减少处理问题的时间，提高解决问题的效率。

1 实时监控系统的技术要点

1.1 基于Scrapy实现高精准度的采集匹配

针对主流B/S架构的应用管理系统，采集、分析、统计其公共特性，建立公共标识资源库，再根据标识资源库，结合Scrapy研发其采集匹配规则，最终实现高精准度匹配，提高采集数据质量。采用Scrapy实现数据采集的原因有以下几个方面。

1.1.1 Scrapy有较高精准度的选择器

Scrapy通常使用XPath或CSS选择器来定位和提取网页中的相关数据。同时，要做到精确地抓准，需要对目标网页的HTML结构进行深入分析，编写针对特定元素或属性的选择器，以准确地抓取所需数据。

1.1.2 Scrapy有处理动态内容的优势

现在的主流网页通常包含动态加载的网页内容，在加载网页时，HTML响应中没有返回数据字段，这就导致采集的数据缺失，或无法采集到相应的内容[1]。但是，可以通过Scrapy并配合Selenium等浏览器自动化工具模拟用户操作，等待动态内容加载完成后再进行抓取。

1.1.3 Scrapy有处理反爬虫机制

现如今，较多网站为了保护数据和网页的访问速度，会设置反爬虫机制，如限制访问频率、设置验证码校验等功能。通过Scrapy中间件，可以方便地添加代理、设置请求头、处理cookies等，从而绕过这些反爬虫机制，同时也可以灵活配置爬虫的访问频率和重试策略，避免对目标网站造成过大的压力。

1.1.4 Scrapy有较强的数据清洗和验证功能

Scrapy提供了实体管道（Item Pipeline）组件，用于对抓取的数据进行清洗和验证。通过编写自定义的管道，可以高效地去除无关数据、处理缺失值、转换数据类型等，从而确保数据的准确性和一致性。

1.1.5 Scrapy有增量抓取和去重功能

为了实现较高精准度的网页采集，通常需要对数据进行定时增量更新，从而避免重复抓取[1]。Scrapy可以通过记录已抓取数据的唯一标识（如URL、唯一ID等），在每次抓取时与已有数据进行比较，只抓取新增或更新的数据。

1.1.6 Scrapy有较强自定义扩展和插件

Scrapy具有较强的可扩展性，用户可以编写自定义的扩展和插件，以满足用户的特定采集需求。例如：用户可以编写自定义的中间件来处理特定类型的网页或数据，或编写自定义的爬虫来适应不同网站的抓取规则。

1.2 基于Pandas提升数据处理分析效率

基于Pandas扩展程序库对所采集的数据实现高效率的处理、统计和分析的方法，制订对采集的多种类型的数据格式进行过滤、汇总的应对方案，并根据不同的数据集制订不同的处理方法，最终实现高效率的数据分析能力。Pandas的优点如下。

1.2.1 高效性能

Pandas构建在NumPy之上，充分运用了NumPy的高效数组运算能力[2]，可以对大规模数据进行快速处理和计算。其内置的数据结构（如Series和DataFrame）设计巧妙，内存使用率较高，对大型表格数据的处理更加高效。

1.2.2 灵活的数据结构

DataFrame是Pandas的核心数据结构[2]，类似电子表格或SQL表，能较灵活地处理异构数据，并且支持行索引和列标签，对多维度数据的查询和分析更加直观。同时，Pandas序列是一维带标签的数组，对单列数据存储更加高效。

1.2.3 易用性与功能性

Pandas提供了丰富的API，可以使数据清洗、转化、合并、重塑、筛选、分组、聚合等操作变得非常简便[2]，同时也支持SQL风格的查询操作，能通过布尔索引实现复杂条件下的数据选取。

1.2.4 兼容性强

Pandas能够无缝集成其他Python库，例如：Matplotlib用于数据可视化，Statsmodels和Scikit-learn进行统计建模和机器学习，以及与SQL数据库交互等[3]。同时，其支持多种数据格式的读写，包括CSV、Excel、SQL数据库、HDF5、Parquet等，极大地提高了数据输入、输出效率。

1.2.5 时间序列功能

Pandas内置了很多类和函数，能便捷地对时间序列数据和各种频率的时间序列数据进行处理，如日期/时间的相关操作、重采样、窗口函数计算等功能。

1.3 通过Matplotlib组件展示多维度数据视图

结合Matplotlib绘图库，对采集分析的数据集合进行多维度优化展示[4]。同时，制定不同业务场景下对不同数据类型自定义生成数据视图图层，最终实现可配置化且直观的多维度数据图表。采用Matplotlib展

中国知网 https://www.cnki.net

示多维度数据视图的原因如下。

1.3.1 Matplotlib有强大的绘图功能

Matplotlib支持绘制各种静态、动态、交互式的可视化图表，包括柱状图、饼图、线图、散点图、等高线图、3D图形等[4]。同时，Matplotlib支持定制图表中的每一个细节，如坐标轴标签、图例、颜色、字体等。

1.3.2 Matplotlib易于集成

Matplotlib对Python的其他库（如Pandas、NumPy等）[4]的集成非常简便，从而使数据处理和可视化的流程的使用更加的顺畅。

1.3.3 Matplotlib提供了丰富的扩展库

Matplotlib提供了许多扩展库，如Seaborn、Plotly等，这些库在Matplotlib的基础上提供了更多的绘图功能和更美观的图表样式，使数据可视化变得更加简单和直观。

1.3.4 Matplotlib交互性较强

Matplotlib支持交互式绘图，用户可以通过鼠标对图表进行缩放、平移、选择等操作，这在探索数据和调试图表时非常有用。

2 实时监控系统的主要功能模块介绍

通过上述内容，为确保实时采集分析监控系统的高可用性，其系统包括以下4个功能模块：数据定时采集匹配、数据比较分析、数据可视化、监控预警。其主要功能模块图如图1所示。

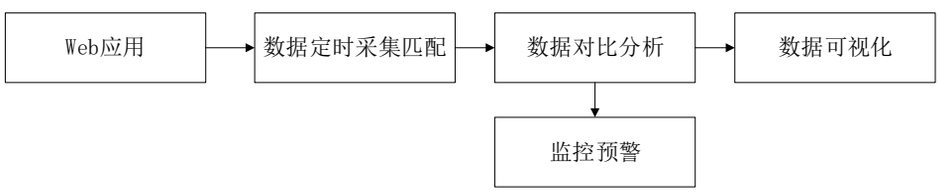

图1 实时监控系统的主要功能模块图

数据定时采集匹配模块的主要功能是通过设定特定的执行时间，在指定时间自动启动并采集目标网站或数据源的信息[5]，同时，结合requests实现发送HTTP请求和解析HTML页面，从而实现对网站数据的抓取和提取，并将采集的数据存储到指定的数据库中，以便后续分析和处理。其工作基本流程为：定时进行爬取B/S架构的应用数据，并对数据进行结构化解析，最后再存入数据库中，为后续数据分析提供数据基础。

数据对比分析模块的主要功能是对采集的数据进行处理分析，以判断管理系统当前所处的状态。其功能模块主要运用Scrapy对网页数据的标识字段进行定时采集，并存入数据库[6]，再运用Pandas对采集的数据标识进行分析和对比数据特征库，从而判断当前网页的所处状态。同时，此模块也实现不同数据集的对比或同一数据集内不同部分之间的差异比较。

数据可视化模块的主要功能是对采集的数据进行加工美化展示，用户能够通过图表的方式更直观地查看到应用的运行情况和对不同时期的数据进行对比，把纯数字和文字的表述转换成直观的数据图形，以为用户后续的排错、找问题提供指引。

监控预警模块的主要功能是基于数据比较分析模块的分析结果，提供用户简便的自定义监控预警功能，如用户短信的绑定和邮箱的绑定两个功能，并且用户可以定制个性化的推送提醒方案，通过方案，用户可以根据不同的预警级别绑定不一样的预警提示。

3 结语

当Web应用出现宕机或异常时，通过实时监控系统对网页进行采集、分析、对比，能及时提醒用户Web应用的当前状态，从而保障了企事业单位的Web应用的安全性和可用性，减少了应用系统巡检监控所产生的人力成本。同时，实时监控系统也可以在应用管理系统出现问题时为技术人员提供数据追溯查询，以便快速排查、解决问题，减少处理问题的时间，提高解决问题的效率。

参考文献

[1] 张楠.基于Python的房产信息网站数据采集策略分析[J].集成电路应用,2024,41(1):344-346.
[2] 郭瑾.基于Python的招聘数据爬取与数据可视化分析研究[J].轻工科技,2024,40(2):94-96,99.
[3] 王纪才,徐启南,袁霄翔.基于Python爬虫的电影数据可视化分析[J].周口师范学院学报,2023,40(5):60-65.
[4] 谢文法,张乐天,刘士浩.Python可视化技术在电动力学教学中的应用[J].物理与工程,2024,34(1):92-96.
[5] 余战秋.Python数据采集软件的设计与应用[J].电子技术,2023,52(7):307-309.
[6] 蔡文乐,秦立静.基于Python爬虫的招聘数据可视化分析[J].物联网技术,2024,14(1):102-105.

中国知网 https://www.cnki.net