基于Scrapy和Selenium框架的期刊数据爬取与分析研究

姜庆玲，张樊，蔡静，张孙德，周豪
（武昌工学院，武汉 430065）

摘　要：在大数据时代和产教融合背景下，如何快速获取海量的期刊数据并分析得到关键信息，是一个值得研究的论题。国内外学者在期刊网站数据爬取方面的研究较少，且使用的技术实现起来较为麻烦。项目采用Scrapy和Selenium框架，结合Matplotlib技术，实现了快速获取期刊数据并图形化显示期刊关键信息。实验结果表明，该方法代码量少、思路清晰、简单易学、结果正确，具有一定的实用性。

关键词：Scrapy框架；Selenium框架；期刊数据爬取
DOI:10.16184/j.cnki.comprg.2025.08.016

1　概述

随着大数据时代的到来，人们获取数据的范围越来越广，知识也越来越新，作为高等教育工作者，产教研融合是立身之本。获取最新知识、学习先进技术、发表研究成果在大数据背景下要求会更高，而这三方面都和学术期刊网站数据的研究密不可分。无论是在海量学术期刊中查找合适的学术论文，还是在海量的学术期刊中筛选合适的期刊进行投稿，都需要花大量的时间去分析和处理。因此，寻找一种快速对海量的学术期刊数据进行分析的方法很有必要。

现阶段，国内基于爬虫框架对学术期刊数据分析的研究较少，近5年成果[1-6]大多侧重于针对某一学科的大量文献进行分析后得出的研究策略或研究述评等。国外对爬虫框架的研究较多，针对网络数据挖掘、社交网络分析、舆情监控等研究，开发了许多优秀的Python爬虫框架，例如Murugudu等[7]和Deng等[8]分别提出了自适应学习的爬虫框架和基于Scrapy框架的网络爬虫系统优化研究等，这些框架大大简化了爬虫的开发过程，提高了爬虫的效率和稳定性，但对于国内学术期刊数据的分析几乎空白，这和跨域资源的获取较难有很大关系。

根据国内外已有的研究成果发现，使用Scrapy和Selenium框架进行学术期刊数据分析的研究成果较少，结合现阶段的研究背景，项目的研究内容有一定意义，且可行性较高。

2　相关技术

2.1　Scrapy爬虫框架

Scrapy框架是一个基于Python语言的快速且高级的网页信息爬取框架，用于从网页中提取结构化数据，它还可以用于数据挖掘、数据监控和自动化测试。目前，关于Scrapy爬虫框架的应用非常广泛，例如，爬取图书网站[4]、招聘网站[5]、新闻网等各大网站信息的应用近两年的成果很多。

Scrapy框架的使用步骤主要分为创建项目、创建爬虫程序、编写爬虫程序、运行爬虫程序并保存数据4个步骤。

2.2　Selenium框架

Selenium框架是一个用于Web应用程序自动化测试的工具，模拟用户操作，让浏览器感觉就像真正的用户在操作一样。其主要功能包括测试与浏览器的兼容性，测试软件功能和用户需求，支持自动录制和自动生成.Net、Java、Perl等不同语言的测试脚本。

现阶段，针对Selenium框架的研究集中于自动爬取[6]。大部分期刊网站在使用Scrapy爬虫时会被拒绝访问，因此需要融入Selenium框架模拟真实用户操作，实现自动翻页爬取数据。

2.3　Matplotlib技术

Matplotlib是Python语言的一个创建静态、动态和交互式可视化图形的扩展库，它以各种硬复制格式和跨平台的交互式环境生成出版质量级别的图形，可以生成折线图、散点图、条形图等十多种图形。通过图像可以更加清晰且直观地展示数据，从而有利于数据分析。

3　实现思路

根据采用的Scrapy框架、Selenium框架和Matplotlib技术，为实现快速获取期刊数据并分析得到关键信息，拟定实现步骤如下。

（1）确定学术期刊网站。

（2）分析所选网站的数据展示特点和用户操作特点，在学术期刊网站上获取期刊数据时大多会以主题形

基金项目：基于Scrapy爬虫框架的学术期刊数据爬取与分析应用研究（2024KY12）；武昌工学院2024年度校级科学研究项目。

作者简介：姜庆玲（1991—），女，讲师，教师，研究方向为计算机基础应用。

中国知网 https://www.cnki.net

式查询，数据多以翻页形式显示，项目以爬取网站中主题为“Python”和“Selenium”的期刊数据为例。

（3）根据网站的特点，使用Scrapy和Selenium框架爬取关键数据，并保存为本地文件。

（4）分析获取的期刊数据，使用Matplotlib图形化展示用户所需的关键信息。

4 具体实现

项目在Windows 10操作系统下，使用Python 3.7环境和PyCharm 2019进行程序编写，并已安装Scrapy、Selenium、Matplotlib等第三方包。下面介绍项目的主要实现过程。

4.1 创建Scrapy项目

在一个空文件夹下打开终端，使用如下命令创建项目。

```
scrapy startproject Project
```

运行后会产生一个名为Project的文件夹，其下的spiders文件夹包含爬虫主程序文件，需要另外创建；_init_.py是初始化文件；items.py用于定义爬取数据的结构；middlewares.py负责定义中间件，可以插入Scrapy的请求/响应处理流程；pipelines.py用于接收并处理爬取的数据；settings.py是项目的配置文件，可自定义爬虫行为；scrapy.cfg是全局配置文件。

4.2 创建爬虫程序

在项目Project文件夹下创建爬虫程序，需要设置爬虫名称和爬取网站的域名，故使用命令如下。

```
cd Project
scrapy genspider Journal kns.cnki.net
```

运行后，即可生成爬虫程序Journal.py文件。

4.3 编写并运行爬虫程序

（1）在爬虫主程序中应设置start_urls为爬取的页面路径和parse()方法。文中以爬取学术期刊网站中主题为“Python”和“Selenium”的期刊数据为例，一共有121条数据，分为7页显示。因为需要模拟用户操作浏览器的行为，故使用Selenium框架自动翻页爬取界面，在Journal.py中编写关键代码如下。

```
def parse(self, response):
driver = webdriver.Chrome()
  driver.get(response.url)
  while True:
    WebDriverWait(driver,10).until(EC.presence_of_element_located((By.ID, ´briefBox´)))
content = driver.page_source
      try:
            next_button = self.driver.find_element(By.XPATH, ´//a[@id="PageNext"]´)
            next_button.click()
      except NoSuchElementException:
            print("已经是最后一页")
            break
```

（2）使用BeautifulSoup抓取页面数据，并将数据保存为result.csv文件，在Journal.py中添加关键代码如下。

```
def parse(self, response):
trList = []
    soup = BeautifulSoup(content, ´html.parser´)
  trs = soup.find_all(´tr´)
  for tr in trs:
    if tr.find(´td´):
      self.trList.append({"序号": tr.find(´td´, class_=´seq´).text,
                    …  #八项数据的获取代码类似
                    })
 with open(´result.csv´, ´w´, newline=´´) as csvfile:
    writer = csv.DictWriter(csvfile, fieldnames=[´序号´,´题名´,´作者´,"来源","发表时间","数据库","被引","下载"])
    writer.writeheader()
    for k in self.trList:
      writer.writerow(k)
```

（3）在控制台运行scrapy crawl Journal命令，将爬取的期刊数据保存在result.csv文件中，如图1所示。

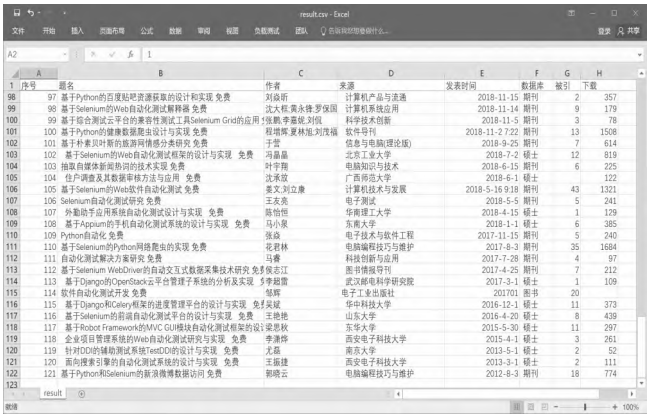

序号	题名	作者	来源	发表时间	数据库	被引	下载
97	基于Python的百度贴吧资源获取的设计和实现 免费	刘焱昕	计算机产品与流通	2018-11-15	期刊	2	357
98	基于Selenium的Web自动化测试解释器 免费	沈大权;黄永锋;罗保国	计算机系统应用	2018-11-14	期刊	9	179
99	基于综合测试云平台的兼容性测试工具Selenium Grid的应用	张鹏;李嘉锐;刘恺	科学技术创新	2018-11-5	期刊	3	78
100	基于Python的健康数据爬虫设计与实现 免费	程增辉;夏林旭;刘茂福	软件导刊	2018-11-2 7:22	期刊	13	1508
101	基于朴素贝叶斯的旅游网情感分类研究 免费	于雪	信息与电脑(理论版)	2018-9-25	期刊	7	614
102	基于Selenium的Web自动化测试框架的设计与实现 免费	冯晶晶	北京工业大学	2018-7-2	硕士	12	819
103	抽取自媒体新闻热词的技术实现 免费	叶宇翔	电脑知识与技术	2018-6-15	期刊	6	225
104	住户调查及其数据审核方法与应用 免费	沈承欣	广西师范大学	2018-6-1	硕士		122
105	基于Selenium的Web软件自动化测试 免费	姜文;刘立康	计算机技术与发展	2018-5-16 9:18	期刊	43	1321
106	Selenium自动化测试研究 免费	王友亮	电子测试	2018-5-5	期刊	5	241
107	外勤助手应用系统自动化测试设计与实现 免费	陈怡恒	华南理工大学	2018-4-15	硕士	1	129
108	基于Appium的手机自动化测试系统的设计与实现 免费	马小泉	东南大学	2018-1-1	硕士	6	385
109	Python自动化 免费	张焱	电子技术与软件工程	2017-11-15	期刊	5	240
110	基于Selenium的Python网络爬虫的实现 免费	花君林	电脑编程技巧与维护	2017-8-3	期刊	35	1684
111	自动化测试解决方案研究 免费	马睿	科技创新与应用	2017-7-28	期刊	4	97
112	基于Selenium WebDriver的自动交互式数据采集技术研究 免费	陈金江	图书情报导刊	2017-4-25	期刊	7	212
113	基于Django的OpenStack云平台管理子系统的分析及实现 免费	李超雷	武汉邮电科学研究院	2017-3-1	硕士	1	109
114	软件自动化测试开发 免费	邹辉	电子工业出版社	2017-01	图书	20	
115	基于Django和Celery框架的进度管理平台的设计与实现 免费	吴斌	华中科技大学	2016-12-1	硕士	11	373
116	基于Selenium的前端自动化测试平台的设计与实现 免费	王艳艳	山东大学	2016-4-20	硕士	8	439
117	基于Robot Framework的MVC GUI模块自动化测试框架的设	梁思敏	东华大学	2015-5-30	硕士	11	297
118	企业项目管理系统的Web自动化测试研究与实现 免费	李潇辉	西安电子科技大学	2015-4-1	硕士	3	261
119	针对DDI的辅助测试系统TestDDI的设计与实现 免费	尤磊	南京大学	2013-5-1	硕士	2	52
120	面向搜索引擎的自动化测试系统的设计与实现 免费	王振捷	西安电子科技大学	2013-3-1	硕士	2	111
121	基于Python和Selenium的新浪微博数据访问 免费	郭晓云	电脑编程技巧与维护	2012-8-3	期刊	18	774

图1 爬取的期刊数据

4.4 数据分析

（1）以分析期刊来源排行为例，将图1中数据进行分类统计，新建rank.py文件，关键代码如下。

```
with open(filename, ´r´) as csvfile:
  reader = csv.DictReader(csvfile)
  for row in reader:
    jname = row[´来源´]
    if jname in jname_count:
```


中国知网 https://www.cnki.net

```
        jname_count[jname] += 1
    else:
        jname_count[jname] = 1
```

（2）将统计后的数据进行倒序排序，代码如下。

```
sorted(jname_count. items(), key=lambda item: item [1], reverse=True)
```

4.5 使用Matplotlib展示结果

在数据分析后，使用横向条形图展示期刊来源排行结果，在rank.py文件中添加代码如下。

```
plt.ylabel('期刊名称')
plt.xlabel('录用数量')
plt.title('期刊来源排行榜')
plt.tight_layout()
plt.show()
```

期刊排行前八的结果，如图2所示。

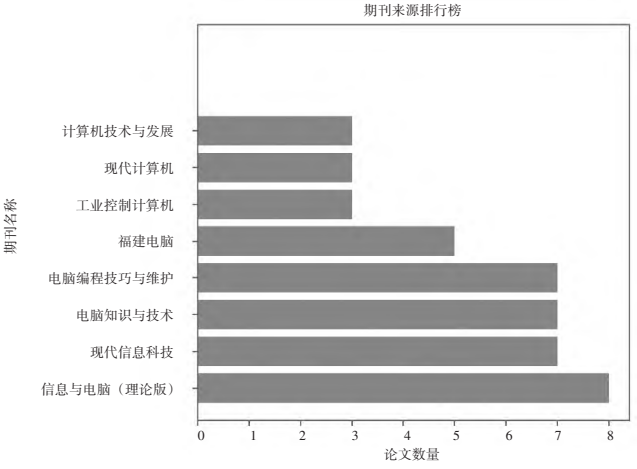

图2 期刊来源排行榜

5 结果分析

由图2可知，“信息与电脑（理论版）”排名第一，论文数量为8，说明网站中以“Python”和“Selenium”为主题的文章有8篇被《信息与电脑(理论版)》期刊录用发表。因此，该排行榜可以帮助用户确定该类论文可投稿的期刊，以提高录用率。

文中获取的数据除了分析期刊来源，还可以用于分析更多的内容，例如，分析该类主题研究最多的作者、被引用量最多的期刊或论文、年份最近的期刊排行或引用排行等信息。因此，项目可以根据用户的各类需求，快速获取关键信息。

6 结语

项目通过分析国内外近5年在期刊数据方面的研究成果发现，寻找一种快速对海量期刊数据进行分析的方法有一定的必要性。采用Scrapy爬虫框架、Selenium框架和Matplotlib图形化展示技术，以爬取网站上主题为“Python”和“Selenium”的期刊数据为例，分析并图形化展示发表该主题论文前八的期刊，实验结果能够帮助用户快速确定投稿期刊，并且利用爬取的数据还可以进行更多方面的研究，为用户进行下一步研究奠定基础。

参考文献

[1] 吴嘉兴，王玉龙，孙美凤．面向科研统计的机构发表论文数据的爬取：以知网为例[J]. 软件，2022，43(12)：31-35.

[2] 奥丽雅．数字出版研究热点的文献计量分析：基于中国知网学术期刊论文数据[J]. 中国传媒科技，2023(1)：136-139.

[3] 陈思彤，那春光．辽宁省高校图书馆20年科研产出多维分析：基于学术期刊论文发表数据的实证研究[J]. 图书馆学刊，2023，45(4)：21-27.

[4] 吕新超．Scrapy框架辅助下的Python爬虫系统研究[J]. 电脑知识与技术，2024，20(7)：49-52.

[5] 郑志建，俞发仁，魏晓微，等．基于Python的职位网站爬取设计与实现[J]. 计算机与网络，2024，50(1)：24-27.

[6] 刘志鹏，陈琦，许超焕，等．基于Selenium的课程评论自动爬取软件设计与实现[J]. 电脑编程技巧与维护，2024(6)：19-22.

[7] MURUGUDU M R,R L S S. Efficiently harvesting deep web interfaces based on adaptive learning using two-phase data crawler framework [J]. Soft Computing: A Fusion of Foundations, Methodologies and Applications, 2023, 27(1): 505-515.

[8] DENG K, CHEN S, DENG J. On optimisation of web crawler system on Scrapy framework [J].International Journal of Wireless and Mobile Computing: IJWMC,2020, 18(4): 332-338.

中国知网 https://www.cnki.net