基于 Scrapy 的农业网络信息采集技术

李　金，费　晶，张　玲
（榆林学院　图书馆，陕西　榆林　719000）

摘　要：在信息化时代背景下，互联网已成为信息传播与交流的重要平台，尤其是在农业领域，网络信息的快速获取与有效利用对于推动农业现代化、促进农业科技发展具有不可估量的价值。农业网络信息不仅涵盖政策法规、市场动态、技术革新等多个方面，还直接关乎农民的生产决策、农产品的销售，以及农业产业链的整合与优化。基于此，该文对基于Scrapy 的农业网络信息采集技术进行了深入探究，旨在高效、准确地从海量网络资源中采集并筛选出有价值的农业信息，为农业领域的发展提供助力。

关键词：Scrapy；农业网络信息；信息采集；网络爬虫
中图分类号：TP274　　**文献标识码：**A
文章编号：2096-0743（2025）01-0096-03　　DOI:10.20264/j.cnki.rse.2025.01.034

0　引言

Scrapy 作为强大的开源网络爬虫框架，以其高度的灵活性、可扩展性和易用性，在数据采集领域占据着举足轻重的地位，不仅能够快速构建定制化的爬虫项目，还支持大规模并发请求处理、数据解析、存储及后续的数据分析，为农业网络信息的精准采集提供了有力的技术支撑。因此，需要充分利用该工具，解决传统信息采集过程中存在的效率低下、信息不全、更新滞后等问题，进而构建高效、智能化的农业网络信息采集系统，为农业生产者、研究者及决策者提供更加丰富、精准的信息资源，助力我国农业实现可持续发展。

1　Scrapy 技术简要分析

Scrapy 是快速、高层次的屏幕抓取和Web 抓取框架，使用Python 编写，并基于Twisted 异步网络库来处理网络通信。Scrapy 的设计旨在简化网络爬虫的开发过程，提供一套完整的组件和工具，使开发人员能够轻松构建大规模、可扩展的爬虫项目，不论是数据采集、数据挖掘、搜索引擎优化还是历史存档，Scrapy 都能提供强大的支持。

Scrapy 由多个核心组件组成，包括引擎、调度器、下载器、爬虫、项目管道等，每个组件都扮演着不可或缺的角色，共同协作完成数据的抓取和处理任务。Scrapy 引擎是整个框架的核心，引擎从爬虫中获取起始URL（统一资源定位符），并将其交给调度器处理。调度器将URL 传递给下载器进行下载，而下载器则将下载的网页返回给引擎，再由引擎交给爬虫处理。下载器是Scrapy 中获取网页内容的组件，建立在Twisted 异步网络框架之上，能够高效地处理多个请求和快速响应。爬虫是用户自定义的部分，主要定义如何“爬取”特定的网站，包括需要抓取的URL 和如何解析网页内容等。爬虫从引擎接收URL，并返回解析结果。项目管道负责处理爬虫从网页中抽取的实体，主要功能是持久化实体、验证实体的有效性、清除不需要的信息[1]。

2　农业网络信息采集中 Scrapy 技术的优势分析

2.1　加速数据采集进程

Scrapy 采用异步IO 模型，能够同时处理多个请求，从而提高了数据采集的效率。在农业网络信息采集中，Scrapy 能够迅速访问多个农业网站，抓取大量数据，而无须等待单个请求完成后再发起下一个请求，这种并发处理机制缩短了数据采集的时间周期，使农业信息的更新更加及时，为农业生产决策提供了有力支持。Scrapy 还内置了高效的下载器，该组件基于Twisted 异步网络框架，能够高效地处理HTTP 请求和响应，Twisted 的非阻塞特性使Scrapy 在处理大规模网络请求时不会阻塞主线程，从而进一步提高了数据采集的效率。基于Scrapy 的农业网络信息采集，能够更快速地响应网络请求，获取更全面的农业信息。

2.2　灵活定制采集需求

Scrapy 提供了丰富的扩展机制和定制选项，使农业网络信息采集更加灵活多变，Scrapy 的架构允许开发者根据实际需求，添加自定义的中间件、项目管道和下载器等组件，以满足特定的数据采集和处理需求。在农业网络信息采集中，Scrapy 的可扩展性体现在多个方面。比如，开发者可以通过编写自定义的爬虫，指定如何抓取特定类型的农业信息，包括农产品价格、天气预报、农业政策、农业知识、专家信息等；Scrapy 支持对多种数据格式的解析和处理，包括HTML、XML、JSON 等，使农业信息的提取更加便捷高效；Scrapy 的Item Pipeline 机制允许开发者对

基金项目：榆林市科技计划项目（2023-CXY-166）
作者简介：李金（1982—），男，陕西榆林人，硕士，副研究馆员，研究方向为农业信息化

中国知网　https://www.cnki.net

提取的数据进行进一步的处理和存储，如数据清洗、转换和持久化等，以满足不同的数据分析需求[2]。

2.3 精准定位关键信息

Scrapy 提供了强大的数据提取功能，支持XPath 和CSS 选择器等多种方式定位和提取网页中的数据。XPath 是一种在XML 文档中查找信息的语言，可以在HTML 文档中提取所需的信息元素；CSS 选择器则通过类似CSS 的选择器定位页面中的特定元素。在农业网络信息采集中，Scrapy 的数据提取功能使开发者能够轻松地从复杂的网页结构中提取出关键信息，比如农产品价格、库存量、销售情况、产地分布等。Scrapy 还支持正则表达式和自定义的数据处理管道，进一步提高了数据提取的灵活性和准确性。例如，通过正则表达式，开发者可以匹配和提取网页中的特定文本或数据模式；通过自定义的数据处理管道，开发者可以对提取的数据进行进一步的清洗、转换和格式化，以满足不同的数据分析需求。

3 基于 Scrapy 的农业网络信息采集技术应用

玉米是干旱区的主要作物之一，也是我国重要的粮食作物，其产量和价格直接关系到国家粮食安全和农民的经济收入，随着农业供给侧结构性改革的深入推进，玉米市场面临着新的挑战和机遇，如何及时、准确地获取玉米价格信息，成为指导农业生产、监测市场动态、制定农业政策的关键。互联网中的玉米价格信息来源多样，包括农业部门统计数据、农产品市场信息、农业网站信息等。这些信息来源广泛且分散，数据格式复杂多样，数据采集难度大[3]。而Scrapy 作为一款功能强大的网络爬虫框架，能够实现对多个信息来源的高效、精准采集。

3.1 需求分析

在进行玉米价格信息采集之前，需要明确采集的目标。本文的采集目标为玉米价格信息，包括不同品种、不同产地、不同时间点的玉米价格数据。确定采集目标后，需要对信息来源进行分析。互联网上的玉米价格信息来源广泛，包括农业部门官方网站、农产品市场信息平台、专业农业网站、社交媒体等，不同网站和平台的数据格式、更新频率和访问限制各不相同。因此，需要对每个来源进行详细分析和评估。

根据信息来源的分析结果，制定合适的采集策略。对于不同的网站和平台，可能需要采用不同的采集方法和工具。比如，对于农业部门的官方网站和专业农业网站，可以使用Scrapy 编写爬虫程序进行定期采集；对于农产品市场信息平台，可以利用其提供的应用程序编程接口（API）进行数据获取；对于社交媒体，可以使用专门的社交媒体数据采集工具进行抓取。在制定采集策略时，需要根据玉米价格信息的更新频率，确定爬虫的采集周期；对于频繁更新的数据，需要设置较短的采集间隔；对于更新较慢的数据，可以适当延长采集周期[4]。

3.2 Scrapy 爬虫项目创建与配置

在环境准备中，需要确保Python 环境已安装，建议使用Python 3.6 及以上版本，使用pip（一个现代的、通用的Python 包管理工具）安装Scrapy，在命令行中输入pip install Scrapy，等待安装完成；然后在命令行中导航到希望存储爬虫项目的目录，运行scrapy startproject cornprice_project 命令，创建名为cornprice_project 的Scrapy 爬虫项目；项目创建成功后，会在当前目录下生成名为cornprice_project 的文件夹，内含项目的所有文件和子目录。

Scrapy 项目创建后，会生成标准的项目结构，包括几个文件和文件夹。比如，cornprice_project/，项目的根目录；cornprice_project/，与项目同名的子目录，包含项目的主要配置文件；items.py，定义爬虫将抓取的数据字段；middlewares.py，定义爬虫的中间件，用于处理请求和响应；pipelines.py，定义数据清洗、验证、存储等后期处理流程。

在配置文件编辑的过程中，可以在items.py 文件中定义需要抓取的玉米价格信息的数据字段，具体如下。

```
import scrapy
class CornPriceItem（scrapy.Item）:
# 定义玉米价格信息的字段
variety = scrapy.Field（）        # 玉米品种
origin = scrapy.Field（）         # 产地
price = scrapy.Field（）          # 价格
date = scrapy.Field（）           # 交易日期
```

3.3 爬虫编写

在CornPriceSpider 类中，首先定义了起始URL，即玉米价格信息网的首页URL，以及允许“爬取”的域名，并根据需要设置其他初始化参数。解析规则是Spider 中的核心部分，定义了如何从“爬取”到的页面中提取所需信息。本文通过分析目标网站的HTML 结构，确定了玉米价格信息的具体位置，使用Scrapy 提供的XPath 或CSS 选择器，从页面中提取出玉米价格、品种、产地、日期等关键信息；根据提取的数据，创建Scrapy 的Item 对象，并将数据填充到相应的字段中。

因为目标网站可能包含多页玉米价格信息，所以需要在Spider 中实现翻页逻辑，以便利所有页面并采集数据。分析网页结构能够确定翻页链接的位置和规律。通常，翻页链接位于页面底部或侧边栏，且链接中的页码参数会随翻页而变化；在解析当前页面数据时，同时提取出下一页

中国知网 https://www.cnki.net

的链接。如果存在下一页，则构建新的请求，并设置回调函数以处理下一页数据[5]。

3.4 数据存储与处理

采集到的玉米价格数据需要被有效地存储起来，以便后续分析。根据数据的特性和使用需求，可以选择MySQL数据库作为数据存储介质。MySQL 是一个关系型数据库管理系统，具有高性能、稳定性和易用性等优点，能够满足对数据存储和查询的需求。在MySQL 数据库中，为玉米价格信息创建专门的数据库表，命名为corn_prices，该表包含ID、品种、产地、价格、日期、来源等字段，其中ID 字段用于唯一标识每条记录，品种、产地、价格和日期字段用于存储玉米价格信息的关键内容，来源字段则用于记录数据的来源网站或页面。在Scrapy 的Item Pipeline 中，编写数据入库的逻辑，每当Spider 采集到一条玉米价格数据时，就会创建一个对应的Item 对象，并将数据填充到相应的字段中；然后，Item Pipeline 会接收Item 对象，并将其中的数据插入MySQL 数据库的corn_prices 表中；配置数据库连接信息，可以确保数据被正确地存储到数据库中。

在数据存储之后，需要对数据进行清洗以确保其准确性和一致性，数据清洗包括去除重复记录、处理缺失值、纠正错误数据等步骤。对于玉米价格数据，需要特别关注价格的合理性和日期的正确性，通过设定合理的价格范围和日期格式，过滤掉异常数据，提高数据的质量。在数据清洗之后，需要对玉米价格数据进行深入的分析，通过统计不同品种、不同产地的玉米价格分布情况，了解市场供需状况和价格趋势，并结合其他农业数据进行综合分析，揭示玉米价格与因素之间的关联关系。此外，为了更好地展示玉米价格数据的分析结果，可以利用数据可视化技术，将复杂的数据转化为直观的图表和图像，绘制价格趋势图、地域分布图等，以便清晰地看到玉米价格的变化规律和地域差异，从而有助于农民、农业企业和政府决策者更好地理解市场情况，制订合理的种植计划，采取科学有效的措施[6]。

3.5 爬虫运行与调试

在爬虫系统设计和解析规则编写完成后，需要运行爬虫以验证其效果。在Scrapy 中，可以通过命令行工具来启动爬虫，首先进入Scrapy 项目的根目录，然后输入scrapy crawl cornprice 命令来启动玉米价格爬取程序。爬虫启动后，会按照预设的规则“爬取”数据。观察爬虫的运行日志，可以了解爬虫的工作状态和进度；如果爬虫运行正常，会不断地发送请求、接收响应、解析数据，并将提取到的数据存储到指定的位置。

在爬虫运行过程中，可能会遇到各种问题，因此需要对爬虫进行调试。首先，检查爬虫的日志信息，以了解问题出现的具体位置和原因。如果请求超时或失败，可以尝试增加重试次数或调整请求参数；如果解析错误，可以检查解析规则是否正确，并对其进行修正；如果数据缺失，则需要检查网页结构是否发生变化，并更新解析规则以适应新的结构。除了日志信息，还可以使用Scrapy 提供的调试工具来辅助调试。比如，可以使用Scrapy Shell 来测试解析规则，观察是否能够正确提取数据，或者使用断点调试逐步执行爬虫代码，检查变量的值和程序的执行流程。

通过试验，本文成功采集到了玉米价格信息，并将其存储到了指定的位置。根据检查采集到的数据，我们发现数据格式规范、内容完整，符合预期要求，这说明Scrapy 可以采集农业信息网络中的玉米价格数据，为农业市场分析和决策提供数据支持。

4 结语

综上所述，基于Scrapy 的农业网络信息采集技术具有良好的应用效果，能够自动从互联网上抓取玉米价格数据，并进行清洗、验证和存储，为农业生产决策、市场监测和政策制定提供有力的数据支持。未来，需要继续优化和完善爬虫系统，从而为我国实现农业信息化和高质量发展提供助力。

参考文献：

[1] 魏海昱，林伟鸿，贺超波. 基于Scrapy 的食品安全舆情数据爬取与分析[J]. 现代计算机，2022，28（14）：49-54.

[2] 万玉龙，顾　峰，冯炜雯，等. 乡村振兴战略下冷链物流信息数据挖掘与分析研究[J]. 商场现代化，2022（08）：63-67.

[3] 陈纯纯，骆旭坤，杨韵芳. 基于MQTT+IOT Hub 的农业信息采集平台设计[J]. 延边大学学报（自然科学版），2018，44（04）：361-364.

[4] 欧善国，彭晓丹，凌　洋. 广州智慧农业气象服务平台设计与实现[J]. 气象科学，2022，42（02）：270-278.

[5] 边柯橙. 基于深度学习的玉米常见病害图像识别研究及应用[D]. 兰州：兰州财经大学，2021.

[6] 贺子康. 基于知识图谱的脱贫县域特色农产品消费问答系统设计与实现[D]. 北京：中国农业科学院，2022.

中国知网 https://www.cnki.net