ISSN 1009-3044
Computer Knowledge and Technology 电脑知识与技术
Vol.20, No.19, July 2024

E-mail：eduf@dnzs.net.cn
http://www.dnzs.net.cn
Tel:+86-551-65690963 65690964

基于Scrapy的新能源汽车评论数据采集与情感分析

于波，冯文雯，于晓雨，周维燕

（广西建设职业技术学院，广西 南宁 530007）

摘要：本研究基于Scrapy爬虫框架从懂车帝网站上爬取新能源汽车评论数据，并进行了数据分析和情感分类。研究发现，用户对新能源汽车主要关注性能、续航能力、外观设计、购车体验和售后服务等方面。情感分析显示用户普遍持积极态度，但亦存在对价格和购车过程中的问题的不满。本研究为新能源汽车行业发展和市场需求提供了数据支持，为互联网时代大数据分析提供了一个实践案例。

关键词：新能源汽车；短评论；网络爬虫；数据分析；情感分类；可视化

中图分类号：TP311　　**文献标识码：**A

文章编号：1009-3044(2024)19-0033-03

开放科学（资源服务）标识码(OSID)：

DOI:10.14004/j.cnki.ckt.2024.0960

0 引言

在互联网时代，网络数据量呈现爆炸性增长的趋势。截至2023年12月，我国网民规模达10.92亿人，较2022年12月新增网民2 480万人，互联网普及率达77.5%[1]。在这个背景下，伴随着国内汽车行业的蓬勃发展，新能源汽车作为其中的主力军之一，吸引了大量消费者的关注。懂车帝网站作为汽车领域的重要信息交流平台，汇集了众多用户对不同新能源汽车的评论与观点。

然而，面对互联网上海量的文本数据，仅依靠人工筛选数据已不再现实。高效地从海量数据中提取有价值信息成了研究人员和企业关注的焦点。自动化网络爬虫技术因其在不同领域的广泛应用而备受瞩目。本文基于Python编写程序，采用Scrapy作为爬虫框架，从懂车帝网站上爬取当下新能源汽车的评论数据。通过对爬取的数据进行清洗与整理，提取其中的有价值信息，并运用可视化技术进行展示。同时，还对评论进行了情感分析，以探索用户对新能源汽车的态度与情感倾向。

本文旨在利用网络爬虫技术，探索并挖掘新能源汽车领域的用户评论数据，为汽车行业的发展和市场需求提供数据支持，同时为互联网时代大数据分析提供一个实践案例。

1 主要技术

1.1 爬虫原理

网络爬虫是一种基于获取不同URL的核心支撑，用于搜索和抓取该URL下的各种文章、链接和图片等内容的技术。在给定的URL中，网络爬虫会持续从中提取URL，并对当前URL的内容进行筛选和获取。当一个URL的内容被完全检索后，网络爬虫会自动转到下一个URL，重复这一过程，直到所有URL都被检索一次。在技术层面上，网络爬虫通过程序模拟浏览器请求站点的行为，将站点返回的数据（如HTML代码、JSON数据或二进制数据）存储在本地，以供后续使用。根据不同的需求，网络爬虫可以针对性地进行爬取，并增加目标定义和过滤机制。

本文采用Scrapy爬虫框架进行数据采集。Scrapy是一个基于Python开发的高层次、快速的网页抓取框架，用于抓取网站信息并从页面中提取结构化数据[2]。在数据挖掘、监测和自动化测试等不同场景下，Scrapy具有广泛应用。

1.2 数据分析流程

数据分析是应用统计、计算机科学、机器学习和领域专业知识等技术和方法，对大量数据进行收集、清洗、处理和分析，以发现有意义的信息、趋势和模式，并从中获得见解，从而支持决策制定、问题解决和创新的过程。

本文使用numpy、pandas、jieba分词、gensim、pyLDAvis、matplotlib和wordcloud等技术工具，对懂车帝比亚迪海豹新能源车的评论信息进行数据分析、情感分类及可视化。具体流程如图1所示。

2 功能实现

2.1 爬虫模块

我们根据懂车帝网站评论页面的URL结构，定义了URL规则。在URL中发现，每一个车型的汽车在`/community` 评论页URL之后的数字对应了每一个车型的汽车，每个车型汽车数字后面则为评论页页码。评论首页URL如下所示。

https://www.dongchedi.com/community/5579/1

通过构造相应的URL，循环生成并遍历每个URL

收稿日期：2024-04-10

作者简介：于波(1991—)，男，山东临沂人，硕士，主要研究方向为自然语言处理；冯文雯(1990—)女，广西南宁人，硕士，主要研究方向图像自动化三维重建；于晓雨(1988—)，男，山东临沂人，硕士，主要研究方向为并行计算；周维燕(1990—)，女，安徽枞阳人，硕士，主要研究方向为计算机视觉。

中国知网 https://www.cnki.net

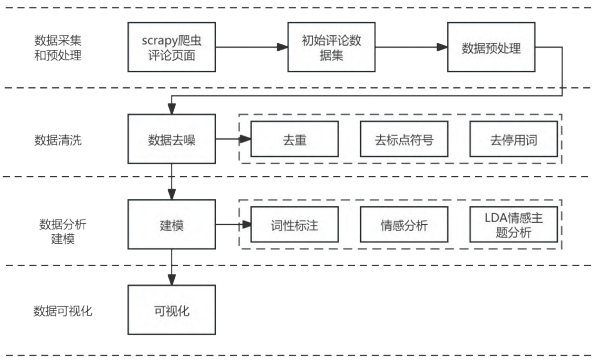

图1 数据分析流程图

来模拟浏览器翻页过程。本文设定爬取的目标页数为前400页，具体代码如下所示：

```
def start_requests(self):
base_url = "https://www.dongchedi.com/community/5579/"
for index in range(1, 401):
url = base_url + str(index)
self.urlArr.append(url)
for url in self.urlArr:
yield scrapy.Request(url=url, callback=self.parse)
```

使用Scrapy框架提供的CSS选择器和正则表达式等方法，成功爬取页面中的评论数据并进行了处理，最终得到共计12 079条包含评论index及评论内容的评论。解析页面评论信息的核心代码如下所示：

```
communityList = response.css('section')
for community in communityList:
sscomment = community. css("div"). css(". tw-text-common-black::text").getall()[0]
```

将爬取到的评论数据保存在csv文件中，数据内容如表1所示。

表1 爬虫评论信息

index	comment
0	这款车的性能是比较强悍的，官方公布的百公里加速只需要7.5 s，我觉得这个加速成绩在新能源轿...
1	有上海海豹车友群吗
2	垃圾比亚迪动不动就是保密协议
3	轮胎里侧磨损严重，已经露出钢线。每2万公里都有去做保养，没出过事故，基本在高速跑，怎么会吃胎...
...	...
12079	等车日记 丐中丐真的不排产吗

2.2 数据预处理

数据预处理是数据分析前的重要步骤，良好的预处理过程可以有效规避数据噪音的影响，大大提高数据分析的水平。本文使用结巴分词工具对评论文本数据进行分词，得到每条评论的分词词组。分词过程的具体源代码如下所示。

```
lambda s: [(x.word, x.flag) for x in psg.cut(s)]
```

对得到的每条评论词组进行词性标注，进而生成包含评论索引、词语和词语词性的DataFrame数据结构的预处理结果。为优化数据质量，本文引入标点符号词典以去除每条评论数据中的标点符号，及引入哈工大停用词词典以去除每条评论数据中的停用词，最终得到预处理数据。预处理数据内容如表2所示。

表2 预处理数据

index	index_comment	word	nature
1	1	款车	n
3	1	性能	n
6	1	强悍	a
9	1	官方	n
...	...	...	...
450145	12079	丐	g

2.3 数据分析

词语的情感倾向判别是文章语义情感倾向研究的基础工作，且情感词主要用于表达对产品的情感倾向，因此需要与名词性词语结合才具有具体的情感倾向性[3]。因此，根据得到的预处理结果，将含有名词词性词语的评论进行提取。读取正面情感词典及负面情感词典作为情感识别来源，词典中正面情感词的权重设为1，词典中负面情感词设置为-1。

将评论分词结果与正负面情感词典进行匹配，定位每条评论中的情感词语。引入否定词典，进一步修正评论分词中的词语情感值。删除情感值加和为0的评论数据，得到情感评论数据集。评论的情感分析表如表3所示。

表3 评论情感分析表

index	index_comment	weight	type
0	1	1.0	pos
1	3	-1.0	neg
2	5	-1.0	neg
...	...	...	...
1564	12061	-2.0	neg
1565	12064	-1.0	neg

对得到的情感评论数据集分别提取正面和负面评论数据，构建正面和负面情感语料库。基于正面和负面情感语料库，分别使用gensim进行LDA主题分析。LDA主题模型是学者Blei等人在2003年提出的一种文本分析模型[4]，每个主题对应一个关键词概率分布，每个文档则对应一个主题概率分布。该模型提升了深层次文本内容挖掘和语义分析的精准度与效率，在情感分析、新兴技术方面均有大量应用[5]。

计算正面和负面评论的主题平均余弦相似度，得到正面和负面评论的主题数寻优结果为3。使用gensim进行LDA主题分析，得到正面和负面评论的各自前三个主题结果，分别如表4、表5所示。

表4 正面评论主题结果

index	comment
0	0.042*"车" + 0.026*"比亚迪" + 0.026*"感觉" + 0.025*"喜欢" + 0.011*"试驾" + 0.010*"内饰" + 0.010*"想" + 0.009*"深蓝" + 0.009*"跑" + 0.008*"车主"
1	0.019*"开" + 0.016*"提车" + 0.016*"续航" + 0.011*"公里" + 0.011*"支持" + 0.011*"满意" + 0.011*"驾驶" + 0.010*"感受" + 0.010*"外观" + 0.009*"店"
2	0.065*"海豹" + 0.016*"太" + 0.013*"月" + 0.012*"销售" + 0.012*"汉" + 0.010*"真的" + 0.007*"底盘" + 0.007*"配置" + 0.006*"车型" + 0.006*"点"

中国知网 https://www.cnki.net

表5 负面评论主题结果

index	comment
0	0.040*"高" + 0.017*"充电" + 0.016*"续航" + 0.014*"感觉" + 0.013*"月" + 0.012*"万" + 0.012*"太" + 0.012*"销售" + 0.010*"充" + 0.010*"低"
1	0.034*"车" + 0.023*"比亚迪" + 0.021*"开" + 0.014*"贵" + 0.013*"提车" + 0.013*"店" + 0.013*"真的" + 0.012*"价格" + 0.011*"电" + 0.009*"深蓝"
2	0.062*"海豹" + 0.012*"底盘" + 0.010*"公里" + 0.010*"电池" + 0.008*"想" + 0.007*"问" + 0.007*"桩" + 0.006*"特斯拉" + 0.006*"有没有" + 0.005*"车型"′

3 数据可视化

数据可视化是将数据分析的结果以图表或图形的形式展示出来，以便更直观地理解数据的趋势、模式和关系。本文中，通过结巴分词及数据预处理后，对所有评论词语进行词频统计，并将词频按照降序排序，选择前100个词，使用WordCloud绘制词云，如图2所示。

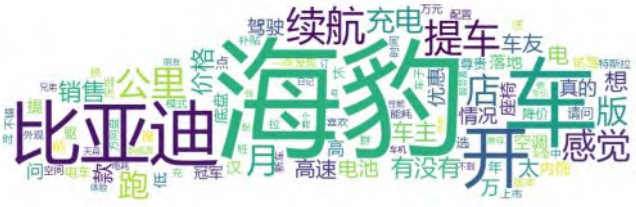

图2 评论词频统计词云图

通过数据分析提取正负面情感评论数据，基于LDA情感主题分析，使用pyLDAvis进行评论情感可视化。得到与正面情感主题相关性排名最高的20个词语，如图3所示。得到与负面情感主题相关性排名最高的20个词语，如图4所示。

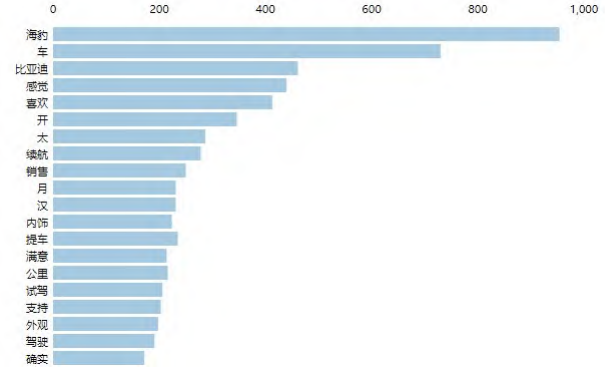

图3 与正面情感主题的相关性排名最高的20个词语

从图3可知，“海豹”“比亚迪”和“续航”等词汇明显突出，表明用户对电动汽车的续航能力和性能表现关注较多。此外，“内饰”“外观”和“驾驶”等词汇显示了用户对汽车外观设计和内部装饰的重视程度。“销售”和“提车”等词汇则暗示了用户在购买过程中的关注点，可能包括购车体验和售后服务等方面。“试驾”“满意”和“支持”等词汇表明用户对汽车性能和使用

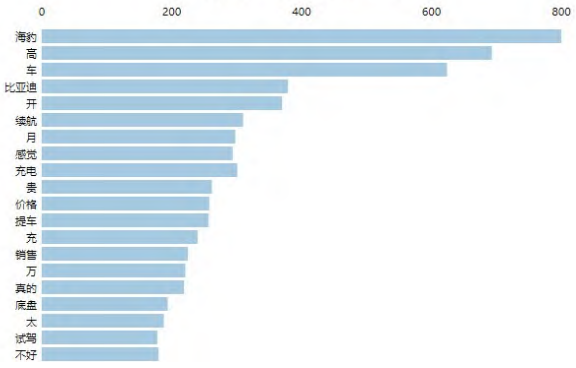

图4 与负面情感主题的相关性排名最高的20个词语

体验的满意度较高，而“感觉”“喜欢”和“确实”等词汇则暗示了用户情感上的积极态度。

从图4可知，负面情感词语中出现了“贵”和“价格”等词汇。这表明价格方面的不满意度在用户中较为普遍，这可能与消费者对于汽车价格的敏感性有关。“续航”一词的出现，表明续航性能对用户影响较大。“提车”“销售”等词汇反映了用户在购车过程中可能遇到的问题。

4 结论与建议

研究结果表明，用户对新能源汽车的续航能力、性能表现、外观设计和内部装饰等方面关注较多，且对汽车性能和使用体验的满意度较高。同时，用户对价格方面的不满意度较为普遍，续航性能和购车过程中遇到的问题也是用户关注的焦点。基于以上研究结果，提出以下建议：

1) 优化续航能力和性能表现。汽车制造商应继续优化新能源汽车的续航能力和性能表现，以满足用户对高性能车辆的需求。在外观设计和内部装饰方面投入更多精力，以提升用户对汽车美学的认同和满意度。同时，应注意调整价格策略，以减轻消费者的经济负担，特别是在价格敏感的市场中。

2) 提升销售和售后服务质量。加强销售和售后服务质量，提升用户购车体验，减少因服务问题导致的负面情感。通过用户反馈和数据分析，持续改进产品和服务，以更好地满足市场和用户的需求。

参考文献：

[1] 中国互联网络信息中心.第53次《中国互联网络发展状况统计报告》[R/OL].(2024-03-29) [2024-04-01]. https://www.cnnic.cn/n4/2024/0322/c88-10964.html.
[2] 米硕,孙瑞彬,李欣,等.Scrapy分布式爬虫原理分析与概述[J].中国新通信,2018,20(4):234.
[3] 柳位平,朱艳辉,栗春亮,等.中文基础情感词词典构建方法研究[J].计算机应用,2009,29(10):2875-2877.
[4] BLEI D M, NG A Y, Latent Dirichlet Allocation [J]. Journal of Machine Learning Research, 2003(3): 993-1022.
[5] 贾元珊,黄恒君.基于LDA主题模型的我国城乡融合政策文本启示分析[J/OL].兰州财经大学学报:1-19[2024-07-02]. http://kns.cnki.net/kcms/detail/62.1213.f.20240318.0950.009.html.

【通联编辑：唐一东】

中国知网 https://www.cnki.net