基于 Scrapy 的电商评论数据采集与情感分析系统设计与实现

田智
（内蒙古商贸职业学院信息技术系，呼和浩特 010070）

摘　要：近年来，电商平台产生了大量商品信息与用户评论数据，而传统的人工采集方式效率低、准确性差。基于Python的Scrapy框架设计并实现了一个自动化的电商平台数据采集与情感分析系统，能高效抓取商品信息与用户评论，并利用TextBlob与VADER两种工具进行情感分类。实验结果表明，该系统具有良好的抓取效率和情感识别能力，可为商家提供优化产品与营销策略的数据支持。

关键词：网络爬虫；数据抓取；Python语言；Scrapy框架；Selenium测试工具
DOI:10.16184/j.cnki.comprg.2026.02.020

1　概述

随着电子商务的迅猛发展，商品信息、用户评论等海量数据成为电商平台的重要资源。这些数据不仅反映了消费者行为，还揭示了市场趋势。传统依赖人工收集数据的方式效率低、覆盖面有限，难以满足大规模数据处理需求[1]。网络爬虫作为自动化工具，具备高效性与灵活性，成为采集商品与评论信息的理想手段。通过网络爬虫技术，商家可快速提取所需数据，提高采集效率与准确性。同时，情感分析作为重要的数据挖掘方法，可识别评论的情绪倾向，帮助商家理解用户态度，优化产品与决策[2]。

研究基于Scrapy框架构建的系统，能够自动抓取商品与评论信息，并进行情感分析。

2　相关技术

2.1　Python Scrapy 框架

Scrapy 是基于 Python 的开源 Web 抓取框架，具备高效、模块化和异步处理等优势，广泛应用于大规模数据采集任务。Scrapy 核心组件包括 Spider（定义抓取规则）、Pipeline（数据清洗与存储）、Scheduler（调度请求）和 Middleware（处理请求与响应过程）[3]。Scrapy 支持 XPath 和 CSS 选择器，能高效提取网页中的结构化数据，适用于抓取电商平台的商品与评论信息。借助丰富的社区资源与插件生态，Scrapy 可灵活应对多样化的数据采集需求。

2.2　情感分析技术

情感分析是自然语言处理中的关键方法，可将文本划分为正面、负面或中性情绪，有助于商家理解用户反馈、优化产品与服务[4]。其中，VADER 是基于词典的方法，适用于分析短文本与社交媒体评论，具备识别表情符号、感叹词等非正式语言的能力，适用于对电商评论的快速分析。TextBlob 则通过极性（Polarity）与主观性（Subjectivity）指标判断文本情感，操作简便，适用于基础情感分类任务。两者各具优势，结合使用可提升电商评论分析的准确性与适应性。

2.3　数据存储与处理

在抓取大规模数据后，合理的数据存储方案对于后续处理至关重要。针对电商平台中的结构化与半结构化数据，采用 MySQL 与 MongoDB 进行分层存储。MySQL 作为关系型数据库，适用于存储商品信息与评分等结构化数据，具备良好的查询性能与数据一致性保障。MongoDB 属于文档型非关系数据库，适用于动态变化的评论数据，具备高扩展性与灵活性。两者结合可提升系统的数据处理能力与适应性。

2.4　网络爬虫反制策略

许多网站采用反网络爬虫技术，例如，IP 封禁、验证码和动态内容加载，防止过度抓取。为保证数据抓取稳定高效，开发者需采取相应对策。常见方法包括使用代理服务器或代理池定期更换 IP，避免被识别为网络爬虫。针对验证码，可通过图像识别或第三方打码服务自动识别并提交验证码。对于 JavaScript 动态加载的内容，结合 Selenium 模拟浏览器行为，以获取完整数据[5]。

3　系统设计与实现

3.1　系统架构

系统采用模块化设计，整体架构如下。

（1）数据抓取模块。利用 Scrapy 自动抓取电商平台的商品信息、评论和评分。

（2）情感分析模块。采用 TextBlob 和 VADER 两种

作者简介：田智（1974—），硕士，副教授，研究方向为云计算应用开发、智能软件系统架构设计、测试技术。

中国知网　https://www.cnki.net

分析工具，对抓取的评论数据进行情感分析，标注每条评论的情感倾向（正面、负面或中性）。

（3）数据存储与处理模块。使用MySQL和MongoDB高效管理抓取数据。

（4）爬虫调度与监控模块。负责网络爬虫任务的调度及运行监控，确保系统稳定。

3.2 数据抓取模块

数据抓取模块主要负责从目标电商平台自动获取商品信息、评论及评分，采用Scrapy框架来实现，通过编写Spider类定义抓取逻辑。研究根据网站结构和数据需求，分别设计了用于抓取商品信息和用户评论的Spider。

代码如下。

```
Python
import scrapy
class ProductSpider(scrapy.Spider):
    name = ´product_spider´
    allowed_domains = [´example.com´]
    start_urls = [´https://example.com/products´]
    def parse(self, response):
        # 获取商品信息
        for product in response.css(´div.product-item´):
            yield {
                        ´product_name´: product. css(´span.
product-title::text´).get(),
                ´price´: product. css(´span. product-price::
text´).get(),
                ´rating´: product. css(´span. product-rating::
text´).get(),
                ´url´: product.css(´a::attr(href)´).get(),
            }
            # 获取评论链接并递归抓取评论界面
            review_url = product.css(´a.product-reviews::
attr(href)´).get()
            if review_url:
                    yield response. follow(review_url, self.
parse_reviews)
    def parse_reviews(self, response):
        # 获取评论内容
        for review in response.css(´div.review-item´):
            yield {
                ´review_text´: review. css(´p. review-text::
text´).get(),
                ´review_rating´: review. css(´span. review-
rating::text´).get(),
                ´review_date´: review. css(´span. review-
date::text´).get(),
            }
```

通过分析目标网站的HTML结构，提取商品名称、价格、评分等关键字段，使用CSS选择器进行定位。针对评论界面，利用递归调用实现多级数据抓取，并结合分页机制获取完整的商品与评论信息。

3.3 情感分析模块

情感分析模块负责对用户评论进行分类，将其标注为正面、负面或中性。系统结合使用TextBlob和VADER两种分析工具。前者基于极性值和主观性判断情感倾向，后者适用于短文本，能识别表情符号等特征并生成综合得分。两者互补，提升了评论情感分析的准确性与适用范围。具体代码如下。

```
Python
from textblob import TextBlob
from vaderSentiment. vaderSentiment import Senti-
mentIntensityAnalyzer
# 使用TextBlob进行情感分析
def analyze_sentiment_textblob(text):
    blob = TextBlob(text)
    sentiment = blob.sentiment.polarity
    return ´positive´ if sentiment > 0 else ´negative´ if
sentiment < 0 else ´neutral´
# 使用VADER进行情感分析
def analyze_sentiment_vader(text):
    analyzer = SentimentIntensityAnalyzer()
    score = analyzer.polarity_scores(text)
    return ´positive´ if score[´compound´] > 0.05 else
´negative´ if score[´compound´] < -0.05 else ´neutral´
```

3.4 网络爬虫调度与监控模块

该模块负责调度多个网络爬虫任务的执行与运行状态监控。系统采用Celery等调度工具定期启动网络爬虫，并通过Scrapy的CrawlSpider管理任务分配。结合Prometheus与Grafana实现实时监控，及时捕捉异常与性能波动，确保网络爬虫稳定运行和数据抓取的完整性。

使用Celery调度任务的代码如下。

```
Python
from celery import Celery
app = Celery(´scrapy_tasks´, broker=´redis://localhost:
6379/0´)
@app.task
def start_scrapy_spider():
    from scrapy import cmdline
        cmdline. execute(´scrapy crawl product_spider´.
split())
```


中国知网 https://www.cnki.net

使用Prometheus监控网络爬虫运行状态的代码如下。

```
Python
   from prometheus_client import start_http_server, Gauge
# 定义Prometheus监控指标
      scrapy_task_duration = Gauge(´scrapy_task_duration_seconds´, ´Time taken by Scrapy task´)
# 在网络爬虫开始时开始计时
scrapy_task_duration.set(0)
start_http_server(8000)
```

4 实验与结果分析

4.1 数据采集

实验中部分抓取的数据如表1和表2所示。

表1 抓取的商品数据

商品名称	价格(元)	评分
iPhone 16 Pro	10 999	4.8
Samsung Galaxy S24 Ultra	8 999	4.7
Sony WH-1 000XM5	2 299	4.6
Apple MacBook Pro 16	18 999	4.9

表2 抓取的评论数据

评论内容	评分	评论日期
非常好用，拍照效果极佳，续航表现非常棒	5	2025-06-01
使用一段时间后，运行流畅但续航一般	4	2025-06-02
价格贵了点，但整体使用体验还是不错的	4	2025-06-03
价格偏高，体验差	2	2025-06-04
音质和降噪效果非常出色，十分满意	5	2025-06-05

4.2 情感分析结果

对于抓取的数据，情感分布与销量及正面评论比例关系如图1所示。展示了情感分布、评分、销量与价格之间的关系。实验结果表明，约70%的评论为正面，显示出消费者整体态度积极。评分与情感呈正相关，高评分商品（例如，iPhone 16 Pro）对应更多正面评论，反映出用户满意度较高。销量趋势与情感反馈一致，正面评价比例高的商品通常销量更佳，表明消费者在决策过程中会参考他人评论，尤其是正面反馈。相比之下，负面评论占比较高的商品销量偏低，说明其未能满足用户需求。

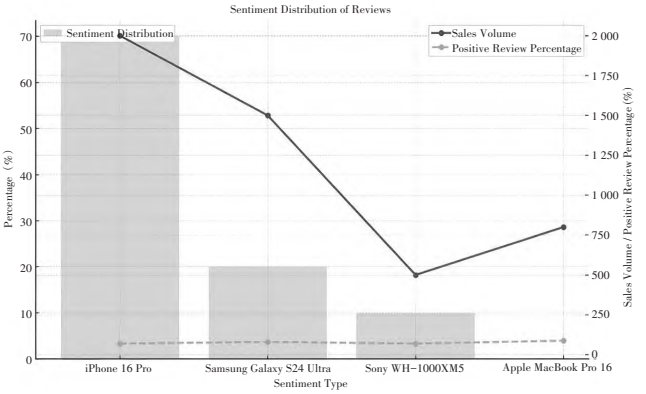

图1 情感分布与销量及正面评论比例关系

5 结语

研究设计并实现了一个基于Python Scrapy框架的电商评论数据采集与情感分析系统。系统能够自动抓取电商平台的商品信息和用户评论，并使用TextBlob和VADER两种情感分析方法对评论进行情感分类。通过对采集的数据进行分析，揭示了消费者的情感态度与商品评分、销量之间的关联。通过系统的应用，商家可以更加直观地了解用户的反馈和市场需求，为改进产品质量和制定个性化的营销策略提供数据支持。

参考文献

[1] 唐姗，黄文意，纪秀国，等．基于Python的网络爬虫算法的商品订单信息抓取与分析[J]. 电脑编程技巧与维护，2025(6): 41-43.

[2] 吕新超．Scrapy框架辅助下的Python爬虫系统研究[J]. 电脑知识与技术，2024, 20(7): 49-52.

[3] 于波，冯文雯，于晓雨，等．基于Scrapy的新能源汽车评论数据采集与情感分析[J]. 电脑知识与技术，2024, 20(19): 33-35.

[4] 朱烨行，赵宝莹，张明杰，等．基于Scrapy框架的微博用户信息采集系统设计与实现[J]. 现代信息科技，2023(24): 41-44.

[5] 邓晓璐，姚松．基于Scrapy的新浪微博数据爬虫研究[J]. 现代信息科技，2023(3): 44-47.

（上接第88页）

可确保经济援助切实覆盖需求群体，更能通过生活关怀与学业帮扶的协同干预，提升育人实效。研究对优化高校治理体系具有显著的实践价值。

参考文献

[1] 游香蕾，杨抒，王斌，等．基于改进K-means算法的学生消费水平的研究[J]. 信息技术，2017(2): 64-68.

[2] 游香蕾，王业，杨抒，等．基于聚类算法的学生消费行为分析研究和应用[J]. 自动化技术与应用，2017, 36(12): 32-35.

中国知网 https://www.cnki.net