微电子学与计算机
Microelectronics & Computer
ISSN 1000-7180,CN 61-1123/TN

《微电子学与计算机》网络首发论文

题目：　基于层次化门控与混合注意力的多模态情感分析
作者：　李娅娅，胡彦蓉，刘洪久
网络首发日期：　2026-03-11
引用格式：　李娅娅，胡彦蓉，刘洪久．基于层次化门控与混合注意力的多模态情感分析[J/OL]．微电子学与计算机.
https://link.cnki.net/urlid/61.1123.tn.20260311.0845.002

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-03-11 16:45:11　　网络首发地址：https://link.cnki.net/urlid/61.1123.tn.20260311.0845.002

微电子学与计算机
MICROELECTRONICS&COMPUTER

基于层次化门控与混合注意力的多模态情感分析

李娅娅，胡彦蓉，刘洪久

(浙江农林大学 数学与计算机科学学院 浙江杭州 310000)

摘要：多模态情感分析通过整合文本与图像信息，能够显著提升对复杂场景中情感表达的理解。然而，现有方法在特征融合过程中常受模态冗余和交互不足的制约，难以有效捕捉细粒度情感语义。为此，本文提出了一种基于层次化门控与混合注意力机制的多模态融合模型（Hierarchical Gated Mixed-Attention Network, HGMA-Net）。在输入阶段，模型利用图像字幕生成技术扩展原始文本语义，并结合图像特征构建多模态输入。在特征建模阶段，引入层次化门控模块，通过多层次投影与动态权重分配实现模态特征的自适应选择，有效减少冗余并突出关键信息。同时，设计混合注意力模块，整合模态内自注意力、多尺度局部卷积注意力以及跨模态交叉注意力，增强模态间交互并提升情感语义一致性。最终，融合后的特征输入分类器完成情感识别任务。实验结果表明，HGMA-Net在TumEmo数据集上的准确率和F1 值分别提升 3.19%和 3.37%；在MVSA-Single数据集上分别提升 0.22%和0.34%；在MVSA-Multiple数据集上表现接近最优基线。整体结果表明，本文模型在多个多模态数据集上均展现出稳定且显著的性能优势，验证了其有效性。

关键词:多模态情感分类；层次化门控；混合注意力；注意力机制；图像字幕

中图分类号：TP391　　文献标识码：A

Multimodal Sentiment Analysis Based on Hierarchical Gating and Mixed Attention

LI Yaya, HU Yanrong，LIU Hongjiu

(College of Mathematics and Computer Science, Zhejiang Agriculture and Forestry University, Hangzhou 310000, China)

Abstract: Multimodal sentiment analysis integrates text and image information to significantly enhance the understanding of emotional expressions in complex scenes. However, existing methods are often limited by modal redundancy and insufficient interaction during feature fusion, making it challenging to effectively capture fine-grained emotional semantics. To address this, a multimodal fusion model based on hierarchical gating and mixed attention mechanisms, named Hierarchical Gated Mixed-Attention Network (HGMA-Net), is proposed. At the input stage, image captioning techniques are employed to expand the semantics of original text, which is combined with image features to form multimodal inputs. During feature modeling, a hierarchical gating module is introduced, utilizing multi-level projections and dynamic weight allocation to achieve adaptive selection of modal features, effectively reducing redundancy and emphasizing key information. Additionally, a mixed attention module is designed, integrating intra-modal self-attention, multi-scale local convolutional attention, and cross-modal attention to enhance inter-modal interaction and emotional semantic consistency. Finally, fused features are fed into a classifier to complete the sentiment recognition task. Experimental results demonstrate that HGMA-Net achieves accuracy and F1 score improvements of 3.19% and 3.37% on the TumEmo dataset, 0.22% and 0.34% on the MVSA-Single dataset, and performance close to the optimal baseline on the MVSA-Multiple dataset. Overall, the model exhibits stable and significant performance advantages across multiple multimodal datasets, verified its effectiveness

Keywords: Multimodal emotion classification; Hierarchical gating; Mixed attention; Attentional mechanisms; Image captioning

1 引言

随着社交媒体的普及，用户通过Twitter、微博和小红书等平台分享生活点滴，表达观点和情感。情感作为人类对外界事物态度的体现，在人际交流、教育及决策等场景中发挥着关键作用。情感分析技术也从早期的文本评论分析逐步演进为融合多种信息源的多模态分析。相比单一模态，融合图像与文本的多模态情感分析能够更全面、准确地捕捉复杂的情绪表达。然而，图文间存在的语义差异与冲突为多模态情感挖掘带来挑战。例如，图像呈现疲惫情绪，而文本却表达“非常高兴工作”，图文情感相悖，整体传达出消极态度。这种图文不一致性在现实场景中普遍存在，若融合策略无法有效解析模态间的语义冲突，易导致情感识别误差，限制多模态模型的精度与泛化能力。

尽管多模态情感分析已经取得了一些显著进展，但现有研究在复杂场景下仍面临挑战。传统融合策略，如简单的特征拼接或加权求和，虽然能整合多模态输入，但缺乏对模态间相关性与互补性的建模能力，导致

基金项目：教育部人文社会科学研究规划基金项目（21YJA630054）

融合特征中存在大量冗余信息和语义冲突。随后引入的注意力机制在一定程度上缓解了这一问题，能够基于注意力权重挖掘模态间的关键关联区域。然而，现有方法往往侧重于静态权重分配，未能根据上下文动态调整模态贡献，从而无法有效过滤无关特征，仍存在模态冗余与噪声累积的现象。此外，由于文本与图像在特征空间分布、表示形式及语义层次上存在天然差异，单一的注意力机制难以同时兼顾模态内与模态间的信息一致性。尤其在图像特征经卷积提取并序列化后，高维特征展平会破坏局部上下文关系，导致模型在融合阶段难以捕捉细粒度的语义依赖，从而限制了跨模态情感线索的有效融合[1]。进而影响后续融合层次的表达质量。同时，现有研究在去除无关特征和保持模态平衡方面缺乏有效机制。例如，Poria等人[2]提出的多层次注意力机制虽通过分层上下文提升了模态间关联，但未能解决层次特征失衡及冗余累积的问题。这些局限限制了模型在复杂场景下对混合特征和层次语义的精细捕捉能力，最终影响情感分析的准确性。

基于上述挑战，本文提出了一种基于层次化门控与混合注意力机制的多模态情感分析模型(Hierarchical Gated Mixed-Attention Network, HGMA-Net)，该模型在融合层引入混合注意力机制以共同建构模态内与模态间的依赖关系，利用特征增强与跨模态交互两个子模块充分挖掘多模态互补信息。同时，通过层次化门控机制对多层次特征进行动态加权与筛选，有效抑制冗余特征和无关模态噪声，实现跨模态特征的自适应融合与优化。使模型能够在复杂场景下灵活调整模态贡献比例，从而显著提升融合的精确性与情感表达能力。

综上，本文的主要贡献可以总结如下：

（1）为改进以往融合方法在动态调控上的不足，提出了层次化门控机制，通过多层特征投影与自适应权重分配，有效捕捉模态间复杂依赖关系，并在融合过程中动态抑制无关噪声，从而提升情感表征的稳定性和精确性。

（2）针对以往研究虽采用注意力机制但并未充分挖掘图像序列局部上下文的局限，设计了混合注意力机制，通过融合模态内自注意力与模态间交叉注意力，协同捕捉局部与全局依赖关系，并辅以多尺度局部卷积进一步增强图像特征序列的上下文表达，显著提升了特征融合的表达能力。

（3）在三个公开基准数据集MVSA-Multiple、MVSA-Single和TumEmo上进行实验，HGMA-Net均显著优于基线模型，验证了所提出方法的有效性与泛化能力。

2 相关研究

为深入理解多模态情感分析的发展路径，本文首先梳理图像与文本情感分析的演进，以奠定研究基础；该结构体现了从单模态特征提取到多模态交互的递进逻辑：图像提供视觉语义，文本表达情感，二者结合实现更全面的情绪捕捉，同时揭示现有方法的局限，为本文的创新提供依据。

2.1 图像情感分析

图像情感分析是图像理解的重要方向，旨在识别图像中的主观情感。早期研究多通过手工设计特征应对该任务。Bertasius等人[3]尝试使用像素级视觉特征预测图像情感，Machajdik等人[4]受心理学和艺术理论启发，提取了可表达情感的艺术特征。Revina等人[5]基于LBP和SIFT描述符提出特征提取优化策略。Zhao等人[6]则引入艺术原理分析图像中更高层次的情感特征，有效改善了语义表达，但对图像多样性的适应性不足。

随着卷积神经网络(CNN)的兴起，深度学习在视觉情感分析中展现出强大能力。Chen等人[7]提出DeepSentiBank，将形容词-名词对与CNN结合用于情感识别；Rao等人[8]构建MldrNet，融合多层次卷积特征虽有效了提升分类性能，但却忽略了局部区域的贡献。You等人[9]强调局部图像区域的重要性，并引入注意力机制以突出关键区域，但其静态融合方式难以适应不同图像的情感表达差异。Wu等人[10]整合全局与局部区域信息，进一步提升识别效果。总体而言，现有图像情感分析方法在特征表达上取得了显著进展，尤其在深度学习驱动下，提取的视觉特征为多模态情感分析中的图文融合提供了重要支持。然而，图像情感分析侧重于视觉线索的捕捉，难以独立处理语言层面的细粒度情感，因此需结合文本情感分析的语义表达，以实现模态间的互补，形成多模态框架的基础。

2.2 文本情感分析

文本情感分析聚焦于语言层面的情感语义建模，已形成较为成熟的研究体系，主要可分为基于情感词典和基于机器学习的方法。Jurek等人[11]提出基于语料的归一化函数增强情绪得分计算；崔彦琛等[12]构建通用与行业特定词典，应用于社交媒体评论倾向识别，为多模态分析中的文本特征提供了领域特定的情感表达，但词典维护成本高，难以应对快速变化的网络语言。

深度学习的发展进一步推动文本情感分析在语义建模中的交互能力。Gamon等人[13]使用SVM对客户反馈进行情感分类，分类性能稳定且易于实现。Tiwari等人[14]和Soumya等人[15]通过多种特征组合提升分类性能。Wang等人[16]基于BERT分析疫情期间公众情绪变化趋势；Yuan等人[17]与Kanwal等人[18]结合注意力机制和自动编码器，优化多领域特征提取，但在长距离依赖处理上效果有限。Karn等人[19]融合LSTM与词袋模型，平衡了效率与性能，但对复杂语义捕捉不足。综合而言，文本情感分析在深度语义建模方面取得显著进展，为多模态情感分析中的图文融合提供了坚实的语义基础，尤其在跨领域和长序列建模中表现优异。尽管文本情感分析在语义深度上取得进展，但其忽略了视觉线索的辅助作用，与图像情感分析类似，受限于单一模态的视角，无法全面捕捉情感的多维度特征。这促使研究转向多模态情感分析，通过融合图像与文本的互补信息来提升整体性能。

2.3 多模态情感分析

基于前述图像情感分析的视觉特征提取和文本情感分析的语义建模，多模态情感分析旨在整合这些单模态方法的优势，克服单一模态的局限性，实现更全面的情感理解。传统情感分析受限于单一模态（如图像或文本），难以全面捕捉情感的多维度特征。近年来，多模态融合技术在计算机视觉和自然语言处理领域得到了广泛关注。早期方法采用特征拼接或加权求和，简单但难以挖掘复杂的模态间交互，易受噪声干扰，对异质性处理不足。

随着发展，深度学习的进步推动了多模态融合研究的快速发展，注意力机制及其他融合策略逐渐展现出优越性。Thomas等人[20]通过上下文信息和交互注意力机制来探索不同模态间的交互联系。Xu[21]等人利用层次语义注意与图像字幕提取视觉特征，并整合上下文注意力来提升分类精度。Tan等人[22]引入跨模态注意力机制，显著提升在细粒度情感分类中的任务性能。Yang[23]等人通过双视角特征映射，并基于记忆网络的交互式学习实现了图文间的跨模态情感建模。Mu等人[24]结合语义增强和跨模态交互融合技术进一步模型效果。Wang等人[25]与Yang等人[26]等人都提出基于图神经网络的框架，并利用多头注意力完成跨模态双向交互，实现图文情感检测。此外，Han等人[27]通过注意力机制捕捉多模态间的互补性信息，同时引入门控策略以增强单模态特征的表达效果。Xu等人[28]则强调图文间的层次语义互动和一致性建模。Zhu等人[29]等人通过跨模态对齐捕获区域-词语对应关系，并整合上下文信息通过自适应门控机制来融合多模态特征。Quan等人[30]以文本引导图像注意力，并结合门控模块过滤噪声，增强了融合表达的情感判别力。Jiang等人[31]引入跨模态门控注意力融合机制以优化模态一致性，但其结构相对单一，缺乏深层次交互设计。

尽管现有研究在多模态信息交互领域取得了显著进展，但仍存在一些局限性。多数方法在交互层次上较为单一，难以充分捕捉多模态特征之间的复杂关联。此外，门控机制与注意力机制通常独立设计，缺乏协同优化的融合策略。在异质模态融合及噪声干扰场景下，模型的稳定性和效率仍有较大提升空间。因此，本文通过多层次门控模块动态调节不同语义层次的图文特征，同时在混合注意力机制中引入多尺度局部卷积，并结合自注意力和交叉注意力，进一步优化模态内外的特征交互。与传统方法将门控与注意力机制独立处理不同，本文模型通过深度融合两者，能够显著提升多模态特征的表达能力与模型整体性能。

3 模型架构

本文提出基于层次化门控与混合注意力机制的多模态情感分析模型，其整体架构如图1所示。首先，利用BLIP为图像生成字幕，并与原始文本拼接以增强语义信息。随后，图文数据分别经过单模态编码器提取特征，并在多模态融合模块中实现深层次的跨模态融合。具体而言，如图1右侧所示，通过层次化门控机制与混合注意力机制实现特征的自适应融合，其中混合注意力模块由特征增强与跨模态交互两部分组成，用于捕捉模态内部的语义依赖与模态之间的交互关系，以增强融合特征的表达能力。整个融合过程包括特征增强、跨模态交互、层次化门控与特征优化四个阶段，逐步提升特征表达的有效性。最终输出的情感分类结果不仅有效抑制模态冗余，还增强了模态间的协同作用，从而显著提升模型在多模态情感分析任务中的整体性能。

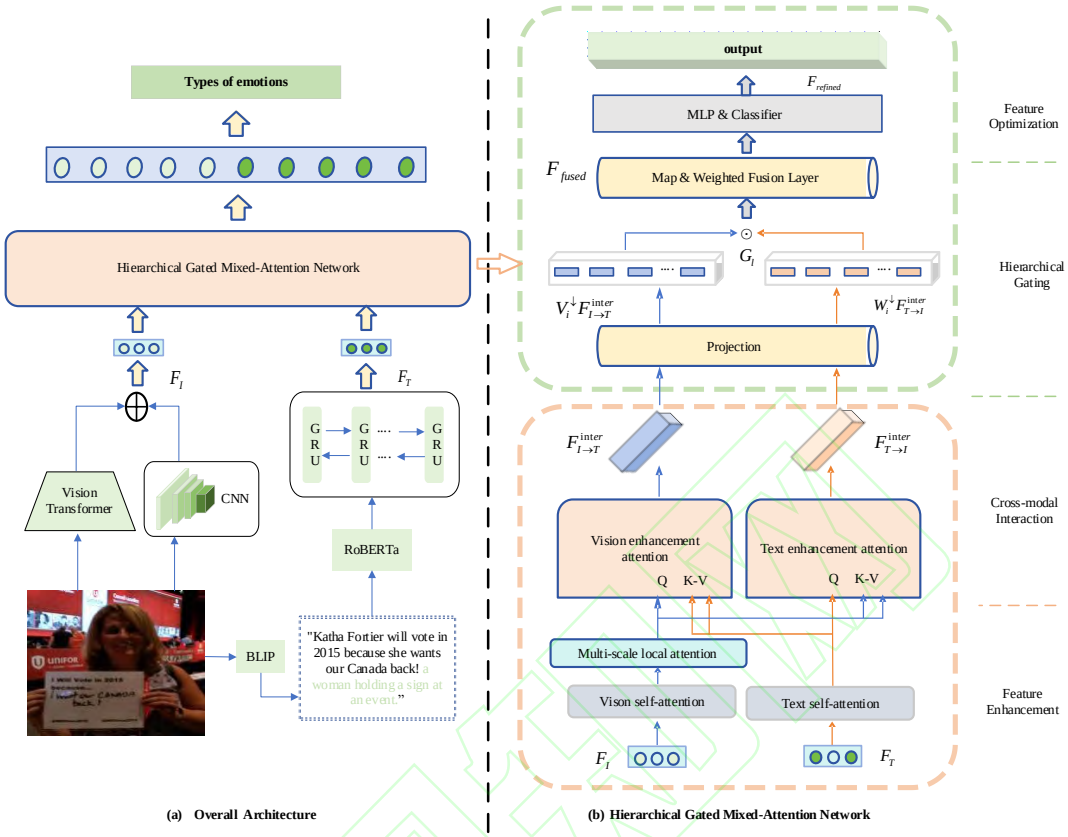

图 1 基于层次化门控与混合注意力机制的多模态情感分析模型的整体结构

Figure 1 The overall structure of the multimodal sentiment analysis model based on hierarchical gating and hybrid attention mechanisms.

3.1 图像字幕生成

为增强文本输入的语义信息，利用BLIP模型从输入图像生成图像字幕C_I。BLIP利用预训练的视觉-语言模型将图像信息生成对应的文本描述。生成过程如图 2 所示。

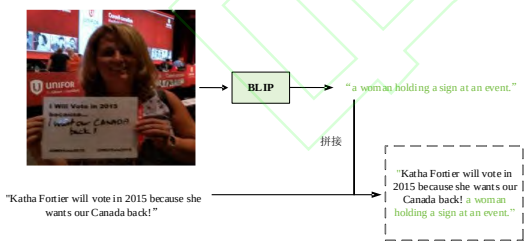

图 2 图像生成字幕

Figure 2 Image caption generation.

最终输入文本T由原始文本T_{raw}和图像字幕C_I拼接构成:

$$T = Concat(T_{raw}, C_I) \tag{1}$$

3.2 文本特征提取

本文采用RoBERTa和双向GRU的混合模型来提取文本特征。

（1）上下文嵌入

输入由公式(1)所得的文本T由分词器转化为标记化序列X，随后由RoBERTa基于Transformer架构提取其上下文语义嵌入，输出最后隐藏状态:

$$H_T = RoBERTa(X) \in R^{B\times N\times d} \tag{2}$$

其中X表示标记化的输入序列和注意力掩码，B为批次大小，N为序列长度，d为嵌入维度。

（2）序列建模与变换

将H_T输入进BiGRU，通过双向门控机制，在文本特征提取中有效结合上下文信息，能够生成更全面的语义表示：

$$\overrightarrow{h}_t = GRU(h_{t-1}^f, H_{T,t}) \tag{3}$$

$$\overleftarrow{h}_t = GRU(h_{t+1}^b, H_{T,t}) \tag{4}$$

$$F_T = Project([\overrightarrow{h}_1, \overrightarrow{h}_2]) \in R^{d_m} \tag{5}$$

其中，$\overrightarrow{h}_t$表示前向隐藏状态，$\overleftarrow{h}_t$表示后向隐藏状态，最终特征经过线性变换生成F_T，d_m为中间隐藏维度。

3.3 全局与局部图像特征提取

为充分获取图像的全局语义信息与局部细节特征，本文采用双分支特征提取策略：一支基于VisionTransformer(ViT)用于捕获图像的全局结构与语义关联；另一支基于ResNeXt，用于提取局部区域的细节特征。在保持全局一致性表达的同时，增强局部区域

的情感判别能力。

（1）全局特征提取

对于输入图像I，ViT将其划分为若干固定大小的图像块，并将这些块展平后输入至Transformer结构中。通过多头自注意力机制，ViT能够建模图像各区域之间的全局依赖关系，进而捕获图像的整体语义特征。其输出经卷积与线性变换调整序列长度和维度，使其与文本特征空间保持一致：

$$G_I = \text{Transform}(Conv1d(ViT(I))) \in R^{B\times N_r \times d_m} \tag{6}$$

其中N_r为调整后的序列长度，d_m为中间隐藏维度。

（2）局部特征增强

ResNeXt保留了ResNet的残差结构，能够在较深网络中稳定训练。同时，ResNeXt 通过“分组卷积”增加特征通道的多样性，以更好地捕捉局部区域的细节与纹理特征。该分支通过卷积骨干网络提取局部特征，并将输出展平后映射至目标维度：：

$$L_I = \text{Map}(\text{Re}sNeXt(I)_{flattened}) \in \text{R}^{B\times N_l \times d_m} \tag{7}$$

其中N_l为展平后的序列长度，d_m为中间隐藏维度。

（3）特征融合

最终，ViT输出的全局特征G_I与ResNeXt输出的局部特征L_I通过拼接操作形成图像的多层次特征表示：

$$F_I = Concat(G_I, L_I) \in R^{B\times(N_r+N_l)\times d_m} \tag{8}$$

融合后的F_I同时保留了全局语义一致性与局部增强细节，为后续多模态融合提供了更加丰富且稳定的视觉表示。

3.4 多模态融合

在HGMA-Net中，层次化门控与混合注意力机制是多模态特征融合的核心组成部分。有效整合文本特征F_T和图像特征F_I，减少冗余并增强模态间关联，从而提升模型在多模态情感分析任务中的性能。

（1）特征增强

特征增强阶段的目的是为了优化输入特征的表达能力，来为后续交互和融合提供高质量表示。该阶段结合自注意力机制和多尺度局部卷积，分别增强特征的全局一致性和局部细节。在模态内注意力和模态间注意力模块中，多头注意力机制发挥着至关重要的作用，能够有效增强特征的全局依赖性。在多头注意力机制下，文本和图像分别计算自注意特征：

$$\text{Q} = \text{W}_\text{Q}X，K = W_K X，V = W_V X \tag{9}$$

其中X表示输入特征，W_Q，W_K，W_V为线性映射矩阵，分别用于将输入特征转换为查询、键和值向量。

多头注意力内部采用缩放点积形式，注意力权重计算为：

$$Attention = soft\max(\frac{QK^T}{\sqrt{d_k}})\cdot V \tag{10}$$

多头拼接后：

$$MultiHead(Q,K,V) = W_0(Concat(head_1,.,head_h) \tag{11}$$

其中d_k是转换后的查询、键和值向量的维度。W_0为投影矩阵，将拼接后的多头特征映射回原维度。

①模态内交互

根据上述公式，最终输出通过残差连接和层归一化稳定，LN表示层归一化。文本和图像的自注意特征分别为：

$$F_I^{attn} = LN(F_I + \text{MultiHead}(F_I, F_I, F_I)) \tag{12}$$

$$F_T^{attn} = LN(F_T + \text{MultiHead}(F_T, F_T, F_T)) \tag{13}$$

残差连接保留原始信息，层归一化稳定输出分布，提升训练稳定性。

②多尺度局部卷积

为进一步增强图像特征的局部表达能力，引入多尺度卷积处理。使用窗口大小ω_i的分组卷积对F_T^{attn}进行局部特征提取：

$$\omega = \text{softmax}(\omega) \tag{14}$$

$$F_I^{enh} = F_I^{attn} + \sum_i \omega_i \cdot Conv_i(F_I^{attn}) \tag{15}$$

其中，ω_i通过可学习参数计算自适应权重，这样可增强图像的局部信息，同时保留自注意力的全局信息。通过全局与局部的协同建模，显著提升图像特征的质量，为跨模态交互奠定基础。而文本特征F_T^{attn}则保持自注意力的输出。

（2）跨模态交互

跨模态交互阶段通过双向多头注意力机制增强文本特征F_T^{attn}和图像特征F_I^{attn}的语义协同性，促进模态间的信息互补与对齐。

①文本引导图像交互

以文本为特征引导图像特征的增强，具体而言是将文本特征作为查询变量，图像特征作为键和值来计算跨模态增强特征：

$$F_{T\to I} = MultiHead(F_T^{enh}, F_I^{enh}, F_I^{enh}) \tag{16}$$

输出通过残差连接和归一化整合：

$$F_I^{\text{int}} = LN(F_I^{enh} + F_{T\to I}) \tag{17}$$

②图像引导文本交互

反之，将图像特征作为查询向量，文本特征作为键和值，生成由图像引导的跨模态增强特征表示：

$$F_{I\to T} = MultiHead(F_\text{I}^{enh}, F_\text{T}^{enh}, F_T^{enh}) \tag{18}$$

输出为：

$$F_\text{T}^{\text{int}} = LN(F_\text{T}^{enh} + F_{\text{I}\to T}) \tag{19}$$

通过双向交互，使文本能够关注图像相关区域，同时图像融入文本语义上下文，从而提升模态间的语义一致性。

（3）层次门控模块

层次门控机制通过多级门控机制动态整合文本和图像特征，减少冗余并优化语义一致性。采用降维、逐级交互和重建来有效融合多尺度特征，增强对模态间关系的适应性。其结构如图 3 所示：

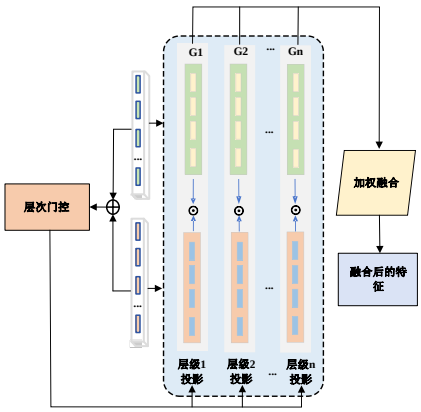

图 3 层次门控结构

Figure 3 Hierarchical Gating Structure.

首先交互特征被投影到较低维度：

$$F_t^l = W_l^{\downarrow} F_t^{\text{int}},\ F_i^l = V_l^{\downarrow} F_i^{\text{int}} \tag{20}$$

其中 $W_l^{\downarrow}$ 和 $V_l^{\downarrow}$ 是对应于不同维度 d_l 的降维矩阵，l为层次数。

通过这种分解，模块能够捕获从全局到局部的多尺度语义信息，适应不同任务的粒度需求。此外，降维设计优化了计算复杂度，提升了模型效率。在每个层次上计算模态间的门控权重：

$$G_l = \sigma(F_t^l \cdot F_i^l) \tag{21}$$

F_t^l 和 F_i^l 进行逐元素乘法来捕捉模态间的局部相关性，其中 σ 是sigmoid函数能够将结果归一化为[0,1]，生成门控特征，从而筛选出模态间的相关特征，有效抑制无关信息（如图像背景噪声或文本冗余词），增强融合特征的语义纯度。同时，逐级交互结合残差结构提升了训练稳定性，使模块在多样化场景下能够保持稳定。

特征通过上采样和加权融合重建：

$$F_{fused} = \sum_l \gamma_l \cdot Map_{d_l \to d_m}(G_l) \tag{22}$$

其中 γ_l 是由门控网络生成的逐级权重，此权重机制根据输入特征动态调整各层次的融合比例，确保文本与图像信息的平衡。

$$\gamma = \text{softmax}(MLP([F_t^{\text{int}}; F_i^{\text{int}}])) \tag{23}$$

通过加权求和整合各层次特征 G_l，γ_l 动态控制每个层次的贡献，最终生成融合特征 F_{fused}。这种动态融合机制为模型赋予了根据任务特性灵活调整模态贡献的能力，从而显著提升了其自适应性。

（4）特征优化

特征优化模块通过残差连接和前馈网络来增强融合特征的稳定性和表达能力，核心优化过程如下：

$$F_{refined} = LN(F_T + F_{fused} + TF(GLU(F_{norm1}))) \tag{24}$$

其中 $F_{norm1} = LN(F_T + F_{fused})$，优化后的特征通过分类器处理以生成类别预测。最终输出为：

$$Output = Classifier(F_{refined}) \in \mathrm{R}^{\mathrm{B} \times \text{num_classes}} \tag{25}$$

为了优化模型参数并提升多模态情感分析性能，本文根据数据集特性设计了不同的损失函数。对于MVSA数据集，采用标准交叉熵损失函数，衡量预测分布与真实标签分布的差异，定义为：

$$L = -\sum_i \hat{y}_i \log y_i \tag{26}$$

其中，$\hat{y}_i$ 是真实标签分布，y_i是最终输出的*output*。

为缓解TumEmo数据集中七类标签分布严重不均的问题，本文设计了加权交叉熵损失函数。类权重根据各类别样本数量计算为 $w_c = N / N_c$，其中N为总样本数，N_c 为第c类样本数。损失函数定义为：

$$L_{wce} = -\sum_i w_i \hat{y}_i \log y_i \tag{27}$$

该策略能有效提升模型对少数类别的判别能力。

4 实验与分析

4.1 数据集

本文在 MVSA-Single、MVSA-Multiple[32] 和 TumEmo[23]三个公开的多模态情感分析数据集上来验证所提方法的有效性。其中，MVSA-Single包含 5129 对图文样本，每条样本均由单个标注者对图像和文本分别标注情感标签。MVSA-Multiple由 19600 对图文样本组成，每条样本由三位标注者独立进行情感标注，以反映不同标注者对同一图文对的情感认知差异。TumEmo数据集来源于Tumblr，包含 195265 组图文样本，并标注了七类情感标签。

在数据预处理中，为了确保情感标签的一致性，对MVSA 数据集按照Xu[28]的方法进行了筛选。对于MVSA-Single，移除文本与图像情感标签冲突（积极、消极）的样本；当一方为中性时，采用另一方的非中性标签作为最终情感标签。对于MVSA-Multiple，先通过投票确定文本和图像的情感标签，保留至少两位标注者一致的样本，再移除标签冲突的样本，并以非中性标签作为最终情感类别。

经过上述预处理，获得最终的数据集，用于模型训练和评估，确保数据质量的同时，也提升了模型在多模态情感分析任务中的可靠性和有效性。MVSA数据集相关数据统计如表 1 所列，Tum Emo数据集如表 2 所示。

表 1 预处理后的MVSA数据集

Table 1 Preprocessed MVSA Dataset

Dataset	Positive	Neutral	Negative	Total
MSVA-Single	2683	470	1358	4511
MSVA-Multiple	11318	4408	1298	17024

表 2 TumEmo数据集情感类别统计
Table 2 Statistics of Sentiment Categories in the TumEmo dataset

情感	Angry	Bored	Calm	Fear	Happy	Love	Sad	Total
数量	14544	32283	18109	20264	50267	34511	25277	195265

4.2 实验具体设置

本文使用PyTorch框架实现模型，在实验设置中，数据集被随机划分为训练集、验证集和测试集，比例为8:1:1。所有实验均在NVIDIA RTX 4090 24GB GPU上进行。为评估模型性能，本文采用准确率(Accuracy)和F1 分数作为评估指标，具体参数如表 3 所示。

表 3 参数设置
Table 3 Parameter Settings

参数名称	MSVA-Single	MSVA-Multiple	TumEmo
批处理大小	32	64	128
学习率	3e-5	3e-5	5e-5
优化器	AdamW	AdamW	AdamW
丢弃率	0.1	0.1	0.2
权重衰减	5e-3	5e-3	5e-3
局部分组卷积	[3,5]	[3,5]	[3,5]
注意力头数	8	8	8

4.3 基线模型

为验证所提出模型的有效性，本文在MVSA-Multiple、MVSA-Single和TumEmo三个多模态情感分析数据集上，与当前具有代表性的先进模型进行了对比实验。考虑到部分基线模型针对特定数据集设计，为确保评估的公平性与科学性，本文在每个数据集上选取了相应的最优对比方法作为比较对象。

HSAN[21]:通过层次语义注意与图像字幕提取视觉特征，引入上下文注意力以提升分类性能。

MVAN[23]:通过记忆网络和多视图注意力融合图文语义，结合物体与场景信息，实现交互式跨模态学习。

CLMLF[33]:提出一种对比学习与多层融合的方法，提升模型对多模态情感特征的学习能力。

MVCN[34]:提出多视图校准网络，通过稀疏注意与校准策略缓解模态异质性问题。

ITIN[29]:通过跨模态对齐和自适应门控融合，捕获区域-词语关系与上下文，实现高精度情感分析。

VSA-PF[35]:通过专家分支与BERT融合，高效实现视觉-文本情感分析。

CIGCN[25]:构建属性图与文本图神经网络，结合多头注意力实现多模态融合，提升图文情感分析准确性。

HIFCL[36]:通过层次交互融合提升多模态情感分析性能。

MDSE[37]:通过挖掘私有与共享特征并融合，引入MACL对齐模态，提升多模态情感分析性能。

MGNNS[26]:通过多模态编码、全局特征学习与注意力机制实现情感感知建模。

CoDe[38]:通过OCR补全语义并结合对比学习对齐情感，提升多模态情感分类性能。

4.4 实验结果与分析

表4和表5展示了不同模型在MVSA-Single、MVSA-Multiple和TumEmo三个数据集上的准确率和F1指标的实验结果。

表 4 不同模型在MVSA数据集上的实验结果
Table 4 The experimental results of different models on MVSA datasets

Method	MVSA-Single		MVSA-Multiple	
	Accuracy	F1	Accuracy	F1
HSAN	0.6988	0.6690	0.6796	0.6776
MVAN	0.7298	0.7298	0.7236	0.7230
MGNNS	0.7377	0.7270	0.7249	0.6934
CLMLF	0.7533	0.7346	0.7200	0.6983
CIGCN	0.7511	0.7333	0.7341	0.7096
MVCN	0.7606	0.7455	0.7207	0.7001
ITIN	0.7519	0.7497	**0.7352**	**0.7349**
MDSE	0.7622	0.7571	0.7231	0.7012
CoDe	0.7694	0.7634	0.7275	0.7069
VSA-PF	0.7558	0.7448	0.7126	0.6872
HGMA-Net	**0.7723**	**0.7652**	**0.7344**	**0.7075**

表 5 不同模型在TumEmo数据集上的实验结果
Table 5 The experimental results of different models on TumEmo datasets

Method	TumEmo	
	Accuracy	F1
HSAN	0.6309	0.5398
MVAN	0.6553	06543
MGNNS	0.6672	0.6669
HIFCL	0.6844	0.6827
CoDe	0.7326	0.7320
VSA-PF	0.7658	0.7657
HGMA-Net	**0.7977**	**0.7994**

相较于早期的HSAN模型，尽管在当时取得了较好效果，但在图像与文本间缺乏有效的交互建模，存在一定局限。MVAN的注意力机制较为单一，难以捕捉细粒度的多模态特征。CLMLF和MVCN分别引入了对比学习机制与稀疏注意力融合架构，以增强特征学习能力，但其融合方式较为静态，缺乏灵活性。HIFCL虽然在小规模数据集上具有良好表现，但在如TumEmo等大规模数据集上泛化能力不足。MGNNS注重样本间的关系建模，但在细粒度特征提取方面存在短板。相比之下，HGMA-Net通过层次化特征融合策略与动态门控机制的协同设计，有效增强了图文间的细粒度情感表达能力。ITIN则结合跨模态对齐与自适应门控融合机制，在MVSA-Multiple数据集上表现优越，甚至在性能上超过HGMA-Net，表明其在区域-词语对齐关系建模方面具有明显优势。但在MVSA-Single数据集上，HGMA-Net凭借更全面的上下文整合与精细的融合策略，展现出更强的稳定性和适应性。

此外，与HGMA-Net相比，VSA-PF虽然也融合了多个预训练模型和多分支结构，但其训练与推理流程更为复杂，增加了模型部署的难度。MDSE则侧重于模态私有特征的建模，忽视了模态间深层次的交互信息。而HGMA-Net在模态内特征提取与模态间交互建模之间实现了有效的平衡，能够充分挖掘上下文语义信息，

从而提升多模态理解能力与模型的泛化性能。

4.5 消融实验

为验证各模块的作用，在MVSA-Single、MVSA-Multiple和TumEmo三个数据集上进行了消融实验。具体而言，分别去除特征增强、跨模态交互和层次门控模块，记为 hn_enh、hn_cross 和 hn_hg。其中，混合注意力模块由特征增强与跨模态交互两部分组成，两者协同实现模态间的信息融合。因此，去除层次门控模块（hn_hg）后，模型仅保留混合注意力结构，用以验证混合注意力模块在多模态融合中的独立作用。为进一步分析层次门控的独立贡献，保留层次门控并移除混合注意力模块，记为hn_att。此外，同时去除所有模块的变体记为hn_all。最后，为了验证图像字幕的加入是否为多模态情感分析提供更丰富的语义信息，将其去除，命名为hn_cap。其结果如表 6 所列。

表 6 消融实验结果

Table 6 Ablation Study Results

Method	MVSA-Single		MVSA-Multiple		TumEmo	
(w/o)	Acc	F1	Acc	F1	Acc	F1
hn_cross	0.7500	0.7443	0.7224	0.6990	0.7835	0.7883
hn_hg	0.7411	0.7356	0.7188	0.6966	0.7785	0.7798
hn_enh	0.7533	0.7346	0.7200	0.6983	0.7924	0.7957
hn_att	0.7433	0.7312	0.7175	0.6872	0.7632	0.7665
hn_cap	0.7567	0.7502	0.7151	0.6887	0.7908	0.7934
hn_all	0.7299	0.7239	0.7115	0.6781	0.7557	0.7592
Our	0.7723	0.7652	0.7344	0.7075	0.7977	0.7994

根据消融实验的结果，可以发现：①HGMA-Net在三个数据集上取得最佳性能，去除任何模块都会导致次优的预测结果。②w/o hn_enh与完整模型相比有较小幅度下降，说明特征增强模块通过多尺度特征挖掘有效强化了图像的表征能力，为情感判别提供了更具区分性的输入表示。③w/o hn_cross的性能下降较为显著，表明跨模态交互模块在图文语义关联方面发挥了关键作用，能够有效促进不同模态之间的语义融合与信息互补。④w/o hn_hg的结果相较性能虽有所下降，但仍保持较强表现，说明混合注意力在增强模态内和模态间交互、捕捉图文深层语义依赖方面起核心作用。⑤w/o hn_att性能略有下降，但仍体现出其在动态调节模态特征权重、抑制冗余信息方面的重要作用。⑥HGMA-Net在移除图像字幕后性能显著下降，说明图像字幕通过提升语义表达能力，为模型注入丰富上下文信息，增强多模态情感分析效果。

总之，每个模块都提供了不同信息处理特性。这些特性凸显了各模块的不可或缺性，使得模型能够全面捕捉图文之间的复杂关系，共同对最终的性能做出贡献。

4.6 超参数分析

为进一步探究层次门控模块在多模态特征融合中的作用，本文在MVSA-Single与MVSA-Multiple两个具有代表性的数据集上，系统分析了层级数(num_levels)的影响，即公式(20)中所述的l。该参数控制融合模块的层次粒度与复杂性，是本模型结构设计中的关键变量。尽管TumEmo数据集包含近 20 万条图文对，为降低计算开销并便于观察性能变化趋势，超参数分析部分仍选取较小数据集进行。如图 4 所示，不同层级数设置下模型性能的变化趋势，进一步验证了层次结构在提升多模态融合表达能力方面的重要性。随着num_levels从 1 增至 9，模型的准确率和F1 值持续提升，在num_levels=9 时达到峰值，取得了最佳性能。这一结果表明，num_levels=9 在捕获细粒度多模态特征交互与防止过拟合之间实现了最佳平衡。而当num_levels=10时，性能显著下降，可能是由于过度复杂的层次结构引入信息冗余或优化难度增加。基于上述分析，最终将层级数设定为 9。

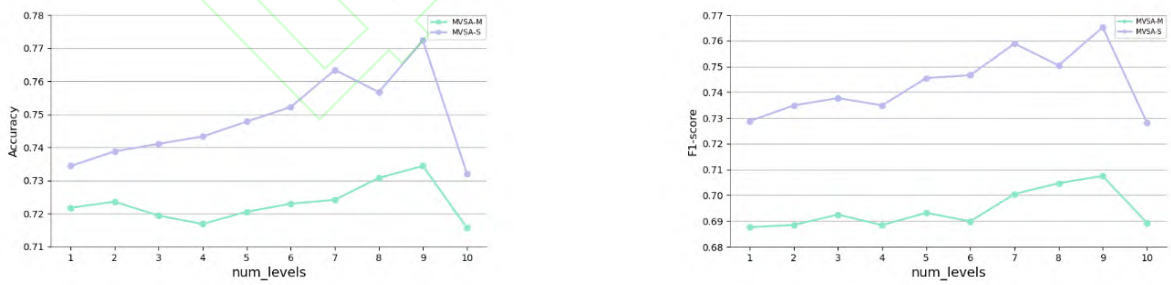

图 4 不同层级数在MVSA数据集上的性能变化

Figure 4 Performance variations with different numbers of layers on the MVSA dataset.

4.7 可视化分析

为了直观展示本文提出模型的优势，本文从数据集中随机抽取三个样本进行可视化对比分析。具体如表 7 所列。

表 7 样本原图

Table 7 Original Sample Image

样本1	样本2	样本3

（1）不同模块的情感特征可视化

通过不同模块的图文融合特征自注意力矩阵，分析图像与文本的交互作用，凸显HGMA-Net在多模态情感分析中的优越性。其中，原始拼接模块仅基于原始文本输入，而其余模块均基于原始文本与图像字幕的组合输入。其结果如表 8 所列。

原始拼接模块通过直接拼接图像与文本特征形成融合表示，能够反映token之间的初步关联性，为图文融合提供基准，但缺乏针对性优化。随着图像字幕的引入，热图中与图像内容相关的文本token相关性显著增强，表明视觉语义有效补充了文本信息，提升了输入的语义完整性。混合注意力模块进一步强化了模态内与模态间的语义联系，使注意力热图更集中于情感判别相关的关键token对，显著深化了图文融合效果。而层次门控模块的热图显示，其能够有效抑制模态间冗余信息，均衡注意力分布，提升融合特征的相关性与判别性。最终，HGMA-Net模型综合各模块优势，热图深色区域清晰对应情感分类关键token对，验证了模型在跨模态语义关联捕捉上的优越性。

表 8 不同模块的情感特征可视化结果

Table 8 Sentiment Feature Visualization Results of Different Modules

样本	文本	原始拼接	+图像字幕	+混合注意力	+层次门控	HGMA-Net
(1)	Knocked doors with the venerable this aft in my hometown, Aurora!	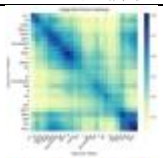	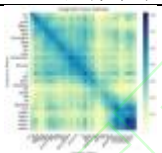	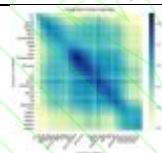	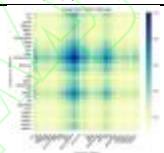	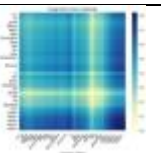
(2)	Great AM with riding neighbors sharing our plan for Real Change!	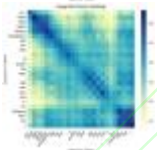	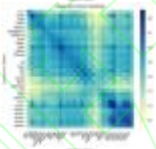	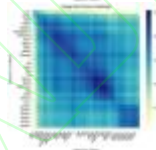	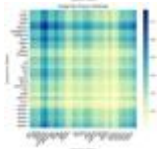	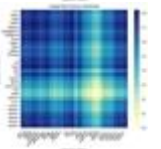
(3)	Huge fan girl moment as I chatted w/ former prime minister, Paul Martin 2day.	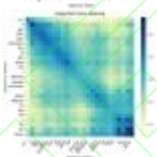	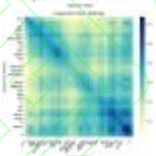	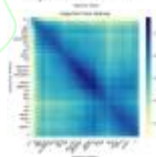	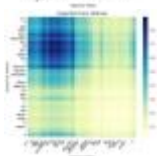	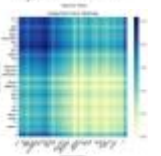

通过可视化对比分析，展示了图文融合中各个模块的独特贡献，体现了HGMA-Net在情感分类中的聚焦能力，验证了其分类性能的优越性。

（2）预测样本分析

为进一步探究HGMA-Net的有效性，对这三个样本进行情感预测，标签分为积极、中性和消极。并将提取到的图像模态表征进行可视化。具体结果如表 9 所列。其中，模型有效捕捉了样本 1 和样本 3 积极情感特征，展现了其在多模态特征融合和情感识别中的强大能力；而样本 2 的预测略有偏差（中性vs积极），可能与特定语境或视觉线索的复杂性有关，但总体而言，模型仍展现出良好的适应性和潜力。未来可通过进一步优化特征权重或扩展训练数据，持续提升其在类似边界案例中的表现，同时结合热图分析深入探讨注意力机制的分布，以充分发挥模型优势。

表 9 预测结果可视化

Table9. Visualization of Prediction Results

样本	文本	图像表征可视化	预测结果	实际结果
(1)	Knocked doors with the venerable this aft in my hometown, Aurora! two men standing in front of a building	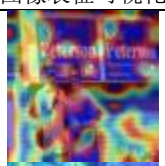	积极(√)	积极
(2)	Great AM with riding neighbors sharing our plan for Real Change! a col of a man and woman in red shirts		中性(×)	积极
(3)	Huge fan girl moment as I chatted w/ former prime minister, Paul Martin 2day.a man and woman standing next to each other people	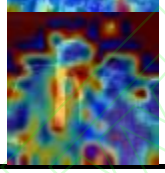	积极(√)	积极

5 结束语

本文提出的HGMA-Net模型整合BLIP生成的图像字幕以提升输入语义层次义，结合层次化门控动态调控模态融合，并通过混合注意力深化模态间语义交互，同时多尺度挖掘图像序列化特征的深层关联，有效解决了多模态融合中的冗余与关联不足问题，突破了传统方法在复杂情感分析中的瓶颈，显著提升了情感的识别精度。实验结果表明，本文方法在三个公开基准数据集上优于一系列基线模型，验证了其有效性。

然而，当前研究仍存在一定局限性：HGMA-Net在处理极端图文语义冲突或高噪声输入时仍面临挑战，模型在复杂场景下的稳定性有待进一步提升。未来的研究将重点优化层次化门控与注意力结构的计算效率，以提升模型在复杂场景下的适应与泛化能力。同时，将探索引入更多模态信息（如音频、视频），以增强情感表达的完整性并扩展模型的多模态应用潜力。

参考文献

[1] Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 10012-10022.

[2] Poria S, Cambria E, Hazarika D, et al. Multi-level Multiple Attentions for Contextual Multimodal Sentiment Analysis[C]//Proceedings of IEEE International Conference on Data Mining. Piscataway, NJ: IEEE Press, 2017: 1033-1038.

[3] Bertasias G, Torresani L, Yu S X, et al. Convolutional Random Walk Networks for Semantic Image Segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 858-866.

[4] Machajdik J, Hanbury A. Affective Image Classification Using Features Inspired by Psychology and Art Theory[C]//Proceedings of the 18th ACM International Conference on Multimedia. 2010: 83-92.

[5] Revina I M, Emanuel W R S. Face Expression Recognition with the Optimization Based Multi-SVNN Classifier and the Modified LDP Features[J]. Journal of Visual Communication and Image Representation, 2019, 62(1): 43-55.

[6] Zhao S, Gao Y, Jiang X, et al. Exploring Principles-of-Art Features for Image Emotion Recognition[C]//Proceedings of the 22nd ACM International Conference on Multimedia. 2014: 47-56.

[7] Chen T, Borth D, Darrell T, et al. DeepSentiBank: Visual Sentiment Concept Classification with Deep Convolutional Neural Networks[J]. arXiv preprint arXiv:1410.8586, 2014.

[8] Rao T, Xu M, Liu H, et al. Multi-scale Blocks Based Image Emotion Classification Using Multiple Instance Learning[C]//2016 IEEE International Conference on Image Processing (ICIP). Piscataway, NJ: IEEE, 2016: 634-638.

[9] You Q, Jin H, Luo J. Visual Sentiment Analysis by Attending on Local Image Regions[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2017, 31(1): 634-638.

[10] Wu L, Qi M, Jian M, et al. Visual Sentiment Analysis by Combining Global and Local Information[J]. Neural Processing Letters, 2020, 51(4): 2063-2075.

[11] Jurek A, Mulvenna M D, Bi Y. Improved Lexicon-Based Sentiment Analysis for Social Media Analytics[J]. Security Informatics, 2015, 4(1): 1-13.

[12] 崔彦琛, 张鹏, 兰月新,等. 消防突发事件网络舆情情感词典构建研究[J]. 情报杂志,2018,37(10):154-160.(Cui Yanchen, Zhang Peng, Lan Yuexin, et al. On the Construction of Sentiment Lexicon for Emergency Network Public Opinion of Fire Services.[J]. journal of intelligence,

基金项目：教育部人文社会科学研究规划基金项目（21YJA630054）

2018,37(10):154-160.)
[13] Gamon M. Sentiment Classification on Customer Feedback Data: Noisy Data, Large Feature Vectors, and the Role of Linguistic Analysis[C]//Proceedings of the 20th International Conference on Computational Linguistics (COLING). 2004: 841-847.
[14] Tiwari P, Kumar S, Kumar V, et al. Implementation of N-Gram Methodology for Rotten Tomatoes Review Dataset Sentiment Analysis[M]//Cognitive Analytics: Concepts, Methodologies, Tools, and Applications. Hershey, PA: IGI Global, 2020: 689-701.
[15] Soumya S, Pramod K V. Sentiment Analysis of Malayalam Tweets Using Machine Learning Techniques[J]. ICT Express, 2020, 6(4): 300-305.
[16] Wang T, Lu K, Chow K P, et al. COVID-19 Sensing: Negative Sentiment Analysis on Social Media in China via BERT Model[J]. IEEE Access, 2020, 8: 138162-138169.
[17] Yuan Z, Wu S, Wu F, et al. Domain Attention Model for Multi-domain Sentiment Classification[J]. Knowledge-Based Systems, 2018, 155: 1-10.
[18] Kanwal I, Wahid F, Ali S, et al. Sentiment Analysis Using Hybrid Model of Stacked Auto-Encoder-Based Feature Extraction and Long Short Term Memory-Based Classification Approach[J]. IEEE Access, 2023, 11: 124181-124197.
[19] Karn A L, Karna R K, Kondamudi B R, et al. Customer Centric Hybrid Recommendation System for E-Commerce Applications by Integrating Hybrid Sentiment Analysis[J]. Electronic Commerce Research, 2023, 23(1): 279-314.
[20] Kipf T N, Welling M. Semi-supervised Classification with Graph Convolutional Networks[J]. arXiv preprint arXiv:1609.02907, 2017.
[21] Xu N. Analyzing Multimodal Public Sentiment Based on Hierarchical Semantic Attentional Network[C]//Proceedings of the 2017 IEEE International Conference on Intelligence and Security Informatics (ISI). Piscataway, NJ: IEEE, 2017: 152-154.
[22] Tan H, Bansal M. LXMERT: Learning Cross-modality Encoder Representations from Transformers[J]. arXiv preprint arXiv:1908.07490, 2019.
[23] Yang X, Feng S, Wang D, et al. Image-text Multi-modal Emotion Classification via Multi-view Attentional Network[J]. IEEE Transactions on Multimedia, 2020, 23(1): 4014-4026.
[24] Mu G, Chen Y, Li X, et al. Semantic Enhancement and Cross-modal Interaction Fusion for Sentiment Analysis in Social Media[J]. PLoS One, 2025, 20(4): e0321011.
[25] Wang H, Ren C, Yu Z. Multimodal Sentiment Analysis Based on Cross-instance Graph Neural Networks[J]. Applied Intelligence, 2024, 54(4): 3403-3416.
[26] Yang X, Feng S, Zhang Y, et al. Multimodal Sentiment Detection Based on Multi-channel Graph Neural Networks[C]//Proceedings of the Association for Computational Linguistics and the International Joint Conference on Natural Language Processing. 2021, 1: 328-339.
[27] Han W, Chen H, Gelbukh A, et al. Bi-bimodal Modality Fusion for Correlation-controlled Multimodal Sentiment Analysis[C]//Proceedings of the International Conference on Multimodal Interaction. New York: ACM Press, 2021: 6-15.
[28] Xu N, Mao W J. MultiSentiNet: A Deep Semantic Network for Multimodal Sentiment Analysis[C]//Proceedings of the ACM Conference on Information and Knowledge Management. New York: ACM Press, 2017: 2399-2402.
[29] Zhu T, Li L, Yang J, et al. Multimodal Sentiment Analysis with Image-text Interaction Network[J]. IEEE Transactions on Multimedia, 2023, 25(3): 3375-3385.
[30] Quan W Z, Feng Y F, Zhou M, et al. TCAN: Text-oriented Cross Attention Network for Multimodal Sentiment Analysis[J]. arXiv preprint arXiv:2404.04545, 2024.
[31] Jiang M, Ji S X. Cross-modality Gated Attention Fusion for Multimodal Sentiment Analysis[J]. arXiv preprint arXiv:2208.11893, 2022.
[32] Niu T, Zhu S, Pang L, et al. Sentiment Analysis on Multi-view Social Data[C]//Proceedings of the International Conference on Multimedia Modeling. 2016: 15-27.
[33] Li Z, Xu B, Zhu C, et al. CLMLF: A Contrastive Learning and Multi-layer Fusion Method for Multimodal Sentiment Detection[C]//Findings of the Association for Computational Linguistics: NAACL 2022. 2022: 2282-2294.
[34] Wei Y, Yuan S, Yang R, et al. Tackling Modality Heterogeneity with Multi-View Calibration Network for Multimodal Sentiment Detection[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics: Long Papers. 2023: 5240-5252.
[35] Chen J, An J, et al. Holistic Visual-Textual Sentiment Analysis with Prior Models[C]//International Conference on Mathematics & Computers in Sciences & Industry. Piscataway, NJ: IEEE Computer Society, 2024: 134-137.
[36] Wang H, Du Q, Xiang Y, et al. Image–Text Sentiment Analysis Based on Hierarchical Interaction Fusion and Contrast Learning Enhanced[J]. Engineering Applications of Artificial Intelligence, 2025, 146: 110262.
[37] Li J, Wang C, Luo Z, et al. Modality-Dependent Sentiments Exploring for Multi-Modal Sentiment Classification[C]//Proceedings of the 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Seoul: IEEE, 2024:

7930-7934.
[38] Wu D, Yang D, Shen H, et al. Resolving Sentiment Discrepancy for Multimodal Sentiment Detection via Semantics Completion and Decomposition[J]. Engineering Applications of Artificial Intelligence, 2025, 146: 110667.

作者简介:

李娅娅　硕士研究生，2518797154@qq.com

胡彦蓉　博士，副教授，yanrong_hu@zafu.edu.cn

刘洪久（通讯作者）博士，教授，joe_hunter@zafu.edu.cn

中国知网