分类号：_____ 单位代码：10300

密　级：_____ 学　　号：202212490416

南京信息工程大学

硕士专业学位论文

论文题目：基于特征优化的文本情感分析研究

申请人姓名：黄方彬

指 导 教 师：王一力

类 别 名 称：电子信息

领 域 名 称：计算机技术

培 养 学 院：计算机学院、网络空间安全学院

提 交 时 间：2025 年 12 月 12 日

二〇二五年十二月

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究进展.....2
1.2.1 文本情感分析技术.....2
1.2.2 表示学习.....5
1.3 主要研究内容.....7
1.4 本文章节安排.....8
第二章 相关技术理论.....9
2.1 特征权重优化.....9
2.1.1 鲸鱼优化算法.....9
2.1.2 遗传算法.....10
2.2 文本情感分析模型.....11
2.2.1 卷积神经网络.....11
2.2.2 循环神经网络.....13
2.2.3 双向长短期记忆网络.....15
2.2.4 Transformer.....16
2.2.5 注意力机制.....18
2.2.6 图神经网络.....22
2.3 评价指标.....23
2.4 本章小结.....23
第三章 基于 CCIGWO 的文本情感分析.....25
3.1 问题引出.....25
3.2 CCIGWO 模型的整体结构.....26
3.2.1 圆混沌初始化.....26
3.2.2 局部开发阶段.....29
3.2.3 全局探索阶段.....30
3.2.4 收敛调整阶段.....31
3.2.5 遗传阶段.....32
3.2.6 输出层.....33
3.3 数据集和实验设置.....33
3.3.1 数据集.....33
3.3.2 实验参数与环境.....34
3.4 实验结果及性能评估.....35
3.4.1 基线方法及对比分析.....35

中国知网 https://www.cnki.net

3.4.2 词嵌入分布可视化与方法随机性排除 39
3.4.3 消融实验.....41
3.5 本章小结.....42
第四章 基于 HP-MHPA 的文本情感分析.....43
4.1 问题引出.....43
4.2 HP-MHPA 模型的整体结构.....44
4.2.1 正负类别嵌入.....45
4.2.2 多头多极注意力机制.....46
4.2.3 混合位置编码.....47
4.2.4 输出层.....49
4.2.5 复合多极损失函数.....50
4.3 数据集和实验设置.....50
4.3.1 实验数据.....50
4.3.2 实验参数.....51
4.4 实验结果与分析.....52
4.4.1 对比实验结果与分析.....52
4.4.2 注意力可视化结果.....55
4.4.3 消融实验.....56
4.5 本章小结.....56
第五章 总结与展望 58
5.1 论文总结.....58
5.2 研究展望.....58
参考文献.....60

中国知网 https://www.cnki.net

摘 要

近些年来，深度学习技术在文本分类、机器翻译、问答系统等自然语言处理领域取得了显著进展。然而，随着社交媒体中文本数量的急剧增长，情感信息的自动化处理遭遇了新的挑战，这促使文本情感分析成为当前的研究热点之一。文本情感分析有助于提高情感识别的准确性，还为舆情监测、用户反馈分析等实际应用提供重要技术支撑。通过深入剖析文本情感分析方法，可有效挖掘潜在情感特征，从而实现更精准的情感倾向识别。表示学习技术的持续进步也推动着文本情感分析方法的发展。其中，特征权重优化作为一种关键技术，通过对词嵌入中的特征权重优化，增强了词语的情感表达能力，为分类任务提供更为有效的输入。

尽管当前基于深度学习的情感分析模型已经取得了一些成果，但是仍然存在诸多不足之处。一方面，大多数方法在特征表达阶段仍然依赖静态词向量或通用预训练词嵌入，难以充分凸显与任务高度相关的情感信息，从而影响模型对情绪倾向的精准刻画。另一方面，现有模型在结构设计上普遍缺乏对多层次特征的充分挖掘与融合，难以精准建模情感转折等复杂情感现象，导致泛化能力和鲁棒性较弱。此外，部分方法对情感特征的深层建模不够，降低了分类效果，针对上述问题，本文围绕特征权重优化与多层特征融合这两个核心方向，分别提出了相应的改进方法，最终得出了以下结论：

（1）提出了一种基于圆混沌初始化与遗传鲸鱼优化的词嵌入优化算法（CCIGWO）。此方法借助 TF-IDF 权重引导机制，运用全局搜索策略对词嵌入向量进行自适应微调，以此提高其情感表征能力，于多个英文情感数据集上，同 GloVe、Word2Vec、Emo2Vec、SoftEMD、WordFast、Doc2Vec 等主流词嵌入方法开展对比实验。实验结果显示，CCIGWO 针对不同词嵌入的 F1 值平均提升幅度处于 2%至 5%范围之间，其中在 Twitter 数据集上表现最佳，最终模型 F1 值为 86.47%。

（2）不同于上述侧重于词嵌入优化的方法，设计了一种融合多头多极注意力机制与混合位置编码的文本情感分析模型（HP-MHPA）。此模型把全局位置编码信息与局部位置编码信息相结合，借助多头多极注意力机制来提高对情感极性特征的捕捉能力，对比试验涉及 TinyBERT、FNet、MobileBERT、Transformer Encoder 等主流模型，HP-MHPA 于 IMDB、Twitter2016 以及 Yelp 这三个英文情感数据集上，分别达成了 68.73%、81.79%以及 85.41%的 F1 值，相较于其他主流模型都有较大优势，尤其在复杂长文本以及多情

中国知网 https://www.cnki.net

感交织的场景里表现更为稳健，呈现出良好的泛化能力与应用潜力。

关键词：文本情感分析，注意力机制，深度学习，特征优化

中国知网 https://www.cnki.net

Abstract

In recent years, deep learning techniques have achieved remarkable progress in natural language processing tasks such as text classification, machine translation, and question answering. However, with the rapid growth of text data on social media platforms, the automated processing of sentiment information has encountered new challenges, making text sentiment analysis a prominent research topic. Text sentiment analysis not only improves the accuracy of sentiment recognition but also provides essential technical support for practical applications such as public opinion monitoring and user feedback analysis. Through an in-depth investigation of sentiment analysis methods, latent sentiment features can be effectively explored, thereby enabling more accurate identification of sentiment polarity. The continuous advancement of representation learning techniques has further promoted the development of sentiment analysis approaches. Feature weight optimization, as a key technique, enhances the sentiment expressiveness of words by optimizing the feature weights in word embeddings, thus providing more effective representations for sentiment classification tasks.

Although some achievements have been made in sentiment analysis models based on deep learning, there are still many problems. One aspect is that most methods still rely on static word vectors or generic pre trained word embeddings during the feature expression stage, which makes it difficult to fully highlight emotional information highly relevant to the task, thereby affecting the accurate characterization of emotional tendencies by the model. On the other hand, in the structural design of existing models, they generally do not fully explore and integrate multi-level features, making it hard to accurately model complex emotional phenomena such as emotional transitions. This makes both generalization ability and robustness relatively weak. Furthermore, some existing methods fail to adequately model sentiment features at a deep level, which degrades classification performance. To address these issues, this study focuses on two core directions, namely feature weight optimization and multi-level feature fusion, and proposes corresponding improvement methods for each. Based on these approaches, the following conclusions are drawn:

(1) A word embedding optimization algorithm based on Circular Chaotic Initialization

中国知网 https://www.cnki.net

and Genetic Whale Optimization (CCIGWO) is proposed to improve sentiment representation capability. This method relies on the TF-IDF weight guidance mechanism and uses the global search strategy to adaptively fine-tune the word embedding vector, thereby improving the ability of the word embedding vector to express emotions. This paper conducts comparative experiments on it with mainstream word embedding methods such as GloVe, Word2Vec, Emo2Vec, SoftEMD, WordFast, and Doc2Vec on multiple English sentiment datasets. The results of the experiment show that CCIGWO can increase the F1 score of different word embeddings by an average of 2% to 5%. Among them, its performance on the Twitter dataset is the best, and the final F1 score of the model reaches 86.47%.

(2) Unlike the aforementioned approach that focus on word embedding optimization, designs a text sentiment analysis model that integrates a multi-head multi-polarity attention mechanism with hybrid positional encoding (HP-MHPA), which is designed to overcome the limitations of existing models in complex semantic modeling. This model combines global position encoding information with local position encoding information and adopts a multi-head and multi-pole attention mechanism, which enhances its ability to capture emotional polarity features. Some mainstream models such as TinyBERT, FNet, MobileBERT and Transformer Encoder were involved in the comparative experiments. HP-MHPA achieved F1 values of 68.73%, 81.79% and 85.41% respectively on three English sentiment datasets, namely IMDB, Twitter2016 and Yelp. Compared with other mainstream models, HP-MHPA performs well in complex long text scenarios and multi-emotion interwoven scenarios. It has very prominent advantages and stronger robustness, which shows that it has good generalization ability and great application potential.

Key words: Text Sentiment Analysis, Attention Mechanism, Deep Learning, Feature Optimization

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景与意义

文本情感分析（Sentiment Analysis, SA），属于自然语言处理（Natural Language Processing, NLP）范畴里的一项关键任务，主要用于辨别和划分文本里的情感信息。随着信息化时代的到来，文本数据大量涌现，人工处理以及理解这些数据变得艰难且十分耗费时间[1]。文本情感分析技术可帮助实现对这些大规模文本数据的自动化处理与分析，从中提取出情感信息，提高对情绪倾向的理解[2]。

随着研究背景与应用需求的变化，文本情感分析方法也出现了诸多创新与突破，已经从传统的基于规则和统计的方法[3]，逐渐演变成如今以深度学习为核心的技术体系[4]。这一转变提高了文本情感分析任务的准确性，还使其能够更好地捕捉文本的上下文信息，甚至在机器翻译、用户反馈分析和社交媒体监测等其他领域也得到了拓展应用。

情感是人类行为和决策的关键驱动因素之一[5]，在诸多应用领域，了解用户或者公众的情感态度对于制定有效的决策和策略来讲非常关键。文本情感分析还可协助识别和理解文本中的情感信息，为决策者给予情感洞察以及意见反馈，以此支持情感驱动的决策制定。比如在大数据应用里，个性化推荐系统可依据用户的偏好推荐相关内容，提升用户体验[6]。另外，文本情感分析技术还可自动识别用户在产品评论和反馈中表达的情感倾向，快速知晓用户需求，帮助企业以及组织及时调整和改进产品、服务以及用户体验，提高用户满意度[7]。依靠文本情感分析技术可以对社交媒体上的用户生成内容进行深入挖掘与传播[8]，促进社会信息的流动，提升公众的参与度。

由此可看出，文本情感分析有关键的研究价值，也呈现出广泛的应用前景。一方面，文本情感分析作为连接语言、心理与行为的关键工具，在语言学、心理学和社会科学等多个学科中有着突出的研究价值。它依靠挖掘文本中的情感信息，可揭示人类情绪表达的规律，还可以加深人们对情感与语言运用、认知过程及行为反应之间关系的理解，为相关领域的理论建构和实证研究提供有力支撑。另一方面，文本情感分析技术在实际应用中有着广泛的价值，文本情感分析技术在实际中呈现出关键的辅助决策与信息过滤能力[9]。社交媒体当中存在着数量众多的非结构化文本数据，这些数据为情感分析提供了极为丰富的信息来源。举例来说，在金融领域，它可以用来分析投资者的情绪，对股票走势预测以及风险控制起到辅助作用[10]，在医疗健康领域，文本情感分析可用于分析公

中国知网 https://www.cnki.net

众针对医疗政策或者突发卫生事件的情感反应，为服务优化给予数据方面的支持，推动医疗服务朝着智能化的方向发展[11]。随着多模态情感计算的发展，文本情感分析也在逐渐和语音、图像等其他信息相互融合，拓展出更为广泛的智能化应用场景[12-13]。 然而，当下文本情感分析技术依旧面临着诸多挑战，比如：上下文理解困难[14]、情绪线索捕捉不够全面等问题[15]。不过随着深度学习技术以及词嵌入技术的发展，许多研究的核心以便更加精准地预测文本所表达的情感，这为解决这些问题奠定了较为坚实的基础。

1.2 国内外研究进展

1.2.1 文本情感分析技术

文本情感分析是一个活跃的研究领域，近年来各种模型如卷积神经网络（Convolutional Neural Network, CNN）、循环神经网络（Recurrent Neural Network, RNN）、长短期记忆网络（Long Short-Term Memory, LSTM）、双向编码器表示（Bidirectional Encoder Representations from Transformers, BERT）等深度学习模型在文本情感分析等自然语言处理任务中得到了广泛应用，并取得了显著的研究进展和实验效果。这些模型在文本特征提取[16]和上下文语义建模[17]方面表现出强大的能力，显著提升了情感分类的效果。随着研究的深入，学者们逐渐关注诸如细粒度情感识别[18]以及情感与语义的深层融合[19]等更具挑战性的问题。为应对这些挑战，注意力机制、预训练语言模型以及轻量化结构等的引入，进一步使文本情感分析模型性能得到了提升。在理论探索与应用实践的双重推动下，文本情感分析方法日趋多样，逐渐形成了多种具有代表性的研究路径。为了更系统地梳理已有工作，文本情感分析技术可根据其建模方式与特征处理策略进行分类，具体可归纳为以下五类：

（1）基于规则的方法，此方法借助预定义的规则以及规则库来识别文本里的情感。Arwa 等[20]提出了一个把基于依赖关系的规则与深度学习模型相结合的框架，其中引入了基于依赖关系的规则，借助语言模式把单词的含义映射到句子依赖结构中的概念，可更精准地捕捉句子中的语义关系以及依赖关系。Saraswathi 等[21]提出了一种基于语言规则的特征选择办法，凭借识别并选择评论数据集中的情感特征，再结合随机森林分类算法来进行情感分类，获得了比现有技术更准确的预测结果，尹明鹤等[22]提出了一种融合语法规则信息的 GCN 情感分析模型，利用 GloVe 与 BiLSTM 提取文本的语义特征，并且凭借 spaCy 进行句法依存分析以获取语法结构信息，随后构建 GCN 模型实现语义与

中国知网 https://www.cnki.net

语法的深度融合完成情感分类，相较于现有方法在准确率和 F1 值方面都有提升。

（2）基于情感词典的方法，这种方法运用情感词典来判断文本中词语的情感极性。凭借对词语情感极性的汇总来确定整个文本的情感倾向，Lin 等[23]提出了一种基于词典的提示方式，凭借引入领域特定的词典来纠正预测错误的单词，该方式无需进行领域自适应技术，还可与领域自适应方法相结合，提升领域特定情感分析的泛化能力。Mohammed 等[24]提出了一种针对资源有限语言构建基于词典的情感分析模型的途径，该途径结合了词典的创建、提高、注释以及微调模型，为低资源语言提供了一种有效的情感分析工具，可应用于社交媒体监测、客户服务以及市场研究等领域，Ojeda 等[25]提出了一种利用形式概念分析（Formal Concept Analysis, FCA）创建自定义词典进行情感分析的办法。与传统方法依赖预定义词典不同，该办法允许根据特定数据和任务创建适应性较强的词典，为情感分析提供了一种个性化且灵活的解决方案，Catelli 等[26]研究使用了一个包含大规模领域特定词典的 NLP 工具，将意见持有者分为普通用户、媒体、医学和政治四类，该方法还使用了意大利情感词典和强调词，丰富了基于特征的情感分析。

（3）基于机器学习的办法，此办法运用机器学习算法构建情感分类模型。Haque 等[27]提出一种基于机器学习的分类办法，以 LSTM 为基础，用于孟加拉社交媒体评论的多类情感分类，该办法用于解决孟加拉语文本特殊性和资源限制带来的挑战，提升情感分类性能，Mercha 等[28]全面综述了不同语言上进行情感分析的办法，囊括早期办法以及当前采用的机器学习和深度学习模型。这帮助研究者了解并比较不同办法的优缺点，给出跨语言情感分析领域的全面概览，2021 年，Zhang 等[29]提出属性加权与实例加权贝叶斯（Naïve Bayes, NB）方法，依靠给每个特征赋权改变特征对分类的影响程度，让更关键或更具区分性的特征在分类过程中发挥更大作用，他们还凭借给重要或困难样本赋更高权重，实例加权引导分类器更关注这些样本，提高分类性能和泛化能力，使文本情感分析更准确。到 2022 年，Zhang 等[30]又提出新的属性加权微调贝叶斯方法，更好考虑属性间相关性，提高分类器对相关特征的建模能力，借助调整特征权重，能让影响力或区分度更大的属性在分类过程中发挥更关键作用，提升分类器准确性。

（4）基于深度学习的方法被广泛应用于情感分类领域，此类方法借助 CNN 或 RNN，像 LSTM 以及门控循环单元（Gated Recurrent Unit, GRU）来开展情感分类工作。这些方法可自动从原始文本里学习特征表示，并且在大规模数据上实施端到端的训练，Maity 等[31]提出一种文本情感分析方法，该方法基于多通道 CNN 和句法结构，运用多通道 CNN

中国知网 https://www.cnki.net

提取文本中的局部特征，同时结合句法结构去捕捉文本的语义信息。另外还引入了注意力机制，以此关注句子中的关键词，利用 CNN 和 RNN 的优势提取丰富的文本特征，更准确地分析和识别文本中的情感极性，Ramshankar 等[32]提出一种基于启发式的 CNN-BiLSTM 方法用于电子商务数据的情感分析，此方法借助预处理和特征提取，运用 CNN 和 BiLSTM 模型进行混合处理，同时引入改进的星系群优化算法，提升了模型性能和收敛速度，在各种电子商务数据上实现了高准确性的情感分析和预测。Aslam 等[33]提出一种名为“AMSAER”的方法用于多模态情感分析和情绪识别，该方法利用视觉、音频和文本模态的特征，采用注意机制提高准确性，凭借将多个模型进行决策级融合，达成了高效的多模态情感分析和情绪识别，实验说明该方法在准确性方面取得了一定改进，Meshrif 等[34]提出一种新型优化深度神经网络技术 ABC-ABO-CNN 用于预测工人的压力水平，并结合情感分析对压力水平进行分类。Liu 等[35]提出一种基于依存关系图的位置编码技术，借助对情感特征加权提高并融入特征表示过程，最终把编码后的情感序列特征与传统的词嵌入特征结合用于情感分析，Mohammad 等[36]提出一种基于注意力机制的双向 CNN-RNN 深度模型，该模型利用两个独立的双向 LSTM 和 GRU 层提取过去和未来的上下文信息，充分考量时间信息流的双向性。Mahadevaswamy 等[37]在情感分析中采用双向 LSTM 网络，借助在模型中引入记忆单元改善预测效果并处理长距离依赖问题。

（5）基于预训练模型的方法，此类模型先于大规模文本数据上展开预训练，而后在特定任务里进行微调，借此能学到丰富的语义以及上下文信息，提升情感分析的性能。Jia 等[38]中提出了一种名为“BERT-CBLBGA”的方法，用于基于文本的情感分析工作，该方法将 BERT 与多个深度学习模型相结合，提取出丰富的文本情感特征，并且依靠自注意力机制融合模型输出。Murfi 等[39]中提出了一种名为“BERT-based CNN-RNN”的方法，用于印尼情感分析，该方法把 CNN 和 RNN 结合起来，同时使用 BERT 提取文本特征，在印尼情感分析中获得了较好的准确性，Wan 等[40]提出了一种名为“Emotion-cognitive reasoning integrated BERT”的方法，用于对紧急情况下在线公众意见开展情感分析。该方法融合了情感模型和深度学习，还利用基于 BERT 的模型提供可靠的辅助知识，以此提高情感分析的准确性与可解释性，刘琦[41]提出了“MPC-BERT”模型，依靠结合提示学习和对比学习机制来改进 BERT 模型，有效提升了小样本情感分析的性能，为提高模型的泛化能力提出了“RDP-BERT”模型，基于多模板奖励机制进行动态提示学习。另外还结合了轻量化模型与 BiLSTM，运用低秩自适应方法，实现了小样本场景

中国知网 https://www.cnki.net

下的高效情感分析。

文本情感分析目前仍存在着一些问题与挑战，主要可细分为以下几个方面，多样性与主观性：情感属于主观概念，不同人针对相同文本可能呈现出各异的情感，情感分析模型较难捕捉个体间的主观差异以及情感表达的多样性[42]，在处理有歧义或复杂语义结构的文本时，模型或许会遭遇困难[43]。上下文理解：情感分析模型大多时候依赖局部上下文信息[44]，却忽视了更为广泛的语境，同一句话的情感会因前后文不同而产生变化，针对长文本或跨句子的情感分析[45]，模型需更优地理解文本的整体语义结构与上下文关系。数据偏见和鲁棒性：情感分析模型多是从大规模标注数据集中训练而来，而这些数据集可能存在偏见与噪声[46]。这些偏见可能致使模型在处理不同文化或背景的文本时，出现不公平或不准确的情感判断，另外模型对于来自训练集之外的新颖文本，可能表现出较低的鲁棒性。情感混合和多标签情感[47]：文本中一般包含多种情感，而情感分析模型一般只能输出单一的情感类别，面对情感混合的文本或多标签情感分类任务时，模型的性能与泛化能力可能受到限制。需要更有效的方法来处理情感的多样性以及混合情感的情形。数据稀缺和领域适应[48]：对于特定领域或特定任务的情感分析，往往需要大量领域相关的标注数据，然而在实际应用中难以获取足够的标注数据，另外模型从一个领域适应到另一个领域时，可能会碰到领域偏移和性能下降的问题。

1.2.2 表示学习

表示学习是借助数据自身来进行学习，把数据转变为机器可识别的特征表示的进程，相较于传统的手工设计特征而言，它可挖掘出数据更为深层的含义，让未来的分类任务更为精准。

表示学习对文本情感分析有着关键作用，原因在于它可帮助识别更为复杂的语义关系并且捕捉情感表达。它并非依赖手工设计，而是凭借上下文感知自动提取特征，降低了时间成本，还掌握了单词的多义性以及其在不同文本集合中的情感极性，这提升了文本情感分析的准确性与鲁棒性，也促进了文本情感分析在各个领域的应用。为了呈现表示学习在文本情感分析中的应用，接下来会重点介绍三类典型方法，分别是词嵌入方法、图神经网络方法以及知识提高表示学习方法。

近年来，不少词嵌入方法纷纷被提出来，像基于词级别的 Word2Vec、GloVe，基于文档级别的 Doc2Vec，以及结合上下文的预训练语言模型比如 BERT。不过不同方法的性能有差别，这表明它们在描述词语情感极性方面仍存在改进空间。（1）Word2Vec 是一

中国知网 https://www.cnki.net

种挺高效的词向量训练办法，它借助神经网络把单词映射到固定维度的向量空间，还可以捕捉单词间的语义关系。Meera 等[49]研究了混合特征提取技术，采用 Word2Vec 和 TF-IDF 结合的方式做情感分析。（2）GloVe 主要依据词共现概率关系来训练，比 Word2Vec 更注重语义与句法关系，能捕捉全局信息，不只是依赖局部上下文，但因为它依赖大规模语料数据，GloVe 的效果一般由数据质量决定。Philomina 等[50]提出了一种基于双向 GRU 编码器的情感分析方法，该方法用 GloVe 进行词嵌入，凭借 BiGRU 层捕捉句子的长距离依赖关系，最后凭借自定义注意力层进行情感分析。（3）Doc2Vec 能生成整个文档的向量表示，其引入了文档向量的概念，是 Word2Vec 的扩展版本。Tirta 等[51]分别用了两种 Doc2Vec 模型，包括分布式存储模型（Distributed Memory, DM）和分布式词袋模型（Distributed Bag of Words, DBOW），同时用支持向量机和 Logistic 回归作为分类器用于文本情感分析。（4）BERT 作为目前较强大的文本表示模型之一，它基于 Transformer 架构，有上下文敏感性。和传统方法不一样，BERT 在计算单词含义时，考虑前文信息，也结合后文信息，能在不同上下文中为相同单词生成不同的嵌入表示，然而由于它要处理更丰富的信息，计算成本相对较高，Hou 等[52]为解决传统 Transformer 模型仅能同时处理两个模态，可能丢失情感信息的局限性，提出了一种新颖的基于张量跨模态融合的 BERT 模型，用于跨模态的复杂情感交互。

图神经网络（Graph Neural Network, GNN），它属于基于图结构数据的深度学习模型类别，借助节点之间的边关系来传播信息，学习节点、边或者图的低维表示。在文本情感分析领域，GNN 被大量应用于对文本里的语法结构、语义关系以及知识关联进行建模，特别适合用于捕捉长距离依赖以及复杂的结构化信息。和传统的词嵌入方法不一样，GNN 可直接运用文本的结构特征，像句法依存树、语义角色标注图、实体关系图等，对文本中的局部与全局关系展开联合建模，以此提升情感特征的表达能力，常见包括图卷积网络（Graph Convolutional Network, GCN）、图注意力网络（Graph Attention Network, GAT）和图同构网络（Graph Isomorphism Network, GIN）等。其中，GCN 借助聚合邻居节点特征来进行节点嵌入更新，GAT 则在聚合过程中引入了注意力机制，实现对关键邻居的动态加权。Das 等[53]系统综述了图神经网络 GNN 与情感分析在股票预测中的融合应用，全面梳理了现有方法、模型结构以及评测指标，指出 GNN 在整合多源情感信息、刻画金融网络结构方面的潜力与挑战。Zhang 等[54]利用图神经网络对社交媒体情感进行建模，并结合时序预测模型提升了股票市场的预测精度，验证了 GNN 在跨领域情感分

中国知网 https://www.cnki.net

析中的有效性。

知识增强表示学习（Knowledge-enhanced Representation Learning），其是将外部知识融入到表示学习过程中，以此提升模型对语义与情感的理解能力。该方法一般凭借引入知识图谱、情感词典、情感概念库等外部资源，辅助模型捕捉词语之间的深层语义关系和情感关联，缓解语义歧义、冷门词汇等问题，知识提高方法主要有三种策略：一是知识引导的特征融合，依靠把知识图谱中的实体关系、上下位关系等嵌入到文本特征中，提高语义表示；二是知识感知的预训练模型，比如 K-BERT、ERNIE 等，直接将知识图谱中的知识插入文本序列中，结合预训练学习；三是知识蒸馏与知识提示机制，利用外部知识作为监督信号或提示信息，引导模型学习特定语义特征。Zhu 等[55]针对多模态情感分析，提出了融合外部情感知识的注意力融合网络 SKEAFN，依靠知识提高模块与特征注意力机制，有效提升了多模态情感特征的交互与融合能力。Ahmad 等[56]研究细粒度情感分析时，提出知识提高模型 sEntIMeldCL，该模型基于统一对比机制，把显式知识和隐式对比学习融合起来，能有效提高多方面情感特征的建模能力。

1.3 主要研究内容

针对当前文本情感分析任务中存在的词向量表达能力不足、模型结构建模能力有限，导致分类准确性不高、鲁棒性欠佳的问题，本文以提升情感分类性能为核心目标，系统针对以下两个问题展开研究：

（1）特征权重优化问题：探讨如何融合词频权重信息与全局优化策略，有效引导词向量在情感语义空间中的分布，从而提升情感特征的表达能力。同时，重点关注所提方法在多样化数据场景中的适应性与泛化能力。

（2）多层特征融合问题：研究如何设计兼具情感引导与位置感知能力的注意力机制，增强模型对情感特征差异的识别能力，并充分建模长短距离语义依赖关系，以实现更精细的情感特征提取与融合。

围绕上述问题，本文从词嵌入表达优化与多层特征融合两个层面展开研究，本文的主要研究内容如下：

（1）提出了一种基于圆混沌初始化与遗传鲸鱼优化算法的词嵌入优化方法（CCIGWO）。该方法以 TF-IDF 权重引导机制为核心，通过提取关键词权重信息，引导词向量在情感语义空间中的自适应优化，从而增强词嵌入对情感词的表征能力，使生

中国知网 https://www.cnki.net

成的词向量更好地保留语义关联与情感极性特征。在优化过程中，融合圆混沌初始化策略以提升初始解多样性，结合遗传算法的选择、交叉与变异机制，有效规避局部最优，提升全局搜索能力。同时，该方法充分考虑不同情感类别的分布特征，确保生成的词向量具备更强的情感分类适应性与泛化能力；

（2）设计了一种融合多头多极注意力机制与混合位置编码的文本情感分析模型（HP-MHPA）。该模型在传统多头注意力机制基础上引入多极注意力机制，能够感知并放大相同词语在不同情感语境中的表达差异，从而引导模型更精准地区分情绪倾向。同时，模型融合混合位置编码策略，综合绝对位置与相对位置的结构信息，提升对长距离依赖关系和句法结构的建模能力。实验结果表明，该模型在复杂语义结构和多情感交织场景下表现出优越的泛化能力和鲁棒性，有效提升了情感分类的准确率与稳定性。

1.4 本文章节安排

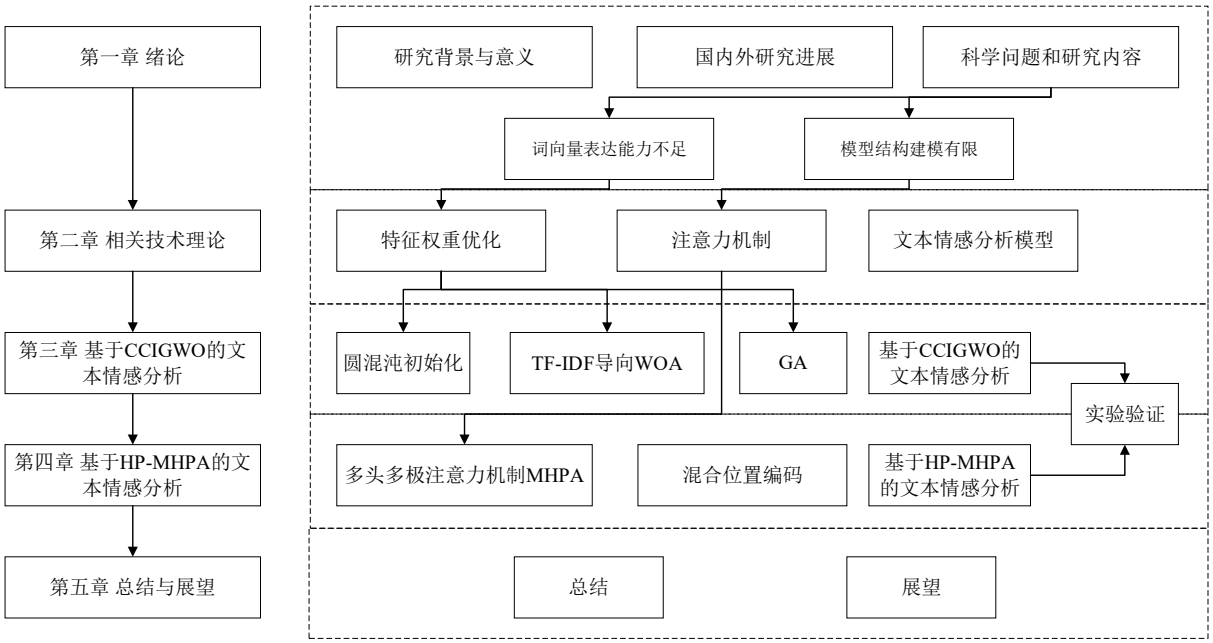

图 1-1 论文整体结构图

中国知网 https://www.cnki.net

第二章 相关技术理论

2.1 特征权重优化

目前，特征权重优化方法已广泛应用于文本情感分析、特征选择等领域，主要包括传统启发式优化方法与新兴智能优化方法两大类。传统方法如粒子群优化算法（Particle Swarm Optimization, PSO）、蚁群优化算法（Ant Colony Optimization, ACO）和差分进化算法（Differential Evolution, DE），通过模拟自然界群体行为进行全局搜索，在特征权重优化中已取得一定成果。此外，近年来贝叶斯优化（Bayesian Optimization）与神经进化算法（Neuroevolution）等方法也逐渐应用于特征权重学习，特别是在高维数据环境下表现出较好的搜索能力和稳定性。部分研究还结合深度学习框架，将对比学习、强化学习等策略引入特征选择过程，有效提升了特征优化的灵活性和适应性。

综合考虑优化效率与实现复杂度，选取了两种具有代表性的启发式优化方法——遗传算法与鲸鱼优化算法[57-58]，分别作为特征权重优化的典型实现，重点分析其在词嵌入优化中的应用效果与机制。在文本情感分析中，特征权重优化是提升模型性能的关键环节之一。由于文本数据普遍存在高维稀疏性强、噪声干扰多等问题，如何有效挖掘并优化情感特征的权重分布，已成为影响模型分类效果与泛化能力的重要因素。近年来，基于启发式优化算法的特征权重优化方法逐渐成为研究热点，这类算法具有强大的全局搜索能力，能够在复杂特征空间中高效寻找最优解，有效缓解陷入局部最优的问题。其中，遗传算法作为经典的进化机制优化方法，已在特征选择与权重优化中得到广泛应用。而鲸鱼优化算法则是一种近年来兴起的仿生智能算法，通过模拟鲸鱼群体的觅食行为，实现对特征权重的高效搜索与优化。本节将重点介绍这两类具有代表性的启发式优化算法，为后续方法设计与模型构建提供理论支撑。

2.1.1 鲸鱼优化算法

鲸鱼优化算法的灵感源自白鲸独特的“气泡网捕食”策略，白鲸会在水中构建气泡网以此高效地捕获猎物，算法里每一头鲸鱼都被当作一个候选解，该算法主要有两个核心策略：气泡网攻击策略（局部开发阶段）和围绕猎物策略（全局探索阶段）。

在气泡网攻击策略当中，会模拟鲸鱼围绕猎物展开的螺旋打圈行为，主要依

中国知网 https://www.cnki.net

靠以下两种方式来更新位置：

（1）收缩包围机制

鲸鱼通过包围猎物来缩小搜索范围，其位置更新公式如下。

$$\vec{D}=\left|\vec{C}\cdot\vec{X}^{*}-\vec{X}_{t}\right| \tag{2-1}$$

$$\vec{X}_{t+1}=\vec{X}^{*}-\vec{A}\cdot\vec{D} \tag{2-2}$$

公式（2-1）、（2-2）中，$\vec{X}^{*}$表示当前最优个体的位置，$\vec{A}$、$\vec{D}$ 为系数向量，具体计算参考（2-3）。

$$\vec{A}=2a\cdot\vec{r_1}-a,\ \vec{D}=2\cdot\vec{r_2} \tag{2-3}$$

其中，a的初始值为 2 随迭代线性递减，其递减规律如公式（2-4），$\vec{r_1}$、$\vec{r_2}$为[0,1]间随机向量。

$$a=2-\frac{2t}{T} \tag{2-4}$$

这里，t为当前迭代次数，T为最大迭代次数。

（2）螺旋更新机制

鲸鱼围绕猎物以螺旋轨迹游动，其位置更新模型为公式（2-5）。

$$\vec{X}_{t+1}=\vec{D}^{'}\cdot e^{bl}\cdot cos(2\pi l)+\vec{X}^{*} \tag{2-5}$$

其中，$\vec{D}^{'}$表示当前个体与最优个体的距离，b为用于螺旋更新机制中的一个固定常数，作用是控制螺旋轨迹的形状，通常被设定为 1，l为[–1,1]区间内的随机数，其公式（2-6）所示。

$$\vec{D}^{'}=|\vec{X}^{*}-\vec{X}_{t}| \tag{2-6}$$

在围绕猎物策略中，当鲸鱼远离猎物时，采用全局探索机制，使个体随机朝任意位置移动以扩大搜索范围，其更新公式与收缩包围机制相似，但使用随机选取的个体$\vec{X}_r$替代最优个体，其公式如（2-7）、（2-8）所示：

$$\vec{D}=\left|\vec{C}\cdot\vec{X}_{r}-\vec{X}_{t}\right| \tag{2-7}$$

$$\vec{X}_{t+1}=\vec{X}_{r}-\vec{A}\cdot\vec{D} \tag{2-8}$$

2.1.2 遗传算法

遗传算法是一种全局优化算法，启发于生物的遗传机制与自然选择，通过种

中国知网 https://www.cnki.net

群初始化、适应度评估、选择、交叉与变异等操作，保留优质个体的特征的同时，将其可能为优质的特征传播给其后代，从而引导整个种群向更优的解逼近[59]。

具体过程为首先初始化种群并为种群所有个体进行适应度衡量，再以问题解的优劣为标准不停地迭代，模拟自然选择的机制，从当前种群中选择适应度较高的个体以一定交叉概率进行交叉和变异操作，以生成新的候选解。其交叉操作为两个父代染色体A和B在k位置进行交换生成个体C_1和C_2，如公式（2-9）所示。

$$\begin{cases} C_1=(a_1,\ldots,a_k,b_{k+1},\ldots,b_n) \\ C_2=(b_1,\ldots,b_k,a_{k+1},\ldots,a_n) \end{cases} \tag{2-9}$$

X_i以一定概率进行变异操作，生成个体$X_i^{'}$，如公式（2-10）所示。

$$X_i^{'}=\begin{cases} 1-X_i, random<P_m \\ X_i, random\geq P_m \end{cases} \tag{2-10}$$

其中P_m是变异概率，通常较小。

通过这样在解空间内不断进行演化，寻找全局最优或局部最优解。遗传算法凭借全局搜索能力强和易于融合其他算法的优点，使其广泛应用于文本情感分析中特征选择、深度学习模型参数优化等领域。

2.2 文本情感分析模型

2.2.1 卷积神经网络

卷积神经网络属于深度学习模型，在自然语言处理、图像识别以及语音识别等诸多任务里都有广泛应用，它借助由浅至深的卷积操作，一层一层地去提取不同层次的特征，并且在这个基础之上，依靠神经网络来自动调节与优化参数。CNN 一般是由卷积层、激活函数、池化层、全连接层以及输出层等部分构成，其整体结构可有效地提取局部特征，还拥有较强的表达能力与泛化能力，完整的卷积神经网络结构如图 2-1 所示。

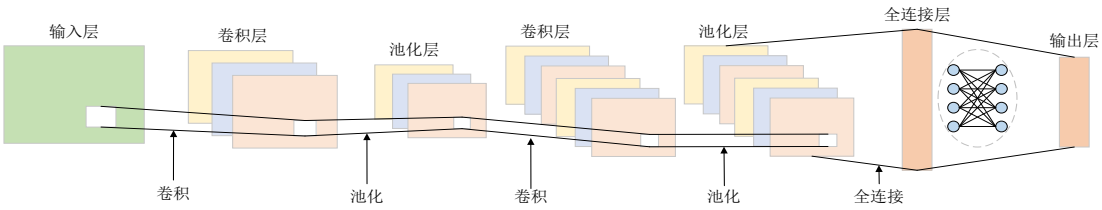

图 2-1 卷积神经网络结构图

（1）卷积层

卷积操作于卷积层得以实现，卷积层为卷积神经网络的关键所在，借助多个

中国知网 https://www.cnki.net

卷积核对输入数据里的特征开展逐元素相乘后相加的操作，此操作旨在提取输入数据的局部特征，捕捉不同空间位置的特征模式，一步步构建起复杂的特征表达，这里，卷积核是一组固定的权重，在训练进程中会自行学习到对任务有帮助的特征表示。

（2）激活函数

激活函数通常是卷积神经网络中每一层的关键组成部分。由于每一层并不会直接生成最终的非线性输出，通过激活函数引入非线性因素，可以使模型能够学习更复杂的模式和关系。常见的激活函数包括 Sigmoid 和 Tanh。

Sigmoid函数将输入映射到 0 到 1 之间，经常用于二分类任务的输出层，用于将模型的输出转化为概率值，而由于其导数在输入值过大或过小时会趋近于 0 的原因，可能导致其在深层网络中出现梯度消失问题。Sigmoid函数的公式如式（2-11）所示，对应图像如图 2-2 所示。

$$Sigmoid(x)=\frac{1}{1+e^{-x}}\sim[0,1] \tag{2-11}$$

除了Sigmoid函数，Tanh函数也是常用的激活函数之一，其数学表达式如公式（2-12）所示。

$$Tanh(x)=\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}\sim[-1,1] \tag{2-12}$$

Tanh函数能够将输入映射到-1 到 1 之间，相较于Sigmoid函数，其输出是零中心化的，有助于缓解梯度更新过程中的偏移问题，从而在某些情况下加快网络的收敛速度。然而Tanh函数同样也存在梯度消失的问题，当输入值绝对值较大时，其导数趋近于 0，梯度传播就会比较困难。Tanh函数的图像也如图 2-2 所示：

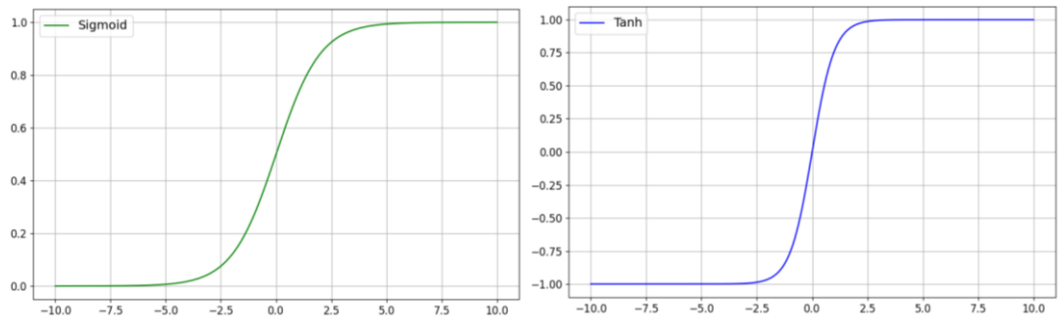

图 2-2 Sigmoid 函数与 Tanh 函数图像

（3）池化层

池化层通过减小特征图的大小来对其进行降维处理，从而降低模型的参数量

中国知网 https://www.cnki.net

和计算量，同时还能增强网络对平移、缩放等变换的鲁棒性。具体操作为在保留重要特征信息的情况下，选择池化窗口内的最大值或平均值对局部区域实现特征压缩。常见的池化操作包括最大池化（Max Pooling）和平均池化（Average Pooling），如图 2-3 所示。

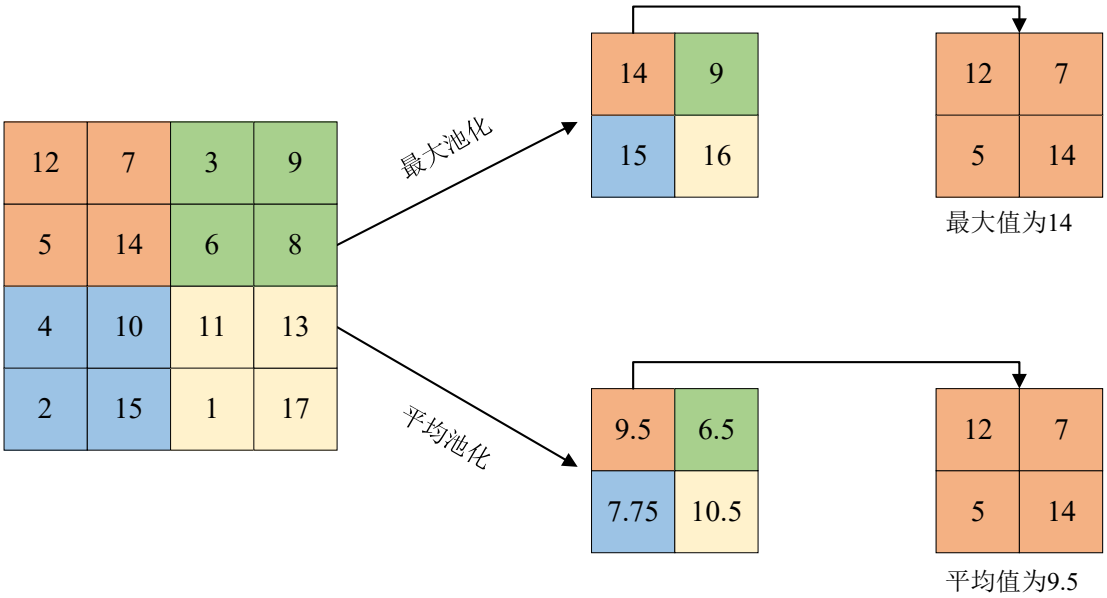

图 2-3 最大池化和平均池化示意图

（4）全连接层

全连接层在整个网络中起到“决策器”的作用，其将提取到的特征映射展平传递至神经元，实现高维特征到具体的输出空间的映射，最后转化为网络的最终输出，实现特征的融合与最终分类等操作。在文本情感分析任务中，全连接层往往连接至 softmax 层或 sigmoid 层，用于输出情感分类结果。

2.2.2 循环神经网络

本节参数及其释义如表 2-1 所示。

表 2-1 循环神经网络参数及其释义

参数	释义
h_t、h_{t-1}	时间步的隐藏状态
x_t、y_t	当前时间步的输入、输出
f_t、i_t、o_t	遗忘门、输入门、输出门
C_t	当前细胞状态
σ、$Tanh$	Sigmoid 和 Tanh 激活函数
W_h、W_x、W_y、W_f、W_i、W_o、W_C	权重矩阵
b_h、b_y、b_f、b_i、b_o、b_C	偏置

中国知网 https://www.cnki.net

循环神经网络是一种专门针对序列数据处理而设计的神经网络结构，借助这种结构可对任意长度的序列数据进行有效处理[60]。和 CNN 相类似，RNN 在自然语言处理等诸多领域都有着广泛的应用。其核心思想是通过隐藏状态在时间步之间传递信息，使当前隐藏状态h_t同时依赖于当前输入x_t和前一时刻的隐藏状态h_{t-1}，从而实现对时序数据的建模。RNN 的每个时间步的计算可以表示为公式（2-13）、（2-14）。

$$h_t=\sigma(W_h h_{t-1}+W_x x_t+b_h) \tag{2-13}$$

$$y_t=W_y h_t+b_y \tag{2-14}$$

从图 2-4 可看到，位于左侧的是 RNN 的基本结构，该结构是由输入层、隐藏层以及输出层共同构成的，而位于右侧的则是其展开结构，此展开结构展示出了网络在各个时间步的具体工作过程，在每一个时间步当中，网络会接收当前时刻的输入以及前一时刻的隐藏状态，经过非线性激活函数进行处理之后生成输出，并且更新隐藏状态，以此形成反馈机制，可记忆并利用历史信息，有效地捕捉序列当中的时间依赖关系。

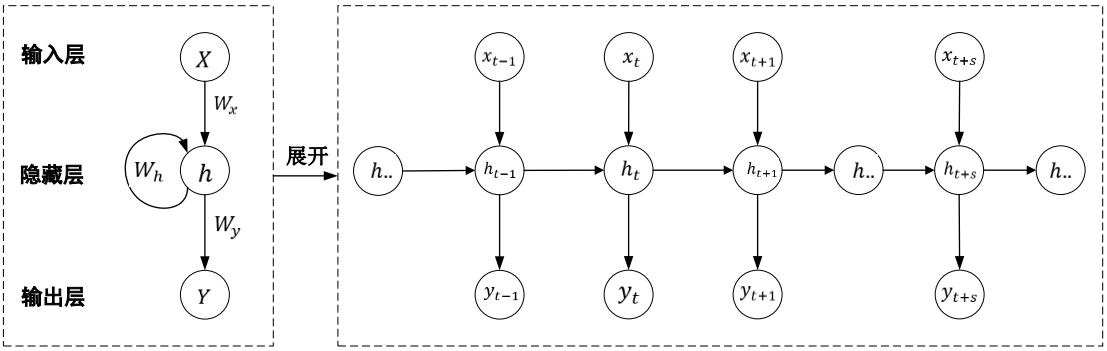

图 2-4 RNN 结构图

长短期记忆网络（Long Short-Term Memory，LSTM），它是对传统 RNN 做出的改进，这种改进可缓解梯度消失以及梯度爆炸问题，可以捕捉长序列里的远程依赖关系，虽然它的计算复杂度以及训练时间比 RNN 要高，不过在处理复杂任务的时候表现更为出色。LSTM 主要是由遗忘门、输入门、输出门以及细胞状态构成的，各门控单元的工作机制如公式（2-15）至（2-20）所示。

$$f_t=\sigma(W_f\cdot[h_{t-1},x_t]+b_f) \tag{2-15}$$

$$i_t=\sigma(W_i\cdot[h_{t-1},x_t]+b_i) \tag{2-16}$$

$$o_t=\sigma(W_o\cdot[h_{t-1},x_t]+b_o) \tag{2-17}$$

中国知网 https://www.cnki.net

$$\tilde{C}_t=Tanh(W_C\cdot[h_{t-1},x_t]+b_C) \tag{2-18}$$

$$C_t=f_t\otimes C_{t-1}+i_t\otimes\tilde{C}_t \tag{2-19}$$

$$h_t=o_t\otimes Tanh(C_t) \tag{2-20}$$

其中，遗忘门用于控制当前细胞状态中需丢弃的历史信息，其输出f_t越接近0，表示遗忘越多；越接近 1，则保留更多信息。输入门决定当前输入中需记忆的新信息，i_t表示输入门的输出，$\tilde{C}_t$为候选细胞状态，提供当前输入的更新信息。输出门则控制最终输出的信息，其输出o_t决定隐藏状态h_t，该隐藏状态将传递至下一时间步作为输入和输出。其整体结构如图 2-5 所示。

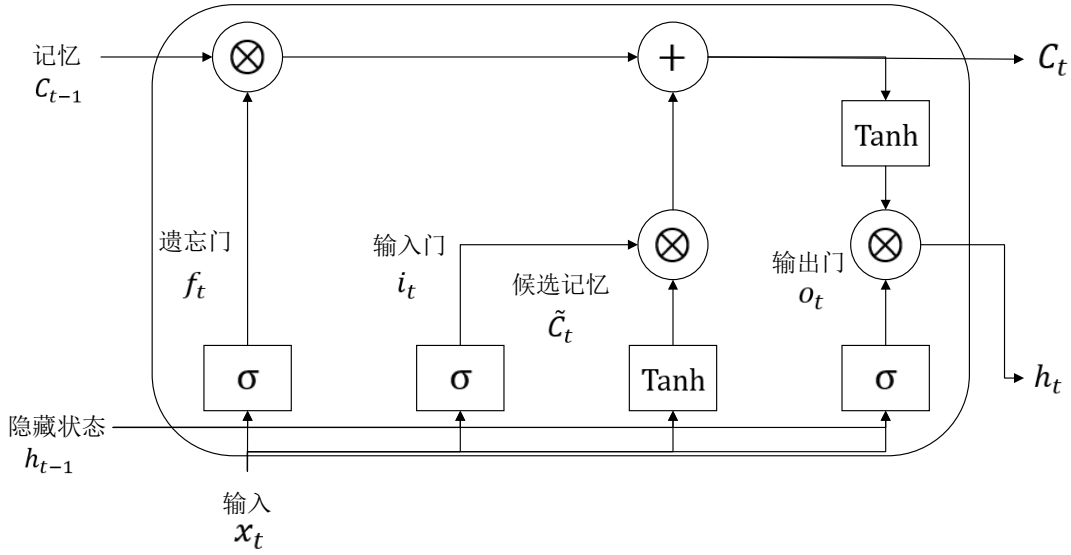

图 2-5 门控单元结构图

2.2.3 双向长短期记忆网络

双向长短期记忆网络（Bidirectional LSTM，BiLSTM），它属于对传统 LSTM 的一种拓展，传统的单向 LSTM 仅仅处理从前往后的信息流，与之不一样的是，BiLSTM 借助引入双向信息流，于模型里同时运用正向以及反向的 LSTM 层，如此一来，BiLSTM 可在每一个时间步的输出当中，融合来自序列前后两个方向的信息，更加全面地捕获序列数据里的上下文依赖关系。

具体而言，BiLSTM 把正向 LSTM 以及反向 LSTM 的输出结合起来，这提高了模型对当前输入的理解，而且还可对序列中的长距离依赖进行建模，这种双向结构让 BiLSTM 在许多任务里可更准确地捕捉到序列数据的复杂关系，提高任务的准确性与效率[61]，BiLSTM 的结构如图 2-6 所示。

中国知网 https://www.cnki.net

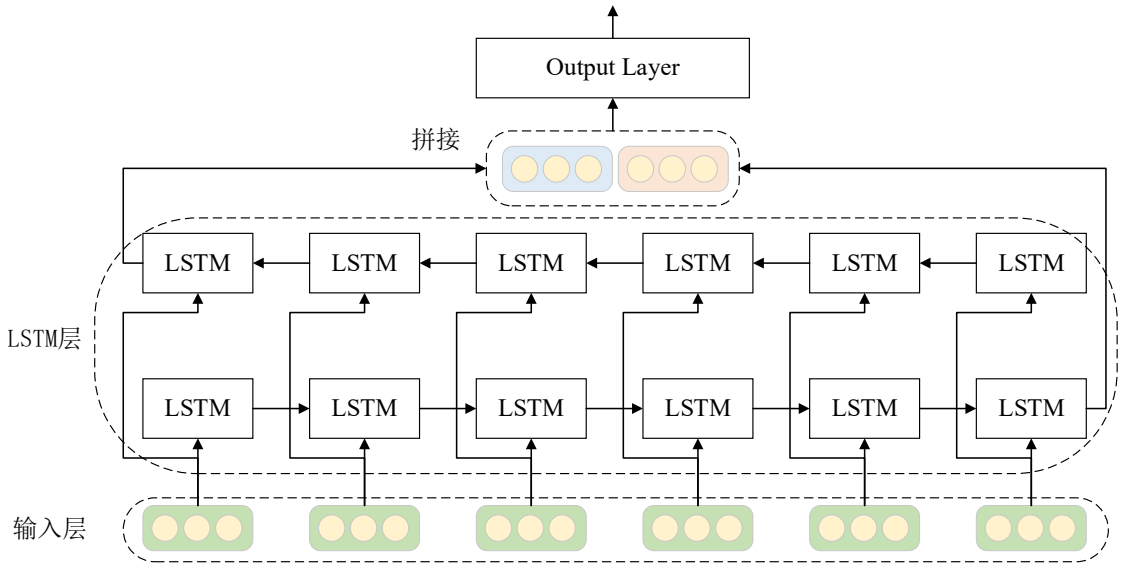

图 2-6 BiLSTM 结构图

其中，对于每个时间步t，正向 LSTM 会输出从序列开始到当前时刻的隐藏状态$h_t^{(f)}$。而反向 LSTM 则输出从序列末尾到当前时刻的隐藏状态$h_t^{(b)}$。最后 BiLSTM 会将正向和反向的输出进行拼接，生成时间步t的最终输出h_t，其公式如（2-21）所示。

$$h_t = \left[h_t^{(f)}, h_t^{(b)}\right] \tag{2-21}$$

2.2.4 Transformer

Transformer 是一种深度学习模型，基于自注意力机制以及并行计算，在自然语言处理领域有着广泛应用，于 SA 任务里收获了成功[62]。它主要由两部分组成，一部分是负责处理输入序列的编码器，另一部分是用于生成输出序列的解码器，这两部分都是依靠堆叠多个一样的模块达成的。

和传统的 RNN 以及 CNN 不一样，Transformer 完全舍弃了循环结构，它的核心想法是借助自注意力机制，计算输入序列中每个词和其他词之间的关系，再依据这些关系调整每个词的表示。这种机制让 Transformer 处理长序列数据时更有效率，在捕捉远程依赖关系上表现出色。Transformer 的整体结构如图 2-7 所示。

中国知网 https://www.cnki.net

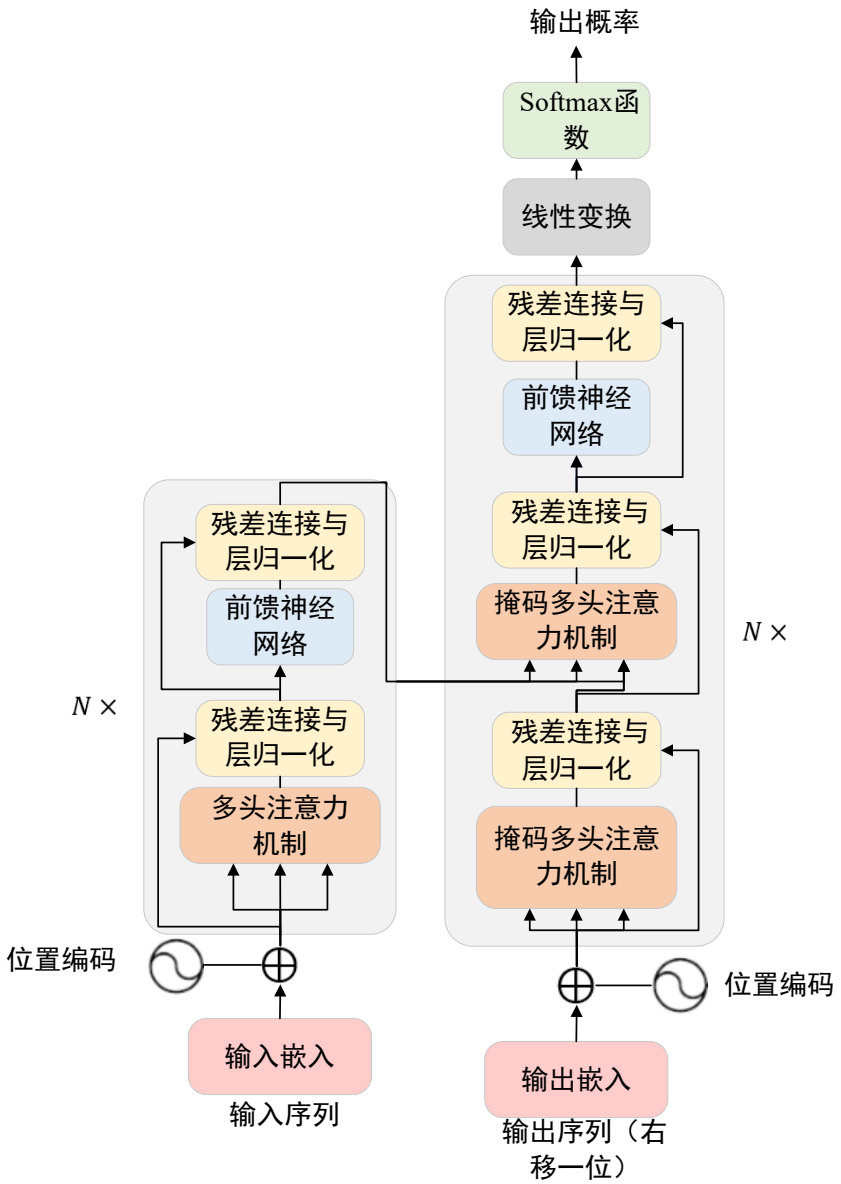

图 2-7 Transformer 整体结构图

每一个编码器都含有两个主要的子层，在每个子层之后，均设有残差连接（Residual Connection），同时还会开展层归一化（Layer Normalization）操作，以此来保证模型训练可更加稳定。

其中，有一个子层是自注意力机制层（Self-Attention Mechanism）。借助这一层，编码器可捕捉输入序列里每个词和其他词之间的依赖关系，并且依据计算得出的相似性来动态调整词向量的表示，这样一来，编码器便可以有效地对词与词之间的全局依赖关系进行建模，另外一个子层是前馈神经网络层（Feed-Forward Neural Network）。它针对每个位置的表示实施独立的非线性变换，丰富每个词的特征表达，提升模型的表达能力。

中国知网 https://www.cnki.net

每个解码器层由三个主要子层组成，其结构和编码器相似，同样是凭借堆叠多个相同的层构建而成，而且每个子层都包含残差连接以及层归一化操作，解码器中也有一个自注意力机制层，不过与编码器不一样的是，解码器中的自注意力机制采用了掩码机制（Masked Attention）。这一机制保证了当前时刻的输出仅能依赖于之前时刻的信息，防止信息泄漏，保证解码器在生成每个词的时候不会看到未来的信息，解码器中以及一个编码器-解码器注意力机制层（Encoder-Decoder Attention），这一层让解码器可关注编码器输出的输入序列中与当前解码步骤相关的部分，提高解码器生成输出时对输入序列的依赖。解码器还包含一个前馈神经网络层，它的功能和编码器中的前馈层一样，主要用于对每个位置的表示进行独立的非线性变换。

此外，Transformer 还引入了位置编码（Positional Encoding）。由于 Transformer 本身无法感知输入序列中每个词的相对位置，因此需要通过位置编码来弥补这一缺陷。位置编码是一个与输入序列长度相同的向量，它被加到输入的词向量中，用于为每个词添加位置信息。通过这种方式，模型能够感知每个词在序列中的相对或绝对位置，从而更好地捕捉序列的顺序关系和上下文信息。

2.2.5 注意力机制

（1）自注意力机制

注意力机制模拟了人类在视觉中聚焦注意点的过程，能够使机器自动关注大量信息中的关键部分，由于输入信息的不同部分应该拥有不同的注意力权重，所以注意力机制的本质就是为了实现这一过程，从而做到突出重点信息、抑制冗余信息的作用，其被广泛应用于自然语言处理、计算机视觉、机器翻译等领域。在文本情感分析中，因为语言表达具有上下文依赖性，注意力机制能够帮助捕捉复杂语境中的情感信息，如特殊的句子结构或句子仅含有少数关键词，在面对这种情况时，传统模型（如 RNN 或 CNN）很难做到去识别文本中所表达出的主观情感极性，为了提高模型的表达能力从而获得更高的性能，这就需要将注意力机制与传统模型结构相结合[63]。注意力机制的结构如图 2-8 所示。

中国知网 https://www.cnki.net

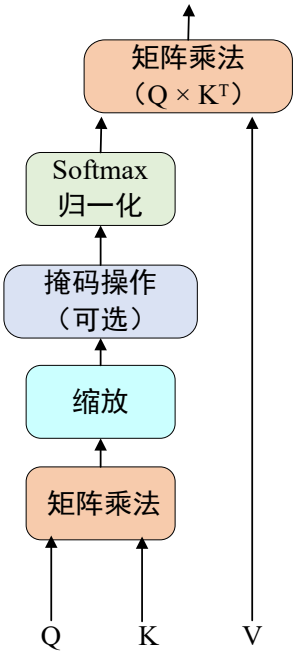

图 2-8 自注意力机制结构图

假设输入为一个句子序列$X=\{x_1,x_2,\ldots,x_n\}$，其中每个x_i是词的表示（如词嵌入向量）。注意力机制将每个词的输入表示映射到三个向量，它们都是由同样的输入矩阵X与不同的对应矩阵相乘线性变换而来的，分别用Q表示 Query（查询向量）、 K表示 Key（键向量）、 V表示 Value（值向量），对应图中 MatMul 模块，其中W^Q、W^K、W^V均为可训练的矩阵。公式如（2-22）至（2-24）所示。计算流程如图 2-9 所示。

$$Q=XW^Q \tag{2-22}$$

$$K=XW^K \tag{2-23}$$

$$V=XW^V \tag{2-24}$$

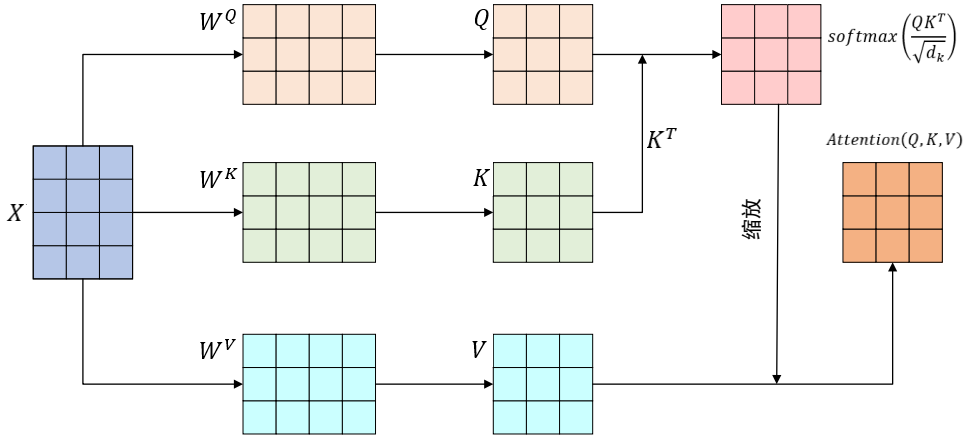

图 2-9 自注意力机制的计算流程

中国知网 https://www.cnki.net

其次，通过相似性函数计算查询向量与每个键向量的相关性，得到一个注意力分数e_i，由于该过程仅依赖于其之前的单词，所以通过图中 Mask 模块避免未来的单词的干扰，如公式（2-25）所示。

$$e_i = Similarity(Q, K_i) \tag{2-25}$$

接着，对注意力分数使用Softmax函数进行归一化处理，将所有注意力分数转化为 0 到 1 之间的概率值，确保它们的总和为 1，对应图中 Softmax 模块，得到注意力分布α_i，如公式（2-26）所示。

$$\alpha_i = Softmax(e_i) = \frac{exp(e_i)}{\sum_{j=1}^{n} exp(e_j)} \tag{2-26}$$

最后使用注意力分布与值向量V进行加权求和，得到最终的输出表示，如公式（2-27）所示。

$$Attention(Q,K,V) = \sum_{i=1}^{n} \alpha_i v_i = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2-27}$$

其中， d_k是向量的维度，使用$\sqrt{d_k}$作为缩放因子平衡注意力权重的大小，对应图中 Scale 模块。

（2）多头注意力机制

多头注意力机制是在注意力机制基础上的一种拓展与增强，其可以通过并行计算不同子空间中的注意力来多个角度捕捉不同的语义特征[64]。它相较于普通的注意力机制关注信息的多个方面，拥有更强的表示能力，多头注意力机制的结构如图 2-10 所示，其中每一个 Scaled Dot-Product Attention 结构都与单头注意力机制一致。

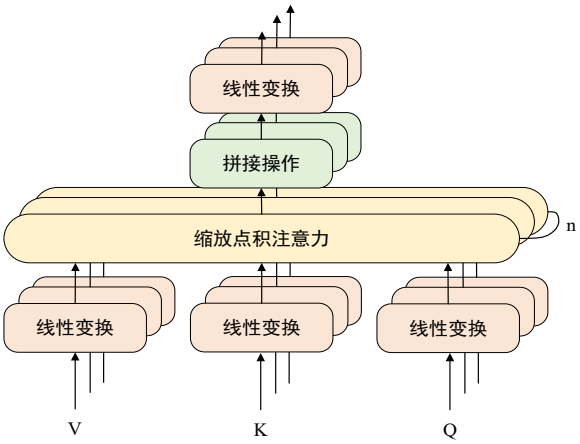

图 2-10 多头注意力机制结构图

中国知网 https://www.cnki.net

多头注意力机制可以看作为多个单头注意力机制的并行组合，假设同样有一个句子序列$X=\{x_1,x_2,\ldots,x_n\}$，使用n组可训练权重矩阵W_i^Q、W_i^K、W_i^V对其进行线性变换得到对应的Q_i、K_i、V_i，其中n为注意力头的数量，而i则代表第i个注意力头，公式如（2-28）至（2-30）所示。

$$Q_i=XW_i^Q \tag{2-28}$$

$$K_i=XW_i^K \tag{2-29}$$

$$V_i=XW_i^V \tag{2-30}$$

其次，为每个注意力头计算注意力分数表示为Z^i，公式如（2-31）所示，其中对应参数的定义与单头注意力机制相同。

$$Z^i=Attention(Q_i,K_i,V_i)=softmax\left(\frac{Q_iK_i^T}{\sqrt{d_k}}\right)V_i \tag{2-31}$$

多头注意力机制具体流程如图 2-11 所示。

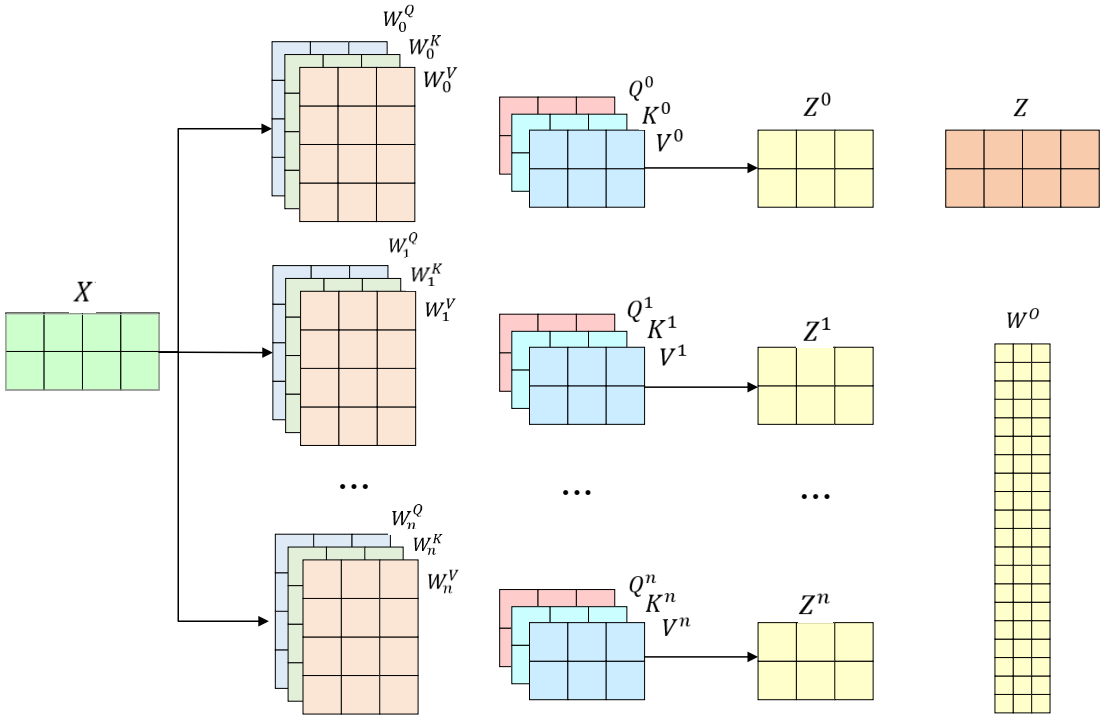

图 2-11 多头注意力机制的计算流程

最后，将所有注意力分数Z^i拼接，整合后与输出层的权重矩阵W^O相乘进行线性变换，用于将拼接后的向量映射回原维度，得到最终的多头注意力输出，公式如（2-32）所示。

中国知网 https://www.cnki.net

$$Z=MultiHead(Q,K,V)=Concat\left(Z^0,Z^1,\ldots,Z^n\right)W^O \tag{2-32}$$

2.2.6 图神经网络

近年来，随着图神经网络（Graph Neural Networks, GNN）技术的发展，基于 GNN 的文本情感分析方法逐渐受到关注。该类方法通过构建图结构，将文本中的单词、句子或实体作为图中的节点，利用边表示词语之间的依赖关系、共现关系或语义相似度，从而实现结构化的情感特征建模。

典型方法之一是 TextGCN[65]，该方法将整个语料库构建为无监督的单词-文档图，通过图卷积网络（GCN）传播语义信息，实现长距离依赖关系的捕捉，适合句子层次或文档层次的情感分类任务，其结构如图 2-12 所示。

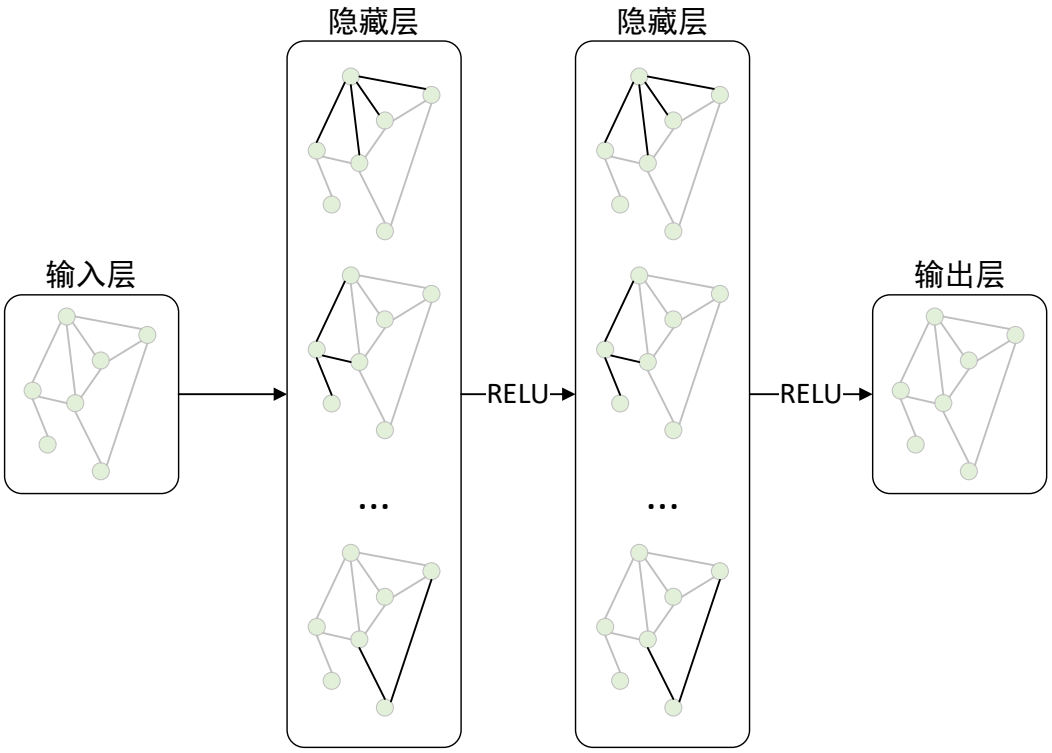

图 2-12 GCN 结构图

GCN 模型通过邻接矩阵的归一化操作实现节点特征的聚合与传播，其核心公式如（2-33）所示。

$$H^{(l+1)}=\sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}H^{(l)}W^{(l)}\right) \tag{2-33}$$

其中，$H^{(l)}$表示第l层的节点特征矩阵（初始层$H^{(0)}=X$为输入特征矩阵），$\tilde{A}=A+I$为加上自环的邻接矩阵，$\tilde{D}$为$\tilde{A}$的度矩阵，$W^{(l)}$是第l层的可训练权重矩阵，

中国知网 https://www.cnki.net

σ为激活函数（通常使用 ReLU）。该公式通过归一化邻接矩阵，对节点的邻居信息进行加权聚合，从而有效捕捉图结构中的局部与全局特征。

2.3 评价指标

算法评价指标是用以衡量机器学习算法性能以及有效性的定量指标，在本文之中，会借助以下这些指标来对测试算法展开评估，其中，准确率即 Accuracy，它指的是正确分类的样本数量与总样本数之间的比值，精确度即 Precision，具体所指的是在所有被预测为正类的样本里面，实际属于正类的比例。召回率即 Recall，其表示的是实际为正类的样本中，被正确预测为正类的比例，F1 分数也就是 F1-score，它的作用是平衡精确度和召回率，是精确度与召回率的调和平均值，适用于数据不平衡的那种场景。具体公式如（2-34）至（2-37）所示。

$$Accuracy=\frac{TP+TN}{TP+TN+FP+FN} \tag{2-34}$$

$$Precision=\frac{TP}{TP+FP} \tag{2-35}$$

$$Recall=\frac{TP}{TP+FN} \tag{2-36}$$

$$F1\text{-}score=\frac{2\times Precision\times Recall}{Precision+Recall} \tag{2-37}$$

其中，TP（True Positive）：真正例，正确预测为正类的样本数。TN（True Negative）：真负例，正确预测为负类的样本数。FP（False Positive）：假正例，错误预测为正类的负类样本数。FN（False Negative）：假负例，错误预测为负类的正类样本数。

2.4 本章小结

本章介绍了文本情感分析中的特征权重优化、注意力机制以及几种主流深度学习模型。首先，特征权重优化方面，讨论了通过模拟自然现象进行优化的鲸鱼优化算法和遗传算法，可以帮助提高特征优化的效果。其次，在模型方面会对多种文本情感分析模型进行介绍，其中 CNN 和 RNN 被用于提取局部以及时序特征，LSTM 和 BiLSTM 解决了长距离依赖的问题，BiLSTM 可同时捕捉前后文的信息，而 Transformer 依靠引入多头注意力机制，使得模型的表现有了很大提升，成为当前 NLP 领域的核心模型之一。而后介绍了注意力机制，重点讲解了自注意力机制和多头注意力机制。自注意力机制可捕获序列当中元素之间的关系，而

中国知网 https://www.cnki.net

多头注意力则是依靠多个子空间并行开展处理工作，以此提高模型的表达能力。最后介绍了几种常用的性能指标，可更全面地评估模型的性能，本章所阐述的理论知识提供了特征优化以及深度学习模型的全面介绍，为后续算法的改进提供了有力的支撑。

中国知网 https://www.cnki.net

第三章 基于 CCIGWO 的文本情感分析

本章主要围绕文本情感分析任务中的词嵌入优化问题展开研究，针对传统词嵌入在语境感知和情感表达能力方面的不足，提出了一种基于圆混沌初始化与遗传鲸鱼优化算法（CCIGWO）的词向量微调方法。该方法结合 TF-IDF 引导机制，实现了对静态词向量的自适应优化，有效提升了情感语义特征的表达能力。本章内容安排如下：3.1 节简述本章工作，引出本章研究的问题；3.2 节详细阐述 CCIGWO 算法的设计思想与实现流程；3.3 节说明所使用的数据集及实验设置；3.4 节从多个指标出发对模型性能进行评估与分析；3.5 节对本章工作进行总结。

3.1 问题引出

在文本情感分析这项任务当中，词嵌入质量会直接对情感分类模型最终呈现出的性能产生影响，虽然当下有关这方面的研究一直在持续推进，然而词嵌入方法还是存在一些迫切需要去解决的问题，主要集中在下面这两个方面：

（1）当前的预训练语言模型已经拥有比较强的语义建模能力，但在情感特征表达这个层面依然存在欠缺，在捕捉情感极性以及细粒度情感差异方面的表现较为有限。

（2）传统优化方法在对词向量进行微调的时候，普遍会面临初始种群质量不高、搜索过程容易陷入局部最优等问题，很难在复杂语境之下达成高质量的词嵌入优化。

为了解决上述问题，本章提出的基于圆混沌初始化与遗传鲸鱼优化的词嵌入算法方案（CCIGWO）如下，旨在更准确地反映词汇的情感极性。

（1）圆混沌初始化与遗传鲸鱼算法融合：通过引入圆混沌函数来提高初始种群的多样性以及覆盖范围，提高全局搜索能力，并且结合遗传算法的交叉与变异机制，可有效地防止种群陷入局部最优，提升优化的稳定性。

（2）阶段性引导优化过程：鲸鱼种群围绕 TF-IDF 引导的情感关键词来进行嵌入向量的调整，凭借记录优秀个体并引导后续迭代，逐步提高词嵌入对情感语义的表达能力。

（3）变异与种群多样性：在每一代种群进化过程中，结合个体相似性进行概率变异，引入噪声扰动来增加多样性，提升整体种群的搜索广度与鲁棒性。

中国知网 https://www.cnki.net

3.2 CCIGWO 模型的整体结构

CCIGWO 模型的总体结构如图 3-1 所示。

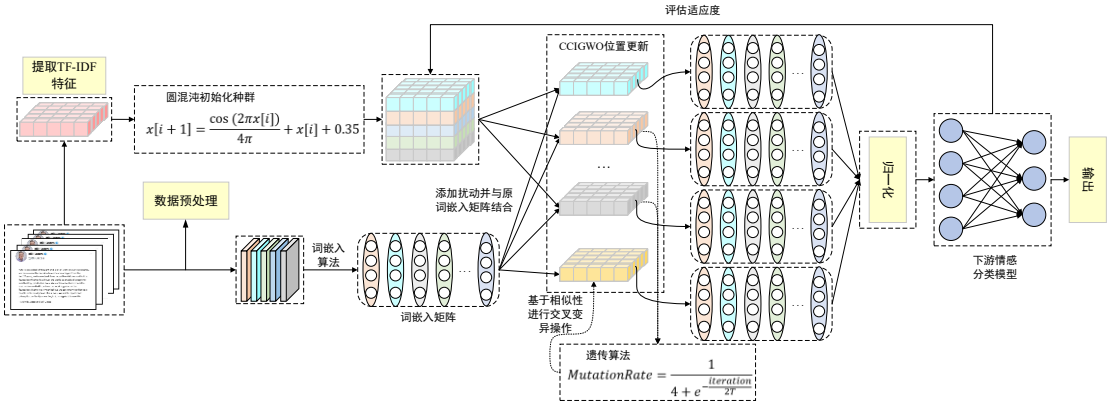

图 3-1 CCIGWO 模型总体结构图

首先，对数据集进行数据预处理，依据该数据集生成一个可描述和评估语料库中词语关键程度的 TF-IDF 矩阵，并且基于正态分布增添一些随机扰动，接着结合 TF-IDF 矩阵运用圆混沌初始化鲸鱼优化算法种群，同时考虑对词嵌入矩阵里不同特征进行缩放。个体位置的更新方式在每个阶段都不一样，是凭借依据适应度和迭代次数在不同阶段之间进行切换来调整的，随着种群不断迭代逐渐朝着更优化的方向收敛。另外结合遗传算法将两个更具前景的解配对生成新个体，还引入基于相似性的变异概率，剖析是否存在更好的优化方法，相较于简单的直接融合，获得了词嵌入矩阵与 TF-IDF 矩阵更为和谐的结合，使得模型性能得到了提升。

3.2.1 圆混沌初始化

随机初始化的种群容易出现分布不均的问题。尽管看起来可以完全覆盖整个搜索空间，但在高维空间中，随机初始化的种群可能会集中在某些区域。此外，随机初始化种群的分布缺乏系统性，导致其探索能力不足，难以发现潜在的全局最优解，从而增加了陷入局部最优解的风险[66]。其对比如图 3-2 所示。

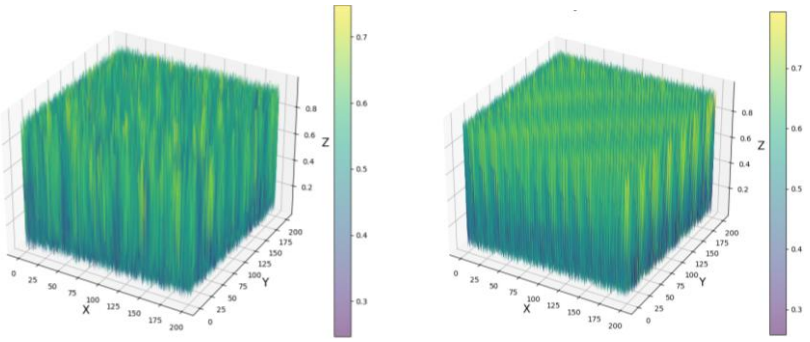

图 3-2 随机初始化的种群与圆混沌初始化的种群

中国知网 https://www.cnki.net

此外，即使满足上述所有条件，随机初始化的种群也无法保证初始质量良好。如果初始种群的适应度较差，优化算法可能需要很长时间才能找到一个较好的解，甚至可能在早期阶段就陷入局部最优解。通过引入循环混沌优化，基于混沌序列的确定性、伪随机性和遍历特性初始化一个多样化的种群，可以解决随机初始化种群集中在某些区域的问题[67]。如公式（3-1）所示。

$$x[i+1]=\left(\frac{cos(2\pi x[i])}{4\pi}+x[i]+0.35\right) \tag{3-1}$$

其中，只有x[0]∈[0,1]会被随机初始化，对于相同的x值，将生成相同的解。词嵌入矩阵将被定义为$M^F \epsilon R_{[0,1]}^{m\times m}$，其中m为嵌入空间的维度，根据上述公式生成一个与维度相同的微调矩阵$M^w \epsilon R_{[0,1]}^{n\times m}$。这样，初始种群的分布更加分散，能够覆盖整个解空间，在一定程度上提高了种群的平均质量，从而增强了优化算法的全局搜索能力，避免了陷入局部最优解。圆混沌初始化取值范围如图 3-3 所示。

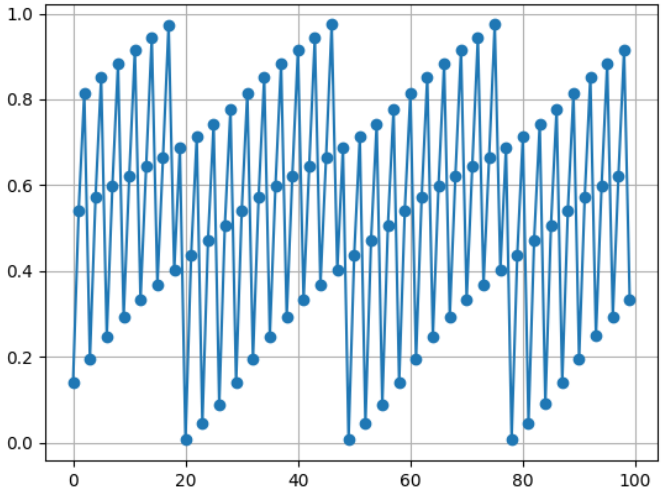

图 3-3 圆混沌初始化取值范围

相较于圆混沌初始化，还有一些其他的混沌映射，拿著名的混沌映射 Logistic 映射举例，这通常也用于生成随机数序列。如公式（3-2）所示。

$$x[i]=r\cdot x[i-1]\cdot(1-x[i-1]) \tag{3-2}$$

其中当r=4时，进入完全的混沌状态。

当情感分析任务中情感特征比较简单或数据集较为平衡时，Logistic 映射可以有效用于生成初始解，但在复杂的情感模式识别任务中，其表现不如圆混沌初始化。这是由于其缺乏圆混沌初始化那种较为均匀和均衡的搜索能力，从而影响模型的最终性能。此外，Logistic 映射的行为受参数r的控制，特别是在r较大时，

中国知网 https://www.cnki.net

系统的行为呈现混沌状态，这种混沌性有助于搜索空间的多样性，但也可能带来收敛速度较慢的问题。而圆混沌初始化具有较强的探索能力，能够跳出局部最优，探索到更为广泛的解空间，同时圆混沌初始化能够提供更好的初始解，这将使得遗传鲸鱼优化算法在寻找最佳词嵌入向量时能够加速收敛。具体实验结果参照本章实验部分。

通过引入$TF_{IDF}(t,d,D)$[68]来引导遗传高维鲸鱼优化算法的迭代方向，而$TF_{IDF}(t,d,D)$定义为公式（3-3）。

$$TF_{IDF}(t,d,D)=\frac{num(t,d)}{N_D}*log\frac{N}{1+|\{d\in D:t\in d\}|} \tag{3-3}$$

其中，num(t,d)表示特征t在文档d中出现的次数，N_D表示文档d中的总特征数，N是语料库中的总文档数，$|\{d\in D:t\in d\}|$表示包含特征t的文档数。

通过引入小的随机扰动来进一步增加种群的多样性表示为$TF_{IDF}(t,d,D)'$。其定义为公式（3-4）。

$$TF_{IDF}(t,d,D)'=TF_{IDF}(t,d,D)+\epsilon,\ \epsilon\sim N\left(0,\delta^2\right) \tag{3-4}$$

其中，使用一个标准差为δ的正态分布ϵ作为随机扰动值，通常在一个小范围内变化，以确保扰动不会破坏$TF_{IDF}(t,d,D)$值的基本特征，同时有助于增加搜索空间的多样性，提升优化算法的全局搜索能力，从而避免算法陷入局部最优解。

将通过圆混沌初始化的M^W矩阵与 $TF_{IDF}(t,d,D)'$结合，公式表示为（3-5）：

$$M^{WT}=TF_{IDF}(t,d,D)'\otimes M^W \tag{3-5}$$

其中，M^{WT}是结合后生成的种群，它会对解空间进行探索并提供初始值。

通过鲸鱼优化算法与遗传算法，在适应度函数的引导下获得优化权重矩阵，用于调整原始词嵌入矩阵，使其更能代表文本中单词所表达的情感。如公式（3-6）所示。

$$M_w^*=M_{best}^{WT}\otimes M^F \tag{3-6}$$

其中，M_w^*为最终得到的词嵌入矩阵，$\hat{X}$来自于M_w^*，M^F为原始的词嵌入矩阵，而M_{best}^{WT}是由优化算法得到的以文本 TF-IDF 为导向的种群中的最优个体。

在文本情感分析这项任务当中，原始词嵌入矩阵大多时候被用来呈现文本里词语的特征，不过鉴于情感特征于不同词语里的关键性有所不同，仅仅依靠原始

中国知网 https://www.cnki.net

词嵌入是很难全面表达出情感信息的，依据原始词嵌入矩阵引入权重矩阵，借助特征权重调整机制，对词嵌入矩阵实施加权优化，以此来提高词语的情感特征表达能力。权重矩阵中的每一个元素体现了对应维度的特征重要性，其优化过程和情感分类模型的性能直接相关。

为了在复杂的特征空间里高效地搜寻最优权重矩阵，运用鲸鱼优化算法来进行权重矩阵的优化，该算法借助模拟群体的觅食行为，同时有全局搜索和局部开发的能力，可有效地防止陷入局部最优。接下来会讲述使用鲸鱼优化算法获取最优权重矩阵的核心过程。

3.2.2 局部开发阶段

不同词语所有的情感信息权重呈现出较为较大的差异情况，故而引入了基于 TF-IDF 的引导机制，以此来提升特征权重优化方面的针对性。换言之，该方法依据文本中的 TF-IDF 权重信息，使种群个体在搜索过程中更倾向于高 TF-IDF 权重的特征维度，从而增强模型对关键情感特征的关注能力。TF-IDF 导向的种群M^{WT}不同阶段的切换由参数B_f控制[69]，其定义为公式（3-7）。

$$B_f=B_0\left(1-\frac{iteration}{2T}\right) \tag{3-7}$$

其中，B_0是一个介于 0 和 1 之间的随机数，iteration表示当前的迭代次数，T表示总迭代次数。通过上述公式获得参数B_f，随着迭代次数的增加，B_f的值范围会从 (0, 1) 变化到 (0, 0.5)。当B_f小于 0.5 时，算法将过渡到探索阶段；否则，将继续处于开发阶段。

鲸鱼在游泳之时表现出诸多社会行为，它们大多时候呈现出同步或者镜像的姿态来游动，始终维持彼此之间的接近状态，这样的合作性游泳行为可给算法里搜索代理位置的更新带来启发，于是算法于局部开发阶段引入了基于维度的正弦跟余弦扰动机制，以此对候选解的位置给予微调，提高局部搜索能力。其定义为公式（3-8）。

$$\begin{cases} \widehat{X}_{i,j,k}^{t+1}=\widehat{X}_{i,j,k}^{t}+(\widehat{X}_{r,j,k}^{t}-\widehat{X}_{i,j,k}^{t})(1+r_1)+sin(2\pi r_2) \\ \qquad ,k=even \\ \widehat{X}_{i,j,k}^{t+1}=\widehat{X}_{i,j,k}^{t}+(\widehat{X}_{r,j,k}^{t}-\widehat{X}_{i,j,k}^{t})(1+r_1)+cos(2\pi r_2) \\ \qquad ,k=odd \end{cases} \tag{3-8}$$

其中，$\widehat{X}_{i,j,k}$表示鲸鱼个体X_i在第j个维度上的更新值和在第k个维度上的更新

中国知网 https://www.cnki.net

值，这里的“鲸鱼个体”实质上对应一个用于优化词嵌入的权重矩阵解，用于调整词嵌入的特征表示。通过对偶数维施加正弦扰动$\sin(2\pi r_2)$、奇数维施加余弦扰动$\cos(2\pi r_2)$，引入周期性非线性变换，从而提升其跳出局部最优的能力。这种基于维度的微粒度调整机制，有助于提升个体的探索多样性，增强种群的全局收敛性能。其中，r_1和r_2均为取值范围在 0 到 1 之间的随机数。

3.2.3 全局探索阶段

鲸鱼会依据周围鲸鱼的位置来调节自身运动，协调捕食行为，彼此分享位置信息，以此提升捕猎成功率，在算法里，这种行为借助一同考量最优解和其他候选解给予模拟，在全局搜索阶段，个体也就是鲸鱼要在解空间中以跳跃方式探索，防止陷入局部最优，此机制对应特征权重矩阵的协同优化进程，能依靠整合多个候选解里的有用特征信息，提升权重矩阵对关键情感特征的表达能力，提高模型对细粒度情感特征的捕捉能力。传统搜索方式比如均匀分布或高斯分布的扰动，在复杂多峰优化问题中可能存在这些问题：一是跳跃幅度有限，容易陷入局部最优，二是缺乏远程突变，搜索范围窄，致使收敛速度慢，三是随机性不足，搜索多样性不高。为解决这些问题，引入了 Levy 飞行机制，其本质是一种跳跃策略，即大部分时间进行小步跳跃，不过偶尔会进行大步长跳，提高搜索范围与跳跃能力来提高算法的收敛效率。如公式（3-9）所示。

$$F_1=2r_4*\left(1-\frac{iteration}{T}\right) \tag{3-9}$$

其中，r_4是一个范围在(0,1)之间的随机数，F_1用于衡量属于 Levy 的飞行强度的随机跳跃强度。其定义如公式（3-10）所示。

$$L_F=0.05\times\frac{u\times\sigma}{|v|^{\frac{1}{\beta}}} \tag{3-10}$$

而 Levy 飞行函数L_F通过上述公式计算，其中u和v是正态分布的随机数，β是一个默认常数，值为 1.5。其定义如公式（3-11）所示。

$$\sigma=\left[\frac{\Gamma(1+\beta)\times\sin\left(\frac{\pi\beta}{2}\right)}{\Gamma\left(\frac{1+\beta}{2}\right)\times\beta\times2^{\frac{\beta-1}{2}}}\right]^{\frac{1}{\beta}} \tag{3-11}$$

此外，σ可以通过上述公式获得。在迭代过程中，逐步引入$TF_{IDF}(t,d,D)'$的动态引导项，并使用λ(t)来控制其比例。如公式（3-12）所示。

中国知网 https://www.cnki.net

$$\lambda(t)=\begin{cases}\lambda_0, iteration<T_{mid}\\ \lambda_0+(1-\lambda_0)*\dfrac{iteration-T_{mid}}{T_{mid}}, iteration\geq T_{mid}\end{cases} \tag{3-12}$$

这里，λ_0为范围在(0,0.1)之间的随机数，T_{mid}代表总迭代次数T的一半。

在迭代过程中，最优个体的鲸鱼位置，即最优解将临时记录并保存为$\hat{X}_{best}^{t}$。通过共享彼此的位置来模拟鲸鱼的捕食行为，并探索是否可以通过使用当前最优解和其他解来获得更优化的解。它定义为公式（3-13）。

$$\hat{X}_i^{t+1}=(1-\lambda(t))*r_3\hat{X}_{best}^{t}-r_4\hat{X}_i^{t}+F_1*L_F*\left(\hat{X}_r^{t}-\hat{X}_i^{t}\right)+\lambda(t)\cdot TF_{IDF}(t,d,D) \tag{3-13}$$

其中，$\hat{X}_r^{t}$是种群中的随机解，$\hat{X}_i^{t}$和$\hat{X}_i^{t+1}$分别表示第i个解在更新前和更新后的信息。

3.2.4 收敛调整阶段

收敛调整阶段模拟了白鲸在迁徙以及觅食进程中遭遇威胁却未能存活下来的状况，不过并非所有鲸鱼在面临威胁时都会坠落，多数鲸鱼可借助相互分享信息的方式来躲避危险，并且为避免鲸鱼种群数量降至初始规模之下，鲸鱼的信息会依据当前信息以及鲸鱼坠落的步长给予更新，此过程对应着对特征权重矩阵的动态修正机制。当模型在优化进程中陷入局部最优且难以提升时，收敛调整阶段可有效引导特征权重矩阵摆脱当前困境，依靠整合多个个体的特征信息，提高权重矩阵对情感极性特征的表达能力。其定义为公式（3-14）。

$$\hat{X}_{step}=(u_b-l_b)*e^{-F_2*\frac{iteration}{T}} \tag{3-14}$$

其中，$\hat{X}_{step}$是鲸鱼坠落的步长，u_b和l_b分别是变量的上限和下限，这里分别取值为 1 和 0。

$$P_{WF}=0.1-0.05\times\frac{iteration}{T} \tag{3-15}$$

$$F_2=2\times n\times P_{WF} \tag{3-16}$$

而F_2可以从上述公式（3-15）、（3-16）中获得，其中n是鲸鱼种群的数量。

$$\hat{X}_i^{t+1}=r_5\hat{X}_i^{t}-r_6\hat{X}_r^{t}+r_7\hat{X}_{step} \tag{3-17}$$

然后，通过当前的解信息$\hat{X}_i^{t}$、随机选择的解信息$\hat{X}_r^{t}$ 和步长$\hat{X}_{step}$，可以获得信息更新后的解$\hat{X}_i^{t+1}$，其公式为（3-17）。其中，r_5, r_6, r_7也是在(0,1)范围内的随

中国知网 https://www.cnki.net

机数。

3.2.5 遗传阶段

增加了遗传阶段[70]以模拟鲸鱼的繁殖过程。通过从适应度较高的鲸鱼中随机选择两个个体作为父母，探索在解空间内是否存在更多优化的解。该过程实质上对应于对高性能特征权重矩阵的重组与交叉，通过继承与组合多个优质权重配置的特征信息，从而进一步提升模型在情感分类任务中的泛化能力与鲁棒性。生成的解的数量不是固定的，并且添加了一定的变异概率。通过父母之间的相似度$S_{parents}$的高低来决定是否会发生变异，这里采用了余弦相似度（cosine similarity）。公式如（3-18）所示。

$$S_{parents}=\frac{\widehat{X}_F^T\widehat{X}_M}{\|\widehat{X}_F\|_2\|\widehat{X}_M\|_2} \tag{3-18}$$

新个体生成的交叉操作是由父个体的信息与母个体的信息以一定比例结合而成的，使用[1, (len$(\widehat{X}_F)$-1)]范围内的随机整数γ控制接合点，其中len$(\widehat{X}_M)$表示父类中元素的个数。其操作如公式（3-19）所示。

$$\widehat{X}_{new}=\left[\widehat{X}_F[:\gamma]:\widehat{X}_M[\gamma:]\right] \tag{3-19}$$

然后，对于新个体，有$S_{parents}$的概率发生突变，而对于需要进行突变的新个体信息内的元素，生成一个(0,1)范围内的随机数，若随机数的值小于变异概率P_M的值，则对该元素进行变异操作，P_M图像如图 3-4 所示。其定义为公式（3-20）：

$$P_M=\frac{1}{4+e^{-\frac{2T}{iteration}}} \tag{3-20}$$

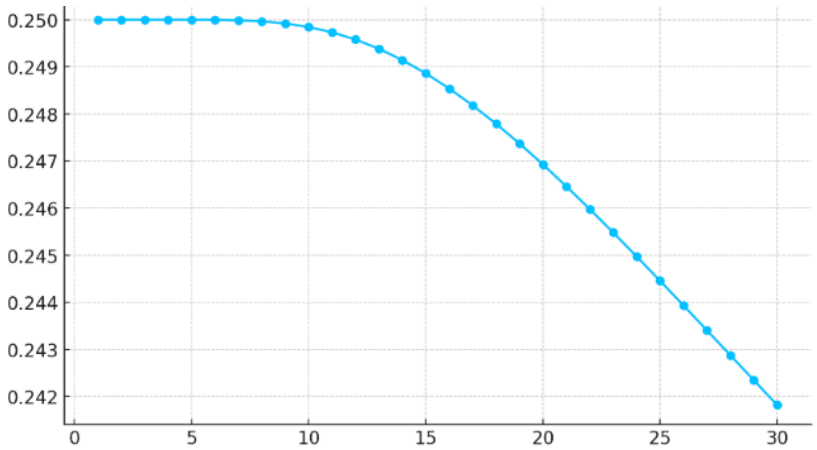

图 3-4 变异概率函数随迭代次数变化图像

中国知网 https://www.cnki.net

图 3-4 模拟结果表明，鲸鱼种群的信息随着迭代逐渐趋于稳定。

$$\hat{X}_{i,j,k}^{t+1}=1-\hat{X}_{i,j,k}^{t} \tag{3-21}$$

对于新个体，使用公式（3-21）对来自不同维度的信息进行变异操作。

3.2.6 输出层

输出层如公式（3-22）、（3-23）所示。

$$hidden=ReLU(W_{input}\otimes\hat{X}+b_{input}) \tag{3-22}$$

$$\hat{y}=W_{output}\otimes hidden+b_{output} \tag{3-23}$$

其中，hidden为隐藏层，$\hat{X}$用于表示模型为单词上下文创建的词嵌入向量序列，即$\hat{X}=\{\hat{x}_{i-k},\hat{x}_{i-k+1},\ldots,\hat{x}_{i-1},\hat{x}_{i+1},\ldots,\hat{x}_{i+k-1},\hat{x}_{i+k}\}$，而$\hat{x}_i$表示最终获得的最优词嵌入矩阵$M_w^*$中对应的词嵌入向量，$\hat{y}$为输出向量，$W_{input}$、$W_{Output}$为权重矩阵，$b_{input}$、$b_{Output}$为偏置，使用交叉熵函数作为损失函数。其定义为公式（3-24）：

$$Loss=-\Sigma_{j=1}^{m}LogP\left(\hat{x}_i\middle|\hat{X}\right) \tag{3-24}$$

3.3 数据集和实验设置

3.3.1 数据集

本章选取三个英文情感分析领域具有代表性的数据集作为实验基础，涵盖社交媒体、通用评论与金融文本三个不同语境，分别为：来源于 Stanford 大学 Alec Go 等于 2009 年发布的经典公开数据集 Sentiment140[71]，原始数据共包含约 160 万条带有情感标签的英文推文，情感标签通过表情符号自动标注为“积极”或“消极”，广泛应用于 SA 任务中；来源于 Kaggle 平台，由用户 abhi8923shriv 整理并发布的通用评论数据集，包含来自多个通用领域的英文评论数据[72]，并标注情感极性；以及同样来源于 Kaggle，由用户 sbhatti 发布[73]，主要包含金融领域的评论与新闻标题的金融文本数据集，具有较强的财经语义特征。为使变量保持一致、让模型训练更加稳定，同时保证分类性能评估公平公正，本文于三个实验数据集中都开展了人工均衡处理，尽力让正负类样本数量接近 1:1，此策略能缓解原始数据里或许存在的类别不平衡状况，防止模型训练时出现偏差，影响其泛化能力。在具体操作时，本文运用下采样策略，从原始数据里分别随机抽取正类与负类样本构建子集，以此控制类别分布的均衡程度。鉴于部分样本有较强代

中国知网 https://www.cnki.net

表性与语义质量，为避免信息丢失并更真切地模拟实际应用中的轻度不平衡现象，没有强行让正负类数量完全相同，适度保留微弱不均衡，可观察模型在接近真实分布时的鲁棒性表现，提高实验结果的实际参考价值。三个均衡处理后的数据集分别定义为 SA-S140-Twitter-EN、SA-Kaggle-General-EN 和 SA-Kaggle-Finance-EN。

本章的研究重点是评估 CCIGWO 对词向量质量的提升效果。因此选用结构较为简单、标注明了、比较容易进行特征比较的一些数据集，例如一些社交媒体中的短文本情感数据。其中这类数据的数据长度、句子结构和情感表达较为规范，优化前后词向量在情感区分度及特征空间结构上的差异具有更清晰的可观察性。此外，这类数据集的规模适中，易于进行多次实验与参数迭代，更加证明了优化方法自身的效果而不会被过于复杂的模型结构、语义多样性所干扰。

数据集在投入使用之前都经历了统一的预处理流程，囊括了去除特殊符号、URL 链接、表情符号，统一字母大小写，以及进行英文分词等一系列步骤，并且仅保留情感标签为正类（1）和负类（0）的样本，以此统一构建成标准的二分类情感分析任务，保证了实验有规范性以及可复现性，具体的统计信息呈现在表 3-1 中。在实验过程里，各数据集依照 8:2 的比例被划分成训练集和测试集。

表 3-1 数据集介绍

数据集	正类		负类	
	训练集	测试集	训练集	测试集
SA-S140-Twitter-EN	2600	650	2680	670
SA-Kaggle-General-EN	6865	1717	6224	1557
SA-Kaggle-Finance-EN	800	200	688	172

3.3.2 实验参数与环境

实验参数设置与实验环境如表 3-2、3-3 所示。

表 3-2 实验参数配置

参数	词嵌入维度	BiLSTM 单元数	丢弃率	全连接层神经元数	Epoch 次数	句子长度	词嵌入学习率	分类器学习率
值	200	128	0.5	128	50	40	0.065	0.001

中国知网 https://www.cnki.net

表 3-3 实验环境

实验环境	操作系统	本地处理器与内存	本地 GPU	云端环境	开发语言	开发工具
具体信息	Windows 10 专业版（64 位）	Intel Core i7-11800H @2.30GHz，16GB 内存	NVIDIA GeForce RTX 3060	Google Colab，Ubuntu 20.04	Python 3.11	PyCharm 2022.3

最后，本章所有实验结果均为在十组不同随机种子设置下独立运行所获得最优结果的平均值，以减少偶然因素对模型性能评估的影响。

3.4 实验结果及性能评估

本章设计了两类实验，旨在全面验证所提出 CCIGWO 词嵌入优化模型在文本情感分类任务中的有效性与鲁棒性。

第一类实验聚焦于词嵌入层面的性能对比，选取 GloVe、Word2Vec、Emo2Vec、SoftEMD、WordFast 等主流嵌入方法作为对比基线，将不同词向量输入统一的 BiLSTM 分类器中进行训练与测试，评估不同嵌入方式在多源情感数据集上的表达能力。

第二类实验侧重于优化策略本身的稳定性与泛化能力评估，具体包括：设置不同的初始化策略（如 Logistic 混沌序列初始化、圆混沌初始化对比）、去除遗传机制的简化版本（即只保留 WOA 与初始化）。通过多次独立运行实验，比较模型在不同配置下的性能波动。

3.4.1 基线方法及对比分析

本章实验旨在全面评估所提出的词嵌入优化方法（CCIGWO）在文本情感分类任务中的整体性能表现。为确保对比的科学性、系统性与公平性，实验选取了多种具有代表性的词嵌入方法作为对照模型，涵盖传统静态词嵌入方法与近年来提出的预训练型情感增强词嵌入方法，具备良好的覆盖性与代表性。

接下来将依次介绍实验中使用的各类词嵌入方法，并说明这些方法在引入 CCIGWO 优化算法后的增强策略，为后续实验分析奠定结构基础。

（1）静态词嵌入方法：

Doc2Vec＋CNN[74]：将文本通过 Doc2Vec 模型生成段落级嵌入向量，输入卷

中国知网 https://www.cnki.net

积神经网络（CNN）提取局部上下文特征，适用于捕捉短文本中的情感特征。

Word2Vec[75] + BiLSTM：使用 Word2Vec 构建词嵌入矩阵，结合双向 LSTM 建模文本序列的前后依赖关系，能够较好捕捉情感的上下文动态变化。

GloVe[76] + BiLSTM：使用 GloVe 模型生成词嵌入向量，通过全局共现矩阵建模词间的统计关系，再输入双向 LSTM 对序列进行前后建模。该组合在情感分析中表现稳定，能有效提升模型对上下文语义的理解能力。

SoftEMD[77] + BiLSTM：SoftEMD 嵌入通过最优传输方式考虑词汇间语义相似性，配合 BiLSTM 提升模型对词序语义差异的感知能力。

Emo2Vec[78] + BiLSTM：Emo2Vec 嵌入融合情感词典和外部任务情感知识，配合 BiLSTM 提升模型对情绪词汇的敏感性与识别准确率。为了确保所有嵌入方法的一致性，并在统一的分类架构内进行公平比较，原始的 300 维 Emo2Vec 向量被线性投影到 200 维。

WordFast[79] + BiLSTM：WordFast 结合快速近邻构造上下文聚类词向量，配合 BiLSTM 增强对词义变化和上下文感知能力。

（2）预训练词嵌入方法：

SentiLARE[80] + BiLSTM：SentiLARE 嵌入通过整合情感词典、情感极性标签与句法信息，显式增强了模型对情感倾向特征的感知能力。配合 BiLSTM 结构，能够有效捕捉文本中的上下文情感线索。

ERNIE-Gram[81] + BiLSTM：ERNIE-Gram 嵌入结合了知识增强机制与短语级语义建模，通过挖掘词汇间的短语关系与语义依赖信息，有效提升模型对复杂语义结构和实体关系的建模能力。结合 BiLSTM 网络，进一步强化对文本上下文信息的全局感知。

RoBERTa-base[82] + BiLSTM：RoBERTa 嵌入基于大规模无监督预训练语料，具备强大的上下文语义表达能力，在多种自然语言处理任务中表现优异。结合 BiLSTM 结构，能够充分挖掘文本中的深层语义关系，增强模型对情感特征的综合建模能力。

（3）CCIGWO 优化后的词嵌入模型：

CCIGWO + Word2Vec[75] + BiLSTM：将 CCIGWO 优化算法引入 Word2Vec 词嵌入中，提升向量对情感极性的表达能力，结合 BiLSTM 增强对情感特征的建

中国知网 https://www.cnki.net

模能力。

CCIGWO + GloVe[76] + BiLSTM：在 GloVe 生成的词嵌入基础上，利用 CCIGWO 算法对向量进行情感优化，引导词向量在情感维度上更具区分性，从而提升 BiLSTM 的分类性能。

CCIGWO + SoftEMD[77] + BiLSTM：在 SoftEMD 嵌入基础上使用 CCIGWO 进一步挖掘传输距离与情感结构的匹配关系，提升模型情感辨识精度。

CCIGWO + Emo2Vec[78] + BiLSTM：使用 CCIGWO 优化 Emo2Vec 中词语情绪分布权重，引导嵌入生成更具情感差异度的表示，进一步强化 BiLSTM 情感识别性能。

CCIGWO + WordFast[79] + BiLSTM：融合 WordFast 上下文敏感嵌入与 CCIGWO 优化策略，提升模型对语义变异和情感极性的双重适应能力。

由于 Doc2Vec 的输出本质上是一个整体语义向量，并不包含原始文本的词序列信息，因此难以直接作为序列建模类网络的输入。而 CNN 对输入的顺序依赖较弱，能够以滑动窗口的方式提取局部特征，更适合处理这类定长向量表示。

各组实验均在相同数据集上进行，如表 3-4、3-5、3-6 所示，整体来看，不同词嵌入方法在文本情感分类任务中的性能差异明显，且在各数据集上表现出一致的趋势。

表 3-4 SA-S140-Twitter-EN 数据集上的实验结果(%)

模型	准确率	精度	召回率	F1值
Doc2Vec + CNN	75.6	75.57	76.08	75.82
Word2Vec + BiLSTM	77.17	77.39	77.77	77.58
GloVe + BiLSTM	78.51	78.09	78.83	78.46
SoftEMD + BiLSTM	80.42	80.11	80.96	80.53
Emo2Vec + BiLSTM	82.2	82.52	82.17	82.34
CCIGWO + Word2Vec + BiLSTM	82.94	83.06	83.11	83.08
SentiLARE + BiLSTM	83.37	83.51	84.01	83.95
CCIGWO + GloVe + BiLSTM	83.8	83.65	84.12	83.88
WordFast + BiLSTM	84.01	84.17	83.78	83.98
ERNIE-Gram + BiLSTM	84.16	83.89	84.38	84.16
RoBERTa-base + BiLSTM	84.4	84.11	84.84	84.56

中国知网 https://www.cnki.net

模型	准确率	精度	召回率	F1值
CCIGWO + SoftEMD + BiLSTM	84.62	84.55	84.78	84.67
CCIGWO + Emo2Vec + BiLSTM	85.7	85.91	85.45	85.68
CCIGWO + WordFast + BiLSTM	**86.44**	**86.17**	**86.79**	**86.47**

表 3-5 SA-Kaggle-General-EN 数据集上的实验结果(%)

模型	准确率	精度	召回率	F1值
Doc2Vec + CNN	71.81	72.31	72.03	72.17
Word2Vec + BiLSTM	74.8	74.54	73.88	74.21
GloVe + BiLSTM	76.37	76.25	77.05	76.65
SoftEMD + BiLSTM	78.16	78.43	78.69	78.56
Emo2Vec + BiLSTM	78.83	78.71	79.28	78.99
CCIGWO + Word2Vec + BiLSTM	79.05	78.94	79.87	79.4
CCIGWO + GloVe + BiLSTM	80.12	80.38	80.56	80.47
WordFast + BiLSTM	81.25	81.46	80.92	81.19
CCIGWO + SoftEMD + BiLSTM	82.36	82.79	82.11	82.45
SentiLARE + BiLSTM	82.83	82.64	82.02	82.21
CCIGWO + Emo2Vec + BiLSTM	83.27	83.42	83.59	83.51
ERNIE-Gram + BiLSTM	83.3	83.26	83.39	83.52
RoBERTa-base + BiLSTM	83.42	83.3	82.63	82.71
CCIGWO + WordFast + BiLSTM	**84.13**	**84.41**	**83.98**	**84.19**

表 3-6 SA-Kaggle-Finance-EN 数据集上的实验结果(%)

模型	准确率	精度	召回率	F1值
Doc2Vec + CNN	71.25	71.48	70.83	71.15
Word2Vec + BiLSTM	74.27	74.84	73.49	74.16
GloVe + BiLSTM	76.58	75.96	76.05	76
SoftEMD + BiLSTM	77.14	76.45	76.84	76.64
CCIGWO + Word2Vec + BiLSTM	77.86	78.31	77.05	77.67
CCIGWO + SoftEMD + BiLSTM	78.01	77.95	77.36	77.65
Emo2Vec + BiLSTM	78.16	78.29	77.33	77.81
CCIGWO + GloVe + BiLSTM	78.87	78.44	77.91	78.17

中国知网 https://www.cnki.net

模型	准确率	精度	召回率	F1值
RoBERTa-base + BiLSTM	79.63	79.91	81.59	81.4
WordFast + BiLSTM	79.76	79.52	79.11	79.32
SentiLARE + BiLSTM	79.91	79.73	80.58	80.57
CCIGWO + Emo2Vec + BiLSTM	80.73	80.98	80.02	80.49
ERNIE-Gram + BiLSTM	81.18	81.24	79.89	80.09
CCIGWO + WordFast + BiLSTM	**81.75**	**81.63**	**81.39**	**81.51**

首先，CCIGWO + WordFast + BiLSTM 组合在所有数据集上均取得最优性能，F1 值分别达到 86.47%、84.19%和 81.51%，在各项指标中均稳居首位，展现了出色的情感特征建模能力和广泛的泛化性。

预训练语言模型（如 SentiLARE、ERNIE-Gram、RoBERTa）整体表现优异，RoBERTa-base + BiLSTM 和 ERNIE-Gram + BiLSTM 在三组数据集上的 F1 值均超过 82%，尤其在 SA-Kaggle-Finance-EN 数据集中，F1 值分别达到 81.40%和 80.09%，显著优于传统静态词嵌入方法，凸显其强大的上下文建模能力。

融合情感知识的词嵌入方法（如 Emo2Vec 和 WordFast）在各数据集上表现稳健，尤其是 WordFast，即便未引入优化，F1 值也能维持在 79%以上。引入 CCIGWO 优化后，CCIGWO + Emo2Vec + BiLSTM 和 CCIGWO + WordFast + BiLSTM 均实现了约 2%的性能提升，验证了进化优化策略与情感词嵌入的互补优势。

此外，传统静态词嵌入方法（如 Word2Vec 和 GloVe）在 CCIGWO 优化下均显著提升，CCIGWO + GloVe + BiLSTM 的 F1 值分别提升至 83.88%、80.47%和 78.17%，表明该优化方法对传统词向量同样有效。相对而言，Doc2Vec + CNN 在所有数据集中表现最弱，F1 值最低，显示其在情感分类任务中因缺乏词序与上下文信息而存在的局限性。

3.4.2 词嵌入分布可视化与方法随机性排除

为深入验证 CCIGWO 优化策略对词嵌入空间结构的影响，选取了优化前后 word2Vec 的 200 个词向量，并使用 t-SNE 对其降维至二维空间进行可视化，如图 3-5 所示。图中蓝色圆点表示原始词嵌入向量，红色圆点表示优化后的词嵌入向量，图中实线连接同一词语表示优化前后的空间位置。

中国知网 https://www.cnki.net

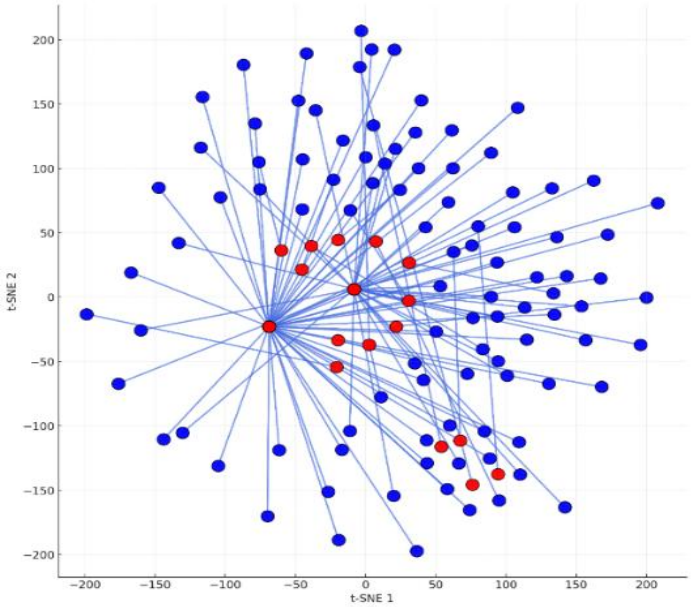

图 3-5 优化前后 word2Vec 的 200 个词向量的 t-SNE 可视化迁移情况

由图 3-5 可知：

（1）向量分布结构更紧凑，语义聚类增强。优化后的词向量（红点）相比原始词向量（蓝点）在空间中呈现出更紧凑的分布，尤其在图中心及右下方区域，出现了多个由红点构成的局部聚类簇。这些簇代表语义相近的词被映射到相邻位置，表明优化算法显著增强了同类词的语义一致性。同时，蓝色原始向量分布更分散，部分无关特征混入其中，而红色聚类簇则显示出噪声特征被有效抑制，有助于情感分类模型更准确地捕捉情感相关信息。

（2）个别词向量收敛至局部区域。图 3-5 中部分词向量在优化后出现了向同一位置靠拢、几乎重合的趋势，右下方及中心区域有一些红色点几乎重合，形成高密度小团簇。这种现象的形成有两个主要原因：这种现象的出现主要有两个原因：（a）语义贡献较小的功能词压缩效应：由于优化目标以分类性能为核心，部分语义贡献较小的词（频繁出现的功能词，如“the”，“of”，“and”等）被压缩到语义上“无差异”的区域，导致它们在可视化中几乎重叠；（b）t-SNE 的降维压缩效应：t-SNE 作为非线性降维方法，会在嵌入向量变化范围较小时产生维度压缩效应，使一些相似向量产生“重叠”或“聚点”效果。这种“集中”并不代表嵌入失败，反而说明模型有选择性地保留了具有情感区分性的特征表达，并将无关或冗余信息折叠到较小区域，从而提升分类的判别能力。

t-SNE 可视化结果验证了 CCIGWO 优化方法在提升词嵌入结构组织性、情感区分性与分类判别能力方面的有效性，也进一步说明该方法能够在不破坏原有

中国知网 https://www.cnki.net

语义的前提下，强化词向量的任务相关性。

3.4.3 消融实验

表 3-7 展示了 SA-S140-Twitter-EN 数据集上，CCIGWO 各模块对模型性能的影响。

表 3-7 SA-S140-Twitter-EN 数据集上各模块对 CCIGWO 的影响(%)

消融实验	准确率	精度	召回率	F1 值
Baseline: Word2Vec + BiLSTM	77.17	77.39	77.77	77.58
TF-IDF: Word2Vec + BiLSTM	80.12	80.45	80.27	80.36
CCIGWO–GA: Word2Vec + BiLSTM	81.98	82.34	81.95	82.14
Logistic-CCIGWO: Word2Vec + BiLSTM	82.55	82.68	82.49	82.58
Full CCIGWO: Word2Vec + BiLSTM	**82.94**	**83.06**	**83.11**	**83.08**

整体来看，完整配置的 CCIGWO + Word2Vec + BiLSTM 在准确率、精度、召回率和 F1 值四项指标中均取得最优，验证了各优化模块的有效性。Baseline 模型（Word2Vec + BiLSTM）F1 值仅为 77.58%，在细粒度情感识别方面表现有限；引入鲸鱼优化与圆混沌初始化的 CCIGWO－GA 模型，将 F1 值提升至 82.14%，凸显了群体智能优化的优势，尤其鲸鱼优化在局部搜索中效果显著。

进一步地，将圆混沌初始化替换为传统 Logistic 映射的 Logistic-CCIGWO 方案，F1 值降至 82.58%，表明圆混沌在保持种群多样性和全局搜索能力方面优于 Logistic 映射。最终，集成圆混沌初始化、遗传机制与鲸鱼优化的完整 CCIGWO 模型，F1 值提升至 83.08%，实现最优性能。此外，为验证静态特征权重策略的效果，实验引入基于 TF-IDF 权重的特征融合方案，F1 值达到 80.36%，优于 Baseline 模型，证明静态特征权重能在一定程度上增强情感特征。然而，与 CCIGWO 系列方法相比，TF-IDF 方案仍存在明显差距，主要因其缺乏动态优化能力，难以充分挖掘复杂语义特征。总体而言，CCIGWO 在动态权重学习与细粒度情感建模方面具备明显优势。

实验表明无论是初始化策略的选取，还是遗传算子的引入，均对最终性能提升发挥了重要作用。各模块协同增强了词向量对情感极性的表达能力，提升了模型的整体稳定性与泛化性能，进一步证明了 CCIGWO 优化机制在情感分析任务中的有效性与实用性。

中国知网 https://www.cnki.net

3.5 本章小结

本章提出一种圆混沌初始化与遗传鲸鱼优化相结合的词嵌入算法，专注于强化特征的情感信息表达。该方法首先通过圆混沌策略生成具有良好分布性的初始种群，以增强搜索多样性；随后引入基于 TF-IDF 的引导机制，对词嵌入矩阵中的各特征进行重要性加权，从而突出高情感信息特征并削弱冗余干扰。结合遗传算法中的选择与变异操作，有效提升了优化效率，实现在增强语义表达能力的同时降低模型复杂度的目标。

实验结果表明，所生成的优化词嵌入向量在多个公开情感数据集上显著提升了情感分类模型的准确率与 F1 值，表现出良好的稳定性与鲁棒性，证明该方法具备较强的实用性与可靠性。然而，CCIGWO 方法主要从词级特征出发进行优化，尚未充分建模上下文依赖关系，难以捕捉情感词之间的全局语义关联。为进一步提升模型对情感结构与语义关系的建模能力，下一章节将探讨结合位置编码与多极注意力机制的深层表示方法。

中国知网 https://www.cnki.net

第四章 基于 HP-MHPA 的文本情感分析

本章主要针对文本情感分析任务中的特征的复杂情感极性表达和模型上下文信息捕捉不全面的问题，提出了一种基于混合位置编码和多头多极注意力机制（HP-MHPA）的文本分类模型。针对现有模型在处理文本的全局语义和局部信息时的局限性，本章通过引入混合位置编码和多头多极注意力机制，提升了模型对文本情感的判别能力。本章安排如下：4.1 节介绍本章的研究内容及其背景；4.2 节详细阐述 HP-MHPA 模型的设计思路及实现方法；4.3 节为数据集和实验设置描述；4.4 节为实验结果分析，并与现有模型进行对比分析；4.5 节本章总结。

4.1 问题引出

虽然 CCIGWO 有效提升了词嵌入的情感表达能力，但在整体文本情感分析任务中，模型结构优化同样发挥着重要作用。与词嵌入优化侧重输入特征不同，模型结构优化主要聚焦于深层语义特征的建模与情感关系的挖掘。在具体的模型结构设计中仍存在以下两个亟待解决的关键问题：

（1）当模型在提取上下文特征时，容易忽略细粒度的极性差异，特别是在复杂语义结构或隐喻性表达中，缺乏对情感主旨词与极性词的精准识别。

（2）全局与局部语义建模难以兼顾：情感表达既包含跨句、跨段的全局依赖信息，也包含局部强突出的情感特征，而传统模型往往难以同时兼顾这两种不同尺度的语义线索，限制了模型的表达能力与泛化性能。

为了解决上述问题，本章提出了基于混合位置编码和多头多极注意力机制（HP-MHPA）的文本分类模型，具体可以在以下方面得到改进：

（1）针对不同类别的相同特征嵌入表示可能相似的问题，通过引入多极头注意力机制来放大嵌入表示在不同类别中的差异，从而生成两个具有明显区分性的嵌入表示。将这两个表示结合起来，有助于显著增强特征嵌入在情感极性表达上的能力，从而提高文本情感分析的准确性和模型的泛化能力。

（2）将并行的多极头注意力机制与混合位置编码相结合，能够更灵活地表示词语在文本中的相对和绝对位置关系，从而帮助模型更好地理解上下文信息，提升情感分析任务中的文本理解能力。

中国知网 https://www.cnki.net

4.2 HP-MHPA 模型的整体结构

HP-MHPA 模型的整体结构如图 4-1 所示。

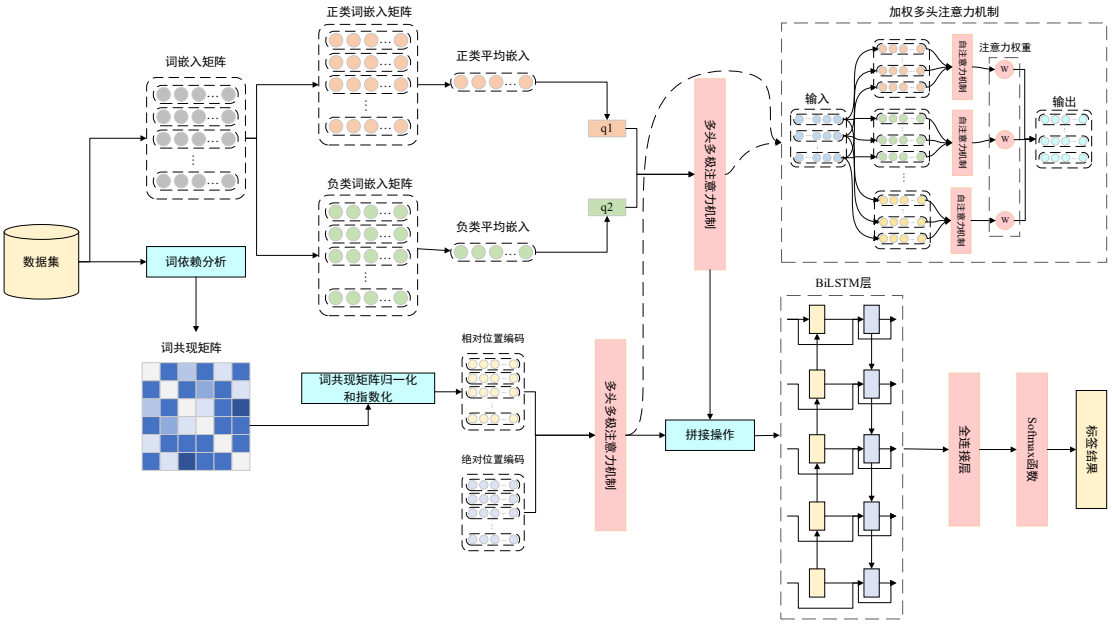

图 4-1 HP-MHPA 模型整体结构图

首先，基于类别标签对数据集进行拆分。对于每个类别，先将该类别下所有文本的词嵌入向量按词汇位置对齐，然后计算每个类别中所有词汇的嵌入均值，作为该类别的类别嵌入。接着，模型定义了一个复合损失函数。这个损失函数由两部分组成：一部分是基于正、负类别嵌入之间的相似性，另一部分是传统的交叉熵损失函数。损失函数的最终值是这两部分损失以一定权重比例的加权，从而平衡类别嵌入的相似性和标准分类任务的交叉熵损失。与此同时，模型将完整的词嵌入矩阵分别与正、负类别嵌入一起输入到多头注意力机制中，从而生成与正类与负类相关的注意力嵌入。这种机制能够捕捉词嵌入在不同类别嵌入下的重要特征，并有助于提升模型的分类性能。

为使模型对输入序列的空间位置感知得以提高，模型会给每个输入序列增添绝对位置编码，这些绝对位置编码是经由对每个词的位置给予编码而生成的，以此保证模型可分辨不同位置的词汇。模型还会借助词共现矩阵与原始词嵌入矩阵相结合，之后进行归一化，生成相对位置编码，把词共现矩阵与词嵌入相结合，可捕捉到词汇间的语义相似性以及依赖关系。归一化操作保证了相对位置编码在数值方面的一致性与稳定性，在此之后，绝对位置编码与相对位置编码会借助多头注意力机制结合到一起，生成最终的位置编码，这一位置编码可帮助模型理解

中国知网 https://www.cnki.net

词汇在序列里的相对位置，还可结合词汇的语义关系，提升模型对上下文信息的理解能力。

最后，模型将位置编码、正类注意力嵌入和负类注意力嵌入进行拼接，形成一个综合的输入表示。这个综合表示包含了词汇的语义信息、位置关系以及类别相关的上下文信息。最终，这个表示将作为输入传入分类模型，经过一系列全连接层和 softmax 层处理后，得到模型的最终输出，用于文本情感分析任务。

4.2.1 正负类别嵌入

为构建类别特定的嵌入表示，从而更细致地挖掘各个词语所传达的情感信息，我们首先根据情感标签将完整的语料库划分为正类语料库和负类语料库。其关系如公式（4-1）所示。

$$D=Concat\left(D_{pos},D_{neg}\right) \tag{4-1}$$

其中，D表示完整的语料库，D_{pos}和D_{neg}分别表示从中划分得到的正类语料库和负类语料库。并根据其中内容生成对应的词嵌入矩阵，使用M表示完整的词嵌入矩阵，M_{pos}和M_{neg}分别表示正类词嵌入矩阵和负类词嵌入矩阵，它们的定义如（4-2）、（4-3）所示。

不同词语的词嵌入表示将仅基于其所在类别语料库的上下文信息进行学习。换言之，对于同时出现在正类和负类语料中的词，其在正类词嵌入矩阵M_{pos}和负类词嵌入矩阵M_{neg}中的表示将是不同的，从而更好地捕捉该词在不同情感语境下的语义差异。

$$M_{pos}=\left[e_1^{pos},e_2^{pos},\ldots,e_m^{pos}\right] \tag{4-2}$$

$$M_{neg}=\left[e_1^{neg},e_2^{neg},\ldots,e_n^{neg}\right] \tag{4-3}$$

其中$e_i^{pos}\in R^d$是正类语料中第i个词的嵌入向量，m为正类词汇的数量，而$e_i^{neg}\in R^d$则为负类语料中第i个词的嵌入向量，n为负类词汇的数量。

对于每个类别 c，计算该类别所有词汇的词嵌入均值用于构建该类的类别嵌入，如公式（4-4）所示。

中国知网 https://www.cnki.net

$$q_c=\frac{1}{|V_c|}\sum_{i\in V_c}e_i \tag{4-4}$$

其中V_c为类别c下的所有词汇的集合，e_i表示每个词的嵌入向量，q_c为该类的类别嵌入。

4.2.2 多头多极注意力机制

在多头注意力机制中，$\alpha_{i,j}^h$表示在第h个头上的第i个查询词和第j个键词之间的注意力权重，用于反映查询词和键词之间的关联程度[83]，如公式（4-5）所示。

$$\alpha_{i,j}^h=\frac{exp\left(Q_i^h,K_j^h\right)}{\Sigma_{k=1}^H exp\left(Q_i^h,K_k^h\right)} \tag{4-5}$$

其中Q_i^h和K_j^h分别为第i个查询词和第j个键词的向量表示，使用指数函数exp进行缩放以增强高相似度的影响力，而分母部分对所有可能的特征词进行归一化，使得所有的注意力权重总和为 1。

通过将注意力权重$\alpha_{i,j}^h$与值向量V_j^h加权求和得到注意力输出O_i^h，为公式（4-6）。

$$O_i^h=\sum_{j=1}^{H}\alpha_{i,j}^h V_j^h \tag{4-6}$$

其中H为注意力头的数量。

最后拼接所有注意力头的输出O_i^h得到最终的注意力输出O_i，如公式（4-7）所示。

$$O_i=Concat\left(O_i^1,O_i^2,...,O_i^H\right) \tag{4-7}$$

然而，标准的多头注意力机制虽然能够捕捉不同语义子空间中的注意力模式，但其对类别信息的感知仍然是隐式的，难以对正负情感特征进行显式建模。为此，进一步引入多极注意力机制，以增强模型对情感极性的显式感知能力。

具体地说，假设x_i为一段输入序列，首先根据词嵌入矩阵M、正类词嵌入矩阵M_{pos}和负类词嵌入矩阵M_{neg}生成该输入序列x_i的对应嵌入序列$M(x_i)$、$M_{pos}(x_i)$和$M_{neg}(x_i)$，将这三个嵌入序列分别输入到多头多极注意力机制 MHPA(Q,K,V)中，得到最终有关正负类的注意力输出，分别表示为O_i^{pos}、O_i^{neg}，如公式（4-8）、（4-9）所示。

中国知网 https://www.cnki.net

$$O_i^{pos}=MHPA\left(M_{pos}(x_i),M(x_i),,M(x_i)\right) \tag{4-8}$$

$$O_i^{neg}=MHPA\left(M_{neg}(x_i),M(x_i),M(x_i)\right) \tag{4-9}$$

这种结构不仅保持了多头注意力在建模上下文关系方面的优势，同时引入正负极性嵌入作为查询向量，使模型能够显式对比并提取与正向或负向情感更相关的语义信息。

通过将正负类的注意力输出O_i^{pos}、O_i^{neg}作为模型的一部分输入，模型在分类的时候，可依据上下文表示的强弱分布情况，并且还可以借助显式情感引导信息，以此提升对细粒度情绪信号的感知能力，更精准地区分正负情感类别，这种策略提升了模型对情感倾向的建模能力，也给后续的分类器提供了更具判别性的表示输入。

4.2.3 混合位置编码

（1）绝对位置编码

绝对位置编码可被应用于不一样长度的输入序列当中，为模型给予有关输入序列里各个元素的位置方面的信息，以此协助模型去理解序列里各个词语的位置关联，得以让模型保持对于词语之间先后顺序信息的感知[84]。

绝对位置编码借助固定的编码方式，也就是运用正余弦函数为每个词语在不同维度上生成特殊的编码，如公式（4-10）所示。

$$\begin{cases} PE_{i,2k}=sin\left(\dfrac{i}{1000^{\frac{2k}{d}}}\right) \\ PE_{i,2k+1}=cos\left(\dfrac{i}{1000^{\frac{2k}{d}}}\right) \end{cases} \tag{4-10}$$

其中i为序列中单词的位置索引，k为每个单词的维度索引，d为嵌入维度。

最后会把输入序列嵌入，使其与对应的唯一绝对位置编码相加，用于下一步和相对位置编码相结合，以此提升模型对序列的建模能力，提高全局的上下文理解，如公式（4-11）所示。

$$x_i^{PE}=x_i+PE(x_i) \tag{4-11}$$

其中，x_i^{PE}用于表示添加绝对位置编码后的输入序列。

中国知网 https://www.cnki.net

（2）词共现相对位置编码

相对位置编码和绝对位置编码存在差异，相对位置编码更侧重于词语之间的相对关联，而非其在序列里的绝对位置[85]，将词共现矩阵用作相对位置编码的主要目的，是依靠获取词语之间的共现关系，以此强化模型对词语在序列中相对位置信息的理解[86]，如图 4-2 所示。

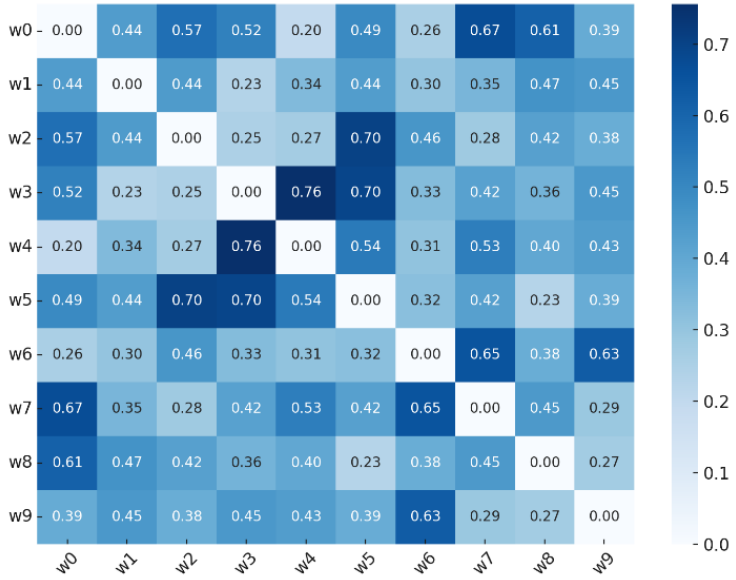

图 4-2 词共现矩阵示意图

词共现矩阵的构建方式是，对词汇表内任意两个词，统计其于固定滑动窗口内同时出现的频率，以此来构建矩阵，该矩阵可用来描绘词语在文本里的共现关系，要是两个词在词共现矩阵中所对应的元素值越大，那就说明它们在语料里共同出现的频率越高，一般也就意味着这两个词在语义方面有更强的相关性。在本章中，词共现矩阵记作C。其结构如公式（4-12）所示。

$$C=\begin{bmatrix} C_{11} & C_{12} & \cdots & C_{1L} \\ C_{21} & C_{22} & \cdots & C_{2L} \\ \vdots & \vdots & \ddots & \vdots \\ C_{L1} & C_{L2} & \cdots & C_{LL} \end{bmatrix} \tag{4-12}$$

其中，C_{ij}表示词i和词j之间的共现频率。为了增强其数值稳定性和表达能力，对词共现矩阵C进行归一化处理，并引入指数函数exp()转换，得到矩阵C^*用于下一步获得相对位置编码。C^*由公式（4-13）获得。

$$C^* = exp\big(Normalize(C)\big) \tag{4-13}$$

中国知网 https://www.cnki.net

通过将C^*与原始词嵌入矩阵进行融合，并对融合结果进行归一化处理，最终生成相对位置编码矩阵R。R由公式（4-14）获得。

$$R=Normalize\left(C^* \cdot M\right) \tag{4-14}$$

最终，将输入序列x_i对应的绝对位置编码x_i^{PE}与相对位置编码$R(x_i)$共同输入至多头多极注意力机制MHPA(Q,K,V)中，得到融合位置信息的最终表示P。其公式为（4-15）。

$$P=MHPA\left(x_i^{PE},R(x_i),R(x_i)\right) \tag{4-15}$$

本研究采用的位置编码模块，一个源于 Transformer 里的经典正弦位置编码，另一个基于词共现矩阵的关系特征矩阵，不过二者融合方式不是简单叠加，而是依据情感分析任务特征需求，设计了专门的融合策略，展开来说，借助加权融合机制，动态调节正弦位置编码和词共现矩阵的关键性权重，以此兼顾句法序列特征与情感共现关系。此策略能在保证序列结构性的情况下，有效捕捉强相关情感词间的共现模式，特别适合多义词、情感转折等复杂语义现象的建模。

4.2.4 输出层

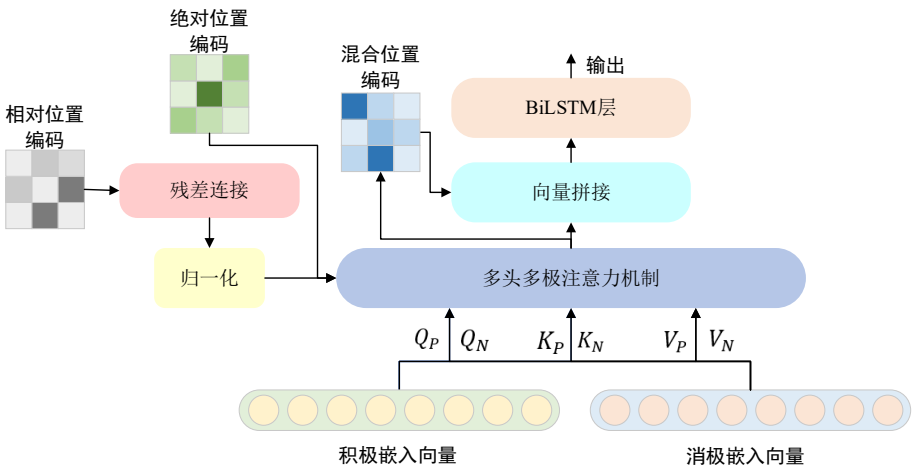

图 4-3 模型结构及位置编码融合机制示意图

将位置编码、与正类相关的注意力输出以及与负类相关的注意力输出进行拼接，构成最终的输入表示x_i^*。其公式为（4-16）。

$$x_i^*=Concat(P,O_i^{pos},O_i^{neg}) \tag{4-16}$$

最终的分类结果通过全连接层和softmax函数进行计算，具体公式如（4-17）所示：

中国知网 https://www.cnki.net

$$\hat{y}_i = softmax\left(W \otimes x_i^* + b\right) \tag{4-17}$$

其中，W为权重矩阵，b为偏置项，$\hat{y}_i$为最终的分类预测。模型结构及位置编码融合机制如图 4-3 所示。

4.2.5 复合多极损失函数

多头多极注意力机制采用损失函数$Loss_1$，这也是模型复合损失函数的一部分，该损失由不同类别向量q_c之间的交叉熵构成，用于衡量类别表示之间的区分度。其公式如（4-18）所示。

$$Loss_1 = -\sum_{i,j \in c} \sum_{k=1}^{d} q_{c_i,k} Log(q_{c_j,k}) \tag{4-18}$$

其中，d表示嵌入维度，q_{c_i}为类别c_i对应的嵌入向量。该损失函数通过计算不同类别嵌入向量之间的交叉熵，有效增强类别之间的可分性，从而提升模型的判别能力。

模型复合损失函数的另一部分为$Loss_2$，用于衡量模型预测标签与真实标签之间的差异。该部分采用标准的交叉熵损失函数，具体定义如（4-19）所示。

$$Loss_2 = -yLog(\hat{y}) \tag{4-19}$$

其中，y表示真实的类别标签，$\hat{y}$表示模型输出的预测概率。该损失函数旨在最小化预测分布与真实分布之间的差异，从而提高分类准确性。

$$Loss = \gamma Loss_1 + (1-\gamma) Loss_2 \tag{4-20}$$

最终总损失函数Loss由$Loss_1$与$Loss_2$如公式（4-20）以一定比例加权融合得到。其中，γ为权重系数，用于平衡两部分损失对整体优化目标的影响，本章中取值为 0.1。

4.3 数据集和实验设置

4.3.1 实验数据

本文在三个公共英文情感分析数据集上进行了实验，分别是 IMDB 数据集[87]、Twitter2016 数据集[88]以及 Yelp 评论数据集[89]。三个数据集分别代表了电影评论、社交媒体文本和通用用户评论三种典型语境，具备良好的通用性与多样性。其中，IMDB 数据集是一个经典的英文电影评论情感分析数据集，其文本篇幅较长、语言规范，情感表达明确，适用于评估模型在长文本场景下对情感语义

中国知网 https://www.cnki.net

的理解与建模能力。Twitter2016 数据集来源于用户在 Twitter 平台发布的真实推文，该数据集文本较短、语言自由，常含缩写、表情符号与非标准表达，是典型的非结构化短文本语料。Yelp 数据集来源于 Yelp 官方开放的“Yelp 学术数据集评论”子集，涵盖用户对餐饮、商铺、服务等多类场景的英文评论，语言自然、表达贴近生活。

本章的目标是验证模型在复杂语义环境下的深度特征表达能力。因此采用了规模更大、语义更复杂、文本长度更不均匀的数据集。这类数据集包含更多隐义的情感暗示、多元性的文体分布以及更强的噪声干扰，更适合检验混合位置编码与多极注意力机制被用于捕捉长短程依赖、增强情感极性特征方面的能力。通过观察与考量统计模型在更复杂的数据集上性能，可以突出模型结构本身的优势，同时展示其在实际应用场景中的鲁棒性与泛化能力。

为控制变量一致性、提升模型训练的稳定性，并确保分类性能评估的公平性，同样在三个实验数据集中均进行了人工均衡处理，尽量使正负类样本数量接近 1:1。三个均衡处理后的数据集分别定义为 SA-IMDB-EN、SA-Twitter2016-EN、SA-Yelp-EN，各数据集介绍如表 4-1 所示。

表 4-1 数据集介绍

数据集	正类		负类	
	训练集	测试集	训练集	测试集
SA-IMDB-EN	384	96	385	97
SA-Twitter2016-EN	692	174	690	173
SA-Yelp-EN	700	176	698	175

同样对本章所用的三个数据集完成统一的预处理操作，包括文本清洗、标签筛选等操作。按照 8:2 的比例划分为训练集和测试集。

4.3.2 实验参数

为验证所提出模型的有效性，在统一实验环境下设置了如表 4-2 所示的参数。

表 4-2 实验参数设置

参数	词嵌入维度	BiLSTM 单元数	丢弃率	全连接层神经元数	注意力头数量	Epoch 次数
值	200	128	0.5	128	4	50

中国知网 https://www.cnki.net

其中，注意力输出维度设为 200；BiLSTM 模块中每个方向的隐藏单元数为 128；丢弃率（Dropout）设置为 0.5；全连接层设置 128 个神经元；多头注意力机制采用 4 个注意力头，以增强模型对不同语义子空间的捕捉能力；训练轮数（Epoch）设为 5，以在保证效率的前提下获得稳定的性能表现。

4.4 实验结果与分析

4.4.1 对比实验结果与分析

本文使用以下模型进行对比，主要包括经典神经网络结构、注意力机制模型以及轻量化预训练模型，涵盖从浅层表示到深度语义建模的不同层次。

（1）基准模型：

BiLSTM：双向长短期记忆网络，通过前向与后向两个方向建模文本序列上下文信息，广泛应用于各类文本分类与情感分析任务中。

TextCNN[90]：基于卷积神经网络的文本分类模型，能够从局部词窗口中提取关键情感特征，结构简单、性能稳定。

Transformer Encoder[65]：Transformer 编码器结构通过多头注意力机制建模文本中的全局依赖关系，是近年来深度学习建模的重要基础。

（2）基于注意力机制的深度模型：

BiLSTM + Attention[91]：在 BiLSTM 基础上引入注意力机制，通过计算词与全局语义之间的重要性权重，提升模型对关键情感词的感知能力。

（3）轻量化预训练模型：

FNet-small[92]：将 Transformer 中的注意力机制替换为傅里叶变换，显著提升模型计算效率的同时保留语义建模能力。

MobileBERT[93]：在保持 BERT 表达能力的基础上进行结构压缩与速度优化，适用于移动端部署。

TinyBERT-2L-128D[94]：极小尺寸的 BERT 变体，具备较快的推理速度和可迁移能力，适合资源受限场景。

SetFit[95]：结合 Sentence-Transformer 编码器和轻量级分类器，通过少量标注样本即可实现快速调优的轻量情感分类框架。三个数据集上的对比实验结果如表、表和表所示，最佳实验结果在表中以粗体标出，以突出 HP-MHPA 相较其他模型的性能优势。

中国知网 https://www.cnki.net

（4）结构改进型预训练模型：

ConvBERT-small[96]：融合卷积神经网络与自注意力机制的轻量级 Transformer 模型，兼具局部特征提取与全局语义建模能力，在文本分类等任务中展现优良的特征捕捉能力，适合对局部与全局特征均有需求的应用场景。

DeBERTa-v3-small[97]：基于解耦式位置编码与相对位置偏移机制的高效 Transformer 模型，擅长长距离依赖建模与细粒度语义表示，兼具强大的上下文理解能力和较高的推理效率，适用于复杂文本特征建模场景。

如表 4-3、4-4、4-5 所示，在 SA-IMDB-EN、SA-Twitter2016-EN 和 SA-Yelp-EN 三个数据集上，本文对所提出的 HPMHPA 模型与多种典型对比模型进行了系统实验，涵盖传统神经网络模型（BiLSTM、TextCNN）、基于注意力机制的模型（BiLSTM + Attention）、轻量化 Transformer 模型（TinyBERT、FNet-small、MobileBERT）、以及近年来结构优化的 Transformer 变体（ConvBERT-small、DeBERTa-v3-small）。

表 4-3 SA-IMDB-EN 数据集上的实验结果(%)

模型	准确率	精度	召回率	F1 值
BiLSTM	65.28	64.69	63.07	63.87
TextCNN	65.56	64.8	63.26	64.08
SetFit	65.8	65.49	64.22	64.97
BiLSTM + Attention	65.9	65.35	63.86	64.61
Transformer Encoder	65.94	66.41	64.36	65.29
TinyBERT-2L-128D	66.51	66.37	65.08	65.71
FNet-small	66.95	66.69	65.71	66.19
ConvBERT-small	67.35	67.2	66.82	67.01
MobileBERT	67.61	67.66	66.64	67.15
DeBERTa-v3-small	68.1	68.25	67.82	68.03
HP-MHPA	**68.57**	**68.44**	**69.03**	**68.73**

表 4-4 SA-Twitter2016-EN 数据集上的实验结果(%)

模型	准确率	精度	召回率	F1 值
BiLSTM	79.24	78.63	76.42	77.46

中国知网 https://www.cnki.net

模型	准确率	精度	召回率	F1 值
TextCNN	79.85	79.11	77.18	78.13
BiLSTM + Attention	80.23	79.4	77.65	78.48
SetFit	80.32	79.96	78.05	78.94
Transformer Encoder	80.54	80.82	78.26	79.39
TinyBERT-2L-128D	81.05	80.87	79.02	79.93
FNet-small	81.62	81.24	79.98	80.58
MobileBERT	82.18	82.25	81.11	81.67
ConvBERT-small	82.43	82.35	80.85	81.59
DeBERTa-v3-small	82.94	83.1	81.54	82.31
HP-MHPA	**83.56**	**83.41**	**80.24**	**81.79**

表 4-5 SA-Yelp-EN 数据集上的实验结果(%)

模型	准确率	精度	召回率	F1 值
TextCNN	79.42	78.9	77.95	78.42
BiLSTM	80.2	79.54	79.54	79.54
BiLSTM + Attention	81.17	79.8	80.07	79.93
Transformer Encoder	82.66	81.95	81.98	81.96
TinyBERT-2L-128D	82.91	81.62	82.21	81.91
FNet-small	83.37	82.57	82.35	82.46
SetFit	85.22	84.55	84.65	84.6
MobileBERT	85.28	84.49	84.41	84.45
ConvBERT-small	85.58	84.71	84.35	84.53
DeBERTa-v3-small	86.11	85.14	84.87	84.98
HP-MHPA	**86.75**	**85.3**	**85.52**	**85.41**

实验结果表明，Transformer 系列模型整体优于传统神经网络模型，随着模型结构复杂度提升，性能持续改善。在长文本的 SA-IMDB-EN 数据集中，HPMHPA 模型以 68.73%的 F1 值实现最优，DeBERTa-v3-small 紧随其后（68.03%），凸显 HPMHPA 在长文本特征提取中的优势。在短文本 SA-Twitter2016-EN 数据集中，HPMHPA 同样表现优越，F1 值达到 81.79%，略高于 DeBERTa-v3-small（82.31%）

中国知网 https://www.cnki.net

和 ConvBERT-small（81.59%），显示了其在短文本场景下的出色特征融合能力。对于中长文本的SA-Yelp-EN数据集，HPMHPA模型F1值进一步提升至85.41%，领先于 DeBERTa-v3-small（84.98%）和 ConvBERT-small（84.53%），在多场景下均展现了较强的稳定性与鲁棒性。

4.4.2 注意力可视化结果

为进一步验证其是否能够有效地捕捉句子中的语义与情感核心信息从而深入理解 HP-MHPA 模型在文本情感分析任务中的决策机制，对模型内部的正负极注意力权重分布进行了可视化分析。通过分别绘制正极性与负极性通道中 Head 1 的注意力热力图，如图 4-4 所示，观察模型在处理具体文本时对哪些词汇给予了更高的关注。

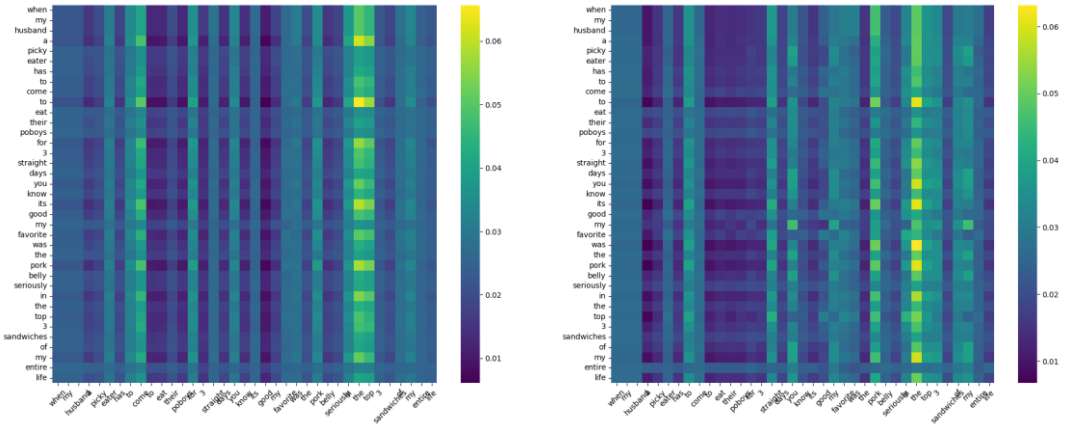

图 4-4 模型在 Head 1 上左图（a）正、右图（b）负极注意力的权重热力图

如图 4-4（a）所示，正向样本的注意力主要集中于“husband”、“picky”、“good”、“seriously”“life”等带有明显积极语义色彩的词语，“good”、“seriously good”等短语区域形成了清晰的高亮聚焦，模型可准确识别并提高典型正面评价词的语义权重分配。另外“favorite”“love”“enjoyed”等表达也获得了较高的注意力值，这意味着模型在处理正向情感时，有较强的语义感知能力，可提取出富有积极情绪的关键词，与之相对，图 4-4（b）中负向样本的注意力分布更集中在“never”、“poor”、“worst”、“waste”、“disappointed”等典型负向情感词上。这些词语在图中呈现出十分突出的注意力高峰，而且在 Query 和 Key 的交互映射上也构成了一定的局部聚合结构，模型在处理负面评论时同样有较强的负向情绪特征识别能力。

综合两个图的表现可以看出，模型的注意力机制在情感极性识别方面具有较

中国知网 https://www.cnki.net

强的区分能力，能够自动捕捉正负评价中的关键情绪词，并在结构层面上展现出较好的语义聚焦效果。这表明所设计的多极多头注意力机制不仅能够关注情绪表达词汇本身，还能够从上下文中提炼情绪相关的短语组合和核心评价主语，进一步提升了情感极性的建模质量与判别精度。

4.4.3 消融实验

消融实验结果如表 4-6 所示，HP-MHPA 模型各模块的引入均对性能提升起到了关键作用。

表 4-6 SA-Yelp-EN 数据集上各模块对 HP-MHPA 的影响

消融实验	准确率	精度	召回率	F1 值
BiLSTM(Baseline)	80.20	79.54	79.54	79.54
PE + BiLSTM	82.73	81.65	81.08	81.36
MHA + PE + BiLSTM	84.89	83.77	83.25	83.51
MHA + MSA + BiLSTM	85.88	84.59	84.3	84.44
HP-MHPA	**86.75**	**85.30**	**85.52**	**85.41**

基础模型 BiLSTM（Baseline）的准确率和 F1 值分别为 80.20% 和 79.54%，在其基础上加入位置编码（PE）后，准确率提升至 82.73%，F1 值提升至 81.36%，说明位置编码在捕捉词语间位置信息、增强上下文结构建模方面具有明显效果。进一步引入多头注意力机制（MHA）后，准确率和 F1 值分别提升至 84.89% 和 83.51%，展示了该机制在建模多层次情感子区域特征中的有效性。随后增加多极注意力机制（MSA），使得准确率和 F1 值达到 85.88% 和 84.44%，进一步提高了模型对不同情感极性的区分能力。而最终整合混合位置策略构成完整的 HP-MHPA 模型后，其准确率和 F1 值分别提升至 86.75% 和 85.41%，表现最为优异。整体结果表明，各模块的逐步引入能够稳步提升模型性能，尤其是注意力机制与位置建模之间的协同作用对情感特征的深层理解起到了决定性作用。

4.5 本章小结

本章提出了一种融合混合位置编码机制与多头多极注意力机制的文本情感分类模型 HP-MHPA，用以弥补模型在特征情感表达与建模能力上的不足。通过上下文结构与相关极性特征进行联合建模，设计混合位置编码旨在增强文本特征的情感表达能力，结合相对与全局位置信息，引导模型充分捕捉情感词与上下文

中国知网 https://www.cnki.net

之间的结构依赖关系。为进一步提升模型对关键情感区域的辨识能力，提出多头多极注意力机制，引入极性权重，设计结合极性差别的损失函数，引导注意力在多子空间中聚焦于高情感强度区域，提升模型对情感极性的感知能力。在三个不同种类的英文情感分析数据集 SA-S140-Twitter-EN、SA-Kaggle-General-EN 与 SA-Kaggle-Finance-EN 上与其他主流模型进行对比实验，结果证明了所提出模型在准确率和 F1 值上的有效性与先进性。

中国知网 https://www.cnki.net

第五章 总结与展望

5.1 论文总结

围绕文本情感分析中词向量情感表达能力不足与模型结构建模能力有限的问题，本文从底层表示优化与高层语义建模两个层面展开系统性研究，构建了一个结构完整、效果优异的情感分析优化框架。

首先，专注于强化特征的情感信息表达，本文提出了一种基于圆混沌初始化与遗传鲸鱼优化的词嵌入优化方法（CCIGWO）。该方法结合 TF-IDF 特征引导机制，在全局搜索与局部微调过程中自适应优化词向量，使其在情感语义空间中的分布更加贴近真实情感特征，从而有效提升词向量对复杂语境中的情感表达能力。实验结果表明，该方法在多个英文情感数据集上相较于 GloVe、Emo2Vec 等主流词嵌入方法，在准确率与 F1 值等指标上均实现显著提升，有效增强了模型的情感建模能力与鲁棒性。

其次，针对情感分类模型在建模长距离依赖关系和捕捉情感极性区域方面的能力瓶颈，本文设计了一种融合混合位置编码与多头多极注意力机制的情感分类模型（HP-MHPA）。该模型通过混合位置编码同时融入绝对与相对位置信息，增强模型对语序、结构与句法关系的感知能力，并引入极性引导的多极注意力机制，提升模型在多个子空间内并行关注情感核心区域的能力，从而强化复杂情绪特征的建模效果。大量对比实验表明，HP-MHPA 在 IMDB、Twitter2016、Yelp 等多个英文情感数据集上，较 TinyBERT、Flan-T5、BiLSTM 等主流轻量级模型在准确率、F1 值等指标上均取得领先表现，充分验证了其在复杂情感分析场景中的优越性能与应用潜力。

5.2 研究展望

相较于现有的文本情感分析方法，本文提出的两种算法在多个公开数据集上取得了较为理想的性能表现，验证了词向量优化与结构建模在提升模型准确率与鲁棒性方面的重要作用。但受限于本人的研究经验和实际条件，本文的工作仍存在一些不足，有待在后续研究中进一步完善与拓展：

（1）本文主要聚焦于情感的二分类任务，在模型设计与实验验证中均以正负情感作为目标标签。而现实中情感状态的种类更加丰富，未来可以进一步引入

中国知网 https://www.cnki.net

更细粒度的多标签、多级别情感识别任务，提升模型对复杂情绪表达的理解能力。

（2）在词嵌入优化方面，本文提出的 CCIGWO 方法虽能有效增强词向量的情感表达能力，但仍依赖于词向量的基础结构，同时缺乏对多语言的适配能力。后续可以考虑结合跨语言模型，引导词向量更好地感知语义背景，进一步增强模型的泛化性能。

（3）在模型结构方面，本文提出的 HP-MHPA 模型仅针对单模态文本数据进行建模，而实际情感传播通常还有语音、图像、视频等多模态信号。未来可以在现有结构基础上引入多模态融合机制，提升模型在真实复杂场景下的应用能力。

中国知网 https://www.cnki.net

参考文献

[1] Chandan M K, Mandal S. A comprehensive survey on sentiment analysis: framework, techniques, and applications[J]. Computer Science Review, 2025, 58: 100777.

[2] Zucco C, Calabrese B, Agapito G, et al. Sentiment analysis for mining texts and social networks data: methods and tools[J]. Wiley Interdisciplinary Reviews: data Mining and Knowledge Discovery, 2020, 10(1): e1333.

[3] Zhang L, Wang S, Liu B. Deep learning for sentiment analysis: a survey[J]. Wiley Interdisciplinary Reviews: data Mining and Knowledge Discovery, 2018, 8(4): e1253.

[4] Zhang M, Chai J, Cao J, et al. Aspect-level sentiment analysis based on deep learning[J]. Computers, Materials and Continua, 2024, 78(3):3743–3762.

[5] 杨永清, 徐运成, 樊治平, 等. 情感驱动的社交网络用户内容创建及信息传播行为研究[J]. 现代情报, 2023, 43(7):162–177.

[6] 高大菊. 基于计算机大数据分析的社交媒体用户行为挖掘与情感分析研究[J]. 信息记录材料, 2024, 25(10):118–120.

[7] Xu Z, Gui S, Dang Y, et al. User satisfaction in the new energy vehicles: an analysis harnessing user-generated content and sentiment analytics[J]. Procedia Computer Science, 2023, 221:1242–1249.

[8] Lian Y, Tang H, Xiang M, et al. Public attitudes and sentiments toward ChatGPT in China: a text mining analysis based on social media[J]. Technology in Society, 2024, 76:102442.

[9] Zhao C, Feng R, Sun X, et al. Enhancing aspect-based sentiment analysis with BERT-driven context generation and quality filtering[J]. Natural Language Processing Journal, 2024, 7:100077.

[10] 吴江, 段一奇. 金融评论文本情感分析研究趋势与未来展望[J]. 信息资源管理学报, 2025, 15(1):86–101.

[11] Zhao Y, Zhang L, Zeng C, et al. Construction of an aspect-level sentiment analysis model for online medical reviews[J]. Information Processing & Management, 2023, 60(6):103513.

[12] Mohanty S, Sahoo D, Das S, et al. Sentiment analysis using CNN for emotion extraction

中国知网 https://www.cnki.net

to synthesize natural speech[J]. Procedia Computer Science, 2025, 258:2737–2747.

[13] Wu H, Kong D, Wang L, et al. Multimodal sentiment analysis method based on image-text quantum transformer[J]. Neurocomputing, 2025, 637:130107.

[14] Chen Z, Lu C, Wang Y. CIEG-Net: context information enhanced gated network for multimodal sentiment analysis[J]. Pattern Recognition, 2025, 168:111785.

[15] Gu T, He Z, Zhao H, et al. Aspect-based sentiment analysis with multi-granularity information mining and sentiment hint[J]. Expert Systems with Applications, 2024, 252(A):124104.

[16] He B, Zhao R, Tang D. CABiLSTM-BERT: aspect-based sentiment analysis model based on deep implicit feature extraction[J]. Knowledge-Based Systems, 2025, 309:112782.

[17] Al-Absi A A, Kang D K, Al-Absi M A. Sentiment analysis and classification using deep semantic information and contextual knowledge[J]. Computers, Materials and Continua, 2022, 74(1):671–691.

[18] Zhou L, Xu X, Wang X. LSRD-Net: a fine-grained sentiment analysis method based on log-normalized semantic relative distance[J]. Computer Speech & Language, 2025, 93:101782.

[19] Verma B, Meel P, Vishwakarma D K. Navigating sentiment analysis through fusion, learning, utterance, and attention methods: an extensive four-fold perspective survey[J]. Engineering Applications of Artificial Intelligence, 2025, 156(B):111195.

[20] Diwali A, Dashtipour K, Saeedi K, Gogate M, Cambria E, Hussain A. Arabic sentiment analysis using dependency-based rules and deep neural networks[J]. Applied Soft Computing, 2022, 127:109377.

[21] Saraswathi N, Rooba T S, Chakaravarthi S. Improving the accuracy of sentiment analysis using a linguistic rule-based feature selection method in tourism reviews[J]. Measurement: Sensors, 2023, 29:100888.

[22] 尹明鹤, 王硕, 罗磐石. 增强语法规则信息的 GCN 情感分析模型[J]. 信息系统工程, 2025, (5):136–139.

[23] Lin W, Liao L C. Lexicon-based prompt for financial dimensional sentiment analysis[J].

中国知网 https://www.cnki.net

Expert Systems with Applications, 2024, 244:122936.

[24] Mohammed I, Prasad R. Building lexicon-based sentiment analysis model for low-resource languages[J]. Methods X, 2023, 11:102460.

[25] Ojeda-Hernández M, López-Rodríguez D, Mora Á. Lexicon-based sentiment analysis in texts using formal concept analysis[J]. International Journal of Approximate Reasoning, 2023, 155:104–112.

[26] Catelli R, Pelosi S, Comito C, et al. Lexicon-based sentiment analysis to detect opinions and attitude towards COVID-19 vaccines on Twitter in Italy[J]. Computers in Biology and Medicine, 2023, 158:106876.

[27] Haque R, Islam N, Tasneem M, et al. Multi-class sentiment classification on Bengali social media comments using machine learning[J]. International Journal of Cognitive Computing in Engineering, 2023, 4:21–35.

[28] Mercha E M, Benbrahim H. Machine learning and deep learning for sentiment analysis across languages: a survey[J]. Neurocomputing, 2023, 531:195–216.

[29] Zhang H, Jiang L, Yu L. Attribute and instance weighted naive Bayes[J]. Pattern Recognition, 2021, 111:107674.

[30] Zhang H, Jiang L. Fine tuning attribute weighted naive Bayes[J]. Neurocomputing, 2022, 488:402–411.

[31] Maity D, Kanakaraddi S, Giraddi S. Text sentiment analysis based on multichannel convolutional neural networks and syntactic structure[J]. Procedia Computer Science, 2023, 218:220–226.

[32] Ramshankar N, Prathap P M. Automated sentimental analysis using heuristic-based CNN-BiLSTM for e-commerce dataset[J]. Data & Knowledge Engineering, 2023, 146:102194.

[33] Aslam A, Sargano A B, Habib Z. Attention-based multimodal sentiment analysis and emotion recognition using deep neural networks[J]. Applied Soft Computing, 2023, 144:110494.

[34] Alruily M. Sentiment analysis for predicting stress among workers and classification utilizing CNN: unveiling the mechanism[J]. Alexandria Engineering Journal, 2023, 81:360–370.

中国知网 https://www.cnki.net

[35] Liu S, Lee I. Sequence encoding incorporated CNN model for email document sentiment classification[J]. Applied Soft Computing, 2021, 102:107104.

[36] Basiri M E, Nemati S, Abdar M, et al. ABCDM: an attention-based bidirectional CNN-RNN deep model for sentiment analysis[J]. Future Generation Computer Systems, 2021, 115:279–294.

[37] Mahadevaswamy U B, Swathi P. Sentiment analysis using bidirectional LSTM network[J]. Procedia Computer Science, 2023, 218:45–56.

[38] Jia K, Meng F, Liang J, et al. Text sentiment analysis based on BERT-CBLBGA[J]. Computers and Electrical Engineering, 2023, 112:109019.

[39] Murfi H, Syamsyuriani S, Gowandi T, et al. BERT-based combination of convolutional and recurrent neural network for Indonesian sentiment analysis[J]. Applied Soft Computing, 2024, 151:111112.

[40] Wan B, Wu P, Yeo C K, et al. Emotion-cognitive reasoning integrated BERT for sentiment analysis of online public opinions on emergencies[J]. Information Processing & Management, 2024, 61(2):103609.

[41] 刘琦. 基于预训练语言模型的小样本情感分析关键技术研究[D]. 华中科技大学, 2024.

[42] Chao G, Liu J, Wang M, et al. Data augmentation for sentiment classification with semantic preservation and diversity[J]. Knowledge-Based Systems, 2023, 280:111038.

[43] Liu H, Xiong K, Wu S, et al. Integrating multiple syntactic structures for enhanced aspect-based sentiment analysis[J]. Engineering Applications of Artificial Intelligence, 2025, 158(A):111297.

[44] 王磊. 基于上下文文本的多元情感分析研究[D]. 南京邮电大学, 2020.

[45] 张昊妍, 段利国, 王钦晨, 等. 基于多任务联合训练的长文本多实体情感分析[J]. 计算机科学, 2024, 51(6):309–316.

[46] Li Z, Zhang H, Wei Z, et al. Learning from noisy labels for sentence-level sentiment classification[C]. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China: association for Computational

中国知网 https://www.cnki.net

Linguistics, 2019:5676–5681.

[47] Liu S M, Chen J H. A multi-label classification based approach for sentiment classification[J]. Expert Systems with Applications, 2015, 42(3):1083–1093.

[48] Rostami M, Jin P, Rabiee H R, et al. Domain adaptation for sentiment analysis using robust internal representations[C]. Findings of the Association for Computational Linguistics: Conference on Empirical Methods in Natural Language Processing (EMNLP) 2023, 2023:11470–11482.

[49] George M, Murugesan R. Improving sentiment analysis of financial news headlines using hybrid Word2Vec-TFIDF feature extraction technique[J]. Procedia Computer Science, 2024, 244:1–8.

[50] Greeshma M, Simon P. Bidirectional gated recurrent unit with glove embedding and attention mechanism for movie review classification[J]. Procedia Computer Science, 2024, 233:528–536.

[51] Hidayat T H J, Ruldeviyani Y, Aditama A R, et al. Sentiment analysis of twitter data related to rinca island development using Doc2Vec and SVM and logistic regression as classifier[J]. Procedia Computer Science, 2022, 197:660–667.

[52] Hou J, Omar N, Tiun S, Saidah S, et al. TF-BERT: tensor-based fusion BERT for multimodal sentiment analysis[J]. Neural Networks, 2025, 185:107222.

[53] Das N, Sadhukhan B, Chatterjee R, Chakrabarti S. Integrating sentiment analysis with graph neural networks for enhanced stock prediction: a comprehensive survey[J]. Decision Analytics Journal, 2024, 10:100417.

[54] Zhang P, Harris R D F, Zheng J. GNN-based social media sentiment analysis for stock market forecasting and trading[J]. Expert Systems with Applications, 2025, 291:128425.

[55] Zhu C, Chen M, Zhang S, et al. SKEAFN: sentiment knowledge enhanced attention fusion network for multimodal sentiment analysis[J]. Information Fusion, 2023, 100:101958.

[56] Ahmad K M, Liu Q, Khan A A, et al. SEntIMeldCL: enhancing explicit knowledge via uniform-based implicit contrastive mechanism for Aspect-level sentiment analysis[J]. Neural Networks, 2025, 191:107711.

中国知网 https://www.cnki.net

[57] Mirjalili S, Lewis A. The whale optimization algorithm[J]. Advances in Engineering Software, 2016, 95:51–67.

[58] Wang Y, Zhao W, Zhang Z, et al. A dimension-wise learning enhancement mechanism for whale optimization algorithm[J]. Applied Soft Computing, 2023, 139:110219.

[59] Holland J H. Adaptation in natural and artificial systems[M]. Ann Arbor: University of Michigan Press, 1975.

[60] Goodfellow I, Bengio Y, Courville A. Deep learning[M]. Cambridge, USA: MIT Press, 2016.

[61] Graves A, Schmidhuber J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. Neural Networks, 2005, 18(5–6):602–610.

[62] Wang X, Liu L, Chen Z, et al. Graph convolutional network based on self-attention variational autoencoder and capsule contrastive learning for aspect-based sentiment analysis[J]. Expert Systems with Applications, 2025, 279:127172.

[63] Deng L, Liu B, Li Z. Multimodal sentiment analysis based on a cross-modal multihead attention mechanism[J]. Computers, Materials and Continua, 2024, 78(1):1157–1170.

[64] V Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS), 2017:5998–6008.

[65] Khemani B, Patil S, Malave S, et al. Improved graph convolutional network for emotion analysis in social media text[J]. MethodsX, 2025, 14:103325.

[66] Yang X S. Nature-inspired optimization algorithms[M]. Elsevier, 2014.

[67] Wang Y, Li J, Li X, et al. A survey of chaotic systems applied to global optimization[J]. Archives of Computational Methods in Engineering, 2018, 25(4):787–822.

[68] Jones K S. A statistical interpretation of term specificity and its application in retrieval[J]. Journal of Documentation, 1972, 28(1):11–21.

[69] Li X, Yang Z, Li X, et al. An adaptive weighting strategy based on feedback for differential evolution[J]. Applied Soft Computing, 2017, 59:108–126.

[70] Mirjalili S, Gandomi A H, Saremi S, et al. Whale optimization algorithm: a survey of applications and hybridization strategies[J]. Swarm and Evolutionary Computation,

中国知网 https://www.cnki.net

2020, 48:100667.

[71] Go A, Bhayani R, Huang L. Twitter sentiment classification using distant super vision[EB/OL]. 2009. http://cs.stanford.edu/people/alecmgo/trainingandtestdata.zip.

[72] abhi8923shriv. Sentiment analysis dataset[EB/OL]. 2022. https://www.kaggle.com/datasets/abhi8923shriv/sentiment-analysis-dataset.

[73] sbhatti. Financial sentiment analysis dataset[EB/OL]. 2022. https://www.kaggle.com/datasets/sbhatti/financial-sentiment-analysis.

[74] Le Q, Mikolov T. Distributed representations of sentences and documents[C]. International Conference on Machine Learning (ICML), 2014:1188–1196.

[75] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space [EB/OL]. arXiv preprint arXiv:1301.3781, 2013.

[76] Pennington J, Socher R, Manning C. GloVe: global vectors for word representation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014:1532–1543.

[77] Huang H, Li Z, Zhang S, et al. Sentence embedding alignment for lifelong relation extraction via soft earth mover's distance[C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL), 2021.

[78] Xu H, Lin H, Pan Y, et al. Emo2Vec: learning generalized emotion representation by multi-task training[EB/OL]. arXiv preprint arXiv:1906.08296, 2019.

[79] Ke Y, Meng F, Lu Z, et al. SentiLARE: sentiment-aware language representation learning with linguistic knowledge[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL), 2020:3957–3967.

[80] Xie Z, Zhang A, Sun Y, et al. ERNIE-Gram: pre-training with explicitly N-gram masked language modeling for natural language understanding[C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL), 2021:1441–1451.

[81] Liu Y, Ott M, Goyal N, et al. RoBERTa: a robustly optimized BERT pretraining approach[EB/OL]. arXiv preprint arXiv:1907.11692, 2019.

[82] Wang X, Zhang Z, Liu Z, et al. WordFast: compact word embedding via complex tensor decomposition[C]. Proceedings of the 2023 Conference on Empirical Methods in

中国知网 https://www.cnki.net

Natural Language Processing (EMNLP), 2023.

[83] Wu Z, Nguyen T S, Ong D C. Structured self-attention weights encode semantics in sentiment analysis[EB/OL]. arXiv preprint arXiv:2010.04922, 2020.

[84] Gehring J, Auli M, Grangier D, et al. Convolutional sequence to sequence learning[C]. Proceedings of the 34th International Conference on Machine Learning (ICML), 2017:1243–1252.

[85] Wang S, Li B, Khabsa M, et al. Linformer: self-attention with linear complexity [EB/OL]. arXiv preprint arXiv:2006.04768, 2020.

[86] Meng F, Wang H, Song J, et al. Co-aware neural networks for fine-grained aspect sentiment analysis[C]. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2019:4568–4576.

[87] Maas A L, Daly R E, Pham P T, et al. Learning word vectors for sentiment analysis[C]. Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics (ACL): Human Language Technologies, 2011:142–150.

[88] Nakov P, Ritter A, Rosenthal S, et al. SemEval-2016 Task 4: sentiment analysis in twitter[C]. Proceedings of the 10th International Workshop on Semantic Evaluation (SemEval-2016). San Diego, USA: Association for Computational Linguistics (ACL), 2016:1–18.

[89] Yelp. Yelp open dataset[EB/OL]. 2023 [2025–06–28]. https://www.yelp.com/dataset.

[90] Kim Y. Convolutional neural networks for sentence classification[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014:1746–1751.

[91] Yang Z, Yang D, Dyer C, et al. Hierarchical attention networks for document classification[C]. Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL), 2016:1480–1489.

[92] Lee K, Ainslie J, Ziegler Z, et al. FNet: mixing tokens with Fourier transforms[C]. Proceedings of the 38th International Conference on Machine Learning (ICML), 2021:8744–8756.

中国知网 https://www.cnki.net

[93] Sun Z, Yu H, Song X, et al. MobileBERT: a compact task-agnostic BERT for resource-limited devices[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL), online: Association for Computational Linguistics, 2020:2158–2170.

[94] Jiao X, Yin Y, Shang L, et al. TinyBERT: distilling BERT for natural language understanding[C]. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2020:4163–4174.

[95] Tunstall L, Von Werra L, Rajani N F, et al. Efficient few-shot learning without prompts[C]. Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2022:1590–1605.

[96] Jiang Z, Yu H, Zhou Y, et al. ConvBERT: improving BERT with span-based dynamic convolution[J]. Advances in Neural Information Processing Systems, 2020, 33:12877–12891.

[97] He P, Liu X, Gao J, Chen W. DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training[EB/OL]. arXiv preprint arXiv:2111.09543, 2021.

中国知网 https://www.cnki.net