· 计算机与电子信息科学 ·
DOI:10.13624/j.cnki.issn.1001-7445.2025.0835

电子竞技比赛视频弹幕评论的实体级情感分析

陈燕[1,2],廖宇翔[1],谭志湘[1],林德沼[1],梁增福[1],杨雨翰[1],胡小春[3,4*]

(1. 广西大学 计算机与电子信息学院,广西 南宁 530004;
2. 广西大学 工商管理学院,广西 南宁 530004;
3. 广西财经学院 大数据与人工智能学院,广西 南宁 530003;
4. 广西财经大数据重点实验室,广西 南宁 530007)

摘要:针对电子竞技比赛视频弹幕评论的实体级情感分析面临反向情感隐蔽表达和多个情感表述的权重平衡问题,本文提出实体级情感分析模型(ELSA-CDC),使用基于全词遮蔽的 RoBERTa 预训练模型、Transformer 编码器和情感补充模块共同提取实体情感特征并融合。自注意力机制通过多次权重评分与情感词多次遮蔽等方法,使模型能学习句子中的多个情感词,获得准确实体情感极性预测结果。在 2 个数据集上的验证结果表明:ELSA-CDC 模型在构建的 CDES 数据集上,准确率、平均 F_1 值分别达到 80.38%、77.80%,较 BERT-SPC 模型分别提升 5.26、6.10 个百分点;在 DanSetiment 数据集上准确率为 90.20%,比 BERT-SPC 模型提升 1.96 个百分点。

关键词:深度学习;情感分析;实体级情感分析;弹幕;电子竞技

中图分类号:TP391.1　　**文献标识码**:A　　**文章编号**:1001-7445(2025)04-0835-11

Entity-level sentiment analysis of danmaku comments in electronic sports video

CHEN Yan[1,2], LIAO Yuxiang[1], TAN Zhixiang[1], LIN Dezhao[1], LIANG Zengfu[1], YANG Yuhan[1], HU Xiaochun[3,4*]

(1. School of Computer, Electronics and Information, Guangxi University, Nanning 530004, China;
2. School of Business, Guangxi University, Nanning 530004, China;
3. School of Big Data and Artificial Intelligence, Guangxi University of Finance and Economics, Nanning 530003, China;
4. Guangxi Key Laboratory of Finance and Economics Big Data, Nanning, 530007, China)

Abstract: Entity-level sentiment analysis of danmaku comments in electronic sports competition videos encountered issues with concealed expressions of opposite sentiment and balancing the weights of multiple sentiment expressions. To address these issues, the paper

收稿日期:2024-03-18;**修订日期**:2024-05-20

基金资助:广西科学研究与技术开发计划项目(桂科 A A20302002-3);广西自然科学基金项目(2020GXNSFAA159090)

通信作者:胡小春(1974—),男,广西桂林人,副教授;E-mail:hxch@gxufe.edu.cn。

引文格式:陈燕,廖宇翔,谭志湘,等. 电子竞技比赛视频弹幕评论的实体级情感分析[J].广西大学学报(自然科学版),2025,50(4):835-845.

中国知网 https://www.cnki.net

proposed a method, namely ELSA-CDC. The model had used the whole word mask based pre-trained model of RoBERTa to extract the semantic vectors, had used Transformer encoders to extract entity sentiment features, and had drawed features from the sentiment complementary module and had fused them. The self-learning mechanism had allowed the model to learn multiple sentiment words in a sentence through methods such as multiple weight scoring with multiple masking of sentiment words, which ultimately had resulted in entity sentiment analysis. ELSA-CDC was evaluated on two datasets. On the constructed CDES dataset, it achieved an accuracy of 80.38% and an average F_1-score of 77.80%, representing improvements of 5.26 and 6.10 percentage points, respectively, over BERT-SPC. On the DanSetiment dataset, the model achieved an accuracy of 90.20%, which is 1.96 percentage points higher than that of BERT-SPC.

Key words: deep learning; sentiment analysis; entity-level sentiment analysis; danmaku; electronic; sports

0 引言

随着在线社交网络和互联网的快速发展,弹幕作为新型视频评论交互形式备受欢迎[1]。弹幕是观众观看视频过程中发出的动态、实时的评论,传统的静态评论是在观看视频之后发表的[2]。弹幕允许观众即时分享观点,增强互动体验[3]。弹幕评论的情感分析有助于预测市场趋势和发现用户潜在需求[4],因此,情感分析利用大数据挖掘用户的情感倾向,对研究用户对不同视频内容的态度具有重要意义[5]。

电子竞技比赛(又称电竞比赛)吸引了全球数千万年轻观众。以哔哩哔哩视频网站上英雄联盟S13全球总决赛的数据为例,比赛视频平均播放量达163.44万次,最高播放量为572.6万次,平均弹幕数量为23 088条,最多的视频弹幕数超过11万条。同时,电子竞技已发展成庞大的产业,吸引了众多国际大型企业赞助[6]。观众通过弹幕进行实时互动,产生了大量的文本数据、丰富的实体和情感信息。

情感分析由Pang等[7]最先提出,根据文本处理层次,可分为粗粒度情感分析与细粒度情感分析[8],其中细粒度情感分析更为精细,也更具有针对性。当前,细粒度情感分析的研究聚焦于方面级情感分析(aspect-based sentiment analysis, ABSA)和实体级情感分析(entity-level sentiment analysis, ELSA)等。例如,对于一间餐厅的评论:“这间餐厅的服务态度很好,菜品很好吃”,其中“这间餐厅”为评论中出现的实体,“服务态度”“菜品”是该餐厅的方面,方面级情感分析的研究对象为实体的方面或属性[9],例句中即为挖掘对“这间餐厅”中“服务态度”或“菜品”方面的情感极性,实体级情感分析的研究目标是分析句子中的实体所蕴含的情感极性[10],在例句中体现为学习“这间餐厅”实体蕴含的情感。

自深度学习技术广泛应用以来,方面级、实体级情感分析的研究已取得显著成果[11-13]。在近期研究中:Song等[14]提出的AEN-BERT引入双向注意力编码器网络作为编码器,有效提升了情感分析性能。Zeng等[15]提出LCF-BERT,设计了统一架构解决多个子任务,并将句法信息嵌入上下文语言模型中。Ding等[16]提出一个基于监督机器学习方法的实体级情感分析工具SentiSW,对GitHub实体评论数据集进行分析。Bai等[17]通过结合全局与局部特征,并采用硬遮蔽与软遮蔽的自注意力机制,有效解决双向变换器模型(bidirectional encoder representations from transformers, BERT)中的过拟合与偏置问题。Luo等[18]提出了实体级情感分析模型NSSM,通过平滑算法调整实体情感分数,实现了对文档所针对实体的情感准确计算。Cui等[19-20]在Mac-BERT中利用近义词替换机制改进了BERT的遮蔽处

中国知网 https://www.cnki.net

理,并改变其替换比例,在 PERT 中引入词序调换策略以增强模型泛化能力。张昊妍等[21]提出基于多任务联合训练的长文本多实体情感分析模型 PAM,通过结合词频-逆文件频率算法(term frequency-inverse document frequency, TF-IDF)、双向长短期记忆网络(bi-directional long short-term memory, Bi-LSTM)和相对位置信息,实现了对关键词的有效提取与学习。尽管现有研究已取得一定进展,但在对多情感词出现时的权重平衡和综合情感进行准确预测等方面仍存在不足,须要进一步深入研究和探索。

关于比赛的情感分析研究取得了一些进展。Yan 等[22]使用自然语言工具包对“守望先锋联赛”的 Twitter 评论进行情感分析。Yang 等[23]从 Steam 平台收集电竞玩家评论,并基于 E2E-ABSA 模型提出一个情感分析框架。项佳星[24]采用情感词典技术,根据词频和情感类型对“英雄联盟 S11 全球总决赛”社交平台的评论进行情感分类。这些模型在应对弹幕文本多维情感动态变化和信息分散等问题上进行了优化,然而,电竞比赛弹幕文本中存在大量隐蔽表达反向情感、明褒暗贬等特点,须要提出更为优秀的方法以取得更好的效果。

综上所述,本文提出一个新的中文弹幕评论实体级情感分析模型(entity-level sentiment analysis model for Chinese danmaku comments, ELSA-CDC)。该模型基于全词遮蔽的 RoBERTa 预训练模型,结合实体级情感分析模块与情感补充模块,共同提取实体情感特征。模型还采用自注意力机制学习多情感词,旨在提高情感分类的准确性。

1　ELSA-CDC 模型

ELSA-CDC 模型结构如图 1 所示。模型的功能如下:①将数据逐行输入模型,在分词拼接层对数据进行加工;②将句子序列化,并输入实体级情感分析模块与情感补充模块进行学习;③将语义特征输入自注意力机制层,并更新权重参数;④通过焦点损失函数,缓解类别不平衡问题;⑤进行特征融合,经过 Tanh 函数得到实体情感预测结果。

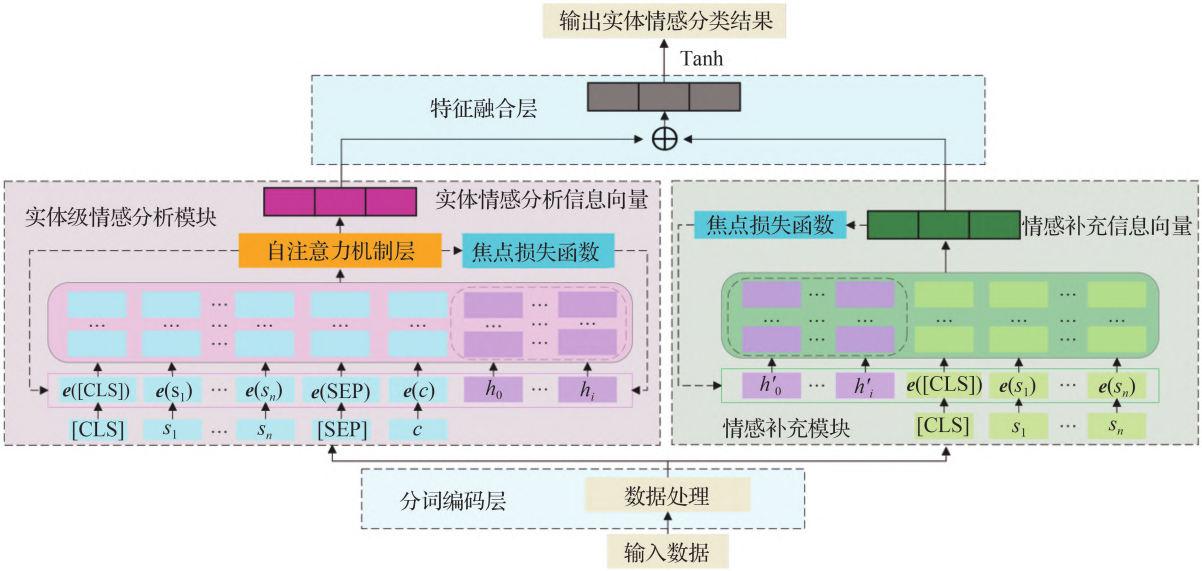

图 1　ELSA-CDC 模型结构

Fig. 1　Structure diagram of ELSA-CDC

1.1　RoBERTa 模型

ELSA-CDC 模型的核心是基于全词掩码策略[25]的 RoBERTa 预训练模型[26]。RoBERTa 模型用多头注意力机制,充分提取文本信息。全词掩码策略能屏蔽整个词语,有助于模型捕捉语义信息和实体

中国知网　https://www.cnki.net

与情感描述的联系。RoBERTa模型编码过程可描述为

$$\hat{h}^{l}=\mathrm{LN}[h^{l-1}+\mathrm{MHAtt}(h^{l-1})],\tag{1}$$

$$h^{l}=\mathrm{LN}[h^{\hat{l-1}}+\mathrm{FFN}(h^{\hat{l-1}})],\tag{2}$$

式中:h^{l}是RoBERTa模型的输入数据,包括标签嵌入、位置嵌入和文本嵌入;$\hat{h}^{l}$为进行线性回归操作;LN为归一化层;MHAtt为多头注意力机制;FFN为前馈神经网络,主要用于对输入的特征进行非线性变换和增强;l为Transformer编码器的深度(本文中$l=24$)。

1.2 实体级情感分析模块

实体级情感分析模块分为4个层次,分别为分词编码层、词嵌入层、特征编码层、自注意力机制层。

1.2.1 分词编码层

将数据输入分词编码层。采用LTP 4.0工具[27]进行中文分词,以提升语义信息的完整性。数据标记参考BERT-SPC[14]的方法,将句子S与实体C结合在同一行上。将输入的弹幕评论数据按词进行划分和编码,提取实体和极性。在句首添加分类标签[CLS],实体词前添加分隔标记[SEP]。由此得到的文本信息序列、实体信息与情感极性属性为

$$S=\{[\mathrm{CLS}],s_1,s_2,\cdots,s_n,[\mathrm{SEP}],c,[\mathrm{SEP}]\},C=c,J=j,\tag{3}$$

式中:s_1、c分别表示句子文本信息与实体文本信息的词表编号;n为输入句子文本信息的长度,均不超过定义的句子最长长度(本文为96);j为情感极性。

1.2.2 词嵌入层

将文本信息S、实体信息C输入词嵌入层,对其进行词嵌入计算,输出语义信息向量$\boldsymbol{e}(S)$与实体信息向量$\boldsymbol{e}(C)$。此过程如式(4)所示:

$$\boldsymbol{e}(S)=\boldsymbol{e}([\mathrm{CLS}])\oplus\boldsymbol{e}(s_1)\oplus\boldsymbol{e}(s_2)\oplus\cdots\oplus\boldsymbol{e}(s_n)\oplus\boldsymbol{e}([\mathrm{SEP}])\oplus\boldsymbol{e}(c)\oplus\boldsymbol{e}([\mathrm{SEP}]),\boldsymbol{e}(C)=\boldsymbol{e}(c),\tag{4}$$

式中:$\oplus$为拼接操作。

1.2.3 特征编码层

ELSA-CDC模型使用具有多头注意力机制的Transformer编码器进行特征编码。计算公式为

$$\begin{aligned}\boldsymbol{Q}&=\boldsymbol{e}(S)\oplus\boldsymbol{e}(C)\times\boldsymbol{W}^{Q},\\\boldsymbol{K}&=\boldsymbol{e}(S)\oplus\boldsymbol{e}(C)\times\boldsymbol{W}^{K},\\\boldsymbol{V}&=\boldsymbol{e}(S)\oplus\boldsymbol{e}(C)\times\boldsymbol{W}^{V},\end{aligned}\tag{5}$$

式中:$\boldsymbol{e}(S)$与$\boldsymbol{e}(C)$拼接起来后分别经过3次线性变换得到$\boldsymbol{Q}$、$\boldsymbol{K}$、$\boldsymbol{V}$这3个向量矩阵,$\boldsymbol{W}^{Q}$、$\boldsymbol{W}^{K}$和$\boldsymbol{W}^{V}$为权重矩阵。经过计算得到特征向量$\boldsymbol{Z}$。

1.2.4 自注意力机制层

自注意力机制层采用多次迭代的情感词遮蔽机制。首先,使用初始弹幕实体评论数据集D训练得到一个初始模型,并提取初始特征,得到训练参数φ_0。其次,基于上一代训练参数φ_{k-1}对句子s进行特征提取,得到$\boldsymbol{v}(c)$。对于每个训练数据项(s,c,j),引入2个小词库U_g与U_e,其中U_g用于存储对实体情感分析有积极影响的上下文词,U_e用于存储起消极作用或无意义的上下文词。在后续训练中,U_g中的词被优先保留并提升权重,而对U_e中的词则降低其权重期望。经此得到的词语表示为

$$h(s')=\{h(s_i')\}_{i=1}^{n}。\tag{6}$$

结合$\boldsymbol{v}(c)$与$h(s')$,即可利用φ_{k-1}对s'的实体进行情感预测,得到的极性为j'。获取s'中每个词语的影响权重

$$\delta(s')=\{\delta(s_1'),\delta(s_2'),\cdots,\delta(s_n')\},\tag{7}$$

式中:$\delta(s_i')$为在对s'进行情感预测时单词s_i'的影响权重。在训练阶段,根据U_g和U_e这2个词库,动态调整s中上下文词的权重。将当前影响权重最高的词语使用"[MASK]"标记屏蔽,并置其权重

中国知网 https://www.cnki.net

为 0,形成新句子 s' 并更新词库数据,进行下一轮训练学习。本机制引入随机噪声,通过平均单词影响力评分来消除梯度噪声以获得更精确的影响力分数。

计算 $\delta(s_i')$ 的方差,以判断句子中是否存在重要上下文词,如式(8)所示:

$$E(\delta(s'))=-\sum_{i=1}^{n}\delta(s_i')\ln[\delta(s_i')]。\tag{8}$$

当方差 $E[\delta(s')]$ 小于设定阈值时,认为 s' 中存在关键情感影响词。本文选择具有最大影响分数的上下文词作为注意力监督标准。

将组成的新数据项 (s',c,j') 补充至数据集 D 中,供后续迭代使用。经过 k 次迭代(本文 $k=5$),更新训练参数,并提取全部受情感影响的上下文词作为注意力监督信息。

1.3　情感补充模块

ELSA-CDC 模型增加基于 RoBERTa 模型的情感补充模块。情感补充模块包含 3 个层次,即分词编码层、词嵌入层、特征编码层,与实体级情感分析模块对应层结构相似,故不赘述。输入情感补充模型的文本序列、情感极性与特征编码序列为

$$S'=\{[\mathrm{CLS}],s_1,s_2,\cdots,s_n\},J'=j,\boldsymbol{e}(S')=\boldsymbol{e}([\mathrm{CLS}])\oplus\boldsymbol{e}(s_1)\oplus\boldsymbol{e}(s_2)\oplus\cdots\oplus\boldsymbol{e}(s_n)。\tag{9}$$

1.4　焦点损失函数

焦点损失(focal loss)函数是一种针对不平衡数据集设计的鲁棒损失函数,通过引入权重因子平衡不同类别之间的损失贡献,减少对多数类的偏向,计算公式为

$$L_{\mathrm{F}}=-y_{\mathrm{g}}(1-y_{\mathrm{p}})^{\gamma}\ln y_{\mathrm{p}}-(1-y_{\mathrm{g}})y_p{}^{\gamma}\ln(1-y_{\mathrm{p}}),\tag{10}$$

式中:L_{F} 为焦点损失函数;y_{g} 表示真实值;y_{p} 表示预测值;γ 为影响因子,当 $\gamma>0$ 时,容易分类样本的权重与损失减小,将损失聚焦在难分类样本(本文 $\gamma=2$)。

2　实验与结果分析

为了全面验证 ELSA-CDC 模型的有效性,本文设计了对比实验与消融实验,从多个维度对模型性能进行评估。

2.1　实验数据集

本文从哔哩哔哩网站爬取了 2023 年“英雄联盟”职业联赛和季中邀请赛视频的弹幕评论,构建了 CDES(Chinese danmaku entity-level sentiment analysis)数据集。经过数据清洗,从原始的 124 574 条弹幕评论中筛选出 14 272 条有效数据。随后对这些数据的实体和极性进行标注,其中极性用 1、0、−1 分别表示积极、中性和消极情感。中文弹幕实体评论例子见表 1。

表 1　中文弹幕实体评论例子

Tab. 1　Examples of Chinese danmaku entity comments

序号	文本	实体	极性
1	[欧恩]躲了一万个技能	欧恩	1
2	[zzm]虽然解说菜,理解还是有的	zzm	0
3	[leave]都 21 了,再给时间磨炼都退役了	leave	−1

1 号句子涉及“欧恩”选手实体,通过描述其技能躲避能力,展现了他在游戏中的高超技术,因此极性标注为 1。2 号句子提到解说实体“zzm”,既包含负面评价“解说菜”,也有积极评价“有理解”,所以对“zzm”的综合评价为中性,极性标注为 0。3 号句子关于“leave”选手实体,指出他虽不年轻但仍未展现出高水平,暗示其能力不足,因此极性标注为−1。

on 选手和 EDG 俱乐部情感极性分布如图 2 所示。外圈为 on 选手情感极性分布状况,内圈为 EDG 俱乐部情感极性分布状况。图中显示 on 选手获得大量积极评价,消极评价较少,表明其能力受到

中国知网　https://www.cnki.net

观众广泛认可,风评良好;相比之下,EDG 俱乐部的消极评价多于积极评价,与中性评价接近,说明该俱乐部风评不佳,须采取措施改善。

完成标注后,将数据集按 8∶2 的比例划分为训练集和测试集,并确保极性分布基本一致。CDES 数据集情感极性分布如图 3 所示,图中外圈为训练集情感极性分布状况,内圈为测试集情感极性分布状况。

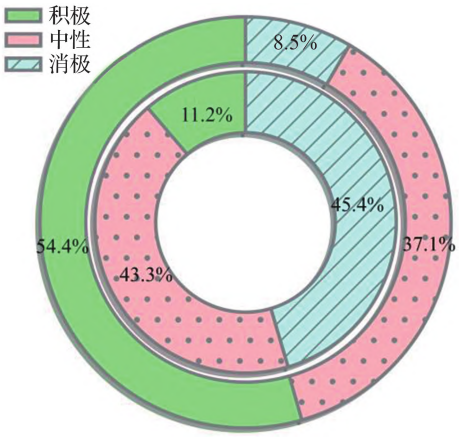

图 2 on 选手和 EDG 俱乐部情感极性分布

Fig. 2 Distribution of emotional polarity about "on" and "EDG"

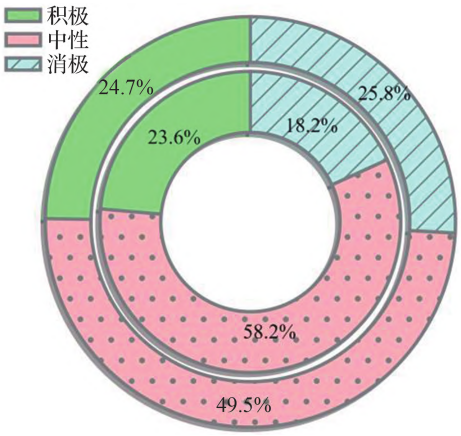

图 3 CDES 数据集情感极性分布

Fig. 3 Distribution of emotional polarity about CDES

为了验证模型的泛化能力,本文选用中文弹幕实体评论公开数据集 DanSetiment[17] 进行对比实验。DanSetiment 主要聚焦于热门综艺和流行电视剧中的明星与角色,数据内容均为观众对以上实体对象发表的弹幕评论,以单情感词与显著情感表达为主。CDES 与 DanSetiment 的极性分布比较如图 4 所示。结果显示,2 个数据集极性分布相似,均存在极性样本分布不均衡的问题。

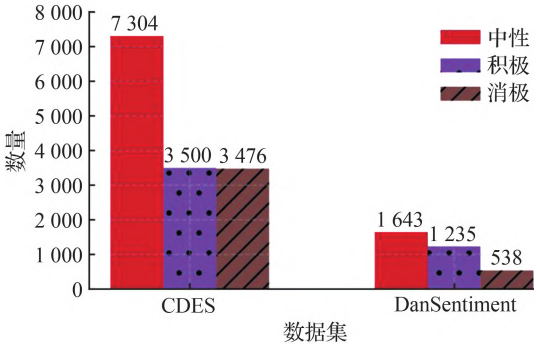

图 4 CDES 与 DanSetiment 的极性分布比较

Fig. 4 Comparison of the polarity distribution of CDES and DanSetiment

2.2 实验环境与参数设置

本文使用 Ubuntu 18.04.6 LTS、Python 3.9.0、Pytorch 2.0.1、Nvidia RTX 3090、CUDA 12.2 作为实验环境。模型使用的批大小为 16,遍历次数为 10,学习率为 1×10^{-5},随机失活为 0.1。

2.3 实验评价指标

本文采用准确率、平均精确率、平均召回率和平均 F_1 值[28] 作为实验评估指标。先计算各情感极性的准确率和召回率并求平均值,再利用平均精确率和平均召回率计算平均 F_1 值。

2.4 实验数据分析

为了全面验证 ELSA-CDC 模型,本研究设计了对比实验与消融实验,通过多个维度来验证模型。

中国知网 https://www.cnki.net

2.4.1　对比实验

本研究设计 2 组对比实验。第 1 组实验是将 ELSA-CDC 模型与其他模型使用 2 个数据集进行对比。第 2 组实验将对 CDES 数据集进行降采样处理,将模型在降采样后的数据集中实验。

在模型对比实验中,将 ELSA-CDC 模型与其他表现较好的 TD-LSTM 模型[11]、MemNet 模型[12]、TNet 模型[13]、BERT-SPC 模型[14]、AEN-BERT 模型[14]、LCF-BERT 模型[15]、Mac-BERT 模型[19]、PERT 模型[20]和 RoBERTa 模型[26]进行实验,各种模型在 CDES 数据集的对比实验结果见表 2。各种模型在 CDES 数据集的准确率对比如图 5 所示。

表 2　各种模型在 CDES 数据集的对比实验结果

Tab. 2　Comparison experiment results of various models on CDES

序号	模型	准确率/%	平均精确率/%	平均召回率/%	平均 F_1 值/%
1	TD-LSTM	59.06	53.51	39.53	45.46
2	TNet	60.50	55.38	45.58	50.00
3	MemNet	60.71	56.21	44.45	49.64
4	AEN-BERT	72.96	69.48	69.78	69.62
5	Mac-BERT	73.10	69.46	70.81	70.12
6	BERT-SPC	75.12	72.05	71.36	71.70
7	RoBERTa	75.66	75.32	69.12	72.08
8	PERT	77.57	75.11	75.03	75.07
9	LCF-BERT	77.75	74.86	75.58	75.21
10	ELSA-CDC	80.38	78.50	77.11	77.80

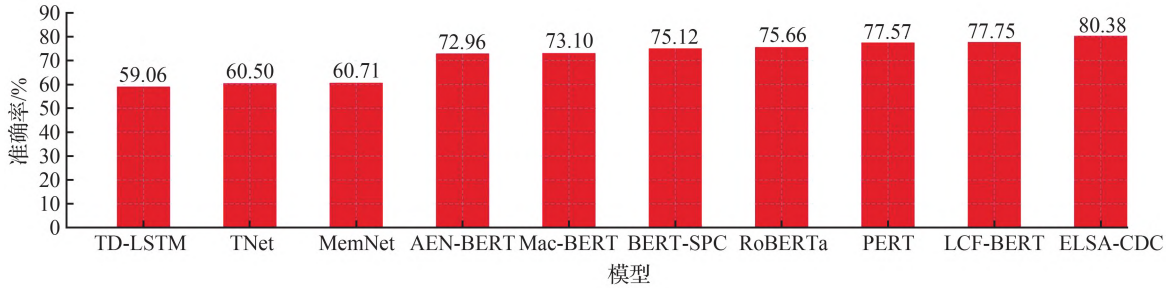

图 5　各种模型在 CDES 数据集的准确率对比

Fig. 5　Comparison of accuracy among various models on CDES

从图 5 可知,TD-LSTM 模型准确率最低。TNet 模型与 MemNet 模型准确率较 TD-LSTM 模型分别提升 1.44、1.65 个百分点,因为这 2 种模型均引入句子细粒度层面的训练。AEN-BERT 模型利用 Tramsformer 的多头注意力机制,准确率较 MemNet 模型提升 12.25 个百分点,证明该机制在上下文词与情感词特征学习上具有优势。Mac-BERT 模型准确率较 AEN-BERT 模型提升 0.14 个百分点,说明近义词掩码机制能更适合中文数据。BERT-SPC 准确率较 Mac-BERT 提升 2.02 个百分点,说明拥有更多先验知识能增强分类效果。RoBERTa 模型对 BERT 模型进行全面改进,准确率较 BERT-SPC 模型提升 0.54 个百分点。PERT 模型与 LCF-BERT 模型准确率较 RoBERTa 模型分别提升 1.91、2.09 个百分点,在获取更多句法信息方面表现出色。ELSA-CDC 模型利用自注意力机制综合利用情感信息,并通过情感补充模块获取深层情感信息,准确率较 LCF-BERT 模型提升 2.63 个百分点,在所有对比模型中表现最优。

各种模型在 DanSetiment 数据集的实验结果对比见表 3。各种模型在 DanSetiment 数据集的准确

中国知网　https://www.cnki.net

率对比如图 6 所示。与表 2 情况基本一致,ELSA-CDC 再次展现了其优越性,准确率较 Mac-BERT 提升 1.23 个百分点,表明该模型具有良好的通用性和泛化潜力。

表 3 各种模型在 DanSetiment 数据集的对比实验结果

Tab. 3 Comparison experiment results of various models on DanSetiment

序号	模型	准确率/%	平均精确率/%	平均召回率/%	平均 F_1 值/%
1	TNet	60.50	55.38	45.58	50.00
2	MemNet	60.71	56.21	44.45	49.64
3	TD-LSTM	70.74	73.06	59.63	65.67
4	LCF-BERT	87.50	88.54	85.75	87.12
5	AEN-BERT	87.50	87.64	88.19	87.91
6	BERT-SPC	88.24	87.75	89.04	88.39
7	PERT	88.24	91.01	84.84	87.82
8	RoBERTa	88.97	89.15	88.49	88.81
9	Mac-BERT	88.97	88.95	89.87	89.41
10	ELSA-CDC	90.20	89.85	91.27	90.55

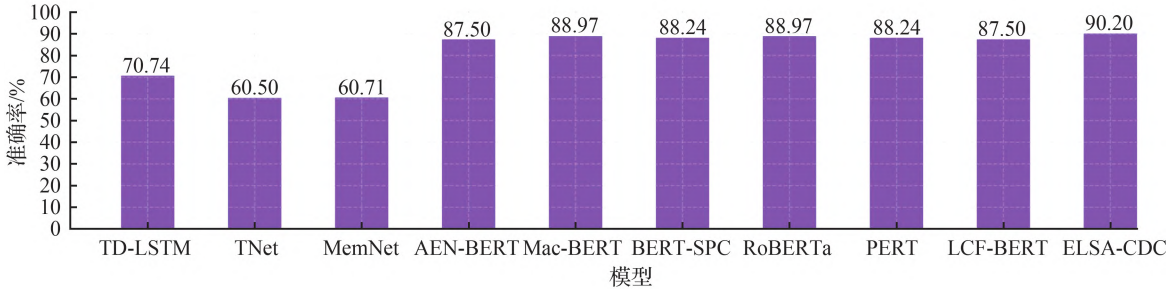

图 6 各种模型在 DanSetiment 数据集的准确率对比

Fig. 6 Comparison of accuracy among various models on DanSetiment

为了验证 ELSA-CDC 模型在样本稀少情况下的性能表现,本研究设计了降采样数据集对比实验。对 CDES 数据集进行降采样处理,将数据集的 80%、60%、40%、20%,命名为 $CDES_{0.8}$、$CDES_{0.6}$、$CDES_{0.4}$、$CDES_{0.2}$,均用作降采样数据集,且极性分布与原数据集保持一致。CDES 数据集降采样后分布情况如图 7 所示。

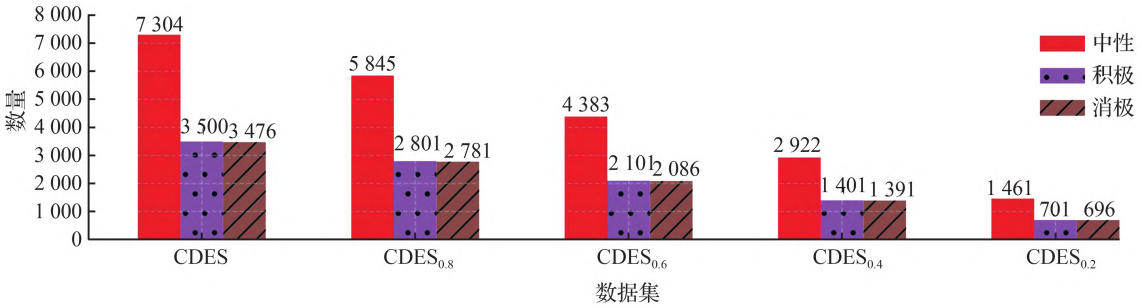

图 7 CDES 数据集降采样后分布情况

Fig. 7 Distribution of CDES after down sampling

为了简化实验、方便对比,本文选用在第一组实验表现较好的 LCF-BERT 模型、Mac-BERT 模型和 PERT 模型进行降采样实验,实验结果见表 4 和图 8。结果表明,随着样本数量的减少,多数模型的实体级情感分类任务的性能呈现出下降趋势。然而,ELSA-CDC 模型在不同样本量下均展现出显著优

中国知网 https://www.cnki.net

势。具体而言,在 $CDES_{0.8}$ 上,ELSA-CDC 模型准确率较 LCF-BERT 模型提升 3.99 个百分点;在 $CDES_{0.6}$ 中,ELSA-CDC 模型准确率较 PERT 模型提高 11.62 个百分点;在 $CDES_{0.4}$ 中,ELSA-CDC 模型准确率较 Mac-BERT 模型提升 3.05 个百分点;在 $CDES_{0.2}$ 中,ELSA-CDC 模型准确率较 Mac-BERT 模型提升 2.5 个百分点,证明 ELSA-CDC 模型通过情感补充模块与自注意力机制的共同作用,在数据量较少时仍能有效提升实体情感分析效果。

表 4　不同模型在降采样数据集的对比

Tab. 4　Comparison of different models on down sampled datasets

数据集	模型	准确率/%	平均精确率/%	平均召回率/%	平均 F_1 值/%
CDES	LCF-BERT	77.75	74.86	75.58	75.22
	Mac-BERT	74.85	69.46	70.81	70.13
	PERT	77.57	75.11	75.03	75.07
	ELSA-CDC	80.38	78.50	77.11	77.80
$CDES_{0.8}$	LCF-BERT	75.17	71.78	74.38	73.06
	Mac-BERT	73.10	74.66	66.30	70.23
	PERT	72.34	69.74	65.75	67.69
	ELSA-CDC	79.16	77.17	75.39	76.26
$CDES_{0.6}$	LCF-BERT	70.64	67.03	69.47	68.23
	Mac-BERT	72.98	72.20	62.70	67.33
	PERT	65.13	59.88	53.95	56.76
	ELSA-CDC	76.75	74.24	72.91	73.57
$CDES_{0.4}$	LCF-BERT	68.64	65.56	70.66	68.01
	Mac-BERT	72.06	70.61	63.05	66.62
	PERT	65.47	61.27	61.35	61.31
	ELSA-CDC	75.11	72.46	71.18	71.81
$CDES_{0.2}$	LCF-BERT	66.19	64.49	67.39	65.90
	Mac-BERT	67.26	62.18	56.33	59.11
	PERT	65.41	62.20	65.80	63.95
	ELSA-CDC	69.76	67.22	65.99	66.60

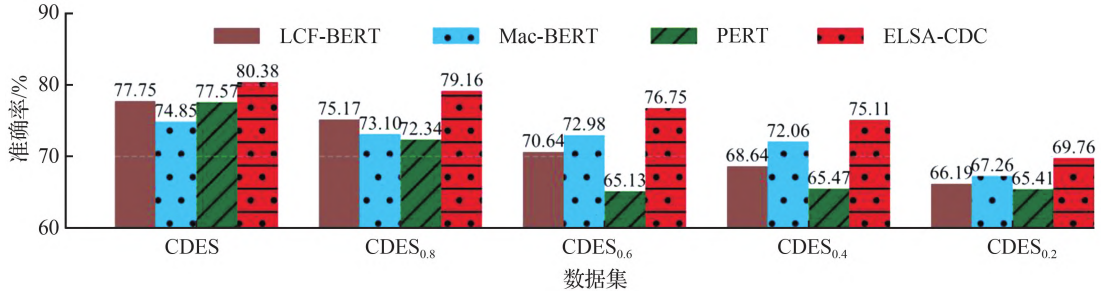

图 8　不同模型在降采样数据集的准确率

Fig. 8　Comparison of different models on down sampled datasetsin accuracy

2.4.2　消融实验

为了评估 ELSA-CDC 模型中焦点损失函数、情感补充模块等对实体级情感分析任务的影响,本研究在 CDES 数据集上进行消融实验,实验对比了 RoBERTa 模型、加入焦点损失函数的RoBERTa-FL模型、进一步增加自注意力机制的 RoBERTa-FL-AS 模型,以及完整的 ELSA-CDC 模型,ELSA-CDC 模型消融实验结果见表 5。由表 5 可知,RoBERTa-FL 模型准确率较使用交叉熵损失函数的 RoBERTa 模型准确率提高 2.54 个百分点,说明焦点损失函数有效解决了样本分布不均衡带来的预测不准确问

中国知网　https://www.cnki.net

题。RoBERTa-FL-AS模型准确率较RoBERTa-FL模型提高2.01个百分点,说明自注意力机制有助于模型捕获更多情感信息。融合情感补充模块的ELSA-CDC模型准确率较RoBERTa-AS-FL模型提升了0.17个百分点,较RoBERTa模型提升了4.72个百分点,证明情感补充模块增强了模型的特征识别能力。这些结果证明了ELSA-CDC模型中各组件对提升实体级情感分析性能具有积极作用。

表5 ELSA-CDC模型消融实验

Tab. 5 ELSA-CDC model ablation experiments

序号	模型	准确率/%	平均精确率/%	平均召回率/%	平均 F_1 值/%
1	RoBERTa	75.66	75.32	69.12	72.09
2	RoBERTa-FL	78.20	75.45	73.54	74.48
3	RoBERTa-FL-AS	80.21	78.39	76.69	77.53
4	ELSA-CDC	80.38	78.50	77.11	77.80

3 结语

本研究以电竞弹幕评论为对象,构建了实体级情感分析模型ELSA-CDC和相应数据集CDES。实验结果表明,ELSA-CDC模型在处理电子竞技比赛视频弹幕中隐藏情感和复杂情感表达方面表现出色,具有良好的泛化能力。该模型能准确分析观众对选手或俱乐部的情感倾向,能为俱乐部和赞助商提供有价值的市场情报。同时,通过观众画像分析,企业可以更深入地了解目标受众对品牌、产品或广告的态度,为市场营销策略提供数据支持,因此,ELSA-CDC模型在电子竞技比赛视频弹幕情感分析中具有重要意义,为实体级情感分析提供了新的研究方向和方法。

参考文献:

[1] LI Z, LI R, JIN G. Sentiment analysis ofdanmaku videos based on naïve bayes and sentiment dictionary[J]. IEEE Access, 2020,8:75073-75084.

[2] LI Z, DUAN S, LI R. Dynamic advertising insertion strategy with moment-to-moment data using sentiment analysis: the case of danmaku video[J]. Journal of Electronic Commerce Research, 2022,23(3):160-176.

[3] BAI Q, HU Q V, GE L, et al. Stories that bigdanmaku data can tell as a new media[J]. IEEE Access, 2019,7:53509-53519.

[4] CAO S, GUO D, CAO L, et al. VisDmk: visual analysis of massive emotional danmaku in online videos[J]. The Visual Computer, 2023,39(12):6553-6570.

[5] DENG Y, ZHANG C, LI J. Video shot recommendation model based on emotion analysis using time-sync comments[J]. Journal of Computer Applications, 2017,37(4):1065-1070.

[6] FUNK D C, PIZZO A D, BAKER B J. eSport management: embracing eSport education and research opportunities [J]. Sport Management Review, 2018,21(1):7-13.

[7] PANG B, LEE L, VAITHYANATHAN S. Thumbs up? sentiment classification using machine learning techniques [C]// Proceedings of the 2002 Conference on Empirical Methods in Natural Language Processing (EMNLP 2002). Morristown: Association for Computational Linguistics, 2002:79-86.

[8] 王海燕,陶皖,余玲艳,等. 文本细粒度情感分析综述[J]. 河南科技学院学报(自然科学版), 2021,49(4):67-76.

[9] DO H H, PRASAD P W C, MAAG A, et al. Deep learning for aspect-based sentiment analysis: a comparative review[J]. Expert Systems with Applications, 2019,118:272-299.

[10] FU X Y, CHEN C, LASKAR M T R, et al. Entity-level sentiment analysis in contact center telephone conversations[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi: Industry Track, 2022:484-491.

[11] TANG D, QIN B, FENG X, et al. Effective LSTMs for target-dependent sentiment classification[C]//Proceedings

中国知网 https://www.cnki.net

of COLING 2016, the 26th International Conference on Computational Linguistics. Osaka: Technical Papers, 2016: 3298-3307.

[12] TANG D, QIN B, LIU T. Aspect level sentiment classification with deep memory network[C]//Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics (ACL), 2016:214-224.

[13] LI X, BING L, LAM W, et al. Transformation networks for target-oriented sentiment classification[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Stroudsburg, PA: Association for Computational Linguistics (ACL), 2018:946-956.

[14] SONG Y, WANG J, JIANG T, et al. Targeted sentiment classification with attentional encoder network[C]//International Conference on Artificial Neural Networks. Cham: Springer, 2019:93-103.

[15] ZENG B, YANG H, XU R, et al. Lcf: a local context focus mechanism for aspect-based sentiment classification [J]. Applied Sciences, 2019,9(16):3389.

[16] DING J, SUN H, WANG X, et al. Entity-level sentiment analysis of issue comments[C]//Proceedings of the 3rd International Workshop on Emotion Awareness in Software Engineering. New York: Association for Computing Machinery (ACM), 2018:7-13.

[17] BAI Q, WEI K, ZHOU J, et al. Entity-level sentiment prediction in danmaku video interaction[J]. The Journal of Supercomputing, 2021,77(9):9474-9493.

[18] LUO M, MU X. Entity sentiment analysis in the news: a case study based on negative sentiment smoothing model (NSSM)[J]. International Journal of Information Management Data Insights, 2022,2(1):100060.

[19] CUI Y, CHE W, LIU T, et al. Revisiting pre-trained models for chinese natural language processing[C]//Findings of the Association for Computational Linguistics: EMNLP 2020. Stroudsburg, PA: Association for Computational Linguistics (ACL), 2020:657-668.

[20] CUI Y, YANG Z, LIU T. PERT: pre-training BERT with permuted language model[EB/OL]. (2022-03-14) [2025-07-28]. https://doi.org/10.48550/arXiv.2203.06906.

[21] 张昊妍,段利国,王钦晨,等. 基于多任务联合训练的长文本多实体情感分析[J]. 计算机科学, 2024,51(6): 309-316.

[22] YAN S A, MAWHORTER P.Twitter sentiment analysis: fan engagement in esports matches[C]//Proc. 13th IADIS Int. Conf. ICT, Soc. Hum. Beings 2020, ICT 2020. New York: Institute of Electrical and Electronics Engineers (IEEE), 2023:257-261.

[23] YANG Y, DINH D T, NGUYEN B H, et al. Mining insights from esports game reviews with an aspect-based sentiment analysis framework[J]. IEEE Access, 2023,11:61161-61172.

[24] 项佳星. 电子竞技重要赛季期间社交媒体文本情感分析[D]. 上海:华东师范大学, 2023.

[25] CUI Y, CHE W, LIU T, et al. Pre-training with whole word masking for chinese bert[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021,29:3504-3514.

[26] LIU Y, OTT M, GOYAL N, et al. Roberta: A robustly optimized bert pretraining approach[EB/OL]. (2022-03-14)[2025-07-28]. https://doi.org/10.48550/arXiv.1907.11692.

[27] CHE W, FENG Y, QIN L, et al. N-LTP: An open-source neural language technology platform for Chinese[EB/OL]. (2020-09-24)[2025-07-28]. https://doi.org/10.48550/arXiv.2009.11616.

[28] SINGH I, AGARWAL K, GANAPATHY S. Advancing allergy source mapping: a comprehensive multidisciplinary framework integrating machine learning, graph theory and game theory[J]. Applied Soft Computing, 2024,166:112147.

（责任编辑　梁碧芬）

中国知网　https://www.cnki.net